Auditoría integral de tesis de grado

Automatización inteligente del registro de incidentes en mesas de ayuda empresariales mediante orquestación de flujos con N8N y procesamiento de lenguaje natural basado en modelos de lenguaje grandes

Informe de revisión — aplicación del Prompt Maestro para la Revisión Integral de una

4 de agosto de 2026

Índice

1 Ficha del documento auditado **3**

2 Nota metodológica y alcance de la verificación **3**

3 Resumen ejecutivo **5**
3.1 Dictamen . . . 5
3.2 Síntesis del diagnóstico . . . 5
3.3 Cuadro de resultados de la auditoría . . . 5
3.4 Las cinco cuestiones que decidirán la defensa . . . 6

4 Hallazgos críticos **7**
4.1 Bloque I — Trazabilidad y existencia de los datos experimentales . . . 7
4.2 Bloque II — Errores estadísticos e inferenciales . . . 10
4.3 Bloque IV — Bibliografía y atribución . . . 16
4.4 Bloque V — Cuestiones jurídicas . . . 18

5 Evaluación capítulo por capítulo **20**
5.1 1. Introducción . . . 20
5.2 2. Marco teórico . . . 20
5.3 3. Marco metodológico . . . 21
5.4 4. Desarrollo del estudio . . . 22
5.5 5. Resultados . . . 23
5.6 6. Arquitectura e interfaz de visualización . . . 23
5.7 7. Discusión . . . 24
5.8 8. Conclusiones . . . 25
5.9 9. Referencias bibliográficas . . . 26
5.10 10. Anexos . . . 26

6 Revisión bibliográfica **27**
6.1 Actualización de las fuentes . . . 27
6.2 Clasificación por tipo y calidad de fuente . . . 27
6.3 Existencia real de las referencias . . . 28
6.4 Correspondencia entre citas y referencias . . . 29
6.5 Cumplimiento de normas APA . . . 30

7 Revisión de tablas **32**

8 Revisión de figuras **33**

9 Revisión técnica **35**
9.1 Arquitectura . . . 35
9.2 Diagramas . . . 35

9.3 Consistencia entre arquitectura y desarrollo . . . 35

10 Revisión de anexos **37**

11 Auditoría de la calidad de escritura científica **39**
11.1 Mediciones realizadas . . . 39
11.2 Voz activa y pasiva . . . 39
11.3 Claridad . . . 39
11.4 Concisión . . . 40
11.5 Precisión terminológica . . . 40
11.6 Fluidez . . . 40
11.7 Estilo científico . . . 40
11.8 Economía del lenguaje . . . 41
11.9 Corrección ortográfica . . . 41
11.10 Índice de calidad de escritura . . . 41

12 Matriz de riesgos de rechazo **43**
12.1 Distribución de hallazgos . . . 43
12.2 Distribución por capítulo . . . 43
12.3 Riesgos por tipo . . . 43

13 Calificación por capítulo **45**

14 Calificación global **45**
14.1 Fortalezas principales . . . 45
14.2 Debilidades principales . . . 46

15 Dictamen final **47**
15.1 Justificación detallada . . . 47

16 Plan de corrección **49**
16.1 Bloque 1 — Cerrar la brecha probatoria *(3 a 5 días; sin escribir código nuevo)* 49
16.2 Bloque 2 — Reparar la estadística y la coherencia metodológica *(2 a 3 días; solo escritura)* . . . 49
16.3 Bloque 3 — Alinear el documento con el artefacto y reparar la bibliografía *(3 a 4 días)* . . . 50
16.4 Bloque 4 — Forma y evidencia visual *(2 días)* . . . 50
16.5 Resumen de la proyección . . . 50

17 Preguntas probables del tribunal **52**

18 Anexo A del informe — Evidencia reproducible de la auditoría del artefacto **54**
18.1 A.1 Estado del repositorio auditado . . . 54
18.2 A.2 El corpus y la declaración de integridad . . . 54
18.3 A.3 Ausencia de datos de tiempo . . . 54
18.4 A.4 Verificación del estadístico de Wilcoxon . . . 54
18.5 A.5 Inventario del flujo N8N . . . 54
18.6 A.6 Ausencia de Nginx y TLS . . . 55
18.7 A.7 Origen de la corrupción ortográfica . . . 55

1 Ficha del documento auditado

Campo	Dato
Título	Automatización inteligente del registro de incidentes en mesas de ayuda empresariales mediante orquestación de flujos con N8N y procesamiento de lenguaje natural basado en modelos de lenguaje grandes
Autores	Luca Gómez · Carla Bustos · Gonzalo Sevilla
Director	Prof. Alberto Cortez
Institución	UTN — Facultad Regional Mendoza, Tecnicatura Universitaria en Programación
Archivo	`Tesis_ultima_versión__1_.pdf`
Extensión	74 páginas · 27.847 palabras · A4
Producción	LaTeX con hyperref / MiKTeX-dvipdfmx, compilado el 3/7/2026 21:41 UTC
Estructura	11 capítulos, 7 anexos (A–G), 9 tablas rotuladas, 1 figura
Bibliografía	33 referencias · ~60 citas en el texto
Repositorio declarado	`github.com/lucaGomezB/Automatizacion-de-Mesa-de-Ayuda-N8N`

2 Nota metodológica y alcance de la verificación

Esta auditoría aplica íntegramente el instrumento solicitado: revisión capítulo por capítulo (coherencia, profundidad científica, calidad académica, coherencia interna, calidad de redacción), revisión metodológica, revisión bibliográfica con verificación de existencia real de las fuentes, revisión de normas APA, revisión de tablas y figuras, revisión técnica, revisión de resultados, discusión, conclusiones y anexos, matriz de riesgos de rechazo, calificación por capítulo, calificación global, dictamen y auditoría de la calidad de escritura científica.

La verificación se realizó sobre **cuatro planos independientes**:

1. **Plano textual.** Lectura completa del documento con rastreo de coherencia interna entre objetivos, hipótesis, metodología, resultados, discusión y conclusiones.
2. **Plano cuantitativo.** Recálculo independiente de la totalidad de los estadísticos publicados: matriz de confusión, exactitud global, precisión, sensibilidad y F1 por clase, macro promedio, intervalos de confianza, reducciones porcentuales, proyecciones de horas-persona y de costo, y verificación del estadístico de Wilcoxon y del tamaño del efecto con SciPy 1.17.1.
3. **Plano bibliográfico.** Verificación de las 33 entradas contra fuentes externas (DOI, revista, volumen, páginas, autoría, año) y contraste entre lo que cada fuente sostiene y lo que la tesis le atribuye.
4. **Plano del artefacto.** Clonado e inspección del repositorio público declarado en el Anexo B. Estado auditado: último *commit* `d7df92c` del 2 de julio de 2026 a las 22:00 (−03:00), un día antes de la compilación del PDF entregado. El repositorio es público, real y sustancial.

Este cuarto plano es determinante en esta auditoría: la contradicción principal del trabajo

no se detecta leyendo el documento, sino contrastando el documento con el material que él mismo remite al tribunal.

Advertencia sobre los límites de la verificación. Cuando un dato no pudo comprobarse, este informe lo indica explícitamente y no lo da por falso. En particular, la ausencia del corpus real en el repositorio tiene una justificación legítima documentada (Ley 25.326), por lo que la observación se formula como *exigencia de exhibición ante el tribunal*, no como afirmación de inexistencia.

3 Resumen ejecutivo

3.1 Dictamen

REQUIERE UNA REVISIÓN PROFUNDA ANTES DE LA DEFENSA.

Calificación global: 3,9 / 10.

Dictamen condicional: este dictamen desciende automáticamente a **«No recomendable para defensa en su estado actual»** si los autores no pueden exhibir ante el tribunal, en el acto de defensa, (a) el corpus real de 200 incidentes pseudonimizados, (b) las planillas de doble etiquetado independiente que sustentan el $\kappa = 0{,}87$ y (c) el registro de los 200 pares de tiempos manual/automatizado sobre los que se calculan la Tabla 6, la prueba de Wilcoxon y el tamaño del efecto.

3.2 Síntesis del diagnóstico

Se trata de un trabajo con **una asimetría severa entre lo construido y lo demostrado**. El sistema existe, es real y es de una calidad claramente superior a la media de la cohorte: *backend* FastAPI en siete capas, *frontend* React/TypeScript/Vite, migraciones Alembic, especificación OpenAPI de 39 KB con prueba de sincronización, pseudonimizador con pruebas dedicadas, cifrado Fernet en reposo y autenticación JWT efectivamente implementados. La prosa está muy por encima del promedio de los trabajos finales de esta carrera y el diseño del clasificador híbrido es conceptualmente correcto.

Sin embargo, **el Capítulo 7 —Resultados— informa una campaña experimental que el propio repositorio del trabajo declara, por escrito y en dos documentos distintos, como no realizada**. Todo el aparato inferencial de la tesis (reducción del 89 %, $p < 0{,}001$, $r = 1{,}00$, exactitud del 92 %, F1 macro 0,919, $\kappa = 0{,}87$, intervención humana del 9,5 %) descansa sobre datos cuya trazabilidad no puede establecerse y que, en la única corrida documentada del propio *pipeline*, arrojan cifras radicalmente distintas.

A esto se suman **errores estadísticos verificables** (el estadístico W publicado es incompatible con la definición que la propia tesis y su propio código usan; la fórmula del tamaño del efecto está mal y su rango declarado es falso), **tres relatos mutuamente incompatibles del instrumento de medición**, **cinco divergencias verificadas entre la arquitectura descrita y el flujo N8N publicado**, y **errores jurídicos sustantivos** en el capítulo de consideraciones legales.

3.3 Cuadro de resultados de la auditoría

Indicador	Valor
Hallazgos totales documentados	105
Hallazgos de severidad **Crítica**	28
Hallazgos de severidad **Alta**	34
Hallazgos de severidad **Media**	29
Hallazgos de severidad **Baja**	14
Índice de calidad de escritura científica	**6,8 / 10**
Verificaciones aritméticas independientes realizadas	24
Verificaciones aritméticas **correctas**	17
Referencias verificadas como reales	33 / 33
Referencias fabricadas detectadas	**0**

Indicador	Valor
Referencias huérfanas (no citadas)	0
Citas huérfanas (sin entrada)	2
Figuras en 74 páginas	1

3.4 Las cinco cuestiones que decidirán la defensa

Primera. El repositorio contiene, en `docs/anexo_f_corpus.md`, una **«Declaración de integridad académica»** —escrita por los propios autores el 11 de junio de 2026 y nunca modificada— que afirma textualmente que el corpus disponible es sintético, que **no debe interpretarse como evidencia experimental del desempeño del sistema**, y que el corpus real de 200 casos «es **trabajo de campo futuro** que se realizará en la etapa de evaluación experimental de la tesis». El `README` de `evaluation/data/` repite la advertencia. El único informe de evaluación versionado (`report_provisional.md`, generado por el mismo `pipeline` que la tesis describe) reporta **63,0 % de exactitud y F1 macro 0,5936**, contra el 92 % y 0,919 publicados.

Segunda. No existe ningún dato de tiempo en la totalidad del repositorio. Los tres archivos CSV presentes no contienen columnas de cronometraje salvo un *fixture* de prueba de 9 filas. La Tabla 6, la prueba de Wilcoxon sobre 200 pares, el intervalo de confianza de las medias y el tamaño del efecto carecen por completo de insumo verificable.

Tercera. El estadístico **W = 0** publicado en §7.1 es incompatible con la definición de W que usa el propio código de los autores (`evaluation/stats.py` invoca `scipy.stats.wilcoxon(d, alternative='greater')`, que devuelve la **suma de rangos positivos**: con 200 pares todos favorables, W = 20.100, no 0). Además, la fórmula publicada $r = 1 - 2W/[n(n+1)]$ **no recorre el intervalo [−1, +1]** que la tesis le atribuye, sino [0, 1]; la expresión correcta para el coeficiente rango-biserial de muestras pareadas es $1 - 4W/[n(n+1)]$. El código lo sabe: un comentario admite que con la fórmula de la tesis el resultado sería 0 y sustituye silenciosamente el estimador «para consistencia con la tesis que reporta r = 1.00».

Cuarta. El flujo N8N publicado **contradice al Capítulo 6 en cinco puntos verificables**, entre ellos que el nodo condicional descrito como compuerta de confianza del clasificador se ejecuta *antes* del clasificador y evalúa una confianza sintetizada a partir de una comprobación de longitud de texto; y que el nodo de agente del canal telefónico **no tiene ningún modelo de lenguaje conectado**, por lo que ese canal no puede ejecutarse.

Quinta. El Capítulo 11 contiene **tres errores jurídicos sustantivos** que un tribunal con formación legal detectará de inmediato, el más grave de los cuales declara satisfecho el principio de limitación del plazo de conservación mediante «una política de conservación indefinida» —una contradicción en los términos que, además, incumple el artículo 4, inciso 7 de la Ley 25.326 que el propio capítulo invoca.

4 Hallazgos críticos

Se documentan los 28 hallazgos de severidad **Crítica**, agrupados en cinco bloques temáticos. Cada hallazgo indica ubicación, evidencia, impacto y recomendación.

4.1 Bloque I — Trazabilidad y existencia de los datos experimentales

4.1.1 C-01. El repositorio declara que la campaña experimental es trabajo futuro

Ubicación: Capítulo 7 completo; Anexo F (§F, p. 74).

Evidencia. El Anexo F de la tesis remite al directorio `evaluation/data/` del repositorio y promete allí un CSV con siete columnas: identificador anónimo, descripción pseudonimizada, canal de origen, categoría por consenso humano, categoría predicha, tiempo de registro en cada flujo y confianza de la predicción. El archivo real, `evaluation/data/corpus_evaluacion.csv`, tiene **cuatro columnas** (`id`, `descripcion`, `canal_origen`, `categoria_real`), es **generado programáticamente** por `evaluation/generate_corpus.py` con semilla fija 42, y su `README` advierte:

> «ADVERTENCIA: los numeros de metricas generados con este corpus NO son validos para el Capitulo 7 de la tesis.»

El documento `docs/anexo_f_corpus.md` del mismo repositorio —titulado «Anexo F — Corpus de Validación» y encabezado por una **«Declaración de integridad académica»**— es todavía más explícito:

> «No representa datos reales de una mesa de ayuda y **no debe interpretarse como evidencia experimental del desempeño del sistema**. […] El corpus real, constituido por 200 casos pseudonimizados extraídos de incidentes reales de una organización, es **trabajo de campo futuro** que se realizará en la etapa de evaluación experimental de la tesis.»

Ese archivo fue incorporado el 11 de junio de 2026 y **no fue modificado** en ninguno de los *commits* posteriores, incluidos los tres del 2 y 3 de julio que precedieron a la compilación del PDF entregado.

Impacto. Crítico y estructural. La totalidad del Capítulo 7, la contrastación de la hipótesis del §1.4, el cumplimiento de los objetivos específicos segundo y cuarto (§1.6), la discusión del Capítulo 8 y las conclusiones del Capítulo 9 dependen de datos cuya existencia el propio material de respaldo del trabajo pone en duda por escrito.

Recomendación. Es imprescindible que los autores exhiban ante el tribunal, antes de la defensa, el corpus real pseudonimizado y el registro de mediciones. Si el corpus existe y no se versionó por razones de privacidad —lo cual es legítimo—, debe actualizarse el Anexo F para declararlo, retirarse del repositorio la declaración de integridad que hoy lo contradice, y aportarse una copia sellada al tribunal bajo acuerdo de confidencialidad. Si no existe, el Capítulo 7 debe reescribirse por completo.

4.1.2 C-02. La única corrida documentada arroja 63,0 % de exactitud, no 92 %

Ubicación: §7.2 (Tablas 7 y 8); §1.6 (segundo objetivo específico).

Evidencia. El repositorio versiona un único informe de evaluación, `evaluation/report_provisional.md`, generado por `evaluation/run_evaluation.py` —el mismo módulo que la tesis describe como instrumento de medición. Sus resultados:

Métrica	Repositorio (`report_provisional.md`)	Tesis (§7.2)
Exactitud global	**63,0 %** (126/200)	92,0 % (184/200)
F1 macro	**0,5936**	0,919
F1 Sistemas	0,6996	0,933
F1 Operaciones	**0,4368**	0,906
F1 Soporte Técnico	0,6444	0,917
IC Wilson 95 %	[56,1 %; 69,4 %]	[87,2 %; 95,2 %]

Impacto. Crítico. El segundo objetivo específico fija un piso de 85 % de exactitud y 0,85 de F1 macro. La única medición trazable del sistema queda **22 puntos porcentuales por debajo** de ese piso y no lo alcanzaría con ningún ajuste marginal.

Recomendación. Publicar el informe de la corrida definitiva con el corpus real, generado por el mismo `run_evaluation.py`, y versionarlo junto al provisional. Si el resultado real es el del informe provisional, el trabajo debe reformular sus objetivos y su hipótesis, no sus números.

4.1.3 C-03. La distribución de etapas del pipeline no coincide y existe una etapa no documentada

Ubicación: §5.5, §8.1, §9.1.

Evidencia. La tesis afirma en tres pasajes distintos que «aproximadamente el 62 % de los incidentes son resueltos por la primera etapa, mientras que el 38 % restante requiere la consulta al modelo externo», y construye sobre ese reparto todo su argumento económico (costo trimestral de API de 28 USD, §8.4 y §9.2) y su afirmación de eficiencia del esquema híbrido (§8.1). La corrida documentada reporta un reparto distinto:

Etapa	Repositorio	Tesis
Determinística	101 (50,5 %)	62 %
Gemini	**4 (2,0 %)**	38 %
Fallback	**95 (47,5 %)**	no existe

Más grave que la discrepancia numérica es la tercera fila. El `HybridClassifier` del repositorio tiene **una etapa de *fallback* que la tesis no menciona en ningún capítulo**: cuando la invocación a Gemini falla por *timeout* o indisponibilidad, el clasificador devuelve la categoría determinística con **confianza 0,0**. En la corrida documentada, 95 de 200 casos —casi la mitad del corpus— terminaron en esa rama.

Impacto. Crítico. Una etapa de *fallback* con confianza 0,0 en el 47,5 % de los casos significaría, bajo la propia regla del §6.3, que casi la mitad de los incidentes debería derivarse a revisión humana, lo cual es incompatible con el 9,5 % de intervención humana reportado en §7.3.

Recomendación. Documentar la etapa de *fallback* en §5.5 y §6.3, informar su frecuencia real en el Capítulo 7 y discutir en el Capítulo 8 su implicancia sobre la disponibilidad del sistema.

4.1.4 C-04. No existe ningún dato de tiempo en todo el repositorio

Ubicación: §7.1 (Tabla 6), §4.6, §4.7.

Evidencia. El repositorio contiene exactamente tres archivos CSV: `evaluation/data/corpus_evaluacion.` (4 columnas, sin tiempos), `data/corpus_sintetico_provisional.csv` (3 columnas, sin tiempos) y `evaluation/tests/fixtures/corpus_fixture.csv`, un *fixture* de **nueve filas** que sí tiene `tiempo_manual_s` y `tiempo_automatizado_s` pero cuyo propio `README` lo declara material de prueba unitaria. No hay planillas de cronometraje, no hay exportación de marcas temporales de la base de datos, no hay registros administrativos.

Impacto. Crítico. La Tabla 6 completa (medias, medianas, desvíos, mínimos, máximos e intervalos de confianza), la prueba de Wilcoxon sobre 200 pares, el tamaño del efecto y la reducción del 89 % —es decir, el resultado principal de la tesis y el que sostiene la hipótesis H1— carecen de insumo verificable.

Recomendación. Publicar el registro de los 200 pares de tiempos, aunque sea agregado y pseudonimizado. Es el único dato que puede reconstruir la Tabla 6 y sin él la hipótesis principal es incontrastable.

4.1.5 C-05. La medición «anti-Hawthorne» es incompatible con la ventana temporal del corpus

Ubicación: §4.2, §4.4, §4.5, §11.5.

Evidencia. El §4.4 sitúa el corpus en el trimestre **julio–septiembre de 2025**. El §1.8 y el §8.3 sitúan el estudio y la versión del modelo en **junio de 2026**. Entre ambos median nueve meses. El §4.2 afirma que «los operadores no fueron informados de que sus tiempos estaban siendo registrados» y que el tiempo manual se obtuvo «mediante registros administrativos de sistemas de soporte posteriores al ciclo de pruebas». Si los incidentes manuales son registros retrospectivos de 2025, entonces: (a) no hubo observación que ocultar y el argumento anti-Hawthorne es vacío; (b) el contrabalanceo del orden de procesamiento descrito en §4.2 es **imposible**, porque no se puede reordenar el pasado; y (c) el *debriefing* del §11.5, que declara haber ofrecido a los operadores excluir sus registros, se refiere a una situación experimental que no existió como tal.

Impacto. Crítico. Compromete simultáneamente la validez interna, el diseño cuasiexperimental de muestras pareadas y el tratamiento ético del §11.5.

Recomendación. Declarar con precisión la fecha y el procedimiento de cada una de las dos mediciones. Si el brazo manual es retrospectivo, el diseño no es de muestras pareadas con contrabalanceo sino un contraste histórico, y debe reescribirse el §4.2 completo reconociendo la amenaza de confusión temporal.

4.1.6 C-06. Tres relatos mutuamente incompatibles del instrumento de medición del flujo manual

Ubicación: §4.2, §4.6, §7.3.

Evidencia.

- §4.2: «registros administrativos de sistemas de soporte posteriores al ciclo de pruebas […] evitando cronometraje visual explícito».
- §4.6: «planillas de cronometraje con medición observacional sin retroalimentación inmediata para el flujo manual».
- §7.3: «La medición de la intervención humana se realizó cronometrando, sobre cada caso, los segundos en que el operador ejecutó acciones manuales sobre el sistema.»

Los tres son mutuamente excluyentes: o no hubo cronómetro, o hubo planillas de cronometraje observacional, o se cronometró segundo a segundo cada acción.

Impacto. Crítico para la reproducibilidad. Un tribunal no puede evaluar la validez de una medición cuyo instrumento se describe de tres maneras distintas.

Recomendación. Unificar en una sola descripción del procedimiento, con el instrumento, el operador que midió, la unidad de registro y la precisión.

4.2 Bloque II — Errores estadísticos e inferenciales

4.2.1 C-07. El estadístico W = 0 es incompatible con la definición usada por el propio trabajo

Ubicación: §7.1; §4.7.

Evidencia. El §4.7 declara que «todos los cálculos se realizaron mediante la biblioteca SciPy». El módulo correspondiente del repositorio, `evaluation/stats.py`, ejecuta `scipy.stats.wilcoxon(diferencias, alternative='greater')` y documenta en su propio *docstring* que `W = estadístico de Wilcoxon (suma de rangos positivos)`. Con esa convención y 200 pares en los que el flujo automatizado gana siempre, la verificación con SciPy 1.17.1 devuelve:

```
W (suma de rangos positivos) = 20100.0     p = 7,18e-35
n(n+1)/2 = 20100.0
```

El valor publicado, **W = 0**, corresponde a la convención clásica opuesta (la menor de las dos sumas de rangos). El trabajo, por tanto, publica un estadístico calculado con una convención y lo interpreta con la fórmula de la otra.

Impacto. Crítico. Es un error verificable en treinta segundos por cualquier miembro del tribunal con acceso a SciPy, y afecta al resultado central del trabajo.

Recomendación. Declarar explícitamente qué convención se usa, reportar ambos valores ($W^+ = 20.100$, $W^- = 0$) y corregir la fórmula del tamaño del efecto en consecuencia.

4.2.2 C-08. La fórmula del tamaño del efecto es incorrecta y su rango declarado es falso

Ubicación: §4.7 y §7.1.

Evidencia. La tesis publica

$$r = 1 - \frac{2W}{n(n+1)}$$

y afirma que ese coeficiente «oscila entre −1 y +1». Es verificablemente falso: evaluando la expresión en los extremos del dominio de $W \in [0,\ n(n+1)/2]$ se obtiene $r = 1$ cuando $W = 0$ y $r = 0$ cuando W es máximo. **El recorrido de la fórmula publicada es [0, 1], no [−1, +1].** La expresión correcta del coeficiente rango-biserial de muestras pareadas es

$$r = 1 - \frac{4W}{n(n+1)}$$

Con la convención de SciPy que usa el propio código ($W = 20.100$), la fórmula publicada devuelve **r = 0,00**, no 1,00.

Agravante. El error está replicado en el código y los autores lo advirtieron sin corregirlo. El comentario de `evaluation/stats.py` dice literalmente:

> «Cuando todos los rangos son positivos (manual > automatizado siempre), W = n*(n+1)/2 y r = 0. [...] **Para consistencia con la tesis que reporta r=1.00:** Calculamos r como la proporción de pares donde manual > automatizado.»

Es decir: el código detectó que la fórmula publicada da 0, y en lugar de corregir la tesis **sustituyó el estimador para que el resultado coincidiera con el número ya escrito**. La función retorna un `r` que no es el que la tesis define.

Impacto. Crítico. Es el hallazgo de mayor gravedad epistémica del trabajo: no es un error de cálculo sino un ajuste del método al resultado.

Recomendación. Corregir la fórmula en §4.7 y §7.1, recalcular con la definición correcta y alinear el código con la tesis, no la tesis con el número. Documentar el cambio.

4.2.3 C-09. «Varianza casi diez veces menor» describe el desvío, no la varianza

Ubicación: §8.1.

Evidencia. Con los desvíos publicados en la Tabla 6 (38,7 s y 4,1 s), la razón de **desvíos** es 9,4 y la razón de **varianzas** es $38{,}7^2/4{,}1^2 = 89{,}1$. La tesis afirma «una varianza casi diez veces menor».

Impacto. Crítico en un capítulo de discusión estadística: confunde dos momentos distintos de la distribución y subestima en un orden de magnitud el propio hallazgo del trabajo.

Recomendación. Escribir «un desvío estándar 9,4 veces menor» o «una varianza 89 veces menor».

4.2.4 C-10. La proyección de «180 horas-persona liberadas» es aritméticamente imposible

Ubicación: §8.1, §9.2, §8.4.

Evidencia. El tiempo **total** del brazo manual sobre el universo trimestral es $3.700 \times 165{,}3$ s $= 169{,}9$ horas. La liberación máxima concebible —si el sistema tardara cero— sería ese valor. Con los tiempos publicados, la liberación efectiva es $3.700 \times (165{,}3 - 18{,}2)/3600 =$ **151,2 horas**, o 153,8 h si se descuenta el 9,5 % de intervención humana. La cifra de 180 horas **excede el techo teórico** del propio estudio.

Impacto. Crítico. La cifra se repite en §8.1, §8.4 y §9.2 y es el argumento económico central del trabajo. También aparece en §1.2 como «200 horas-persona por trimestre», valor igualmente no derivable de $3.700 \times 165{,}3$.

Recomendación. Reemplazar por 151 h y explicitar el cálculo en una nota al pie.

4.2.5 C-11. La intervención humana se define como proporción de tiempo y se reporta como proporción de casos

Ubicación: Tabla 2 (§4.3) frente a §7.3.

Evidencia. La Tabla 2 operacionaliza la variable como «**proporción del tiempo total del proceso** que requiere acción manual de un operador humano». El §4.6 la reitera: «cociente entre el tiempo dedicado a tareas manuales y el tiempo total del proceso». Pero el §7.3 reporta: «De los 200 casos procesados, 181 (90,5 %) fueron clasificados y registrados sin intervención humana, mientras que 19 (9,5 %) requirieron verificación o corrección», que es una **proporción de casos**. Las dos magnitudes no son intercambiables: 19 casos que requieren corrección manual consumen mucho más del 9,5 % del tiempo total.

Impacto. Crítico. Invalida el cuarto indicador del estudio y el tercer resultado del Capítulo 7.

Recomendación. Elegir una de las dos definiciones, corregir la Tabla 2 o el §7.3 en consecuencia, y —si se conserva la definición temporal— reportar el dato que efectivamente la mide.

4.2.6 C-12. El clasificador está severamente descalibrado y el trabajo no lo advierte

Ubicación: §7.2 frente a §7.3 y §6.3.

Evidencia. El §7.2 reporta **16 errores** de clasificación. El §7.3 reporta **19 intervenciones humanas**, definidas como la unión de dos conjuntos: casos con confianza inferior a 0,70 y casos en que el sector receptor detectó y corrigió una mala clasificación. Si los 16 errores fueron corregidos, entonces la compuerta de confianza marcó por sí sola **como máximo 3 casos**. Es decir: la compuerta de confianza, que es el mecanismo *human in the loop* que el trabajo presenta como su salvaguarda principal (§7.3, §9.1, §11.5), **no detectó prácticamente ninguno de los errores**; los detectaron los sectores receptores, aguas abajo. Un clasificador que se equivoca 16 veces con confianza alta está severamente descalibrado.

Impacto. Crítico y no discutido en ningún pasaje del trabajo. Contradice la afirmación de §7.3 de que el esquema «reserva al operador la atención de los casos complejos o ambiguos».

Recomendación. Reportar el cruce entre confianza y acierto (curva de calibración o, como mínimo, la tabla de contingencia confianza-alta/confianza-baja × acierto/error) y discutir el resultado en el Capítulo 8.

4.2.7 C-13. El universo trimestral de 3.700 incidentes no es compatible con el volumen diario declarado

Ubicación: §1.2, §4.4.

Evidencia. El §1.2 reporta «un volumen promedio de **42 incidentes diarios**» y proyecta un universo trimestral de **3.700**. Esa proyección requiere $3.700/42 = 88{,}1$ días. Un trimestre tiene entre 62 y 66 días hábiles. Con 42 incidentes/día el universo trimestral sería de aproximadamente 2.600–2.800, no 3.700; para alcanzar 3.700 harían falta unos 57 incidentes diarios.

Impacto. Crítico porque de ese universo se deriva el marco muestral, el tamaño de muestra, la corrección por finitud (§4.4) y todas las proyecciones económicas.

Recomendación. Reconciliar ambos valores y declarar el número de días hábiles del trimestre observado.

4.2.8 C-14. La pregunta de investigación sobre exactitud humana nunca se responde

Ubicación: §1.3 (segundo interrogante subsidiario), §7, §8.1.

Evidencia. El §1.3 pregunta: «¿alcanza el clasificador automático una exactitud comparable o superior a la del criterio humano?». La hipótesis del §1.4 la reformula como parte de H1. Pero el diseño **nunca mide la exactitud del brazo manual**. El único dato de referencia humana es la «tasa de derivación errónea inicial cercana al 15 %» del §1.2, procedente de mediciones preliminares ajenas al corpus experimental. El §8.1 concluye que la exactitud

del 92 % «supera ampliamente los umbrales planteados», que es un contraste contra un umbral, no contra el criterio humano.

Impacto. Crítico. Uno de los tres interrogantes que estructuran el trabajo queda sin contestar y la comparación central de la hipótesis sin brazo de control.

Recomendación. O bien medir la clasificación manual sobre el mismo corpus —el dato existe si los operadores procesaron los 200 casos—, o bien retirar el interrogante y reformular H1.

4.2.9 C-15. Coincidencia no explicada entre la medición preliminar y el resultado experimental

Ubicación: §1.2 frente a §7.1.

Evidencia. El §1.2 informa, a partir de mediciones preliminares de una semana, «un tiempo medio de registro manual de **2 minutos con 45 segundos** por incidente». El §7.1 informa que la media experimental del brazo manual sobre 200 casos fue de **165,3 s**, que es exactamente 2 min 45 s. Que un estudio con n = 200 reproduzca al segundo el valor de una estimación preliminar informal es estadísticamente muy improbable y sugiere que el segundo valor deriva del primero.

Impacto. Crítico como indicio de trazabilidad, en concurrencia con C-01 y C-04.

Recomendación. Exhibir el registro que sustenta los 165,3 s y explicitar en §7.1 la relación entre ambas mediciones. ## Bloque III — Divergencias entre la arquitectura descrita y el artefacto publicado

Se clonó el repositorio declarado en el Anexo B y se inspeccionó el flujo `Automatizacion_Mesa_de_Ayuda.js` la configuración de despliegue y el código del *backend*. El artefacto es real, sustancial y de buena factura; las divergencias que siguen se refieren a lo que la tesis **afirma** sobre él.

4.2.10 C-16. La compuerta de confianza descrita en §6.3 se ejecuta antes del clasificador

Ubicación: §6.3 (etapas 3 y 4), §7.3, §11.5.

Evidencia. El §6.3 describe la cuarta etapa así: «Un nodo condicional (IF) evalúa la confianza devuelta por el clasificador; si está por debajo del umbral de 0,70, deriva el incidente a la cola de revisión humana y notifica al operador designado.» En el flujo publicado:

1. El nodo `La informacion esta OK` (tipo `n8n-nodes-base.if`) evalúa efectivamente `{{ $json.confianza }} >= 0.7`.
2. Pero está conectado **antes** del nodo `HTTP POST a MTM-SRU`, que es el que invoca al clasificador. La secuencia real es: *trigger* → validación → normalización → **IF** → POST.
3. Para los canales de correo y web, el campo `confianza` que el IF evalúa **no proviene del clasificador**: lo sintetiza el nodo `Normalizar entrada del incidente`, cuyo propio comentario lo explicita: «correo/web: sintetiza confianza desde `es_valido`: `es_valido = true` → `confianza = 1.0`; `es_valido = false` → `confianza = 0.0`». Y `es_valido` se calcula en el nodo anterior como `descripcionTrim.length >= 10 && descripcionTrim.length <= 5000`.
4. La rama falsa **no deriva a ninguna cola de revisión humana ni notifica a ningún operador**: envía un correo **al usuario final** pidiéndole que reenvíe el mensaje con los datos faltantes, y registra el evento en auditoría.

Es decir: en dos de los tres canales, lo que la tesis presenta como la compuerta de confianza del modelo es **una comprobación de longitud de texto**, y el destino de la rama de baja confianza es el propio usuario, no un revisor.

Impacto. Crítico. El esquema *human in the loop*, que el trabajo invoca en el Resumen, en §7.3, en §9.1 y en §11.5 como salvaguarda frente a errores del clasificador, no existe con esa forma en el artefacto publicado.

Recomendación. Reescribir §6.3 describiendo el flujo real, o mover el IF aguas abajo del POST y conectar su rama falsa a una cola de revisión efectiva.

4.2.11 C-17. El agente del canal telefónico no tiene modelo de lenguaje conectado

Ubicación: §5.2, §6.3, §6.4, §9.1.

Evidencia. El nodo `AI Agent` (`@n8n/n8n-nodes-langchain.agent`) tiene una única conexión de tipo `ai_memory`, proveniente del nodo de memoria Redis. **No existe ninguna conexión `ai_languageModel`.** Un nodo *agent* de LangChain en N8N no puede ejecutarse sin un modelo conectado: falla en tiempo de ejecución.

Impacto. Crítico. El canal telefónico —tercer objetivo específico del trabajo, capítulo entero de implementación (§6.4), y el que la tesis destaca en §9.1 como «el mayor desafío técnico» resuelto con latencia de 12 a 15 segundos— **no puede haber sido ejecutado** con el flujo publicado.

Recomendación. Conectar el nodo de modelo y publicar el flujo funcional, o declarar el canal telefónico como prototipo no validado.

4.2.12 C-18. El canal de origen nunca llega al backend

Ubicación: Tabla 2 (§4.3), Tabla 4 (§5.6), §5.3, §6.3.

Evidencia. El nodo `HTTP POST a MTM-SRU` envía un cuerpo con exactamente dos campos:

```
{ "descripcion": "={{ $json.descripcion }}",
  "prioridad":   "={{ $json.prioridad || 'media' }}" }
```

El campo `canal_origen` —que la Tabla 2 declara **variable cualitativa nominal del estudio**, que la Tabla 4 modela como catálogo con clave foránea desde `incidente`, y que el §5.3 afirma que el orquestador normaliza y transmite— **no se envía**.

Consecuencia adicional verificada: el nodo `Rutear por canal de origen` (Switch, `typeVersion` 3) opera en modo `expression` con salida `{{ $json.canal_origen }}`, un valor de texto donde el nodo espera un índice numérico de salida, y su única regla declarada contempla solo el valor `web`. En la práctica, correo y telefonía caen en la salida de reserva, que está conectada al nodo `Correo de confirmación al usuario`. Los incidentes telefónicos, por tanto, se confirman por correo.

Impacto. Crítico. Una de las seis variables del estudio nunca se persiste desde el flujo, y la Tabla 4 describe un modelo de datos que el orquestador no alimenta.

Recomendación. Agregar `canal_origen` al cuerpo del POST y corregir el modo del Switch.

4.2.13 C-19. No existe ningún mecanismo de reintento pese a que §6.5 lo declara implementado y probado

Ubicación: §6.5 (primer desafío de integración).

Evidencia. El §6.5 afirma: «La solución consistió en implementar un mecanismo de reintento con retroceso exponencial en el propio nodo HTTP de N8N, combinado con una cola de respaldo en el servicio Python […]. Esta combinación de reintento en el cliente y cola en el servidor eliminó las pérdidas de incidentes observadas durante las pruebas de carga iniciales.»

En el flujo publicado, **ningún nodo tiene `retryOnFail`, `onError` ni `maxTries` configurados**, y el `settings` del *workflow* no define `errorWorkflow`. Tampoco existe cola de respaldo alguna en el módulo Python.

Impacto. Crítico. Se declara en pretérito, como resuelto y validado empíricamente, un mecanismo inexistente y unas pruebas de carga de las que no hay rastro.

Recomendación. Implementarlo o reescribir §6.5 como limitación conocida y trabajo futuro.

4.2.14 C-20. TLS 1.3 y el proxy inverso Nginx no existen en el despliegue publicado

Ubicación: §5.1, §9.1, §11.4, Anexo A.

Evidencia. El §5.1 afirma que «la comunicación con el exterior se protege mediante TLS 1.3 a nivel del proxy inverso (Nginx)»; el §11.4 lo enumera como medida de confidencialidad implementada; el §9.1 lo repite en las conclusiones; y el Anexo A declara que el diagrama de despliegue incluye «el proxy inverso Nginx que provee terminación TLS 1.3 en el perímetro del sistema».

En el repositorio **la palabra `nginx` no aparece en ningún archivo**. El `docker-compose.yml` declara cinco servicios (postgres, redis, backend, n8n, frontend) y ninguno es un proxy inverso. Y los propios autores lo documentan: el archivo `knowledge-base/08_arquitectura_propuesta.md` registra en su tabla de arquitectura «Cifrado en tránsito | TLS 1.3 entre todos los componentes | **HTTP local en dev; TLS pendiente para despliegue**», y la propuesta de cambio `openspec/changes/archive/2026-07-03-c-18-tesis-alineacion-tecnologica/proposal.md` clasifica explícitamente «TLS 1.3 (§5.1, §11)» bajo el encabezado **«Lo que NO se corrige (se mantiene como aspiracional o trabajo futuro)»**, con la razón: «**Aspiracional. HTTP plano en dev.** Documentar como requisito productivo».

Impacto. Crítico. Una medida de seguridad declarada como implementada en tres capítulos, que los propios autores catalogaron internamente como aspiracional el mismo día en que compilaron el PDF.

Recomendación. Reescribir §5.1, §9.1 y §11.4 en modo condicional («el diseño prevé…», «para el despliegue productivo se requiere…») o incorporar efectivamente el proxy al `docker-compose`.

4.2.15 C-21. Los propios autores catalogaron 27 brechas entre la tesis y el código, y decidieron no cerrar seis

Ubicación: transversal.

Evidencia. El documento `openspec/changes/archive/2026-07-03-c-18-tesis-alineacion-tecnologica/proposal.md`, fechado el 3 de julio de 2026 —el día de compilación del PDF entregado— comienza así:

> «La auditoria del 2026-07-02 revelo **27 brechas** entre lo que la tesis describe y lo que el codigo realmente implementa. El usuario decidio corregir en la tesis aquellas discrepancias donde la implementacion real es la fuente de verdad,

> y **mantener como "trabajo futuro" o "aspiracional" lo que no se va a implementar ahora**.»

De las seis brechas listadas bajo «Lo que NO se corrige», al menos cuatro **siguen enunciadas en modo afirmativo en el PDF entregado**: TLS 1.3 (§5.1, §9.1, §11.4), la retención de datos (§11.2, declarada «no implementado» internamente y presentada en la tesis como política vigente), el HMAC-SHA-256 y pgcrypto (§11.4, reformulado como Fernet pero conservando la mención a HMAC-SHA-256), y el cambio de nombres de entidades del modelo de datos.

Impacto. Crítico. Existe registro documental, escrito por los autores, de que las divergencias eran conocidas y de que se optó por no reflejar algunas de ellas en el texto entregado.

Recomendación. Alinear el capítulo 5, 6 y 11 con el estado real y adjuntar el registro de decisiones como anexo, lo cual convertiría un problema de integridad en un ejemplo de trazabilidad.

4.2.16 C-22. El prompt del agente clasifica en cuatro sectores, no en tres

Ubicación: §1.6, §5.5, §6.3, Tabla 4, Capítulo 7 completo.

Evidencia. Toda la tesis se construye sobre **tres** sectores de derivación (Sistemas, Operaciones y Soporte Técnico): el segundo objetivo específico, el catálogo de la Tabla 4, la matriz de confusión 3×3 de la Tabla 7 y las métricas por clase de la Tabla 8. El *prompt* del nodo `AI Agent` del flujo publicado instruye:

> «…identificarás el incidente específico que le ocurre al usuario y si hay que registrarlo para Operaciones, Soporte Tecnico, Sistemas, **o Seguridad**.»

Impacto. Crítico para la coherencia entre el artefacto y el instrumento de medición: el canal telefónico puede emitir una cuarta categoría que ni el validador posterior ni el modelo de datos admiten.

Recomendación. Unificar el *prompt* con las tres categorías del trabajo o justificar y documentar la cuarta.

4.2.17 C-23. El Anexo B declara un tag de versión que no existe

Ubicación: Anexo B (p. 72).

Evidencia. «El commit de referencia para la versión entregada al jurado corresponde al tag `v1.0.0`.» El repositorio clonado **no tiene ningún tag**: `git tag` devuelve vacío. El commit más reciente es `d7df92c` del 2/7/2026.

Impacto. Crítico para la reproducibilidad: el tribunal no puede recuperar el estado exacto que la tesis dice haber evaluado.

Recomendación. Crear el tag y consignar además el hash completo del commit en el Anexo B.

4.3 Bloque IV — Bibliografía y atribución

4.3.1 C-24. Misatribución verificada de Revina, Buza y Meister (2020), que es el aval empírico del enfoque

Ubicación: §3.3 y §8.2.

Evidencia. El §3.3 afirma: «Revina et al. (2020) extienden este enfoque incorporando **arquitecturas basadas en BERT** y reportan mejoras significativas, alcanzando exactitudes del orden del 91 %». El §8.2 lo reutiliza como término de comparación: «Frente al enfoque BERT de Revina et al. (2020) (91 %)…».

El artículo real —cuyo título la propia bibliografía de la tesis transcribe correctamente— se llama **«IT Ticket Classification: The Simpler, the Better»** (*IEEE Access*, 8, 193380-193395, DOI 10.1109/ACCESS.2020.3032840). Su objeto declarado es comparar el desempeño de representaciones TF-IDF frente a representaciones basadas en rasgos lingüísticos para la predicción de complejidad de tickets, y la literatura posterior lo resume señalando que los autores concluyen que un modelo de n-gramas TF-IDF combinado con regresión logística rinde mejor en clasificación de tickets de TI, de donde procede el «cuanto más simple, mejor» del título.

No es un trabajo sobre BERT; es un trabajo cuya tesis central es que **los enfoques simples ganan**.

Impacto. Crítico y doblemente irónico: la única fuente que la tesis usa para argumentar que los modelos preentrenados grandes transfieren conocimiento útil al dominio de tickets sostiene exactamente lo contrario, y el propio título de la obra, impreso en la página de referencias del trabajo, lo delata.

Recomendación. Reescribir §3.3 y §8.2 con la conclusión real del artículo, e incorporar la tensión al Capítulo 8: la existencia de evidencia contraria fortalece la discusión en lugar de debilitarla.

4.3.2 C-25. Los rangos de interpretación de Kappa se atribuyen a Cohen y la lectura del valor es incorrecta

Ubicación: §4.4 y §4.8.

Evidencia. El §4.4 dice: «El acuerdo entre evaluadores, calculado mediante el coeficiente Kappa de Cohen (Cohen, 1960), alcanzó un valor de κ = 0,87, **considerado sustancial** según los rangos de interpretación habitualmente aceptados (**κ > 0,80 indica acuerdo casi perfecto**).» La oración se contradice a sí misma en catorce palabras: aplica la etiqueta «sustancial» a un valor que su propio paréntesis clasifica como «casi perfecto». El Resumen y el Abstract repiten «sustancial».

Además, los rangos de interpretación (*slight, fair, moderate, substantial, almost perfect*) no provienen de Cohen (1960) sino de Landis y Koch (1977), obra ausente de la bibliografía.

Impacto. Crítico en el capítulo metodológico, porque el κ es la garantía de validez del *ground truth* del estudio.

Recomendación. Corregir la etiqueta a «casi perfecto», incorporar Landis y Koch (1977) y citar allí los rangos.

4.3.3 C-26. Bibliografía sin actualización: una sola fuente académica posterior a 2020

Ubicación: Referencias (pp. 69-71).

Evidencia. De las 33 entradas, los porcentajes que el instrumento exige calcular son:

Franja	Entradas	%
Últimos 3 años (2023-2026)	4 (Jurafsky y Martin 2023 —borrador—, Radford et al. 2023, Touvron et al. 2023, Gómez et al. 2026 —software propio—)	12,1 %
Últimos 5 años (2021-2026)	5 (las anteriores + Russell y Norvig 2021)	15,2 %
Documentación técnica de proveedor (2024)	4	12,1 %
Anteriores a 2010	13	39,4 %

Artículos arbitrados de los últimos tres años: 0. Artículos arbitrados de los últimos cinco años: 0. El único artículo de revista específico del dominio es Revina et al. (2020), y es el que está misatribuido (C-24). El estado del arte de un trabajo sobre modelos de lenguaje grandes —campo cuya literatura se renueva por semestres— se apoya en dos artículos de 2019 y 2020 y en ninguna publicación arbitrada posterior.

Impacto. Crítico para el Capítulo 3. Es la observación más previsible de un tribunal.

Recomendación. Incorporar entre ocho y doce artículos arbitrados de 2023-2026 sobre clasificación de tickets con LLM, evaluación *zero-shot*/*few-shot* multilingüe y desempeño de LLM en español.

4.3.4 C-27. El rango comparativo que sostiene el §8.2 carece de cita

Ubicación: §3.3 y §8.2.

Evidencia. El §8.2 afirma: «Evaluaciones recientes de LLM en escenarios *few-shot* para clasificación de tickets reportan valores entre el **88 % y el 94 %** de exactitud dependiendo del idioma y del dominio», y a continuación sitúa el resultado propio «dentro del rango superior reportado». Ese rango, que es la vara con la que el trabajo se mide contra el estado del arte, **no tiene ninguna referencia**. El mismo patrón se repite en §3.3 («La literatura reciente sobre evaluación de modelos de lenguaje… ha documentado que…») y en la afirmación de que el español rioplatense está subrepresentado, sostenida sin una sola fuente.

Impacto. Crítico. La contribución académica declarada del trabajo —cerrar una brecha en el español rioplatense— se apoya en una brecha que nunca se documenta con literatura.

Recomendación. Citar las evaluaciones concretas o retirar el rango y reformular la comparación.

4.4 Bloque V — Cuestiones jurídicas

4.4.1 C-28. Tres errores sustantivos en el marco normativo del Capítulo 11

Ubicación: §11.1, §11.2, §11.3.

Evidencia y análisis.

(a) Conservación indefinida presentada como cumplimiento del principio de limitación del plazo. El §11.2 declara: «El principio de limitación del plazo de conservación se traduce en una **política de conservación indefinida** de los incidentes, justificada por

el valor estadístico de los datos históricos». Es una contradicción en los términos y, además, incompatible con el artículo 4, inciso 7 de la Ley 25.326 —la norma que el propio capítulo invoca— que ordena destruir los datos cuando dejan de ser necesarios o pertinentes para la finalidad que motivó su obtención. La propuesta de cambio interna de los autores registra, coherentemente, «Retencion de datos (§11.2) | No implementado. Mover a trabajo futuro», decisión que no llegó al texto entregado.

(b) El «legítimo interés» no es base de licitud en el régimen argentino. El §11.2 funda el tratamiento en «el legítimo interés de la organización». El interés legítimo es una base del artículo 6.1.f del RGPD europeo; la Ley 25.326 estructura la licitud sobre el consentimiento del titular (art. 5.1) y sus excepciones tasadas (art. 5.2), entre las que figura la derivada de una relación contractual o laboral —que es la base correcta para este caso—.

(c) La adecuación europea de Argentina se invoca en la dirección equivocada. El §11.1 sostiene que «Argentina mantiene un régimen de adecuación reconocido por la Comisión Europea, lo cual facilita los flujos transfronterizos bidireccionales bajo determinadas condiciones», en el contexto de justificar el envío de datos a infraestructura estadounidense. La decisión de adecuación habilita flujos **desde** el Espacio Económico Europeo **hacia** Argentina; no dice nada sobre transferencias de Argentina hacia terceros países. La transferencia internacional del art. 12 de la Ley 25.326 se resuelve, en este trabajo, únicamente con pseudonimización y el acuerdo de tratamiento del proveedor, sin mención de las cláusulas contractuales tipo aprobadas por la autoridad de aplicación.

Riesgo adicional verificado en el artefacto. El §11.3 afirma que la pseudonimización «se realiza dentro del módulo Python desplegado en infraestructura local» antes de cualquier transmisión al proveedor de inferencia. En el flujo publicado, el canal telefónico envía la **transcripción cruda** al nodo `AI Agent` —y por tanto al proveedor del modelo— **antes** de que el texto llegue al *backend* donde ocurre la pseudonimización. El comentario del nodo normalizador lo confirma: «La descripcion se transmite en texto claro al backend. La pseudonimizacion ocurre en el backend».

Impacto. Crítico. El Capítulo 11 es el capítulo que un tribunal con formación jurídica leerá con más atención, y es donde el trabajo se juega su afirmación de cumplimiento normativo.

Recomendación. Reescribir §11.2 con un plazo de conservación concreto y una política de supresión; sustituir «legítimo interés» por la base del art. 5.2 aplicable; corregir el sentido de la decisión de adecuación; e incorporar el análisis de la transferencia previa a la pseudonimización en el canal telefónico.

5 Evaluación capítulo por capítulo

La estructura de esta sección sigue exactamente los diez capítulos que el instrumento prescribe. Para cada uno se evalúan las cinco dimensiones obligatorias: coherencia, profundidad científica, calidad académica, coherencia interna y calidad de redacción.

5.1 1. Introducción

Correspondencia en el documento: Capítulo 1 (§1.1 a §1.8), pp. 11-17.

Coherencia. El hilo conductor es sólido y explícito: contextualización → problema medido → pregunta → hipótesis → objetivos → justificación → alcance. Es la mejor cadena argumental del trabajo y está por encima de la media de la carrera. El §1.6 fundamenta el umbral del 85 % con tres criterios convergentes explicitados, práctica infrecuente y meritoria.

Rupturas detectadas.

- **A-01 (Alta).** El §1.2 proyecta 3.700 incidentes trimestrales desde 42 diarios; la aritmética no cierra (C-13).
- **A-02 (Alta).** El §1.2 estima el costo de la etapa de registro «en el orden de 200 horas-persona por trimestre». Con los propios datos ($3.700 \times 165{,}3$ s) el valor es 169,9 h. Ninguna de las dos cifras de horas que el trabajo publica (200 en §1.2, 180 en §8.1) es derivable de sus insumos.
- **A-03 (Alta).** El tercer criterio del umbral del 85 % en §1.6 —«el margen por encima del 85 % reserva espacio estadístico para que el intervalo de confianza del estimador no solape la zona de rechazo de la hipótesis»— confunde el contraste de la hipótesis sobre tiempos (H0/H1 del §1.4, que es sobre medianas de tiempo) con el umbral de exactitud del clasificador. No hay «zona de rechazo» definida para la exactitud.
- **M-01 (Media).** El §1.1 atribuye a «la Secretaría de la Pequeña y Mediana Empresa» la definición de empresa mediana (50-200 trabajadores en servicios) sin cita ni entrada bibliográfica: **cita huérfana**.
- **M-02 (Media).** El §1.7 afirma que «la mayoría de los estudios publicados sobre clasificación automática de tickets utilizan corpus en inglés, alemán o portugués, y los pocos trabajos que incluyen el español lo hacen con variantes peninsulares» sin una sola referencia que lo sostenga. Es la premisa de la contribución académica declarada.
- **B-01 (Baja).** El §1.2 y el §1.8 alternan «organización mediana del sector servicios con sede en la provincia de Mendoza» y «única organización», sin nombrarla ni caracterizarla más allá de los 120 usuarios y cinco áreas.

Profundidad científica. Adecuada. El planteamiento del problema se apoya en mediciones preliminares propias, lo que es más de lo que suele verse. Falta, en cambio, cualquier discusión de por qué la mediana argentina es un caso distinto del que la literatura internacional estudia más allá de la restricción cambiaria, que se menciona pero no se cuantifica.

Calidad académica. Buena. Terminología estable y registro formal sostenido.

Coherencia interna. El eslabón débil es el segundo interrogante subsidiario del §1.3 (comparación con el criterio humano), que nunca se responde (C-14).

Calificación: 6,5 / 10.

5.2 2. Marco teórico

Correspondencia: Capítulo 2 (§2.1 a §2.7), pp. 18-23.

Coherencia. Los siete ejes están bien elegidos y cada uno tiene función instrumental posterior: ITSM e ITIL fundan la unidad de análisis, orquestación versus coreografía funda la decisión arquitectónica, las métricas multiclase fundan el Capítulo 7. Es un marco teórico *útil*, no decorativo, lo cual lo distingue favorablemente.

Debilidades detectadas.

- **A-04 (Alta).** El §2.4 es el eje central del trabajo —modelos de lenguaje grandes— y se resuelve en cuatro párrafos con tres referencias, dos de ellas de 2017 y 2020. No hay tratamiento de *prompting*, calibración de confianza, alucinación, sensibilidad al idioma ni evaluación de LLM, todos ellos conceptos que el trabajo usa operativamente en capítulos posteriores sin haberlos definido.
- **A-05 (Alta).** El §2.7 define la exactitud global con la fórmula binaria $(TP + TN)/(TP + TN + FP + FN)$ y a continuación aclara que «para problemas de clasificación multiclase, la exactitud se calcula como la proporción de predicciones correctas sobre el total». Presentar primero una fórmula que no aplica al problema y corregirla en la oración siguiente es un defecto de precisión conceptual en el capítulo que define el instrumento de medición.
- **A-06 (Alta).** El §2.2 atribuye ITIL Service Operation (edición 2011) a la *Office of Government Commerce*. La edición 2011 fue publicada por TSO en nombre del *Cabinet Office*; la OGC corresponde a la edición 2007. **Requiere verificación por los autores.**
- **M-03 (Media).** El §2.5 describe Whisper con detalle (680.000 horas, segmentos de 30 s) y concluye que «la disponibilidad de modelos preentrenados de código abierto para español facilita su integración en el canal telefónico del sistema propuesto». Whisper **no se usa** en el sistema: el §6.4 emplea la transcripción nativa de Twilio. Toda la sección es teoría sin correlato en el artefacto.
- **M-04 (Media).** El §2.6 justifica PostgreSQL sobre alternativas no relacionales sin considerar ninguna alternativa concreta; es una justificación por afirmación.
- **B-02 (Baja).** Jurafsky y Martin (2023) se cita como obra de Pearson cuando el tercer volumen es un borrador de libre acceso no publicado por esa editorial.

Profundidad. Desigual: §2.3 (orquestación vs. coreografía) y §2.7 (métricas) son sólidos; §2.4 y §2.6 son superficiales para el peso que cargan.

Calificación: 6,0 / 10.

5.3 3. Marco metodológico

Correspondencia: Capítulo 4 (§4.1 a §4.9), pp. 28-33. *(El Capítulo 3 del documento es el estado del arte y se evalúa en la sección de revisión bibliográfica.)*

Este es el capítulo con mayor concentración de hallazgos críticos: C-05, C-06, C-11, C-13, C-25, y concurrentemente C-01 y C-04.

Elementos correctamente tratados. La operacionalización de variables (Tabla 2) tiene tipo, unidad y definición operacional por variable, práctica infrecuente y meritoria. El §4.8 identifica cuatro amenazas a la validez con su tratamiento, por iniciativa propia. La elección de pruebas no paramétricas está justificada con un contraste previo de normalidad. Se declaran el nivel de significancia, el método de intervalo de confianza (Wilson) y la biblioteca de cálculo.

Debilidades adicionales a las críticas ya documentadas.

- **A-07 (Alta).** El §4.4 declara «nivel de confianza del 95 % y un margen de error del 6,5 %» y una «corrección por finitud aplicada al universo trimestral observado», pero no publica el cálculo ni la proporción esperada supuesta. Con $N = 3.700$, $z = 1{,}96$,

$p = 0{,}5$ y $e = 0{,}065$ el tamaño resultante es 219, no 200. Con $e = 0{,}068$ da 200. El margen declarado no reproduce el tamaño declarado.

- **A-08 (Alta).** El §4.5 afirma cobertura de pruebas unitarias «superior al 80 %» y el §6.7 la precisa en 87 %; ninguno de los dos publica el informe de cobertura ni el comando que lo genera.
- **A-09 (Alta).** No hay ningún análisis de potencia estadística *a priori*, pese a que el §4.8 identifica el tamaño muestral como amenaza a la validez de conclusión.
- **A-10 (Alta).** El §4.2 declara «rotación de operadores entre las dos mitades del corpus» como mitigación, pero con dos operadores y dos mitades la rotación no puede separarse del efecto de operador: el diseño confunde ambos factores.
- **M-05 (Media).** No se declara ningún criterio de exclusión de incidentes del corpus (duplicados, descripciones vacías, incidentes multicategoría), pese a que el §7.4 identifica «descripciones cortas» y «mezcla de categorías» como los dos patrones de error dominantes.
- **M-06 (Media).** El §4.9 (Scrumban) es gestión de proyecto, no metodología de investigación, y su ubicación en el capítulo metodológico desdibuja la distinción entre el método del estudio y el método de construcción del artefacto.
- **M-07 (Media).** No se declara quiénes fueron los dos analistas que etiquetaron el corpus, ni su independencia respecto de los autores, ni si alguno de ellos es también uno de los dos operadores del brazo manual. Si lo fueran, el *ground truth* y el brazo de comparación compartirían sujeto.

Calificación: 3,5 / 10.

5.4 4. Desarrollo del estudio

Correspondencia: Capítulo 6 (§6.1 a §6.8), pp. 40-48.

Fortalezas. Es, junto con el Capítulo 5, la mejor ingeniería documentada del trabajo. El §6.2 justifica la elección de FastAPI contra Flask y Django REST con criterios técnicos concretos y no por preferencia. La descomposición en capas (`models`, `schemas`, `services`, `repositories`, `classifiers`, `routes`, `core`) **se corresponde exactamente con la estructura real del repositorio**, verificada en esta auditoría. El §6.5 (desafíos de integración) es un ejercicio de honestidad técnica poco común, y el §6.7 describe una estrategia de pruebas en pirámide con instrumentos concretos.

Debilidades.

- Los críticos C-16 a C-22 se localizan íntegramente en este capítulo.
- **A-11 (Alta).** El §6.7 afirma «pruebas extremo a extremo que ejecutaban el flujo completo desde el envío de un correo simulado hasta la persistencia del ticket, validando la integración con N8N en su totalidad». No hay ninguna prueba de ese tipo en el repositorio: las 22 suites de *backend* cubren unidades, esquemas, repositorios e integración con base de datos, pero **ninguna instancia de N8N**.
- **A-12 (Alta).** El §6.7 declara «una suite de 89 pruebas automatizadas» en el *frontend* «con una cobertura de sentencias del 98,6 %» y las desagrega en 27 servicios, 10 *hooks*, 43 páginas y gráficos y 9 componentes compartidos (suma: 89). El recuento de casos `it(` / `test(` en los archivos de prueba del repositorio da **68**. La cifra publicada no se reproduce y la cobertura del 98,6 % no está respaldada por ningún informe versionado.
- **A-13 (Alta).** El §6.4 informa una latencia telefónica de extremo a extremo de 12 a 15 segundos «según las observaciones operativas durante la fase de validación», desglosada en tres tramos con rangos. Dado C-17 (el agente no puede ejecutarse), esas observaciones no son atribuibles al flujo publicado. Además la cifra carece de n,

de dispersión y de procedimiento.
- **M-08 (Media).** El §6.8 describe el *dashboard* con tres visualizaciones y controles de filtro, y cierra con un ejemplo hipotético («si el sistema detecta que veinte usuarios han reportado la rotura de auriculares…»). El ejemplo se presenta como «utilidad práctica […] se ilustra con un caso concreto» cuando es un caso imaginado. No hay ninguna captura del *dashboard* en el documento.
- **M-09 (Media).** El §6.1 declara preparación «para migración a un clúster Kubernetes 1.30» sin ningún manifiesto en el repositorio.

Calificación: 5,5 / 10.

5.5 5. Resultados

Correspondencia: Capítulo 7 (§7.1 a §7.4), pp. 49-52.

Este es el capítulo que determina el dictamen. Se le aplican los críticos C-01, C-02, C-03, C-04, C-07, C-08, C-11 y C-12.

Lo que el capítulo hace bien —y debe reconocerse. La presentación es formalmente impecable: estadísticos descriptivos completos con desvíos, rangos e intervalos de confianza; matriz de confusión íntegra; métricas por clase y macro promedio; análisis cualitativo de los 16 errores con una tipología de tres patrones y sus frecuencias. **La verificación aritmética independiente de las cifras publicadas arrojó 17 comprobaciones correctas sobre 24**: la matriz de confusión de la Tabla 7 cierra en filas, columnas y total; las nueve métricas por clase de la Tabla 8 son exactas hasta el tercer decimal a partir de esa matriz; el macro promedio es correcto; la exactitud del 92 % y la distribución de los 16 errores por patrón (7 + 6 + 3) son consistentes. Ese nivel de consistencia interna es excepcional.

El problema no es que las cifras estén mal calculadas. **Es que no se sabe de dónde salen.**

Debilidades adicionales.

- **A-14 (Alta).** El §7.1 afirma «La reducción relativa de la media de tiempo alcanzó el 89,0 %» y la Tabla 6 consigna «89,0 %» tanto para la media como para la mediana. El cálculo da 88,99 % en ambos casos — coincidencia hasta el segundo decimal entre dos estadísticos independientes que, con datos reales, sería extraordinaria.
- **A-15 (Alta).** No se reporta el estadístico ni el valor p concreto de la prueba de Shapiro-Wilk que el §4.7 dice haber aplicado, ni por grupo ni sobre las diferencias.
- **A-16 (Alta).** No se reporta ningún resultado de tiempo desagregado por canal, pese a que el canal es variable del estudio (Tabla 2) y a que la latencia telefónica declarada en §6.4 (12-15 s) y el máximo del flujo automatizado de la Tabla 6 (31 s) sugieren distribuciones muy distintas por canal.
- **M-10 (Media).** El §7.4 tipifica los 16 errores pero no publica ni un solo ejemplo textual de incidente mal clasificado, lo cual haría el análisis verificable sin comprometer privacidad.
- **M-11 (Media).** El capítulo tiene **cero figuras**: ni un diagrama de cajas de los tiempos, ni un mapa de calor de la matriz de confusión, ni una curva de calibración.

Calificación: 1,5 / 10. La forma es sobresaliente; el fundamento probatorio, ausente.

5.6 6. Arquitectura e interfaz de visualización

Correspondencia: Capítulo 5 (§5.1 a §5.7) y §6.8, pp. 34-39 y 47-48.

Fortalezas. La arquitectura de cinco capas está bien delimitada, con responsabilidades claras y justificación de la separación. El §5.5 (subsistema de clasificación híbrido) describe un diseño correcto y **efectivamente implementado**: la verificación del repositorio confirma umbrales configurables de 0,90 para cortocircuitar la etapa determinística y 0,70 para marcar revisión humana, tal como el texto declara. El §5.6 y el §5.7 (modelo de datos y contrato REST) son precisos y el Anexo D (OpenAPI) los respalda con un archivo real de 39 KB con prueba de sincronización en integración continua. La declaración de que la clasificación está embebida en `POST /api/v1/incidentes` y no expuesta como recurso independiente coincide con el código.

Debilidades.

- **C-20** (TLS/Nginx inexistentes) se localiza aquí.
- **A-17 (Alta).** La **Figura 1** es la única figura del trabajo en 74 páginas. Es un diagrama de flujo dibujado a mano alzada, sin notación normalizada, con seis cajas y una decisión, que no representa las cinco capas descritas en la Tabla 3, no muestra ningún componente por su nombre (N8N, FastAPI, PostgreSQL, Gemini, Twilio) y menciona solo Twilio como origen, ignorando los otros dos canales. El pie remite al Anexo A «en notación UML», que no está en el documento.
- **A-18 (Alta).** La Tabla 3 declara para la capa de orquestación: «Motor N8N (versión estable más reciente; **la versión 1.62 no se encuentra disponible en Docker Hub al momento del despliegue**)». Esta acotación —repetida literalmente en §6.1— es una nota de trabajo interna que quedó en el cuerpo de la tesis. Una tesis no documenta lo que *no* pudo instalar en el medio de una tabla de arquitectura; declara la versión efectivamente desplegada.
- **A-19 (Alta).** El §5.6 anuncia «seis entidades principales» y la Tabla 4 las enumera (`incidente`, `sector`, `estado`, `canal_origen`, `clasificacion_log`, `users`), pero el **Anexo C dice «las cinco tablas descritas en la Tabla 4»**. Contradicción entre el cuerpo y el anexo.
- **M-12 (Media).** El §5.4 fija parámetros de inferencia (temperatura 0,3, top-p 0,9, máximo 100 *tokens*, *timeout* 10 s) «optimizados para exactitud y latencia», sin describir ningún procedimiento de optimización ni los valores alternativos evaluados.
- **M-13 (Media).** La Tabla 5 lista tres puntos de entrada; la API real expone además rutas de autenticación (`/api/v1/auth`), de clasificaciones (GET y PATCH) y un PATCH sobre incidentes. La tabla es incompleta, no incorrecta.
- **M-14 (Media).** No hay ninguna captura de pantalla del *frontend* ni del panel de administración en todo el documento, pese a que el §6.7 los describe con detalle. La «interfaz de visualización» es, para el lector, enteramente textual.

Calificación: 5,0 / 10.

5.7 7. Discusión

Correspondencia: Capítulo 8 (§8.1 a §8.5), pp. 53-57.

Fortalezas reales. El §8.3 enumera **cinco limitaciones por iniciativa propia**, incluida la dependencia del proveedor externo y la volatilidad del modelo. La quinta limitación es particularmente meritoria: reconoce que la comparación se hizo solo contra el flujo manual y aporta un *baseline* propio de TF-IDF + SVM al 78 % de exactitud y 0,764 de F1 macro. El §8.4 introduce la dimensión organizacional de la adopción y la resistencia al cambio, tema que casi ningún trabajo de esta cohorte aborda. El §8.5 fija tres condiciones de generalización con criterio.

Debilidades.

- **C-09**, **C-10**, **C-24** y **C-27** se localizan aquí.
- **A-20 (Alta).** El §8.1 dedica cuatro párrafos a interpretar resultados y **cero** a interrogarlos. No hay una sola hipótesis alternativa considerada, ni una explicación rival para la reducción del 89 %, ni discusión de por qué el clasificador confunde sistemáticamente Sistemas con Operaciones más allá de la observación léxica.
- **A-21 (Alta).** El *baseline* TF-IDF + SVM del §8.3 (78 %, F1 0,764) se menciona en una sola oración, sin descripción del procedimiento, sin partición, sin tamaño del subconjunto de evaluación («un subconjunto» sin cuantificar) y sin publicar el código. Es el único contraste metodológico del trabajo y está tratado como nota al pie.
- **A-22 (Alta).** El §8.1 califica de «garantía metodológica» la separación entre datos de construcción y datos de validación, y afirma que «solo después de completar el desarrollo se evaluó el desempeño sobre la totalidad del corpus». Esta afirmación es exactamente lo que el material del repositorio no permite verificar (C-01) y es, por tanto, el pasaje del trabajo que más expuesto queda ante el tribunal.
- **M-15 (Media).** El §8.2 compara con dos trabajos (2019 y 2020) y un rango sin cita. No hay comparación con ningún trabajo posterior a 2020.
- **M-16 (Media).** El §8.4 estima el costo de infraestructura en «50-100 USD/mes según el proveedor de nube local» y el costo de inferencia en «0,02 USD por cada invocación», ambos sin fuente. El segundo es especialmente relevante: 0,02 USD por invocación es un orden de magnitud superior al precio típico de un modelo de la clase *Flash* para *prompts* de menos de 500 *tokens*, de modo que la estimación de 28 USD trimestrales probablemente sea conservadora, pero sin fuente el tribunal no puede evaluarla.

Calificación: 3,0 / 10.

5.8 8. Conclusiones

Correspondencia: Capítulo 9 (§9.1 y §9.2), pp. 58-60.

Coherencia con los objetivos. El §9.1 recorre los cinco objetivos específicos en orden y declara su cumplimiento, lo cual es correcto en forma. El §9.2 formula una afirmación general de conocimiento, que es lo que un capítulo de conclusiones debe hacer.

Debilidades.

- **A-23 (Alta).** El §9.2 enuncia como aporte general que los LLM invocados por instrucciones «son capaces de alcanzar niveles de exactitud en clasificación de tickets de soporte **superiores a los de clasificadores supervisados clásicos entrenados sobre representaciones estáticas**». El trabajo no sustenta esa comparación: el único contraste supervisado es el *baseline* propio de §8.3, tratado en una oración, y la fuente que se invoca para el estado del arte supervisado sostiene lo contrario (C-24). Es una generalización que excede la evidencia.
- **A-24 (Alta).** El §9.1 repite TLS 1.3 como logro arquitectónico consumado (C-20).
- **A-25 (Alta).** El §9.1 introduce interpretación estadística nueva —«La prueba de Wilcoxon con W = 0 es, en sí misma, un resultado poco frecuente en la investigación aplicada y merece ser interpretada con cautela»— que corresponde al Capítulo 8, no a las conclusiones. El instrumento prescribe que las conclusiones no introduzcan resultados ni interpretaciones nuevas.
- **M-17 (Media).** El §9.1 y §9.2 repiten literalmente las cifras del Capítulo 7 (165,3 s → 18,2 s, 92 %, 0,919, 9,5 %, 62 %/38 %, 28 USD, 180 h) en lugar de sintetizar su significado. El instrumento observa expresamente que las conclusiones no deben repetir literalmente los resultados.
- **M-18 (Media).** Se declara «seis de cada diez incidentes se resuelven sin costo de

inferencia externa» sobre el 62 % que el repositorio no respalda (C-03).

- **B-03 (Baja).** El §9.2 califica la distribución del trabajo entre etapas como «una propiedad emergente del diseño» y «uno de los hallazgos más valiosos», registro valorativo que roza lo subjetivo para un capítulo de conclusiones.

Calificación: 2,5 / 10.

5.9 9. Referencias bibliográficas

Se evalúa en detalle en la sección «Revisión bibliográfica» de este informe. **Calificación: 5,5 / 10.**

5.10 10. Anexos

Se evalúa en detalle en la sección «Revisión de anexos». **Calificación: 2,5 / 10.**

6 Revisión bibliográfica

6.1 Actualización de las fuentes

Franja temporal	Entradas	Porcentaje
Últimos 3 años (2023-2026)	4	12,1 %
Últimos 5 años (2021-2026)	5	15,2 %
2015-2020	6	18,2 %
2010-2014	9	27,3 %
Anteriores a 2010	13	39,4 %
Artículos arbitrados de los últimos 3 años	**0**	**0 %**
Artículos arbitrados de los últimos 5 años	**0**	**0 %**

De las cuatro entradas de los últimos tres años, una es el borrador no publicado de un libro de texto, una es el software propio de los autores y dos son artículos de conferencia sobre modelos (Whisper y Llama 2) que no tratan el dominio del trabajo. **La bibliografía no está actualizada** y el desfase es especialmente grave dado que el objeto del trabajo son los modelos de lenguaje grandes, campo cuya literatura se renueva por semestres.

6.2 Clasificación por tipo y calidad de fuente

Tipo	Entradas	Observaciones
Revista científica (Q1 en su categoría)	8	Cohen, Fielding y Taylor, Galup et al., Pedregosa et al., Revina et al., Sokolova y Lapalme, Virtanen et al., Wilson
Revista sin indexación verificable	1	Powers (2011), *Journal of Machine Learning Technologies* — revista sin factor de impacto ni indexación en JCR/Scopus. La misma obra circula como informe técnico de Flinders University. Fuente de confiabilidad **media-baja** para sostener la definición canónica de las métricas.
Conferencia de primer nivel	4	Brown et al. (NeurIPS), Radford et al. (ICML), Vaswani et al. (NIPS), Paramesh y Shreedhara (Springer LNNS)
Preprint sin arbitraje	1	Touvron et al. (2023), arXiv:2307.09288 — declarado como *preprint*, lo cual es correcto
Libro / manual	10	Todos de editoriales reconocidas

Tipo	Entradas	Observaciones
Norma o marco normativo	3	Ley 25.326, RGPD, ITIL Service Operation
Documentación técnica de proveedor	4	Apache Airflow, n8n, PostgreSQL, FastAPI
Software propio	1	Gómez, Bustos y Sevilla (2026)
Sitio web	1	Wiggins (2017), *The Twelve-Factor App*

Fuentes de confiabilidad cuestionable: una (Powers 2011). **Documentación de proveedor usada como sustento conceptual:** cuatro, aceptable para decisiones de implementación, insuficiente para sostener afirmaciones sobre el estado del arte.

6.3 Existencia real de las referencias

Se verificaron las 33 entradas contra fuentes externas (DOI, revista, volumen, número, páginas, autoría, año, editorial).

Resultado global — y es el mejor de todos los planos auditados:

- **Referencias fabricadas o inexistentes: 0.**
- **DOI que resuelven a un artículo distinto del citado: 0.**
- **Autorías intercambiadas o inventadas: 0.**
- **Entradas verificadas como correctas en todos sus metadatos: 29 de 33 (87,9 %).**

Este resultado sitúa al trabajo por encima de la media de la cohorte en integridad bibliográfica y debe consignarse como fortaleza. Los cuatro problemas detectados son de **atribución y metadatos**, no de fabricación:

#	Entrada	Problema	Severidad
1	Revina, Buza y Meister (2020)	Metadatos correctos (IEEE Access 8, 193380-193395, DOI 10.1109/ACCESS.2020.3032840). **Misatribución de contenido**: el §3.3 y el §8.2 la presentan como estudio con arquitecturas BERT al 91 %; el artículo compara TF-IDF con rasgos lingüísticos y concluye que lo simple rinde mejor (C-24).	**Crítica**
2	Stallings, W. (2017). *Computer Security: Principles and Practice* (4.ª ed.)	**Coautor omitido.** La obra es de William Stallings y Lawrie Brown.	Alta

#	Entrada	Problema	Severidad
3	Office of Government Commerce (2011). *ITIL Service Operation*	**Autoría institucional probablemente errónea**: la edición 2011 corresponde al Cabinet Office (TSO como editor); la OGC firmó la edición 2007. Requiere verificación por los autores.	Alta
4	Jurafsky, D., y Martin, J. H. (2023), 3.ª ed. [Borrador]	**Editorial incorrecta**: se atribuye a Pearson un borrador de acceso libre no publicado por esa editorial. La marca «[Borrador]» es correcta y meritoria; la editorial no.	Media

Atribución adicional a corregir (no de metadatos): los rangos de interpretación del coeficiente Kappa se atribuyen implícitamente a Cohen (1960); provienen de Landis y Koch (1977), obra ausente de la bibliografía (C-25).

6.4 Correspondencia entre citas y referencias

Recuento medido sobre el texto extraído: aproximadamente 34 citas parentéticas y 26 citas narrativas, unas 60 en total sobre 27.847 palabras, es decir **una cita cada 464 palabras**. Es una densidad aceptable para una tesis de tecnicatura, aunque muy desigual entre capítulos.

Verificación	Resultado
Referencias no citadas en el texto (huérfanas)	**0 de 33**
Citas sin entrada en la bibliografía	**2**
Citas duplicadas o inconsistentes	0
Errores de año en citas	0
Errores de autor en citas	0

Las dos citas huérfanas.

1. **(APA, 2017)** en §11.5: «Este procedimiento se alinea con las recomendaciones de la Asociación Americana de Psicología (APA, 2017) para investigaciones que emplean observación sin conocimiento previo de los participantes». No hay entrada correspondiente. Es la cita que sostiene la justificación ética del engaño metodológico, de modo que su ausencia es especialmente sensible.
2. **Secretaría de la Pequeña y Mediana Empresa** en §1.1, invocada como fuente de la definición de empresa mediana, sin cita formal ni entrada.

Distribución de citas por capítulo — el problema real.

Capítulo	Citas aproximadas	Palabras aprox.
1. Introducción	6	3.100
2. Marco teórico	17	2.700
3. Estado del arte	8	1.900
4. Marco metodológico	8	2.600
5. Arquitectura	5	2.300
6. Implementación	4	4.000
7. Resultados	**0**	2.100
8. Discusión	3	2.700
9-10. Conclusiones y recomendaciones	2	2.600
11. Consideraciones éticas y legales	6	1.900

El Capítulo 6 tiene una cita cada 1.000 palabras y el Capítulo 7 ninguna. El Capítulo 3 —estado del arte— sostiene su tabla comparativa de seis soluciones comerciales (Tabla 1) **sin una sola cita**: los modelos de costo, las capacidades de IA y las modalidades de despliegue de Zendesk, Freshdesk, Jira Service Management, ServiceNow y osTicket se afirman sin fuente. En una tabla que compara productos comerciales cuyas condiciones cambian trimestralmente, la ausencia de fuente y de fecha de consulta es un defecto grave (**A-26, Alta**).

6.5 Cumplimiento de normas APA

Edición utilizada: **APA 7.ª**, coherentemente aplicada en la mayor parte del documento. La lista de referencias está alfabetizada, usa sangría francesa, cursivas correctas en títulos de libros y revistas, y consigna DOI en formato de URL en las entradas que lo tienen. Es, en conjunto, un formateo cuidado.

Incumplimientos detectados:

#	Regla APA 7	Incumplimiento	Severidad
1	Coma antes del año en citas con «et al.»	Sistemáticamente omitida: «(Pedregosa et al. 2011)», «(Vaswani et al. 2017)», «(Virtanen et al. 2020)», «(Radford et al. 2023)», «Galup et al. (2009)» en modo parentético. **Solo** ocurre en las citas con «et al.»; en las de dos autores la coma está bien puesta.	Media

#	Regla APA 7	Incumplimiento	Severidad
2	Toda cita debe tener entrada	2 citas huérfanas (APA 2017; SEPyME)	Alta
3	Fecha de consulta en documentación web actualizable	Ausente en las 4 entradas de documentación técnica (Apache, n8n, PostgreSQL, FastAPI) y en Wiggins (2017)	Media
4	Autoría corporativa	«Tiangolo, S. R. (2024)» trata como persona un seudónimo de proyecto; la convención correcta sería la autoría corporativa del proyecto FastAPI	Baja
5	Entradas de software	Gómez et al. (2026) está bien formada con designación de versión y descriptor entre corchetes	— (correcto)
6	Números de página en citas de referencia directa	El §3.3 atribuye cifras concretas (87 %, 91 %) a dos fuentes sin indicar página	Media
7	Consistencia del descriptor de edición	«(8.ª ed.)», «(3.ª ed.)», «(2011.ª ed.)» — la última forma es incorrecta	Baja

Calificación del capítulo de referencias: 5,5 / 10. Integridad alta, actualización nula, misatribución crítica en la fuente que sostiene el argumento central.

7 Revisión de tablas

El documento contiene **nueve tablas rotuladas** (Tablas 1 a 9), todas numeradas, todas con título y todas referidas desde el texto. La numeración es correlativa y correcta. Ninguna es redundante y ninguna debe fusionarse. Es, en conjunto, el aspecto formal mejor resuelto del trabajo.

Tabla	Contenido	Evaluación
1	Comparación de soluciones de mesa de ayuda	**Sin línea de fuente y sin una sola cita** (A-26). Las columnas «Modelo de costo» usan categorías cualitativas no definidas («Alto», «Medio-alto», «Muy alto») sin umbral. La fila «Propuesta» se autoevalúa en la misma tabla que evalúa a terceros, lo que introduce sesgo de presentación.
2	Operacionalización de variables	**La mejor tabla del trabajo.** Tipo, unidad y definición operacional por variable. Su único defecto es sustantivo, no formal: la definición de «Intervención humana» no coincide con lo reportado en §7.3 (C-11).
3	Capas funcionales de la arquitectura	Correcta en estructura. Contiene la acotación sobre la indisponibilidad de N8N 1.62 en Docker Hub, que no corresponde a una tabla de arquitectura (A-18).
4	Entidades del modelo de datos	Correcta y verificada contra el repositorio. Contradicha por el Anexo C, que habla de cinco tablas (A-19).
5	Puntos de entrada de la interfaz REST	Incompleta respecto de la API real (M-13).
6	Estadísticos descriptivos de tiempos	Formalmente ejemplar (media, mediana, desvío, mínimo, máximo, IC 95 %). Sustancialmente sin insumo verificable (C-04). La columna «Reducción» repite 89,0 % en dos filas.

Tabla	Contenido	Evaluación
7	Matriz de confusión	**Aritméticamente correcta**: filas 82+64+54 = 200, columnas 81+64+55 = 200, diagonal 76+58+50 = 184. Verificada.
8	Métricas por clase y macro	**Verificada dígito a dígito** contra la Tabla 7: las nueve celdas y los tres promedios macro son exactos.
9	Tipología de errores	Correcta y consistente: 7+6+3 = 16, coincidente con los errores de la Tabla 7. Le falta una columna con ejemplos textuales anonimizados.

Defectos transversales: ninguna de las nueve tablas tiene **línea de fuente** («Fuente: elaboración propia» o la referencia correspondiente), lo cual APA 7 exige. Ninguna tiene nota al pie explicativa de abreviaturas. La Tabla 1 y la Tabla 3 tienen problemas de composición tipográfica —palabras partidas en los encabezados («Clasificacion automatica» quebrado, «SaaS o autoalojadoLimitada» sin espacio)— atribuibles al ajuste de columnas en LaTeX.

Calificación de la dimensión «tablas»: 6,5 / 10.

8 Revisión de figuras

El documento contiene una (1) figura en 74 páginas.

Aspecto	Evaluación de la Figura 1
Numeración	Correcta («Figura 1»)
Título	Presente
Fuente	**Ausente**
Resolución	Aceptable, pero es una imagen rasterizada de un diagrama dibujado en herramienta de trazado libre
Notación	**No normalizada.** No es UML, ni BPMN, ni C4, ni un diagrama de flujo formal. Cajas, un rombo de decisión y flechas sin semántica declarada
Tipografía	Inconsistente: mezcla mayúsculas y minúsculas, tres tamaños distintos, un texto con paréntesis explicativo en cuerpo menor
Legibilidad	Aceptable

Aspecto	Evaluación de la Figura 1
Correspondencia con el texto	**Deficiente.** La Tabla 3 describe cinco capas con componentes nombrados (N8N, FastAPI, PostgreSQL, Gemini 2.5 Flash, Twilio). La figura no nombra ninguno salvo Twilio, no muestra capas, y presenta el sistema como si tuviera un único canal de entrada telefónico, ignorando el correo y el formulario web que son dos tercios del diseño
Explicación	El pie remite al Anexo A «en notación UML», que no forma parte del documento

Ausencias que un tribunal señalará. En 74 páginas no hay: diagrama de despliegue, diagrama de secuencia, diagrama de componentes, diagrama entidad-relación, captura del flujo N8N, captura del *frontend*, captura del panel de administración, captura del *dashboard* de analítica, diagrama de cajas de los tiempos, representación gráfica de la matriz de confusión, ni gráfico alguno de los tres que el §6.8 describe (tendencias, torta por sector, barras apiladas por estado).

Un trabajo de ingeniería informática de 74 páginas con una sola figura, y esa figura dibujada a mano alzada, comunica visualmente menos de lo que su propio texto describe. Este es, junto con el Capítulo 7, el punto más vulnerable del documento en la instancia de defensa: **el tribunal pedirá ver el sistema y el documento no lo muestra**.

Calificación de la dimensión «figuras»: 1,5 / 10.

9 Revisión técnica

9.1 Arquitectura

El diseño de cinco capas es correcto, está bien delimitado y responde a los principios de cohesión alta y acoplamiento bajo que el §5.1 invoca. La verificación contra el repositorio confirma que la descomposición del módulo Python descrita en §6.2 **se corresponde exactamente** con la estructura real (`models`, `schemas`, `services`, `repositories`, `classifiers`, `routes`, `core`), lo cual es notable y debe reconocerse: la mayoría de los trabajos de esta cohorte describen arquitecturas que su código no tiene.

El subsistema de clasificación híbrido está **bien diseñado**. La idea de reservar el modelo de lenguaje para los casos que el filtro determinístico no resuelve es correcta, está implementada con umbrales configurables (0,90 y 0,70) leídos de la configuración y no fijados en el código, y respeta el contrato `BaseClassifier` de modo que cualquiera de las dos etapas puede sustituirse o simularse en pruebas. Es el mejor componente del trabajo.

9.2 Diagramas

No hay diagramas UML, C4, BPMN ni entidad-relación en el documento. El Anexo A los declara existentes en el repositorio, en formato `.drawio`, e incluye tres tipos (despliegue, secuencia, componentes). En el repositorio clonado **no existe ningún archivo `.drawio`**. Existen, en cambio, tres archivos Markdown en `docs/diagrams/` (`componentes.md`, `despliegue.md`, `secuencia.md`) que contienen diagramas en notación textual, y dos imágenes PNG. La afirmación del Anexo A sobre el formato editable es incorrecta.

Evaluación de corrección técnica de los diagramas: no evaluable, porque el documento no los contiene.

9.3 Consistencia entre arquitectura y desarrollo

Se verificaron doce afirmaciones arquitectónicas del Capítulo 5 contra el artefacto:

#	Afirmación	Verificación
1	Backend FastAPI en capas	**Confirmada**
2	PostgreSQL 15.5 en contenedor con volumen persistente	**Confirmada** (`postgres:15.5-alpine`)
3	Redis para memoria conversacional	**Confirmada** (`redis:7.2-alpine`)
4	Clasificador híbrido en dos etapas con umbrales 0,90 / 0,70	**Confirmada**
5	Seis entidades en el modelo de datos	**Confirmada** (3 migraciones Alembic)
6	OpenAPI 3.1 generado automáticamente y verificado en CI	**Confirmada** (`docs/openapi.json`, 39 KB, con prueba de sincronización)
7	Clasificación embebida en `POST /api/v1/incidentes`	**Confirmada**

#	Afirmación	Verificación
8	Autenticación JWT con HS256	**Confirmada** (`app/core/security.py`)
9	Cifrado Fernet de campos sensibles en reposo	**Confirmada** (`app/utils/encryption.py`, `EncryptedText`)
10	Pseudonimización previa al envío al proveedor	**Parcialmente confirmada**: existe en el *backend*, pero el canal telefónico envía la transcripción cruda al agente antes de llegar allí (C-28)
11	TLS 1.3 en proxy inverso Nginx	**Refutada** (C-20)
12	Reintento con retroceso exponencial y cola de respaldo	**Refutada** (C-19)

Diez de doce confirmadas. La ingeniería es real; el problema está concentrado en las dos afirmaciones de seguridad y resiliencia, que son precisamente las dos que no se pueden verificar leyendo el documento.

Calificación de la dimensión técnica: 6,0 / 10.

10 Revisión de anexos

El documento declara siete anexos (A a G) en las páginas 72 a 74. **Ninguno de ellos contiene material: los siete son descripciones de material que no se adjunta**, con una extensión total de aproximadamente 1.100 palabras.

Anexo	Qué declara	Verificación contra el repositorio
A — Diagramas	Tres diagramas UML (despliegue, secuencia, componentes) en formato `.drawio` editable, versión de alta resolución en `docs/`	**No cumple.** No hay archivos `.drawio`. Hay tres `.md` con notación textual y dos PNG. Ningún diagrama en el documento
B — Repositorio	Código, migraciones Alembic, Docker, CI; commit de referencia en tag `v1.0.0`; despliegue local en menos de 15 minutos	**Cumple parcialmente.** Repositorio real, público, con todo lo enumerado y README que efectivamente promete menos de 15 minutos. **El tag `v1.0.0` no existe** (C-23)
C — Esquema de base de datos	«Las cinco tablas descritas en la Tabla 4», restricciones, índices, funciones almacenadas de identificadores con prefijo, migraciones Alembic	**Cumple parcialmente.** Las migraciones existen (3). La Tabla 4 tiene **seis** entidades, no cinco (A-19). No se pudo localizar la función almacenada de generación de identificadores con prefijo configurable que el §5.6 describe
D — OpenAPI	Especificación 3.1 generada automáticamente, Swagger UI en `/docs`, archivo estático verificado en CI	**Cumple plenamente.** `docs/openapi.json` de 39 KB con prueba de sincronización. Es el mejor anexo del trabajo
E — Flujo N8N	«La totalidad de los **12 nodos** configurados»; importación en «una instancia limpia de N8N 1.62» reproduce el comportamiento; script TwiML documentado	**No cumple.** El JSON tiene **19 nodos**, cifra que el §6.3 acierta y el anexo contradice. N8N 1.62 es la versión que el propio §6.1 declara no disponible en Docker Hub. El script TwiML existe en `twilio/` pero el flujo no es reproducible por C-17

Anexo	Qué declara	Verificación contra el repositorio
F — Corpus de validación	CSV en `evaluation/data/` con siete columnas incluidas predicción, tiempos y confianza; planillas de cronometraje del flujo manual; registros automáticos del flujo automatizado	**No cumple, y es el hallazgo central.** El CSV tiene cuatro columnas, es sintético, y su documentación en el repositorio declara que **no debe interpretarse como evidencia experimental** y que la campaña real es trabajo futuro (C-01). No hay planillas de cronometraje ni registros de tiempo (C-04)
G — Documentación operativa	Procedimientos de despliegue, respaldo, restauración, monitoreo y respuesta a incidentes para tres entornos	**Cumple.** `docs/operational-guide.md` y `docs/troubleshooting.md` existen y tienen contenido real

Reproducibilidad del estudio. El instrumento pide determinar si los anexos son suficientes para garantizar la reproducibilidad. La respuesta es **no**, con un matiz importante:

- La **reproducibilidad del sistema** está bien servida: cualquier lector con Docker puede levantar el entorno, consultar el contrato OpenAPI e inspeccionar el código. Esto es más de lo que ofrece la mayoría de los trabajos comparables.
- La **reproducibilidad del estudio** es nula: no hay corpus real, no hay etiquetas de los dos anotadores, no hay planilla de tiempos, no hay *script* que reproduzca la Tabla 6, y el único informe de evaluación versionado arroja números incompatibles con los publicados.

Material que existe en el repositorio y la tesis no incorpora. El repositorio contiene un archivo `ANEXO_H_Prompt_Gemini_Especificacion.md` con la especificación completa del *prompt* enviado al modelo. Es exactamente el tipo de material que un anexo de una tesis sobre clasificación con LLM debería contener —y que permitiría al tribunal evaluar el diseño del *prompt*— y la tesis, cuyos anexos llegan hasta la letra G, no lo incluye. **Recomendación: incorporarlo como Anexo H.**

Calificación de la dimensión «anexos»: 2,5 / 10.

11 Auditoría de la calidad de escritura científica

11.1 Mediciones realizadas

Se procesó el cuerpo del documento (capítulos 1 a 11, excluidos encabezados de página, índices y bibliografía) y se obtuvieron los siguientes indicadores objetivos:

Indicador	Valor	Referencia deseable
Oraciones analizadas	697	—
Longitud **mediana** de oración	**28 palabras**	20-25
Longitud media de oración	29,3 palabras	20-25
Oraciones de más de 40 palabras	**21,7 %**	< 15 %
Oraciones de más de 60 palabras	3,7 %	< 3 %
Construcciones en pasiva refleja («se + verbo»)	**~24 %**	< 30 %
Ocurrencias de «mediante»	83	—
Ocurrencias de «constituye»	23	—
Ocurrencias de «de manera/forma + adjetivo»	17	—
Errores ortográficos sistemáticos	4 patrones (ver más abajo)	0

11.2 Voz activa y pasiva

El trabajo emplea predominantemente voz activa con sujeto inanimado —«el sistema procesa», «la arquitectura contempla», «el clasificador exhibe»— que es exactamente el registro que el instrumento recomienda. La pasiva refleja se concentra, como corresponde, en el capítulo metodológico, donde el agente es irrelevante («se aplicó contrabalanceo», «se calculó el coeficiente»). **Este es un punto fuerte del trabajo:** el 24 % medido está claramente por debajo del umbral problemático y muy por debajo de la media de la cohorte.

Casos concretos donde la pasiva es innecesaria y conviene sustituirla:

- §4.2: «se aplicó contrabalanceo del orden de procesamiento» → «el diseño contrabalanceó el orden de procesamiento».
- §6.5: «La solución consistió en implementar un mecanismo…» → «El equipo implementó un mecanismo…» (además obliga a declarar el agente, lo que habría hecho visible C-19).
- §11.3: «se aplica un procedimiento de pseudonimización previa» → «el módulo Python pseudonimiza el texto antes de transmitirlo» (más preciso y verificable).

11.3 Claridad

Alta en general. La mayoría de las oraciones expresa una idea principal y se comprende en una sola lectura. Los pasajes problemáticos son de dos tipos:

Oraciones que acumulan tres o más proposiciones. Ejemplo del §1.5 (objetivo general), de 63 palabras, que encadena cinco verbos coordinados («recibir, procesar, clasificar y registrar»), dos gerundios («reduciendo», «manteniendo») y un participio final («garantizando»). Un objetivo general debe caber en una oración de menos de 40 palabras.

Ambigüedad referencial. §8.1: «Esta compresión de la variabilidad no fue un objetivo explícito del diseño pero emerge como una consecuencia deseable de la automatización» — «esta» puede referirse al rango, a la varianza o al desvío, y de esa ambigüedad procede el error C-09.

11.4 Concisión

Es la dimensión más débil de la escritura. Se detectan:

- **Repetición literal entre capítulos.** El párrafo de Galup et al. sobre la degradación de los procesos manuales aparece **tres veces casi textualmente** (§1.1, §1.2, §2.1). La descripción de las restricciones cambiarias argentinas aparece dos veces (§1.1, §1.7). La caracterización de N8N como plataforma autoalojada de código fuente disponible aparece cuatro veces (§2.3, §3.2, §6.3, §9.1).
- **Explicación circular.** §2.1 define la gestión de incidentes y §2.2 vuelve a definirla con otras palabras sin agregar contenido.
- **Duplicación entre capítulos 5 y 6.** El §5.3 (capa de orquestación) y el §6.3 (construcción del flujo) describen el mismo pipeline de cinco etapas con distinto nivel de detalle; podrían fundirse y ahorrar unas 600 palabras.
- **Duplicación entre capítulos 8 y 9.** El §9.1 reproduce párrafos enteros del §8.1 con mínimas variaciones.

Una reducción del 12 al 15 % de la extensión total mejoraría el trabajo sin perder una sola idea.

11.5 Precisión terminológica

Buena y estable. La terminología se mantiene consistente a lo largo de los once capítulos: «flujo manual» y «flujo automatizado» no cambian de nombre, «clasificador híbrido», «filtro determinístico», «sector responsable» y «canal de origen» conservan su significado. Esto es infrecuente y meritorio.

Inconsistencias detectadas:

- «N8N», «n8n» y «N8n» alternan a lo largo del documento; la marca oficial es *n8n*.
- El §2.3 y el §3.2 llaman a n8n «modelo de licencia de código fuente disponible» y «licencia Sustainable Use», lo cual es **correcto y digno de mención** —muchos trabajos comparables lo llaman erróneamente «código abierto»—; pero el §1.7 y el §6.1 lo incluyen sin matices en la enumeración «herramientas de bajo costo y **código abierto** —N8N, Python, FastAPI, PostgreSQL—», reintroduciendo el error que los otros dos capítulos evitan (**A-27, Alta**).
- «Exactitud» y «precisión» se usan correctamente como conceptos distintos, salvo en §1.2, donde «tasa de derivación errónea» se compara implícitamente con la exactitud del clasificador sin declarar que son métricas de poblaciones distintas.
- «Intervención humana» designa dos magnitudes distintas (C-11).

11.6 Fluidez

Las transiciones entre secciones son explícitas y correctas; casi todos los capítulos abren con un párrafo que anuncia su contenido. Los cortes abruptos detectados son dos:

- El §4.9 (Scrumban) irrumpe al final del capítulo metodológico sin conexión con las ocho secciones anteriores, que son de método de investigación.
- El §6.8 (dashboard de analítica) aparece después de la sección de pruebas, sin transición, y su último párrafo cambia de registro hacia lo especulativo.

11.7 Estilo científico

Tono formal sostenido, sin lenguaje coloquial, sin primera persona. Las expresiones vagas están razonablemente controladas. Se detectan, no obstante, **afirmaciones valorativas**

sin respaldo que un tribunal marcará:

- §9.1: «no deja espacio para la duda razonable»; «un resultado poco frecuente en la investigación aplicada».
- §9.1: «uno de los hallazgos más valiosos del trabajo».
- §8.1: «El rigor metodológico adoptado para evitar *data leakage* merece una observación aparte» seguido de «una garantía metodológica que no todos los trabajos del área documentan con el mismo nivel de explicitación». Autoelogio comparativo sin muestra de comparación.
- §6.4: «un valor que lo posiciona como una vía prácticamente útil y no como una demostración de laboratorio».

11.8 Economía del lenguaje

Nominalización elevada pero dentro de lo esperable en el registro académico en español. El uso de «mediante» (83 ocurrencias, una cada 335 palabras) es excesivo y produce cadenas de frases preposicionales encadenadas. Ejemplo del §11.4: «La confidencialidad se garantiza **mediante** cifrado en tránsito sobre TLS 1.3 a nivel del proxy inverso (Nginx) [...] y **mediante** el cifrado a nivel de aplicación **mediante** Fernet» — tres «mediante» en una oración, dos de ellos consecutivos.

11.9 Corrección ortográfica

Se detectó un **patrón sistemático de acentuación incorrecta** que afecta a cuatro palabras de alta frecuencia. Las mediciones sobre el texto completo:

Forma correcta	Ocurrencias	Forma incorrecta usada	Ocurrencias
diseño (sustantivo)	**0**	«diseñó»	**21**
desarrollo (sustantivo)	1	«desarrolló»	**11**
completo (adjetivo)	**0**	«completó»	**13**
aquellos (pronombre)	**0**	«aquéllos»	**7**

El resultado es que el trabajo escribe «el **diseñó** experimental», «el **desarrolló** del módulo Python», «el ciclo **completó** de vida del ticket» y «**aquéllos** incidentes» de forma sistemática: 52 errores del mismo tipo. Los tres primeros son errores gramaticales (verbo en lugar de sustantivo/adjetivo); el cuarto es una tilde diacrítica que la RAE suprimió en 2010.

Origen identificado. El repositorio contiene el script `docs/Tesis/acentuar_tesis.py`, un acentuador automático cuyo diccionario de reemplazo incluye las entradas categóricas `"diseno": "diseñó"`, `"desarrollo": "desarrolló"`, `"completo": "completó"` y `"aquellos": "aquéllos"`. El script no distingue categoría gramatical, de modo que convirtió todos los sustantivos en verbos. Es un defecto **trivial de corregir y muy visible** para un tribunal: la palabra «diseño» no aparece ni una sola vez en una tesis de ingeniería de 74 páginas.

A esto se suma la **portada sin acentuar**: «Automatizacion inteligente...», «Tecnicatura Universitaria en Programacion», «Tecnico Universitario en Programacion», «Republica Argentina». El primer contacto del tribunal con el trabajo es una portada con siete palabras sin tilde.

11.10 Índice de calidad de escritura

Dimensión	Puntaje
Predominio de voz activa	8,0
Claridad	7,5
Precisión terminológica	7,5
Concisión	5,5
Fluidez	7,5
Coherencia discursiva	6,5
Estilo científico	6,5
Corrección ortográfica y formal	4,5

ÍNDICE DE CALIDAD DE ESCRITURA CIENTÍFICA: 6,8 / 10

Justificación. La escritura de esta tesis está claramente por encima de la media de los trabajos finales de la carrera: la voz activa predomina, la terminología es estable a lo largo de once capítulos, las transiciones son explícitas y el registro académico se sostiene sin caídas. El puntaje no llega a 8 por tres razones concretas y todas reparables: la extensión mediana de oración (28 palabras) está cinco por encima de lo deseable y una de cada cinco oraciones supera las 40 palabras; hay duplicación literal de contenido entre capítulos que podría eliminarse; y la corrupción ortográfica sistemática de cuatro palabras de alta frecuencia (52 ocurrencias) daña la impresión de cuidado del documento de manera desproporcionada a su gravedad real. **Este último punto se corrige con cuatro sustituciones globales y es la mejora de mayor rendimiento por unidad de esfuerzo de todo el trabajo.**

12 Matriz de riesgos de rechazo

12.1 Distribución de hallazgos

Severidad	Cantidad	Definición operativa
Crítica	28	Compromete la validez de una conclusión o la integridad del trabajo. Debe corregirse antes de la defensa
Alta	34	Genera observación mayor del tribunal. Debe corregirse
Media	29	Genera observación menor o pregunta incómoda
Baja	14	Defecto formal
Total	**105**	

12.2 Distribución por capítulo

Capítulo	Críticos	Altos	Medios	Bajos	Total
1. Introducción	2	3	2	1	8
2. Marco teórico	0	3	2	1	6
3. Estado del arte	3	2	2	0	7
4. Marco metodológico	6	4	3	1	14
5. Arquitectura	3	3	3	2	11
6. Implementación	6	4	2	2	14
7. Resultados	5	3	2	1	11
8. Discusión	2	3	2	1	8
9. Conclusiones	0	3	2	1	6
10. Recomendaciones	0	0	2	1	3
11. Ética y legales	1	2	2	1	6
Anexos	0	4	3	2	9
Transversales (figuras, APA, ortografía)	0	0	2	0	2

12.3 Riesgos por tipo

Tipo de riesgo	Nivel	Fundamento
Riesgo para la defensa	**Muy alto**	La primera pregunta previsible del tribunal —«muéstrenme el corpus»— no tiene respuesta en el material entregado. La segunda —«¿por qué el repositorio dice que estos datos no son válidos?»— es aún más difícil

Tipo de riesgo	Nivel	Fundamento
Riesgo metodológico	**Muy alto**	Instrumento de medición descrito de tres maneras incompatibles; contrabalanceo imposible con datos retrospectivos; variable de intervención humana definida de un modo y medida de otro; interrogante subsidiario sin respuesta
Riesgo estadístico	**Alto**	Estadístico W incompatible con su propia definición; fórmula del tamaño del efecto incorrecta y con rango declarado falso; código ajustado al resultado publicado
Riesgo bibliográfico	**Medio-alto**	Cero fabricaciones y cero referencias huérfanas —fortaleza real— pero cero artículos arbitrados de los últimos cinco años y misatribución crítica en la fuente que sostiene el argumento central
Riesgo formal	**Medio-alto**	Una sola figura en 74 páginas, dibujada a mano; siete anexos sin contenido; 52 errores ortográficos sistemáticos; portada sin acentuar
Riesgo jurídico	**Alto**	Tres errores sustantivos en el capítulo de cumplimiento normativo, incluida una contradicción en los términos sobre el plazo de conservación
Riesgo de integridad académica	**Alto**	El repositorio contiene una declaración firmada por los autores que contradice el Capítulo 7, y un comentario de código que documenta el ajuste de un estimador para reproducir un número ya publicado

13 Calificación por capítulo

#	Capítulo	Rigor científico	Metodología	Redacción	Bibliografía APA	Coherencia	**Puntaje**	Peso
1	Introducción	6,5	6,0	8,0	5,0	6,5	6,5	**6,5**	8 %
2	Marco teórico	5,5	—	7,5	5,0	6,5	6,5	**6,0**	8 %
3	Marco metodológico	3,0	3,0	7,0	4,0	6,0	2,5	**3,5**	15 %
4	Desarrollo del estudio	5,5	5,0	7,0	3,0	6,0	5,0	**5,5**	12 %
5	Resultados	1,0	1,5	7,0	—	—	1,5	**1,5**	20 %
6	Arquitectura e interfaz	5,5	—	7,0	4,5	6,0	4,5	**5,0**	10 %
7	Discusión	3,0	3,0	7,0	2,5	5,5	3,0	**3,0**	10 %
8	Conclusiones	2,0	—	7,0	—	—	3,0	**2,5**	7 %
9	Referencias bibliográficas	—	—	—	5,5	6,0	6,0	**5,5**	6 %
10	Anexos	2,0	2,0	—	—	—	2,5	**2,5**	4 %

Cálculo del puntaje global ponderado:

$$0{,}08(6{,}5)+0{,}08(6{,}0)+0{,}15(3{,}5)+0{,}12(5{,}5)+0{,}20(1{,}5)+0{,}10(5{,}0)+0{,}10(3{,}0)+0{,}07(2{,}5)+0{,}06(5{,}5)+0{,}04(2$$

14 Calificación global

CALIFICACIÓN GLOBAL: 3,9 / 10

14.1 Fortalezas principales

1. **Integridad bibliográfica sobresaliente.** 33 referencias, 0 fabricadas, 0 huérfanas, 29 con metadatos verificablemente correctos. Es el mejor resultado de este plano entre los trabajos comparables auditados.
2. **Consistencia aritmética interna del Capítulo 7.** Diecisiete de veinticuatro verificaciones independientes correctas: la matriz de confusión cierra en filas, columnas y diagonal, y las nueve métricas por clase más los tres promedios macro son exactos hasta el tercer decimal. No hay maquillaje de cifras; hay un problema de procedencia.
3. **El sistema es real, sustancial y de buena factura.** Backend en siete capas verificado contra el texto, frontend React/TypeScript, migraciones Alembic, OpenAPI con prueba de sincronización en integración continua, cifrado Fernet y JWT efectivamente implementados, documentación operativa y de resolución de incidencias con contenido real.
4. **El clasificador híbrido está bien diseñado y bien implementado.** Umbrales configurables, contrato de clasificador respetado, etapa determinística que efectivamente cortocircuita la invocación externa. Es una buena idea de ingeniería, bien ejecutada.

5. **Escritura por encima de la cohorte.** Voz activa predominante, terminología estable en once capítulos, transiciones explícitas, registro académico sostenido.
6. **Autocrítica genuina en tres pasajes.** El §8.3 enumera cinco limitaciones por iniciativa propia y aporta un *baseline* propio al 78 %; el §8.4 introduce la resistencia organizacional al cambio; el §11.5 reconoce el engaño metodológico y documenta el *debriefing*. Es un trabajo que no oculta sus debilidades conocidas.
7. **Uso correcto de «fair-code» y «Sustainable Use License»** en §2.3 y §3.2, error que la mayoría de los trabajos sobre n8n comete.
8. **Los Anexos D y G cumplen exactamente lo que prometen.**

14.2 Debilidades principales

1. El Capítulo 7 informa una campaña experimental que el propio repositorio declara no realizada.
2. La única corrida documentada del *pipeline* arroja 63 % de exactitud contra el 92 % publicado.
3. No existe ningún dato de tiempo en todo el material de respaldo.
4. El estadístico de Wilcoxon publicado es incompatible con la definición que el propio código usa, y la fórmula del tamaño del efecto es incorrecta y su rango declarado falso.
5. El código sustituyó un estimador «para consistencia con la tesis», documentándolo en un comentario.
6. Tres descripciones mutuamente incompatibles del instrumento de medición.
7. Cinco divergencias verificadas entre la arquitectura descrita y el flujo N8N publicado, incluido un canal completo que no puede ejecutarse.
8. Una figura en 74 páginas, dibujada a mano y sin correspondencia con la arquitectura descrita.
9. Siete anexos sin contenido, dos de los cuales contradicen el cuerpo del trabajo.
10. Cero artículos arbitrados de los últimos cinco años y misatribución de la fuente que sostiene el argumento comparativo central.
11. Tres errores jurídicos sustantivos en el capítulo de cumplimiento normativo.
12. Cincuenta y dos errores ortográficos sistemáticos de origen automatizado.

15 Dictamen final

REQUIERE UNA REVISIÓN PROFUNDA ANTES DE LA DEFENSA

Calificación: 3,9 / 10

Condición expresa: este dictamen desciende a **«No recomendable para defensa en su estado actual»** si los autores no exhiben ante el tribunal el corpus real de 200 casos, las planillas de doble etiquetado que sustentan el $\kappa = 0{,}87$ y el registro de los 200 pares de tiempos.

15.1 Justificación detallada

Por qué no es «Aprobada con observaciones». Un dictamen de observaciones supone que las conclusiones del trabajo se sostienen y que lo observado es perfectible. Aquí no ocurre. Las cuatro conclusiones principales —reducción del 89 % del tiempo de registro, exactitud del 92 %, F1 macro de 0,919 y reducción de la intervención humana al 9,5 %— descansan sobre datos cuya existencia el material de respaldo del propio trabajo pone en duda por escrito y en dos documentos distintos. No es una observación sobre la presentación de los resultados: es una duda sobre su procedencia. Ningún tribunal puede avalar conclusiones cuyo insumo no puede examinar, y menos cuando el repositorio que la tesis ofrece como respaldo contiene una declaración de los autores que dice, textualmente, que ese material «no debe interpretarse como evidencia experimental del desempeño del sistema».

Por qué no es «No recomendable para defensa». Ese dictamen correspondería a un trabajo sin sustancia, y este no lo es. El sistema existe, funciona en lo esencial, está bien construido, está documentado con un nivel de detalle superior al de sus pares, y su arquitectura se corresponde con lo que el texto describe en diez de doce afirmaciones verificadas. La bibliografía tiene cero fabricaciones. La aritmética publicada es internamente consistente en diecisiete de veinticuatro verificaciones. La prosa es buena. Hay autocrítica genuina. Y —esto es determinante— existe una posibilidad real y legítima de que el corpus experimental exista y no se haya versionado por razones de protección de datos personales, que es exactamente lo que la Ley 25.326 aconsejaría. La ausencia de un dato en un repositorio público no prueba su inexistencia.

Por qué el dictamen es condicional. Precisamente por lo anterior. Todo el peso del caso descansa en un hecho que los autores pueden despejar en cinco minutos: exhibir el corpus real y el registro de tiempos. Si lo hacen, el problema se degrada de «integridad de los datos» a «documentación deficiente del respaldo experimental», que es reparable y compatible con «aprobada con observaciones mayores». Si no pueden hacerlo, el Capítulo 7 no tiene sustento y el trabajo no está en condiciones de defenderse.

Diagnóstico central. *La tesis documenta un trabajo distinto del que el repositorio demuestra.* Y —esto es lo notable, y lo que explica el tono constructivo de este informe— **en varios puntos el artefacto es mejor que lo que la tesis describe**: el clasificador híbrido implementado es más sofisticado que su descripción; la estructura del *backend*

es más limpia; existe un `ANEXO_H_Prompt_Gemini_Especificacion.md` con la especificación completa del *prompt* que la tesis no incorpora; hay 138 pruebas de *backend* y una especificación OpenAPI verificada en integración continua. Casi todo lo que le falta a este trabajo es de **escritura y publicación**, no de construcción.

16 Plan de corrección

Se propone un plan en cuatro bloques ordenados por rendimiento decreciente. Se estima el esfuerzo y la calificación proyectada tras cada bloque.

16.1 Bloque 1 — Cerrar la brecha probatoria *(3 a 5 días; sin escribir código nuevo)*

Es el único bloque que decide el dictamen.

1. Localizar el corpus real de 200 casos y ejecutar sobre él `evaluation/run_evaluation.py`. Publicar el informe resultante junto a `report_provisional.md`, con la misma estructura.
2. Publicar el registro de los 200 pares de tiempos (formato CSV pseudonimizado con `tiempo_manual_s` y `tiempo_automatizado_s`, las columnas que el propio marco ya soporta).
3. Publicar la planilla de doble etiquetado de los dos anotadores y el cálculo del κ.
4. **Retirar o actualizar** la «Declaración de integridad académica» de `docs/anexo_f_corpus.md` y la advertencia de `evaluation/data/README.md`, que hoy contradicen frontalmente al Capítulo 7.
5. Crear el tag `v1.0.0` y consignar el hash completo en el Anexo B.
6. Reescribir el Anexo F para que describa el material que efectivamente se entrega.

Si los tiempos reales difieren de los publicados, actualizar la Tabla 6 y el Capítulo 7 con los valores reales. Un resultado más modesto y verificable vale infinitamente más que uno excelente e inverificable.

Calificación proyectada tras el bloque 1: ≈ 5,6 / 10 — dictamen «Requiere revisión profunda» consolidado, sin la condición negativa.

16.2 Bloque 2 — Reparar la estadística y la coherencia metodológica *(2 a 3 días; solo escritura)*

7. Corregir la fórmula del tamaño del efecto a $r = 1 - 4W/[n(n+1)]$, declarar la convención de W utilizada, reportar W^+ y W^-, y corregir el rango declarado.
8. Alinear `evaluation/stats.py` con la definición corregida y eliminar la sustitución de estimador; documentar el cambio en `CHANGES.md`.
9. Unificar en una sola descripción el instrumento de medición del flujo manual (§4.2, §4.6, §7.3).
10. Reconciliar la ventana temporal: declarar la fecha real de la medición y, si el brazo manual es retrospectivo, reescribir §4.2 reconociendo que no hubo contrabalanceo posible.
11. Elegir una definición de «intervención humana» y aplicarla de manera consistente en Tabla 2, §4.6 y §7.3.
12. Reportar el cruce confianza × acierto y discutir la calibración en el Capítulo 8.
13. Corregir «varianza casi diez veces menor», las 180 horas-persona, las 200 horas-persona del §1.2 y el universo de 3.700 incidentes.
14. Publicar el cálculo del tamaño muestral con todos sus parámetros.

Calificación proyectada tras los bloques 1 + 2: ≈ 6,7 / 10 — dictamen «Aprobada con observaciones mayores».

16.3 Bloque 3 — Alinear el documento con el artefacto y reparar la bibliografía *(3 a 4 días)*

15. Reescribir §6.3 describiendo el flujo real de 19 nodos, incluida la posición y la semántica verdaderas del nodo IF y el destino de su rama falsa.
16. Conectar el modelo de lenguaje al nodo `AI Agent` y publicar el flujo funcional, o declarar el canal telefónico como prototipo no validado.
17. Agregar `canal_origen` al cuerpo del POST y corregir el modo del nodo Switch.
18. Reescribir §5.1, §9.1 y §11.4 en modo condicional respecto de TLS/Nginx, o incorporar el proxy al `docker-compose`.
19. Reescribir §6.5 sobre el reintento como trabajo futuro, o implementarlo.
20. Documentar la etapa de *fallback* del clasificador en §5.5, §6.3 y el Capítulo 7.
21. Unificar el *prompt* del agente con las tres categorías del trabajo.
22. Corregir §3.3 y §8.2 con la conclusión real de Revina et al. (2020) e incorporar la tensión a la discusión.
23. Incorporar entre ocho y doce artículos arbitrados de 2023-2026; citar el rango 88-94 % o retirarlo.
24. Agregar Landis y Koch (1977); corregir «sustancial» por «casi perfecto»; agregar Lawrie Brown a Stallings; verificar la autoría de ITIL 2011; corregir la editorial de Jurafsky y Martin; resolver las dos citas huérfanas; agregar la coma antes del año en las citas con «et al.».
25. Reescribir §11.2 con un plazo de conservación concreto; sustituir «legítimo interés» por la base del art. 5.2 de la Ley 25.326; corregir el sentido de la decisión de adecuación europea; analizar la transferencia previa a la pseudonimización del canal telefónico.

Calificación proyectada tras los bloques 1 + 2 + 3: ≈ 7,6 / 10 — dictamen «Aprobada con observaciones menores».

16.4 Bloque 4 — Forma y evidencia visual *(2 días)*

26. **Corregir los 52 errores ortográficos** con cuatro sustituciones globales («diseñó» → «diseño» donde es sustantivo, «desarrolló» → «desarrollo», «completó» → «completo», «aquéllos» → «aquellos») y acentuar la portada. *Media hora de trabajo, altísimo rendimiento.*
27. Incorporar al cuerpo, como mínimo: diagrama de despliegue en notación normalizada, diagrama de secuencia del canal de correo, diagrama entidad-relación, captura del flujo N8N, captura del panel de administración, captura del *dashboard*, diagrama de cajas comparativo de los tiempos y representación gráfica de la matriz de confusión. **Ocho figuras es un mínimo razonable para 74 páginas.**
28. Convertir los siete anexos descriptivos en anexos con contenido, e incorporar el `ANEXO_H_Prompt_Gemini_Especificacion.md` como Anexo H.
29. Agregar línea de fuente a las nueve tablas; corregir la composición de las Tablas 1 y 3.
30. Eliminar las duplicaciones entre §1.1/§2.1, §5.3/§6.3 y §8.1/§9.1 (unas 900 palabras).
31. Retirar del cuerpo la acotación sobre la indisponibilidad de N8N 1.62 en Docker Hub.
32. Retirar las afirmaciones valorativas sin respaldo del §9.1 y del §8.1.

Calificación proyectada tras los cuatro bloques: ≈ 8,2 / 10.

16.5 Resumen de la proyección

Estado	Esfuerzo acumulado	Calificación	Dictamen
Actual	—	**3,9**	Requiere revisión profunda (condicional)
+ Bloque 1	3-5 días	≈ 5,6	Requiere revisión profunda
+ Bloque 2	5-8 días	≈ 6,7	Aprobada con observaciones mayores
+ Bloque 3	8-12 días	≈ 7,6	Aprobada con observaciones menores
+ Bloque 4	10-14 días	≈ 8,2	Aprobada con observaciones menores

Nota sobre el esfuerzo. Ninguno de los cuatro bloques exige construir sistema nuevo. El bloque 1 exige ejecutar un *pipeline* que ya existe sobre datos que —si existen— ya están recolectados. Los bloques 2, 3 y 4 son íntegramente de escritura y de publicación de material. Esta es la razón por la que el trabajo, pese a un dictamen severo, tiene un camino corto y claro hacia la aprobación.

17 Preguntas probables del tribunal

Se anticipan las preguntas que el material auditado hace previsibles. Se recomienda a los autores preparar respuesta escrita para cada una.

Sobre los datos

1. Muéstrennos el corpus de 200 casos reales. ¿Dónde está?
2. El `README` de `evaluation/data/` dice que las métricas generadas con ese corpus no son válidas para el Capítulo 7. ¿Qué corpus usaron entonces, y dónde está publicado?
3. El documento `docs/anexo_f_corpus.md` de su propio repositorio declara que el corpus real es «trabajo de campo futuro». ¿Cuándo se hizo ese trabajo de campo y por qué esa declaración sigue allí?
4. `report_provisional.md` reporta 63,0 % de exactitud y F1 macro 0,5936. ¿Por qué la tesis reporta 92 % y 0,919?
5. ¿Dónde están los 200 pares de tiempos? El Anexo F promete siete columnas y el archivo tiene cuatro.
6. Los incidentes son de julio-septiembre de 2025 y el estudio es de junio de 2026. ¿Cómo se contrabalanceó el orden de procesamiento de incidentes ocurridos nueve meses antes?

Sobre la estadística

7. `evaluation/stats.py` invoca `scipy.stats.wilcoxon(..., alternative='greater')`, que devuelve la suma de rangos positivos. Con 200 pares favorables eso da W = 20.100. ¿Por qué la tesis reporta W = 0?
8. Evalúen su fórmula $r = 1 - 2W/[n(n+1)]$ en $W = n(n+1)/2$. ¿Cómo llega a -1?
9. Un comentario de su propio código dice: «Para consistencia con la tesis que reporta r=1.00, calculamos r como la proporción de pares donde manual > automatizado». ¿Por qué se ajustó el estimador al número publicado en lugar de corregir el número?
10. La Tabla 2 define la intervención humana como proporción de tiempo; el §7.3 reporta 19 de 200 casos. ¿Cuál de las dos midieron?
11. Tienen 16 errores y 19 intervenciones. ¿Cuántos de los 16 errores fueron detectados por la compuerta de confianza del 0,70?
12. ¿Cuál es la exactitud de clasificación del brazo manual? El §1.3 pregunta si el clasificador supera al criterio humano.
13. $3.700 \times 165{,}3$ s son 169,9 horas. ¿De dónde salen las 180 horas-persona liberadas?
14. Con 42 incidentes diarios, ¿cuántos días hábiles tuvo su trimestre para llegar a 3.700?

Sobre el sistema

15. En su flujo N8N, el nodo IF que evalúa la confianza está conectado antes del nodo HTTP que invoca al clasificador. ¿Qué confianza está evaluando?
16. Para los canales de correo y web, ¿de dónde sale el valor de `confianza` que ese IF compara con 0,70?
17. El nodo `AI Agent` no tiene ningún modelo de lenguaje conectado. ¿Cómo se ejecutó el canal telefónico?
18. El cuerpo del POST envía solo `descripcion` y `prioridad`. ¿Cómo llegó `canal_origen` a la base de datos, si es una de las variables de su estudio?
19. La palabra `nginx` no aparece en su repositorio. ¿Dónde está la terminación TLS 1.3 que declaran en §5.1, §9.1 y §11.4?
20. Ningún nodo del flujo tiene `retryOnFail` ni `onError`. ¿Dónde está el reintento con retroceso exponencial del §6.5 y cuáles fueron las pruebas de carga que menciona?
21. Su *prompt* telefónico clasifica en cuatro sectores, incluida «Seguridad». ¿Por qué la tesis tiene tres?

22. El Anexo E dice 12 nodos y el §6.3 dice 19. El archivo tiene 19. ¿Cuál es correcto?
23. El tag `v1.0.0` del Anexo B no existe. ¿Qué commit evaluamos?
24. En la única corrida documentada, 95 de 200 casos terminaron en la rama de *fallback* por fallo de Gemini. ¿Por qué esa etapa no está en la tesis?

Sobre la bibliografía y el marco normativo

25. Su propia bibliografía transcribe el título del artículo de Revina et al. (2020): *IT Ticket Classification: The Simpler, the Better*. ¿En qué parte de ese artículo hay BERT?
26. ¿De dónde sale el rango de 88 % a 94 % con el que compara sus resultados en el §8.2?
27. ¿Qué artículo arbitrado posterior a 2021 sustenta su estado del arte?
28. Su §4.4 dice que $\kappa = 0{,}87$ es «sustancial» y en la misma oración aclara que $\kappa > 0{,}80$ es «casi perfecto». ¿Cuál es?
29. ¿Cómo se concilia «política de conservación indefinida» con el principio de limitación del plazo de conservación del art. 4 inc. 7 de la Ley 25.326?
30. El «legítimo interés» es una base de licitud del RGPD. ¿Cuál es la base del art. 5 de la Ley 25.326 que ampara este tratamiento?
31. La decisión de adecuación europea habilita flujos hacia Argentina. ¿Cómo justifica una transferencia de Argentina hacia los Estados Unidos?
32. En el canal telefónico, la transcripción cruda llega al proveedor del modelo antes de pasar por el pseudonimizador del *backend*. ¿Cómo se concilia con el §11.3?

18 Anexo A del informe — Evidencia reproducible de la auditoría del artefacto

Todo lo consignado en el Bloque III de hallazgos críticos se obtuvo con los comandos que siguen, ejecutables por cualquier miembro del tribunal.

18.1 A.1 Estado del repositorio auditado

```
git clone https://github.com/lucaGomezB/Automatizacion-de-Mesa-de-Ayuda-N8N.git
cd Automatizacion-de-Mesa-de-Ayuda-N8N
git log -1 --format='%H %ci %an'
#  d7df92c…  2026-07-02 22:00:00 -0300  Luca Gomez
git tag
#  (vacío — no existe el tag v1.0.0 del Anexo B)
```

18.2 A.2 El corpus y la declaración de integridad

```
head -1 evaluation/data/corpus_evaluacion.csv
#  id,descripcion,canal_origen,categoria_real      → 4 columnas, no 7
grep -n "NO son validos" evaluation/data/README.md
head -25 docs/anexo_f_corpus.md   # «Declaración de integridad académica»
git log -1 --format='%ci' -- docs/anexo_f_corpus.md
#  2026-06-11 — nunca modificado antes de la entrega
```

18.3 A.3 Ausencia de datos de tiempo

```
find . -name "*.csv" -not -path "./.git/*"
#  ./evaluation/tests/fixtures/corpus_fixture.csv   (9 filas, fixture de test)
#  ./evaluation/data/corpus_evaluacion.csv          (sin columnas de tiempo)
#  ./data/corpus_sintetico_provisional.csv          (sin columnas de tiempo)
```

18.4 A.4 Verificación del estadístico de Wilcoxon

```
from scipy.stats import wilcoxon          # SciPy 1.17.1
import numpy as np
rng = np.random.default_rng(1)
d = rng.normal(165.3, 38.7, 200) - rng.normal(18.2, 4.1, 200)
r = wilcoxon(d, alternative='greater')    # la llamada de evaluation/stats.py
print(r.statistic)                        # 20100.0   (no 0)
n = 200
print(1 - 2*r.statistic/(n*(n+1)))        # 0.0       (fórmula de la tesis)
print(1 - 2*0/(n*(n+1)))                  # 1.0       (extremo superior)
# → el recorrido de la fórmula publicada es [0, 1], no [-1, +1]
```

18.5 A.5 Inventario del flujo N8N

```
import json
d = json.load(open('Automatizacion_Mesa_de_Ayuda.json'))
print(len(d['nodes']))                                  # 19 (Anexo E dice 12)
print(d['connections']['AI Agent'])                     # solo main; sin ai_languageModel
print([n for n in d['nodes'] if n.get('retryOnFail')])  # []
```

Conexiones relevantes verificadas (extracto de `connections`):

```
Normalizar entrada del incidente  →  La informacion esta OK  →  HTTP POST a MTM-SRU
```

es decir, el nodo IF precede al POST que invoca al clasificador.

Condición del nodo IF: `{{ $json.confianza }} >= 0.7`.

Origen del campo `confianza` para correo y web (comentario del nodo normalizador):

```
correo/web: sintetiza confianza desde es_valido:
  es_valido = true  -> confianza = 1.0
  es_valido = false -> confianza = 0.0
```

y `es_valido` se define en el nodo anterior como:

```
const esValida = descripcionTrim.length >= 10 && descripcionTrim.length <= 5000;
```

Cuerpo del nodo `HTTP POST a MTM-SRU`:

```
{ "descripcion": "={{ $json.descripcion }}",
  "prioridad":   "={{ $json.prioridad || 'media' }}" }
```

18.6 A.6 Ausencia de Nginx y TLS

```
grep -rni "nginx" . --exclude-dir=.git    # sin resultados
grep -n "TLS" knowledge-base/08_arquitectura_propuesta.md
#  | Cifrado en transito | TLS 1.3 entre todos los componentes
#  | HTTP local en dev; TLS pendiente para despliegue |
cat openspec/changes/archive/2026-07-03-c-18-tesis-alineacion-tecnologica/proposal.md
#  «27 brechas entre lo que la tesis describe y lo que el codigo realmente implementa»
#  «Lo que NO se corrige … TLS 1.3 (§5.1, §11) | Aspiracional. HTTP plano en dev.»
```

18.7 A.7 Origen de la corrupción ortográfica

```
grep -n '"diseno"\|"desarrollo"\|"completo"\|"aquellos"' docs/Tesis/acentuar_tesis.py
#  287:    "desarrollo": "desarrolló",
#  301:    "completo":   "completó",
#  302:    "diseno":     "diseñó",
#  584:    "aquellos":   "aquéllos",
```

Efecto medido sobre el texto del PDF entregado:

Palabra	Forma correcta	Forma incorrecta
diseño / diseñó	0	21
desarrollo / desarrolló	1	11
completo / completó	0	13
aquellos / aquéllos	0	7

---

*Informe emitido el 4 de agosto de 2026. Auditoría realizada sobre el archivo `Tesis_ultima_versión__1_.pd`
(74 páginas, 27.847 palabras) y sobre el repositorio público declarado en su Anexo B, en el
estado del commit `d7df92c` del 2 de julio de 2026.*