Devolución de segunda instancia — TFI «Automatización inteligente del registro de incidentes en mesas de ayuda empresariales»

Entrega auditada: versión 1.2.18 (9/11/2026) · Fecha de emisión: Nov 11, 2026

1. Ficha y alcance de la verificación

Esta devolución audita la versión 1.2.18 contra los 105 hallazgos de la auditoría del 4 de agosto de 2026 (calificación entonces: 3,9/10) y contra el repositorio declarado.

Campo	Dato
Título	Automatización inteligente del registro de incidentes en mesas de ayuda empresariales mediante orquestación de flujos con N8N y procesamiento de lenguaje natural basado en modelos de lenguaje grandes
Autores	Luca Gomez · Carla Bustos · Gonzalo Sevilla
Directores	Prof. Alberto Cortez y Prof. Ariel Enferrel
Institución	UTN — Facultad Regional Mendoza, Tecnicatura Universitaria en Programación
Archivo	tesis_ultima_version.pdf — versión 1.2.18, fechada el 9/11/2026
Extensión	120 páginas (antes 74) · ≈53.800 palabras (antes 27.847) · 26 tablas · 10 figuras (antes 1) · 9 anexos (A–I)
Bibliografía	≈88 entradas (antes 33), 37 fechadas en 2023–2026, de las cuales ≈18 son artículos arbitrados (antes 0)
Repositorio	github.com/lucaGomezB/Automatizacion-de-Mesa-de-Ayuda-N8N — tag anotado v1.2.18 sobre el commit 457b14ae2c77ea221429345602aacc9213878640 (coincide con el Anexo B)
Auditoría previa	Auditoría integral del 4/8/2026: 105 hallazgos (28 críticos), 3,9/10

Planos verificados en esta instancia.

1. **Textual:** lectura completa de los 11 capítulos y los 9 anexos, con rastreo de coherencia entre hipótesis, métodos, resultados y conclusiones.
2. **Cuantitativo:** recálculo independiente con SciPy 1.18.1 sobre los archivos versionados (corpus, predicciones, doble etiquetado, brazo manual e intervenciones) de más de 30 cifras publicadas.
3. **Artefacto:** clonado del repositorio en el tag v1.2.18 e inspección del flujo n8n, la configuración de despliegue, los datos y la bitácora de correcciones.
4. **Bibliográfico:** verificación externa de una muestra de las referencias nuevas de 2023–2026.

Cuando un dato no pudo comprobarse, se lo indica como no verificable y no como falso.

2. Dictamen

APTA PARA DEFENSA CON OBSERVACIONES MAYORES. Calificación global: 7,0 / 10 (antes 3,9 / 10).

La nota es definitiva para esta instancia y no está sujeta a condición. Las correcciones de la Sección 7 deben incorporarse al ejemplar que se lleve al acto de defensa; su ausencia se evaluará en la defensa como observación no atendida.

Síntesis. La versión 1.2.18 es, en lo sustancial, otro trabajo. El capítulo de resultados ya no informa la campaña sintética de julio, sino datos versionados que este informe pudo recalcular dígito a dígito: reducción del tiempo medio de 61,6 s a 17,76 s (71,2 %), Wilcoxon $W = 363$ con $r = 0{,}9639$, exactitud estricta de 73,5 % y macro-F1 de umbral de 0,6508. Los autores refutan con honestidad parte de su propia hipótesis, corrigieron los tres errores jurídicos, alinearon el flujo n8n con el texto y reemplazaron una bibliografía sin artículos recientes por otra con evidencia arbitrada 2023–2026.

Por qué no es «observaciones menores». Quedan dos problemas de procedencia y cuatro de método:

- El $\kappa = 0{,}87$ sigue en el Resumen y en tres capítulos, aunque su tabla no existe y el valor ya figuraba en la versión de julio, cuando el corpus real no existía (N-01).
- La tesis no declara que la versión de julio reportó resultados de un corpus sintético, pese a que la bitácora de los propios autores lo admite (N-02).
- La campaña complementaria midió tiempos manuales con operadores independientes y la tesis no los informa: un operador promedió 20,1 s y el otro 76,6 s (N-03).
- El mecanismo de selección de los 200 casos se describe de dos formas incompatibles (N-04).
- 119 de los 200 tiempos automatizados no tienen registro primario verificable (N-05).
- El brazo telefónico automatizado se alimentó con llamadas recitadas por un autor (N-06).

Por qué no es una nota menor. Ninguno de esos puntos invalida el resultado central: la propia campaña complementaria, recalculada en esta auditoría, reproduce la reducción de tiempo (69,3 %, $p = 3{,}0 \times 10^{-28}$) con sujetos independientes. Todos se resuelven con escritura y declaración, no con nuevo desarrollo.

3. Estado de los 28 hallazgos críticos del 4 de agosto

De los 28 críticos, 24 quedan corregidos, 3 parcialmente y 1 sigue abierto (C-25, por la persistencia del κ = 0,87). La verificación se hizo sobre el PDF y sobre el repositorio en el tag v1.2.18.

Código	Hallazgo de agosto	Estado	Evidencia en la v1.2.18
C-01	El repositorio declaraba la campaña experimental como trabajo futuro	Corregido	Corpus real pseudonimizado versionado el 9/10/2026; la declaración de integridad del Anexo F fue reescrita. Ver N-02: falta declararlo en la tesis
C-02	La única corrida daba 63 % y la tesis 92 %	Corregido	Se informa 73,5 % (147/200), recalculado sin diferencias
C-03	Etapa de fallback no documentada	Corregido	§5.5 describe tres etapas; la reserva no registró casos
C-04	No existía ningún dato de tiempo	Parcial	200 pares versionados; los 81 telefónicos coinciden con su registro primario, los 119 de correo y web no (N-05)
C-05	Contrabalanceo imposible con datos retrospectivos	Corregido	§4.2 declara ejecución secuencial y que el contrabalanceo no se ejecutó
C-06	Tres relatos incompatibles del instrumento manual	Corregido	Un solo relato: cronometraje mutuo en vivo, redondeo hacia arriba
C-07	W = 0 incompatible con la convención de SciPy	Corregido	W = mín(T+, T−) = 363, T+ = 19.737, ambos declarados
C-08	Fórmula y rango del tamaño del efecto	Corregido	r = (T+ − T−)/[n(n+1)/2] = 0,9639, rango [−1, +1] (Kerby, 2014)
C-09	«Varianza diez veces menor»	Corregido	Se habla de desvío (44,9 s frente a 13,52 s)
C-10	180 horas-persona imposibles	Corregido	32,2 h brutas, con cálculo al pie, y balance neto en §9.5
C-11	Intervención humana definida de dos formas	Corregido	Tabla 3 rotula las dos dimensiones y §8.3 informa ambas

Código	Hallazgo de agosto	Estado	Evidencia en la v1.2.18
C-12	Clasificador descalibrado sin advertirlo	Corregido	§8.4 y Tabla 14: la confianza de Gemini (0,85–1,00) no discrimina; el gate no derivó ningún caso
C-13	3.700 incidentes incompatibles con 42 diarios	Corregido	42 × 63 = 2.646
C-14	Exactitud humana nunca medida	Corregido	Campaña complementaria: 0,8278 manual, McNemar no significativo
C-15	165,3 s coincidía con la estimación preliminar	Corregido	Media experimental de 61,6 s, distinta de la preliminar
C-16	El IF de confianza precede al clasificador	Corregido	En el flujo, «Requiere revision humana» está aguas abajo del POST
C-17	Agente telefónico sin modelo conectado	Corregido	El nodo AI Agent fue retirado; la telefonía usa la cascada del backend
C-18	canal_origen no llegaba al backend	Corregido	El POST envía canal_origen_id
C-19	Reintento inexistente	Corregido	retryOnFail, 3 intentos, 5 s, en la configuración entregada; la tesis aclara que no es la evaluada
C-20	TLS y Nginx inexistentes	Corregido	nginx/ y servicio en docker-compose; §5.1 aclara que la medición telefónica corrió sin proxy
C-21	27 brechas conocidas no reflejadas	Parcial	Tabla 19 distingue configuración evaluada, entregada y de campaña; el Anexo I no traza la auditoría de agosto (N-02)
C-22	Prompt con cuatro sectores	Corregido	Taxonomía de cinco sectores canónicos coherente en prompt, modelo y resultados
C-23	Tag v1.0.0 inexistente	Corregido	Tag anotado v1.2.18 sobre 457b14ae…, verificado

Código	Hallazgo de agosto	Estado	Evidencia en la v1.2.18
C-24	Misatribución de Revina et al. (2020)	Corregido	§3.3 y §9.2 informan la conclusión real y discuten la tensión
C-25	Kappa mal rotulado y sin Landis y Koch	Abierto	Etiqueta y cita corregidas, pero el κ = 0,87 sigue sin tabla y con procedencia dudosa (N-01)
C-26	Cero artículos arbitrados recientes	Corregido	≈18 arbitrados 2023–2026 y protocolo de búsqueda declarado
C-27	Rango 88–94 % sin cita	Corregido	Rango retirado; comparación declarada no directa
C-28	Tres errores jurídicos	Parcial	Retención de 12 meses, art. 5.2.d, adecuación en la dirección correcta y transferencia previa del audio declarada; falta precisar el instrumento del art. 12 efectivamente usado (N-13)

El cuerpo de hallazgos altos, medios y bajos de agosto quedó atendido en su gran mayoría: fórmula de exactitud multiclase, criterios de exclusión, potencia a priori, Shapiro-Wilk informado, desglose por canal, ejemplos textuales de error, diez figuras, capturas del panel, fuentes en tablas y ortografía (las 52 formas «diseñó», «desarrolló», «completó» y «aquéllos» desaparecieron). Persisten A-08 (no se informa el porcentaje de cobertura del backend) y la concisión, que empeoró (N-07).

4. Verificación independiente de cifras y artefacto

Todas las cifras recalculadas coinciden con las publicadas; ninguna discrepa más allá del redondeo. Es el cambio de mayor peso respecto de agosto, cuando 7 de 24 verificaciones fallaron.

Cifra publicada	Valor en la tesis	Recálculo de esta auditoría	Fuente del recálculo
Tiempo manual: media, mediana, desvío	61,6 / 50,0 / 44,9 s	61,585 / 50,0 / 44,90 s	data/corpus_evaluacion_pseudonimizado.json

Cifra publicada	Valor en la tesis	Recálculo de esta auditoría	Fuente del recálculo
Tiempo automatizado: media, mediana, desvío	17,76 / 17,47 / 13,52 s	17,761 / 17,471 / 13,516 s	ídem
Reducción de la media y de la mediana	71,2 % / 65,1 %	71,16 % / 65,06 %	ídem
Wilcoxon bilateral	W = 363, p = 3,08e−32	W = 363, p = 3,085e−32	scipy.stats.wilcoxon
T+ y T−	19.737 / 363	19.737 / 363	rangos recalculados
Rank-biserial r	0,9639	0,96388	(T+ − T−)/20.100
dz	1,00	1,0004	43,82 / 43,81
Shapiro-Wilk (manual, automático, diferencias)	0,803 / 0,902 / 0,822	0,8031 / 0,9022 / 0,8225	scipy.stats.shapiro
Pares en que el automático no fue más rápido	12 de 200	12	ídem
Sensibilidad −5 s / −10 s	68,6 % / 65,6 %; r = 0,8683	68,61 % / 65,57 %; r = 0,8683	ídem
Por canal: reducción y dz	77,0 / 51,1 / 93,4 %; 1,37 / 0,73 / 1,61	77,0 / 51,1 / 93,4 %; 1,37 / 0,73 / 1,61	ídem
Matriz de confusión (Tabla 11)	diagonal 15+77+48+0+7 = 147	idéntica celda a celda	evaluation/evidence/predicciones_hybrid-v3_2026-10-07.json
Exactitud estricta e IC de Wilson	73,5 % [67,0; 79,1]	0,735 [0,670; 0,791]	statsmodels
Macro-F1 de umbral (4 clases) y de 5 clases	0,6508 / 0,5207	0,65084 / 0,52067	ídem
Exactitud laxa	179/200	179	ídem
Etapas: determinística y Gemini	131 (97 aciertos) / 69 (50)	131 (97) / 69 (50)	ídem

Cifra publicada	Valor en la tesis	Recálculo de esta auditoría	Fuente del recálculo
Confianza de Gemini	mínimo 0,85; bandas 22/31 y 28/38	0,85; 22/31 y 28/38	ídem
Kappa nuevo, po, pe, PABAK	0,5569; 0,69; 0,30; 0,6125	0,55686; 0,69; 0,30045; 0,6125	evaluation/data/campana/doble_etiquetado.csv
IC asintótico del kappa (Fleiss et al., 1969)	[0,4725; 0,6413]	[0,4725; 0,6413]	fórmula de Fleiss, Cohen y Everitt
Exactitud manual O1 / O2	71/80 = 0,8875; 54/71 = 0,7606	71/80; 54/71	brazo_manual.csv contra consenso E1–E2
Intervenciones que cambiaron la derivación	25 de 147; Wilson [11,8; 23,9] %	25/147; [11,79; 23,90] %	intervenciones.csv
Prueba binomial contra 0,15	p = 0,28	p = 0,2796 unilateral (0,488 bilateral)	scipy.stats.binomtest
Consenso nuevo igual al sector original	116 de 138	116/138	doble_etiquetado.csv y corpus
Margen de error con n = 200 y N = 2.646	6,66 %	6,664 %	fórmula con corrección por finitud
Ahorro bruto trimestral	32,2 h	32,19 h	43,82 s × 2.646 / 3.600
Balance neto central (15 %, 10 min)	−18,5 h; a* = 77,7 %	−18,51 h; 77,7 %	fórmula de §9.5

Artefacto verificado en el tag v1.2.18.

- El flujo n8n/workflow.json tiene 32 nodos (29 operativos y 3 notas), como declaran §6.3 y el Anexo E.
- El nodo condicional «Requiere revision humana» recibe la salida del POST: la compuerta quedó aguas abajo del clasificador.
- No queda ningún nodo de LangChain; el canal telefónico entra por webhook y se clasifica en el backend.
- El POST envía canal_origen_id, reportante_email y reportante_telefono.

- Los nodos HTTP declaran retryOnFail con 3 intentos y 5.000 ms, y la creación desvía los errores a una rama propia.
- docker-compose.yml incluye Nginx en la red edge, con terminación TLS.
- Las predicciones, la tabla primaria del doble etiquetado (400 registros), el brazo manual (220 registros) y las intervenciones (147) están versionados.

Bibliografía. Se buscaron externamente cinco referencias nuevas. Colavito et al. (2025), Bernal-Beltrán et al. (2025) y Ramón-Ferrer et al. (2026) existen con los metadatos citados. De Mayor-Rocher et al. se confirmó la versión de arXiv de 2024, no la de *Applied Linguistics* (2026) que cita la tesis. Paket et al. (2024) no pudo localizarse en esta instancia (N-16). No se detectó ninguna referencia fabricada.

5. Observaciones de esta instancia

Se registran 16 observaciones: 2 críticas, 6 altas, 5 medias y 3 bajas. Las críticas son de procedencia y declaración; ninguna exige nuevo desarrollo.

Críticas

N-01. El κ = 0,87 no tiene respaldo y su origen es anterior al corpus que describe. Resumen, Abstract, §1.7, §4.4 y §4.8.

- La tesis admite que la tabla de acuerdo «no se conservó», pero sigue presentando el valor como acuerdo de los analistas originales.
- El mismo 0,87 ya figuraba en la versión de julio, compilada cuando el repositorio declaraba el corpus real como «trabajo de campo futuro» y cuando, según la propia §4.2, el brazo manual aún se estaba cronometrando (junio a agosto).
- El doble etiquetado independiente nuevo da 0,5569 (moderado), y el consenso nuevo coincide con el sector original solo en 116 de 138 casos (84,1 %).
- **Corrección exigida:** retirar el 0,87 del Resumen, del Abstract y de la Introducción como evidencia de fiabilidad, o exhibir las planillas que lo sustentan con su fecha. Si no existen, declararlo en una oración en §4.4.

N-02. La tesis no declara que la versión de julio informó resultados de un corpus sintético. Anexo I.

- La bitácora de los autores (docs/Tesis/Correcciones/dictamen-correcciones.md) dice que los valores de la versión anterior «siguen siendo los del corpus sintético descartado». El archivo docs/anexo_f_corpus.md atribuye ese descarte a «los revisores».

- El Anexo I traza nueve autoevaluaciones generadas con un modelo de lenguaje, pero omite la auditoría del tribunal del 4 de agosto, que está en el propio repositorio (auditorias/) y que originó la reformulación.
- **Corrección exigida:** una nota de versiones de media página, al inicio del Anexo I, que diga qué informó la versión del 3 de julio (165,3 s, 92 %, W = 0, κ = 0,87), que esas cifras provenían de un corpus sintético y que fueron reemplazadas. Agregar la auditoría del 4 de agosto como primera fila de la trazabilidad.

Altas

N-03. Los tiempos manuales de la campaña complementaria no se informan. §4.5 y §8.7. brazo_manual.csv registra inicio y fin por caso para O1 y O2 (220 registros), y la tesis los usa solo para el efecto de posición. Recalculados en esta auditoría:

Operador	Casos	Media manual	Media automatizada (mismos casos)	Reducción	p (Wilcoxon)
O1	110	20,1 s	13,3 s	33,8 %	$9{,}8 \times 10^{-7}$
O2	110	76,6 s	15,5 s	79,7 %	$9{,}0 \times 10^{-20}$
Agregado por caso	200	47,6 s	14,6 s	69,3 %	$3{,}0 \times 10^{-28}$

El resultado agregado replica el de la campaña 2026-10 con sujetos independientes y fortalece la tesis. Pero muestra que la magnitud depende del operador (34 % a 80 %). Además, los tiempos manuales por caso de ambas campañas no se correlacionan (Spearman 0,15 y −0,05): el tiempo manual no es una propiedad estable del incidente. Hay un registro de 0 s (R025, O1). **Corrección exigida:** informar esta tabla en §8.7, aclarar si la tarea manual de ambas campañas es la misma (lectura y carga del ticket, o solo la decisión de sector) y discutir la dependencia del operador en §9.1.

N-04. El mecanismo de selección de los 200 casos es contradictorio. §4.4. La tesis dice que el corpus se construyó «por muestreo estratificado con asignación proporcional» y, párrafos después, que los 200 casos «son los incidentes efectivamente cronometrados» por disponibilidad. También admite que la distribución del universo no está disponible. No se declaran las fechas del «período relevado» ni cómo se eligieron 200 de unos 2.646 incidentes (7,6 %). **Corrección exigida:** describir una sola forma de selección, con fechas y criterio, y si fue por conveniencia, llamarla así y llevar el sesgo de selección a §4.8.

N-05. 119 de los 200 tiempos automatizados carecen de registro primario verificable. §4.5 y Anexo F. Los 81 telefónicos coinciden exactamente con data/corpus_resultados_telefonia.json (duración más latencia). Los 119 de correo y formulario no coinciden con ningún registro versionado: data/corpus_resultados.json tiene otra corrida (media de 0,41 s) y el registro de la ingesta por n8n tiene 4 filas frente a

119 y no se versiona, según data/README.md. **Corrección exigida:** declarar en §4.5 que esos 119 valores no tienen respaldo primario conservado y de dónde se transcribieron, o versionar el registro.

N-06. El brazo telefónico automatizado se alimentó con llamadas recitadas por un autor. §4.5. Un autor parafraseó las descripciones pseudonimizadas en un softphone. Hubo dos configuraciones distintas entre el 5 y el 6 de octubre, y la versión de los 56 casos del día 6 «no consta». Un locutor que conoce el caso y el sistema habla más claro y más breve que un usuario real, lo que favorece tiempo y exactitud del canal. **Corrección exigida:** incorporarlo como amenaza a la validez en §4.8 y como explicación rival en §9.1.

N-07. La escritura perdió concisión y el texto se lee como bitácora de cambios. Todo el documento. El cuerpo pasó de ≈26.000 a ≈35.200 palabras. La mediana de oración subió de 28 a 34 palabras; las oraciones de más de 40 palabras, del 21,7 % al 37,1 %; y las de más de 60, del 3,7 % al 13,5 %. Hay 47 «de modo que», 166 remisiones «Subsección» e identificadores internos de cambios (c-82, c-153, C-61…) en cuerpo, tablas y epígrafes. **Corrección exigida:** sacar los identificadores de cambio del cuerpo (pueden quedar en el Anexo I) y partir las oraciones de más de 60 palabras de los capítulos 1, 4, 8 y 9.

N-08. Las métricas primarias se calculan contra una referencia cuya fiabilidad no se puede demostrar. §8.2 y §9.3. La exactitud de 73,5 % se mide contra el etiquetado original (sin tabla de acuerdo); contra el consenso independiente nuevo, la exactitud es 0,7971 sobre 138 casos. La tesis lo informa como limitación, pero lo deja fuera de las tablas de resultados. **Corrección exigida:** agregar a la Tabla 12 una fila con la exactitud contra el consenso nuevo y su IC, para que el lector vea ambas referencias juntas.

Medias

N-09. La regla de decisión de la segunda sub-hipótesis se fijó después de ver los datos. §1.4 y §8.3. Según el Anexo I (Tablas 22 y 24), la proporción quedó «sin concluir» y el change c-190 la declaró «refutada» después. Con 25/147, IC [11,8 %; 23,9 %] y p = 0,28, la lectura estadística correcta es no concluyente con estimación puntual sobre la cota. La decisión va contra el interés de los autores, lo que la atenúa, pero debe declararse posterior. Indicar también que p = 0,28 es unilateral.

N-10. No se informa el porcentaje de cobertura de las pruebas del backend. §6.7. Se da el comando pero no el valor, mientras el frontend sí lo informa (99,6 %).

N-11. Las Figuras 2, 7, 8 y 10 son ilegibles a tamaño de impresión. Su texto queda por debajo de 6 puntos en A4. Pasar a orientación apaisada o dividir por capas.

N-12. Las conclusiones conservan valoraciones sin respaldo y repiten cifras. §10.1: «un valor que lo posiciona como una vía prácticamente útil» sobre 20,1 s de tiempo telefónico, que es cota inferior y fue medido con llamadas recitadas (N-06). Sintetizar en lugar de reiterar los números del capítulo 8.

N-13. Falta decir qué instrumento del art. 12 de la Ley 25.326 se usó durante el estudio. §7.3. La tesis explica bien que hacen falta consentimiento o cláusulas modelo (Disposición 60-E/2016), pero no dice si se celebraron. Si en el estudio solo cruzó texto pseudonimizado y audio recitado por un autor, decirlo, y dejar el instrumento como requisito del adoptante.

Bajas

N-14. El Anexo I (Tabla 26, A1) dice que la confirmación escrita del consentimiento «queda diferida», mientras §7.5 la da por firmada. El registro del repositorio la fecha el 10/11/2026: actualizar el anexo.

N-15. Los nombres de sector aparecen sin tilde en la prosa («Seguridad Informatica», «Soporte Tecnico»). Si son cadenas canónicas del sistema, ir en monoespaciado; en la prosa, con tilde.

N-16. Aportar copia o DOI verificable de Paket et al. (2024) y aclarar si Mayor-Rocher et al. se cita en su versión de revista o de arXiv.

6. Calificación por capítulo

Con los mismos pesos de la auditoría de agosto, el promedio ponderado da 6,97, que se informa como 7,0. Las mayores subas están en Resultados (de 1,5 a 6,5) y Anexos (de 2,5 a 7,0).

Capítulo evaluado	Correspondencia en la tesis	Agosto	Esta instancia	Peso	Motivo principal
Introducción	Cap. 1	6,5	7,5	8 %	Hipótesis desdoblada con criterios de falsación; aritmética del universo corregida; persiste κ = 0,87 en §1.7
Marco teórico	Caps. 2 y 3	6,0	7,5	8 %	Eje de LLM con calibración, alucinación e idioma; protocolo de búsqueda declarado; Whisper ubicado como marco
Marco metodológico	Cap. 4	3,5	6,0	15 %	Instrumento único, potencia, exclusiones y Shapiro-Wilk; restan N-01, N-04, N-06 y N-09
Desarrollo	Caps. 6 y 7	5,5	7,5	12 %	Flujo, reintentos y TLS alineados con el repositorio; marco legal corregido; falta N-10 y N-13
Resultados	Cap. 8	1,5	6,5	20 %	Cifras reproducibles dígito a dígito; restan N-03, N-05 y N-08

Capítulo evaluado	Correspondencia en la tesis	Agosto	Esta instancia	Peso	Motivo principal
Arquitectura	Cap. 5	5,0	7,5	10 %	Cinco capas, diagramas de despliegue y ER, siete entidades coherentes; figuras poco legibles (N-11)
Discusión	Cap. 9	3,0	7,0	10 %	Explicaciones rivales, balance neto con punto de equilibrio y lectura honesta de la calibración; falta la dependencia del operador
Conclusiones	Caps. 10 y 11	2,5	6,5	7 %	Objetivos con grado de cumplimiento realista; valoraciones residuales y cifras repetidas (N-12)
Referencias	Bibliografía	5,5	8,0	6 %	≈18 artículos arbitrados 2023–2026, sin fabricaciones detectadas; dos por confirmar (N-16)
Anexos	Anexos A–I	2,5	7,0	4 %	Corpus, prompt, configuración y trazabilidad con contenido real; Anexo I incompleto (N-02)
Global ponderado		**3,9**	**7,0**	100 %	

```
0{,}08(7{,}5)+0{,}08(7{,}5)+0{,}15(6{,}0)+0{,}12(7{,}5)+0{,}20(6{,}5)+0{,}10(7{,}5)+0{,}10(7{,}0)+0{,}07(6{,}5)+0{,}06(8{,}0)+0{,}04(7{,}0)=6{,}97
```

Índice de calidad de escritura: 6,9 / 10 (antes 6,8). Mejoraron la corrección ortográfica (de 4,5 a 8,5), la precisión terminológica (8,0) y el estilo científico (7,5). Empeoraron la concisión (de 5,5 a 4,0) y la claridad (de 7,5 a 6,0), por la longitud de las oraciones y las calificaciones acumuladas en cada corrección.

Fortalezas que el tribunal debe reconocer.

- Reproducibilidad completa de las cifras del estudio desde el repositorio público.
- Honestidad metodológica infrecuente: la tesis refuta dos de sus tres sub-hipótesis, declara las métricas como estimaciones dentro de la muestra y estima el sesgo del ajuste con el corpus (Tabla 15).
- Análisis de balance neto con exactitud mínima de equilibrio (Tabla 17), que convierte un resultado mixto en una regla de decisión útil para un adoptante.
- Campaña complementaria con etiquetadores y operadores independientes, plan pre-registrado y tablas primarias versionadas.

- Corrección completa del marco jurídico y alineación del sistema con lo que el texto describe.

7. Correcciones obligatorias antes de la defensa

Son diez correcciones de escritura y declaración, ordenadas por prioridad; se estiman en 3 a 5 días de trabajo y no requieren código nuevo ni nuevas mediciones.

1. **Retirar o documentar el κ = 0,87** del Resumen, del Abstract, de §1.7, §4.4 y §4.8 (N-01).
2. **Agregar la nota de versiones** al inicio del Anexo I, con las cifras de julio, su origen sintético y la auditoría del 4 de agosto como primera fila de la trazabilidad (N-02).
3. **Informar los tiempos manuales de la campaña complementaria** por operador y agregados, y discutir la dependencia del operador (N-03).
4. **Describir una sola forma de selección de los 200 casos**, con fechas del período y criterio (N-04).
5. **Declarar la procedencia de los 119 tiempos de correo y formulario** o versionar su registro primario (N-05).
6. **Agregar la recitación por un autor** a las amenazas a la validez y a las explicaciones rivales (N-06).
7. **Agregar a la Tabla 12 la exactitud contra el consenso independiente** (0,7971 sobre 138 casos) con su IC (N-08).
8. **Declarar posterior la regla de tres vías** de la segunda sub-hipótesis e indicar que p = 0,28 es unilateral (N-09).
9. **Sacar los identificadores de cambio del cuerpo** y partir las oraciones de más de 60 palabras (N-07).
10. **Atender las observaciones medias y bajas** N-10 a N-16.

La nota de 7,0 refleja el documento tal como fue entregado. La defensa se evaluará sobre el ejemplar corregido y sobre las respuestas del grupo a la Sección 8.

8. Preguntas probables del tribunal

Se recomienda que el grupo prepare una respuesta escrita para cada una.

Sobre la procedencia de los datos

1. ¿En qué fecha etiquetaron los analistas originales los 200 casos y dónde está la planilla del κ = 0,87, si ese valor ya figuraba en la versión del 3 de julio?
2. La versión de julio informó 165,3 s, 92 % y W = 0. ¿De dónde salieron esas cifras y por qué la tesis actual no lo dice?

3. ¿Cómo eligieron 200 incidentes entre unos 2.646, y en qué fechas exactas transcurrió el período relevado?
4. ¿De qué registro se transcribieron los 119 tiempos automatizados de correo y formulario del 2 de octubre?

Sobre el contraste de tiempos

5. En la campaña complementaria O1 tardó 20,1 s de media y O2 76,6 s. ¿Cuánto de la reducción del 71,2 % depende de quién opere?
6. ¿La tarea manual de la campaña complementaria (inicio a fin en la planilla) es la misma que la de la campaña 2026-10 (lectura, búsqueda y carga del ticket)?
7. ¿Por qué los tiempos manuales del mismo caso no se correlacionan entre las dos campañas?
8. ¿Qué efecto tiene que las llamadas automatizadas las haya recitado un autor que conocía el caso?
9. En el formulario web el automático mide 1,88 s desde el envío y el manual 28,7 s desde la lectura. ¿Miden el mismo tramo del proceso?

Sobre la clasificación y la supervisión humana

10. Si el consenso independiente coincide con la etiqueta original solo en el 84 % de los casos, ¿cuál es la exactitud «verdadera» del clasificador?
11. La compuerta de 0,70 no derivó ningún caso y la etapa determinística resuelve el 65,5 % sin derivación por confianza. ¿Qué supervisión humana efectiva tiene hoy el sistema?
12. De 85 confirmaciones humanas con consenso disponible, 11 confirmaron un sector incorrecto. ¿Qué dice eso de la revisión como salvaguarda?
13. ¿Cuándo se fijó la regla de tres vías de la segunda sub-hipótesis, antes o después de conocer el 17,0 %?
14. Con el escenario central el balance neto es de −18,5 a −43,9 horas-persona por trimestre. ¿Recomendarían adoptar el sistema hoy?

Sobre el marco legal

15. ¿Se firmó alguna cláusula contractual modelo de la Disposición 60-E/2016 con Google o Twilio, o en el estudio solo se transfirieron datos pseudonimizados y audio recitado?
16. Las autoevaluaciones del Anexo I se generaron con un modelo de lenguaje. ¿Qué parte del texto de la tesis fue redactada con asistencia de un modelo de lenguaje y cómo lo declaran?