UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL MENDOZA

Tecnicatura Universitaria en Programación

Automatización inteligente del registro de incidentes en mesas de ayuda empresariales mediante orquestación de flujos con N8N y procesamiento de lenguaje natural basado en modelos de lenguaje grandes

Trabajo Final de Carrera presentado para obtener el título de

Técnico Universitario en Programación

Autores

Luca Gomez · Carla Bustos · Gonzalo Sevilla

Directores

Prof. Alberto Cortez y Prof. Ariel Enferrel

Mendoza, República Argentina

21 de octubre de 2026

Resumen

La creciente digitalización de los procesos organizacionales ha generado una dependencia cada vez mayor de los sistemas informaticos para la ejecución de las actividades operativas. En este contexto, la gestión eficiente de incidentes tecnologicos constituye un factor determinante para garantizar la continuidad del negocio y la calidad del servicio brindado a los usuarios internos. Sin embargo, en numerosas organizaciones medianas el proceso de registro inicial de incidentes continua realizandose de manera manual, lo que introduce demoras operativas, errores de clasificación y una utilización ineficiente de los recursos técnicos disponibles.

La presente investigación tiene como proposito el diseño, desarrollo, implementación y validación experimental de un sistema automatizado de mesa de ayuda empresarial basado en la integración de orquestación de flujos mediante la plataforma N8N, un modulo de procesamiento de lenguaje natural desarrollado en Python con el marco FastAPI, una capa de inferencia linguistica sustentada en el modelo Gemini 3.6 Flash de Google, una capa de persistencia sobre PostgreSQL versión 15 y un canal de telefonia gestionado por Twilio. La arquitectura propuesta contempla la recepción de solicitudes a través de tres canales paralelos —correo electrónico, formulario web y llamadas telefonicas con transcripción automática— y deriva cada incidente al sector responsable (Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos o Sistemas) mediante un clasificador hibrido en etapas que combina reglas deterministicas, un modelo de lenguaje grande y una etapa de reserva.

El estudio se desarrolló bajo un enfoque cuantitativo con diseño cuasiexperimental de muestras pareadas y ejecución secuencial de ambos flujos sobre los mismos 200 casos. El corpus de validación, construido por muestreo estratificado proporcional sobre un universo aproximado de 3.700 incidentes, comprende 200 casos representativos del entorno operativo. El acuerdo entre los dos analistas que realizaron el doble etiquetado independiente alcanzó un coeficiente Kappa de Cohen de 0,87, considerado casi perfecto.

Los resultados obtenidos evidencian una reducción estadísticamente significativa del tiempo medio de registro, que descendio desde 61,6 s en el flujo manual hasta 17,76 s en el flujo automatizado, lo que representa una reducción relativa del 71,2 %. La prueba de Wilcoxon de rangos con signo aplicada sobre las mediciones pareadas arrojo un estadístico $W = 363$

con $p = 3{,}08 \times 10^{-32}$ y un tamaño del efecto $r = 0{,}9639$, permitiendo rechazar la hipotesis nula de igualdad de medianas. La exactitud estricta del clasificador alcanzó el 73,5 % (147 de 200 casos) y el valor F1 macro promediado se ubico en 0,5207 sobre los cinco sectores canónicos. La proporción de intervención humana descendio desde el 100 % en el flujo manual hasta el 9,5 % en el flujo automatizado, materializando un esquema *human in the loop* en el cual el operador conserva la potestad de revisión sobre los casos de baja confianza o ambiguedad estructural.

Los hallazgos confirman la viabilidad tecnica, económica y operativa de la automatización inteligente del registro de tickets en organizaciones medianas. La investigación aporta una arquitectura reproducible y escalable construida sobre componentes maduros de código abierto e inferencia linguistica externa, evidencia empírica sobre el desempeño de modelos de lenguaje grandes aplicados a clasificación de tickets en espanol rioplatense, y un marco normativo aplicable que contempla la Ley 25.326 de Proteccion de los Datos Personales de la Republica Argentina.

Palabras clave: automatización, mesa de ayuda, procesamiento de lenguaje natural, modelo de lenguaje grande, N8N, FastAPI, clasificación de tickets, espanol rioplatense, human in the loop

Abstract

The increasing digitization of organizational processes has made IT incident management critical for business continuity. Yet in many medium-sized organizations, incident registration remains entirely manual, introducing delays, classification errors, and inefficient use of technical resources. This thesis presents the design, implementation, and experimental validation of an automated help desk system integrating N8N workflow orchestration, a Python-based natural language processing module built with FastAPI, Google's Gemini 3.6 Flash large language model, PostgreSQL for persistence, and Twilio for telephony. The architecture receives requests through three parallel channels —email, web form, and phone calls with automatic transcription— and routes each incident to the appropriate sector using a two-stage hybrid classifier that combines deterministic rules with a large language model.

The study employed a quantitative quasi-experimental paired-samples design with a stratified proportional sample of 200 incidents drawn from a universe of approximately 3,700, processed sequentially by both flows. Inter-rater agreement reached a Cohen's Kappa of 0.87. Results show a statistically significant reduction in mean registration time from 61.6 s to 17.76 s —a 71.2 % reduction— with a Wilcoxon signed-rank test yielding $W = 363$, $p = 3.08 \times 10^{-32}$ and an effect size $r = 0.9639$. Strict classification accuracy reached 73.5 % (147/200) with a macro-averaged F1 score of 0.5207 across the five canonical sectors. Human intervention decreased from 100 % to 9.5 %, establishing a *human-in-the-loop* scheme where routine cases are automated while ambiguous ones are reserved for operator review.

The findings confirm the technical, economic, and operational feasibility of intelligent ticket registration automation in medium-sized organizations. The thesis contributes a reproducible architecture on mature open-source components, empirical evidence on large language model performance for ticket classification in Rioplatense Spanish, and a regulatory framework aligned with Argentina's Personal Data Protection Law 25.326.

Keywords: automation, help desk, natural language processing, large language model, N8N, FastAPI, ticket classification, Rioplatense Spanish, human in the loop

Indice general

1 Introducción **11**

1.1 Contextualización 11

1.2 Planteamiento del problema 11

1.3 Pregunta de investigación 12

1.4 Hipótesis de trabajo 13

1.5 Objetivo general 13

1.6 Objetivos específicos 14

1.7 Justificación 15

1.8 Alcance y delimitaciones 16

2 Marco teórico **18**

2.1 Gestión de servicios de tecnologías de la información 18

2.2 Mesa de ayuda y modelo ITIL 18

2.3 Automatización de procesos y orquestación de flujos 19

2.4 Procesamiento de lenguaje natural y modelos de lenguaje grandes 20

2.5 Reconocimiento automático del habla 22

2.6 Bases de datos relacionales y persistencia transaccional 23

2.7 Métricas de evaluación de clasificadores multiclase 24

3 Estado del arte **26**

3.1 Soluciones comerciales de mesa de ayuda 26

3.2 Plataformas de orquestación de flujos 27

3.3 Trabajos académicos previos sobre clasificación de tickets 27

3.4 Análisis comparativo y brecha identificada 29

4 Marco metodológico **31**

4.1 Enfoque y tipo de investigación 31

4.2 Diseño experimental 31

4.3 Operacionalización de variables 32

4.4 Población, muestra y corpus 32

4.5 Protocolo de pruebas 35

4.6 Métricas e instrumentos 36

4.7 Análisis estadístico 36
4.8 Amenazas a la validez 37
4.9 Gestión del proyecto bajo enfoque Scrumban (método de construcción del artefacto) 38

5 Arquitectura del sistema **40**
5.1 Visión general 40
5.2 Capa de canales de entrada 42
5.3 Capa de orquestación 44
5.4 Capa de procesamiento 44
5.5 Subsistema de clasificación híbrido 45
5.6 Modelo de datos 46
5.7 Contrato de la interfaz REST 48

6 Implementación **51**
6.1 Entorno de despliegue y dependencias 51
6.2 Construcción del módulo Python 51
6.3 Construcción del flujo en N8N 52
6.4 Integración del canal telefónico 55
6.5 Desafíos de integración 55
6.6 Conexión con el proceso Scrumban 57
6.7 Pruebas automatizadas 58
6.8 Dashboard de analítica 59

7 Resultados **61**
7.1 Comparación de tiempos de registro 61
7.2 Matriz de confusión y métricas de clasificación 63
7.3 Reducción de la intervención humana 65
7.4 Calibración de la confianza 66
7.5 Análisis de errores y casos límite 66

8 Discusión **69**
8.1 Interpretación de los resultados 69
8.2 Comparación con la literatura 72

8.3 Limitaciones del estudio 73
8.4 Implicancias prácticas 74
8.5 Reflexiones sobre la generalización 76

9 Conclusiones 77
9.1 Cumplimiento de los objetivos del trabajo 77
9.2 Aportes y generalización 78

10 Recomendaciones y líneas de trabajo futuro 80
10.1 Incorporación de un clasificador supervisado con corpus propio 80
10.2 Ampliación de canales de entrada 80
10.3 Panel de monitoreo en tiempo real 80
10.4 Mecanismos de aprendizaje activo 81
10.5 Estudios de replicación 82
10.6 Evaluación de modelos de lenguaje de código abierto 82
10.7 Base de conocimientos para resolución automática 82
10.8 Agente conversacional telefónico en tiempo real 83

11 Consideraciones éticas y aspectos legales 85
11.1 Marco normativo aplicable 85
11.2 Principios aplicados al tratamiento de datos 85
11.3 Transferencia internacional y pseudonimizacion 87
11.4 Seguridad tecnica 87
11.5 Consentimiento, derechos del usuario y supervision humana 88

Referencias bibliograficas 90

Appendices 95

A Diagrama de arquitectura del sistema 95

B Repositorio de código fuente 95

C Esquema de base de datos 96

D Especificación OpenAPI de la interfaz REST 96

E Configuración del flujo N8N **97**

F Corpus de validación **98**

G Documentación operativa **99**

H Especificación del prompt de Gemini 3.6 Flash **100**

H.1 Estructura y contenido del prompt 100

H.2 Parámetros de configuración 101

H.3 Validación de la respuesta 101

H.4 Iteración y mejora del prompt 102

H.5 Recomendaciones para futuras iteraciones 102

I Trazabilidad de las correcciones del dictamen **102**

Indice de tablas

1 Comparacion de soluciones para gestion automatizada de mesa de ayuda 29
2 Operacionalizacion de variables del estudio 33
3 Capas funcionales de la arquitectura del sistema 40
4 Entidades principales del modelo de datos 47
5 Puntos de entrada principales de la interfaz REST 50
6 Estadisticos descriptivos de los tiempos de registro por flujo ($n = 200$) 61
7 Tiempo automatizado de registro por canal de origen ($n = 200$) 62
8 Matriz de confusion del clasificador automatico ($n = 200$). Filas: sector asignado; columnas: sector predicho principal. 63
9 Métricas de clasificación por clase (una contra el resto) 65
10 Exactitud por banda de confianza declarada 66
11 Confusiones observadas en la clasificación automática, por frontera 67
12 Parámetros de configuración de la inferencia con `gemini-3.6-flash` 101

Indice de figuras

1 Diagrama de componentes del módulo Python organizado en capas (routes, services, repositories, classifiers). 41
2 Diagrama de arquitectura del sistema. La version completa en notacion UML se detalla en el Anexo A y en las fuentes Mermaid del repositorio (`docs/diagrams/`). 42
3 Diagrama de despliegue del entorno local. Servicios, red Docker, volumenes y servicios externos. 43
4 Diagrama de secuencia del flujo extremo a extremo de un incidente, desde el canal de entrada hasta la confirmacion o la derivacion a revision humana. 44
5 Diagrama entidad-relación de las siete entidades principales del modelo de datos. El esquema completo se documenta en el Anexo C. 49
6 Distribucion del tiempo de registro por canal de origen (manual frente a automatizado). El panel de telefonia incorpora la duracion de la llamada grabada. 63
7 Matriz de confusion del clasificador ($n = 200$). Filas: sector asignado (verdad); columnas: sector predicho principal. 64
8 Reconstrucción esquemática del flujo de orquestación N8N 98

1. Introducción

1.1. Contextualización

La evolucion de las tecnologías de la información ha transformado profundamente la dinamica operativa de las organizaciones contemporaneas. En la actualidad los sistemas informaticos constituyen el soporte fundamental para la ejecución de procesos administrativos, productivos y de comunicación, y esa dependencia tecnologica ha incrementado de manera correlativa la importancia de los servicios de soporte técnico, particularmente aquellos relacionados con la gestión de incidentes informaticos. La disciplina que da marco a esa actividad —la gestión de servicios de tecnologías de la información (ITSM)— se desarrolla en la Sección 2, donde se define su alcance y su relación con la mesa de ayuda.

No obstante, en muchas organizaciones medianas el proceso de registro inicial de incidentes continua realizandose manualmente, lo que introduce demoras, inconsistencias y una marcada dependencia del criterio individual del operador.

El contexto argentino presenta caracteristicas particulares que acentuan esta problematica. Las organizaciones medianas del país —segmento que la Secretaría de la Pequeña y Mediana Empresa encuadra por tramos según el sector y parámetros como el personal ocupado o el volumen de ventas anuales (Secretaría de la Pequeña y Mediana Empresa, 2026)— operan con presupuestos de tecnología acotados y enfrentan restricciones cambiarias que encarecen la adopción de soluciones comerciales internacionales. La combinación de estas restricciones con una demanda creciente de servicios digitales configura un escenario en el que las soluciones basadas en componentes de código abierto y servicios de inferencia bajo demanda resultan particularmente atractivas desde el punto de vista económico y operativo.

1.2. Planteamiento del problema

La presente investigación se desarrolla en el marco de una organización mediana del sector servicios con sede en la provincia de Mendoza, Republica Argentina, cuya plantilla asciende a aproximadamente 120 usuarios internos distribuidos en cinco áreas funcionales. El área de operaciones desempeña simultaneamente tareas vinculadas a la gestión operativa cotidiana y a la atención de incidentes informaticos reportados por los usuarios, lo que obliga al personal responsable a interrumpir actividades críticas para registrar manualmente fallas de hardware, inconvenientes de software o solicitudes de asistencia tecnica.

Las mediciones preliminares realizadas durante una semana laboral representativa evidenciaron un volumen promedio de 42 incidentes diarios, un tiempo medio de registro manual de 2 minutos con 45 segundos por incidente y una tasa de derivación erronea inicial cercana al 15 %. Aquel valor de 2 minutos con 45 segundos constituyó una estimación a priori, obtenida del promedio de una semana completa de operación sin cronometraje individual por caso, y sirvió para dimensionar el problema. La campaña experimental posterior midió el tiempo de registro incidente por incidente con cronometraje en vivo, consignado en la planilla descrita en la Subsección 4.2, y arrojo una media de 61,6 s sobre los 200 casos del corpus, sustancialmente inferior a la estimación preliminar. Sobre estos indicadores, el tiempo que el personal podría redirigir a tareas de mayor valor agregado si la etapa de registro estuviera automatizada se estima en el orden de 45,0 horas-persona por trimestre (véase Subsección 8.1). Este tiempo representa un costo de oportunidad significativo para la organización.

El registro manual de incidentes implica además la lectura de correos electrónicos, la interpretación de descripciones textuales heterogeneas, la clasificación del problema según el área responsable y la carga manual de la información en un sistema de tickets. Este procedimiento requiere tiempo, interrumpe las tareas del personal técnico y puede generar errores de clasificación que prolongan la cadena de resolución cuando un ticket es derivado a un área incorrecta. La dispersión de los canales de comunicación —correo, llamada telefonica y formularios internos— agrava la situacion al obligar al personal a monitorear multiples fuentes simultaneamente.

Este escenario responde a un patron documentado en la literatura: Galup et al. (2009) advierten que los procesos de soporte no automatizados tienden a degradarse cuando crece el volumen de solicitudes, con un impacto desproporcionado en organizaciones medianas donde el personal combina multiples roles (véase Subsección 2.1). Estos indicadores justifican la busqueda de una alternativa tecnologica que reduzca el costo operativo, mejore la calidad de la derivación temprana y disminuya la variabilidad asociada al criterio individual.

1.3. Pregunta de investigación

A partir del problema descrito, esta investigación se orienta a responder la siguiente pregunta: ¿reduce la automatización del registro inicial de incidentes mediante orquestación de flujos y procesamiento de lenguaje natural el tiempo de registro respecto del proceso manual, y alcanza la exactitud de clasificación el umbral objetivo definido para una mesa de ayuda

empresarial mediana?

La pregunta se descompone en tres interrogantes subsidiarios que guian el diseño experimental y la selección de metricas. Primero, ¿cual es la magnitud de la reducción del tiempo de registro que puede obtenerse mediante la automatización, y resulta esa reducción estadísticamente significativa? Segundo, ¿alcanza el clasificador automático el umbral objetivo de exactitud global del 85 % y un valor F1 macro no inferior a 0,85, y como se distribuyen los errores entre las categorías objetivo? Tercero, ¿permite la arquitectura propuesta integrar canales multiples de recepción sin degradar la latencia ni la calidad de la clasificación?

1.4. Hipótesis de trabajo

La hipotesis principal de este trabajo sostiene que la implementación de un sistema automatizado de registro de incidentes basado en orquestación de flujos con N8N y procesamiento de lenguaje natural mediante un modelo de lenguaje grande permite reducir significativamente el tiempo de registro y la proporción de intervención humana, alcanzando una exactitud de clasificación global no inferior al umbral objetivo del 85 % y un valor F1 macro no inferior a 0,85.

Formalmente, la hipotesis nula H_0 postula la inexistencia de diferencias significativas entre ambos flujos en las variables observadas: $H_0 : M_{\text{manual}} = M_{\text{automatizado}}$, donde M representa la mediana poblacional del tiempo de registro. La hipotesis alternativa H_1 postula que la mediana del flujo automatizado es inferior: $H_1 : M_{\text{manual}} > M_{\text{automatizado}}$.

Como hipotesis subsidiarias se plantea, en primer lugar, que la integración de multiples canales de entrada dentro de un único flujo automatizado mejora la accesibilidad del sistema y reduce la dispersión operativa sin introducir cuellos de botella adicionales. En segundo lugar, que un esquema hibrido de clasificación basado en reglas deterministicas y modelo de lenguaje grande resulta mas eficiente —en terminos de la relacion entre exactitud, latencia y costo de inferencia— que un esquema construido exclusivamente sobre modelo externo, dado que una proporción sustancial de los incidentes presenta marcadores lexicos inequivocos que no requieren consulta al modelo de lenguaje.

1.5. Objetivo general

Desarrollar e implementar un sistema automatizado de mesa de ayuda empresarial basado en orquestación de flujos con N8N y procesamiento de lenguaje natural en Python que

permita recibir, procesar, clasificar y registrar incidentes de usuarios de manera automática, reduciendo el tiempo de registro y la proporción de intervención humana en la etapa inicial del proceso, manteniendo la supervisión tecnica para la resolución de los casos y garantizando la trazabilidad de las decisiones tomadas por el sistema.

1.6. Objetivos específicos

El primer objetivo específico consiste en diseñar una arquitectura distribuida y modular que integre un motor de orquestación de flujos, un modulo de procesamiento de lenguaje natural, un canal de telefonia con transcripción automática del habla y una base de datos relacional, garantizando comunicación asincronica entre componentes mediante interfaces de programacion de aplicaciones de tipo REST sobre HTTP cifrado.

El segundo objetivo específico se orienta a implementar un clasificador automático que asigne cada incidente a uno de los cinco sectores canónicos —Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos o Sistemas— alcanzando una exactitud global no inferior al 85 % sobre un corpus controlado de 200 casos representativos del entorno operativo, y un valor F1 macro promediado no inferior a 0,85. El umbral del 85 % se fundamenta en tres criterios convergentes. Primero, los trabajos de Paramesh y Shreedhara (2019) reportan exactitudes de aproximadamente 87 % con enfoques de maquinas de vectores de soporte (SVM) y representaciones TF-IDF, estableciendo un piso de referencia para el estado del arte en clasificación de tickets. Segundo, el costo organizacional de una derivación erronea implica al menos 10 a 15 minutos adicionales de reasignacion según las mediciones preliminares de la organización, por lo que una exactitud inferior al 85 % resultaria en tiempos de resolución comparables a los del flujo manual para un volumen de errores inaceptable. Tercero, el margen por encima del 85 % es una propiedad del umbral elegido y no un resultado del estudio: situar el umbral en el 85 % deja margen para que, si la exactitud verdadera del clasificador supera ese valor, el límite inferior de su intervalo de confianza pueda ubicarse por encima de la frontera de interés en lugar de quedar solapado con ella. Se trata, en consecuencia, de un criterio de desempeño verificable contra la exactitud observada y su intervalo de confianza, distinto del contraste sobre la mediana de los tiempos formulado en la Subsección 1.4.

El tercer objetivo específico plantea integrar tres canales de entrada paralelos —correo electrónico, formulario web y llamada telefonica con transcripción automática— dentro de un

único flujo automatizado que normalice la entrada y centralice el procesamiento, mejorando la accesibilidad del sistema sin incrementar la complejidad operativa percibida por los usuarios finales.

El cuarto objetivo específico consiste en evaluar comparativamente el flujo manual y el flujo automatizado en terminos de tiempo medio de registro, dispersión, exactitud de clasificación y proporción de intervención humana, mediante un diseño cuasiexperimental con muestras pareadas, prueba estadística no parametrica y reporte de intervalos de confianza al 95 %. El diseño experimental sigue las recomendaciones de Hernández Sampieri y Mendoza Torres (2018) para investigaciones tecnologicas de carácter aplicado.

El quinto objetivo específico se orienta a documentar exhaustivamente la arquitectura, los procedimientos de despliegue y los resultados experimentales, proponiendo una hoja de ruta de evolucion que oriente futuras mejoras y replicaciones del estudio en organizaciones de caracteristicas comparables.

1.7. Justificación

La justificación del trabajo se sostiene en tres dimensiones complementarias.

Desde la dimensión organizacional, la automatización propuesta libera capacidad operativa del personal técnico, reduce el tiempo de respuesta percibido por los usuarios y disminuye la variabilidad introducida por el criterio individual. La evidencia recogida en este trabajo permite cuantificar esa mejora en el contexto específico de una organización mediana argentina, aportando un caso documentado que otras organizaciones pueden utilizar como referencia para estimar el retorno esperado de una inversion similar.

Desde la dimensión tecnologica, la solución combina componentes de código abierto —Python, FastAPI y PostgreSQL— con N8N, una plataforma de orquestación de flujos cuyo código fuente se distribuye bajo licencia Sustainable Use (*fair-code*) y admite despliegue completamente autoalojado (n8n GmbH, 2024), lo que permite una implementación reproducible en organizaciones de tamaño mediano sin requerir grandes inversiones de capital ni dependencia exclusiva de proveedores comerciales. Esta propiedad es particularmente relevante en el contexto argentino, donde las restricciones de acceso a divisas y los costos de suscripcion en moneda extranjera constituyen barreras significativas para la adopción de soluciones comerciales internacionales. Ademas, el despliegue autoalojado de la totalidad de los componentes —con excepcion del servicio de inferencia— otorga a la organización control pleno sobre sus

datos operativos, en línea con el principio de soberanía digital promovido por la Ley 25.326 de Proteccion de los Datos Personales (Honorable Congreso de la Nación Argentina, 2000).

Desde la dimensión académica, el trabajo aporta evidencia empírica sobre el desempeño de modelos de lenguaje grandes aplicados a la clasificación de tickets en espanol rioplatense, dominio escasamente documentado en la literatura comparativa disponible. Buena parte de la literatura relevada sobre clasificación automática de tickets se apoya en corpus en inglés y, en menor medida, en alemán o portugués (Colavito et al. 2025; Zangari et al. 2023), y los pocos trabajos que incorporan el espanol lo hacen con variantes peninsulares o con corpus genericos no específicos del dominio de mesas de ayuda (Grandury et al. 2025; Mayor-Rocher et al. 2026). Este trabajo contribuye a cerrar esa brecha mediante la validación rigurosa de un clasificador hibrido sobre un corpus de 200 casos en espanol rioplatense con doble etiquetado independiente y acuerdo inter-evaluador cuantificado.

Adicionalmente, la mayoría de las soluciones comerciales disponibles —tales como Zendesk Suite, Freshdesk o ServiceNow ITSM— presentan modelos de costos por agente y mes que escalan linealmente con el equipo y operan exclusivamente en modalidad de software como servicio con almacenamiento de datos en jurisdicciones extranjeras. La propuesta desarrollada en esta investigación utiliza herramientas de despliegue autoalojado, lo que facilita su adopción en organizaciones medianas y simplifica el cumplimiento de la normativa argentina de proteccion de datos personales.

1.8. Alcance y delimitaciones

El alcance del trabajo se circunscribe a la etapa de recepción, clasificación y registro inicial de incidentes, sin abarcar la resolución tecnica de los mismos, la cual permanece bajo responsabilidad del personal humano. El sistema contempla tres canales de entrada (correo electrónico, formulario web y llamada telefonica con transcripción automática) y cinco sectores de derivación (Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos y Sistemas). La validación experimental se realiza sobre un corpus en idioma espanol rioplatense recolectado en una organización mediana del sector servicios con sede en la provincia de Mendoza, de aproximadamente 120 usuarios internos distribuidos en cinco áreas funcionales.

Quedan fuera del alcance los siguientes aspectos, los cuales se proponen como líneas de trabajo futuro en la Sección 10. Primero, la integración con sistemas externos de inventa-

rio de activos informaticos o con sistemas de gestión de configuración. Segundo, los modelos de aprendizaje supervisado entrenados con corpus propios de la organización, dado que el volumen actual de datos etiquetados resulta insuficiente para esa estrategia. Tercero, la implementación de paneles de monitoreo avanzados con visualización en tiempo real de metricas operativas. Cuarto, la automatización de la etapa de resolución tecnica, que trasciende el alcance del presente trabajo.

Las delimitaciones del estudio incluyen: la restricción geografica a una única organización de la provincia de Mendoza, lo que limita la validez externa de los hallazgos; la dependencia operativa del servicio externo de inferencia gemini-3.6-flash, cuyo rendimiento y condiciones comerciales escapan al control de los investigadores; y la naturaleza temporal de los resultados, que reflejan el comportamiento del modelo en la versión vigente al momento del estudio (entre junio y octubre de 2026), sujeta a modificaciones futuras por parte del proveedor.

2. Marco teórico

Este capítulo establece los fundamentos conceptuales sobre los cuales se construye la investigación. Se abordan siete ejes tematicos que proporcionan el andamiaje teórico necesario para comprender el diseño, la implementación y la evaluación del sistema propuesto.

2.1. Gestión de servicios de tecnologías de la información

La gestión de servicios de tecnologías de la información (ITSM) constituye una disciplina sistematizada que articula procesos, personas y tecnologías con el proposito de entregar valor al negocio a través de servicios tecnologicos confiables y mensurables. Galup et al. (2009) caracterizan la disciplina como un cuerpo de prácticas orientado a alinear la operación tecnologica con los objetivos del negocio, donde la mesa de ayuda opera como punto único de contacto entre el usuario y el área de tecnología. Este enfoque rompe con la concepcion anterior que entendia a la informatica como un área de soporte estrictamente reactivo y la posiciona, en cambio, como un proveedor de servicios sujeto a acuerdos de nivel de servicio explicitos.

Dentro de este marco general, la gestión de incidentes constituye uno de los procesos operativos centrales. Su objetivo principal consiste en restaurar el servicio afectado en el menor tiempo posible, minimizando el impacto adverso en la operación del negocio. El proceso comprende cuatro etapas secuenciales: la recepción y registro inicial, la clasificación y priorizacion, la asignación al área responsable y, finalmente, la resolución y cierre. Galup et al. (2009) advierten que los procesos manuales de soporte tienden a degradarse cuando el volumen de solicitudes crece de manera no lineal o cuando el personal debe alternar entre tareas operativas heterogeneas, situacion que coincide con la observada en el entorno empresarial analizado en el presente trabajo.

2.2. Mesa de ayuda y modelo ITIL

El marco de buenas prácticas ITIL (Information Technology Infrastructure Library), en su edicion de operaciones de servicio (Office of Government Commerce, 2011), publicada por The Stationery Office (TSO) por encargo del Cabinet Office y cuyo titular histórico es el Office of Government Commerce, establece la distinción conceptual entre incidente —definido como una interrupción no planificada del servicio o una reducción de su calidad— y solicitud de servicio —definida como un pedido formal de información, asesoramiento, acceso a un componente

o ejecución de una operación estandarizada—. Esta distinción resulta especialmente relevante para el diseño del clasificador propuesto en este trabajo, ya que orienta la categorizacion inicial y condiciona la priorizacion subsiguiente.

El marco ITIL postula adicionalmente tres principios operativos que guian el diseño de la solución propuesta. El primero es la centralización de la recepción mediante un punto único de contacto (SPOC, por su sigla en inglés), que en el sistema propuesto se materializa a través del flujo unificado de orquestación que normaliza las entradas de los tres canales. El segundo es la operación bajo acuerdos de nivel de servicio (SLA), que cuantifican la calidad esperada en terminos de tiempo de respuesta y tiempo de resolución. El tercero es la mejora continua del proceso, que en el sistema propuesto se habilita mediante la trazabilidad de cada decision del clasificador y la retroalimentacion de los sectores responsables.

Los modelos tradicionales de mesa de ayuda se basan en la interacción manual entre el usuario y el operador, lo que implica tiempos de respuesta variables y una dependencia directa del personal disponible. Cuando el volumen de incidentes excede la capacidad del equipo o cuando los operadores deben alternar simultaneamente entre tareas operativas y de soporte, la calidad del servicio se degrada de manera observable. La automatización del registro inicial constituye, en consecuencia, una intervención que aborda el cuello de botella en el punto de mayor sensibilidad del proceso, sin requerir la reestructuración completa del modelo operativo.

2.3. Automatización de procesos y orquestación de flujos

La automatización de procesos empresariales (BPA, por su sigla en inglés) permite reducir la intervención humana en tareas repetitivas mediante la ejecución automática de acciones definidas a partir de eventos específicos. Russell y Norvig (2021) ubican a la automatización inteligente dentro del paradigma de los agentes orientados a objetivos, en el cual un sistema reactivo percibe eventos del entorno, decide acciones según una politica preestablecida y actua modificando el estado del entorno. Esta caracterizacion ofrece un marco conceptual robusto para el diseño de sistemas que combinan reglas deterministicas con decisiones derivadas de modelos probabilisticos, como el clasificador hibrido propuesto en este trabajo.

Las herramientas de orquestación, también denominadas plataformas de integración como servicio (iPaaS), posibilitan integrar distintos servicios, procesar información y ejecutar acciones automáticas en función de condiciones predefinidas. Estas plataformas se caracterizan por ofrecer modelos visuales de construcción de flujos, soporte nativo para webhooks y

disparadores reactivos, y capacidad de transformación de datos entre sistemas heterogeneos. n8n GmbH (2024) documenta las capacidades de N8N, la herramienta seleccionada para este trabajo, que se distingue dentro del segmento por su modelo de licencia de código fuente disponible y su capacidad de despliegue completamente autoalojado, caracteristica que resulta decisiva en escenarios donde el tratamiento de datos sensibles exige mantener la información dentro del perimetro organizacional.

El paradigma de orquestación se diferencia conceptualmente del paradigma de coreografia. Hohpe y Woolf (2003) establecen que la orquestación centraliza la lógica de control en un componente único, lo que simplifica la trazabilidad de cada ejecución pero introduce un punto de coordinacion cuya disponibilidad condiciona al sistema completo. La coreografia, en cambio, distribuye la coordinacion entre los participantes mediante eventos publicados en un bus comun, lo que aumenta la robustez frente a fallos parciales pero dificulta la observabilidad. El presente trabajo adopta el enfoque de orquestación por simplicidad operativa y por la prioridad otorgada a la trazabilidad auditiva de cada decision del sistema, en línea con los requisitos de la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000).

2.4. Procesamiento de lenguaje natural y modelos de lenguaje grandes

El procesamiento de lenguaje natural (NLP) constituye un área de la inteligencia artificial orientada a la interpretación del lenguaje humano por parte de sistemas informaticos. Jurafsky y Martin (2023) sistematizan la disciplina en torno a tres ejes principales: el modelado estadístico de secuencias, la representación distribuida de palabras y la comprension semántica mediante arquitecturas neuronales profundas. Mediante estas tecnicas resulta posible analizar texto o audio transcrito, identificar palabras clave, determinar la intención del usuario y clasificar contenido en categorías predefinidas.

La evolucion del campo durante la última decada ha estado dominada por la arquitectura Transformer (Vaswani et al. 2017), cuyo mecanismo de atención permite a los modelos capturar dependencias de largo alcance sin las limitaciones de las redes neuronales recurrentes. El mecanismo de atención multi-cabeza, en particular, permite que el modelo pondere simultaneamente distintas partes de la secuencia de entrada, lo que resulta especialmente útil para la clasificación de descripciones textuales donde la información relevante puede aparecer en cualquier posicion del texto.

Sobre esta arquitectura se construyeron los modelos de lenguaje grandes (LLM) con-

temporaneos, los cuales exhiben capacidades robustas de clasificación en escenarios de pocos ejemplos (*few-shot*) o sin ejemplos (*zero-shot*), fenomeno conocido como aprendizaje en contexto. Brown et al. (2020) demostraron que modelos suficientemente grandes pueden generalizar a tareas nuevas a partir de instrucciones expresadas en lenguaje natural, sin requerir ajuste fino sobre datos específicos del dominio. Esta capacidad es particularmente relevante para el contexto de esta investigación, donde el volumen de datos etiquetados resulta insuficiente para entrenar un clasificador supervisado tradicional desde cero.

La forma en que se formula la instrucción condiciona el resultado tanto como la capacidad del modelo. El aprendizaje en contexto admite dos configuraciones principales: el planteamiento *zero-shot*, en el que la instrucción describe la tarea sin ejemplos, y el *few-shot*, en el que se incorporan unos pocos casos resueltos dentro del propio mensaje para orientar la respuesta. La evaluación multilingüe de Ahuja et al. (2023) y el ajuste por instrucciones de Lai et al. (2023) evidencian que la selección de ejemplos, su orden y la redacción de la instrucción modifican el rendimiento de manera sustancial, por lo que el diseño del *prompt* constituye una decisión de ingeniería y no un detalle accesorio.

Los LLM generan, junto con la etiqueta asignada, una estimación de confianza que no necesariamente coincide con la probabilidad empírica de acierto. La calibración designa el grado de correspondencia entre la confianza declarada por el modelo y su corrección observada: un modelo bien calibrado acierta con una frecuencia próxima a la confianza que expresa. Xuan et al. (2025) documentan, a partir de una evaluación comparativa en múltiples idiomas, que la calibración depende del modelo y del dominio. En el sistema propuesto este concepto fundamenta el umbral operativo de revisión humana, ya que las clasificaciones con confianza inferior a 0,70 se derivan a supervisión; la fiabilidad de ese umbral depende tanto de la exactitud como de la calibración del clasificador.

Una limitación central de los modelos generativos es la alucinación, es decir, la producción de contenido plausible en su forma pero falso o no sustentado en la entrada. En una tarea de clasificación la alucinación puede manifestarse como la asignación de una categoría inexistente o como una justificación inventada a partir de indicios débiles. Colavito et al. (2025) muestran que el etiquetado automático mediante LLM requiere validación contra un conjunto de referencia y no puede aceptarse sin control. Esta observación motiva dos decisiones del sistema propuesto: la restricción del espacio de salida a las cinco categorías canonicas y la validación de cada clasificación contra el conjunto de etiquetas válidas antes de su persisten-

cia.

El rendimiento de los LLM tampoco es uniforme entre idiomas ni entre variedades de un mismo idioma. Zhang et al. (2023) documentan que los modelos multilingües no generalizan de manera homogenea fuera del inglés, y la evaluación de variedades del español peninsular y latinoamericano de Grandury et al. (2025) y Mayor-Rocher et al. (2026) muestra diferencias de desempeño atribuibles al dialecto y a la disponibilidad de recursos. Esta sensibilidad resulta directamente relevante para el presente trabajo, cuyo corpus está redactado en español rioplatense, una variedad escasamente representada en los conjuntos de evaluación internacionales.

La evaluación de un LLM no se agota en una medida única de exactitud. Los benchmarks multilingües como los de Xuan et al. (2025) y Ahuja et al. (2023) combinan múltiples tareas y reportan resultados desagregados, en reconocimiento de que una cifra global puede ocultar un desempeño dispar entre categorías. Esta advertencia, que este capítulo desarrolla en la Sección 2.7 para el caso de clasificadores multiclase, fundamenta la decisión metodológica de reportar, además de la exactitud global, métricas por clase y el valor F1 macro promediado.

En el contexto de una mesa de ayuda, el uso de NLP permite clasificar incidentes y derivarlos al sector correspondiente sin intervención manual, mejorando la velocidad de respuesta y reduciendo la carga operativa del personal encargado del registro. La eleccion entre un clasificador supervisado entrenado sobre corpus específico, un modelo de lenguaje grande de proposito general invocado mediante instrucciones, o un esquema hibrido que combine ambas estrategias, constituye una decision de diseño que depende de la disponibilidad de datos etiquetados, del presupuesto de inferencia disponible y de los requerimientos de soberanía sobre los datos procesados.

2.5. Reconocimiento automático del habla

Los sistemas de reconocimiento automático del habla (ASR) permiten convertir audio en texto mediante modelos previamente entrenados sobre grandes corpus de habla anotada. Rabiner y Juang (1993) describen los fundamentos clasicos del reconocimiento basado en modelos ocultos de Markov (HMM), que durante decadas constituyeron el enfoque dominante. La generación contemporanea de sistemas se apoya mayoritariamente en redes neuronales profundas con arquitecturas codificador-decodificador, de las cuales el modelo Whisper (Radford

et al. 2023) representa un exponente reciente con alta robustez en escenarios multilingues y en presencia de ruido ambiental.

Whisper fue entrenado sobre 680.000 horas de audio multilingue recolectadas de la web, lo que le confiere una capacidad de generalización notablemente superior a la de sistemas entrenados sobre corpus curados de menor escala. Su arquitectura codificador-decodificador con atención procesa el audio en segmentos de 30 segundos y genera transcripciones que incluyen puntuacion y normalización ortografica. Este modelo se menciona en el presente capítulo como exponente del estado del arte del reconocimiento del habla y no forma parte de la implementación desarrollada: el canal telefonico del sistema propuesto delega la transcripción en el servicio nativo de Twilio, cuya integración se detalla en la Subsección 6.4.

En el contexto de la mesa de ayuda, la integración entre reconocimiento del habla y procesamiento de lenguaje natural permite automatizar completamente la recepción y clasificación de solicitudes telefonicas, posibilitando que el sistema interprete la solicitud del usuario y genere el ticket correspondiente sin intervención humana en la etapa de captura de voz.

2.6. Bases de datos relacionales y persistencia transaccional

La persistencia de los incidentes en una base de datos relacional permite garantizar las propiedades de atomicidad, consistencia, aislamiento y durabilidad (ACID) propias del modelo transaccional clasico (Date, 2003). PostgreSQL, el motor seleccionado para este trabajo, ofrece soporte completo del estandar SQL, extensiones para tipos de datos avanzados como JSON binario y arreglos, y un modelo de concurrencia basado en control multiversional (MVCC) que resulta adecuado para cargas mixtas de lectura y escritura (The PostgreSQL Global Development Group, 2024).

La eleccion de un motor relacional se comprende mejor al contrastarla con alternativas concretas. Un motor de documentos como MongoDB almacena registros con esquema flexible y favorece la evolucion de la estructura sin migraciones, pero no impone las relaciones entre incidentes, sectores, estados y canales de origen, de modo que la integridad referencial queda delegada a la aplicación. Un motor clave-valor en memoria como Redis ofrece latencias de acceso muy bajas y resulta adecuado para cache o contadores efímeros, pero no está orientado a la persistencia duradera ni a consultas relacionales complejas. El dominio de este trabajo exige precisamente esas propiedades: las relaciones entre incidentes, sectores, estados y canales se modelan como tablas vinculadas mediante claves foraneas con integridad referencial

declarativa, las operaciones de registro y actualización requieren las garantías ACID de la transacción clasica, el dashboard de analítica se apoya en consultas relacionales de agregación sobre múltiples tablas y la trazabilidad de cada decision del sistema demanda un registro duradero y auditable. Esta combinación de requisitos justifica la eleccion de PostgreSQL, en línea con los requisitos normativos identificados en la seccion de consideraciones eticas y legales (Sección 11).

2.7. Métricas de evaluación de clasificadores multiclase

La evaluación de clasificadores multiclase requiere metricas que capturen tanto el desempeño global como el desempeño por clase. Powers (2011) describe el conjunto canonico de metricas derivadas de la matriz de confusion, entre las cuales destacan la exactitud global (*accuracy*), la precision por clase, la sensibilidad o exhaustividad (*recall*) por clase, y la medida F1 como media armonica de las dos anteriores.

La exactitud global se define como la proporción de predicciones correctas sobre el total de casos evaluados:

$$\text{Exactitud} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[\hat{y}_i = y_i]$$

donde N es el número de casos, $\hat{y}_i$ la clase predicha para el caso i, y_i su clase verdadera y $\mathbb{1}[\cdot]$ la función indicadora, que vale uno cuando la predicción coincide con la etiqueta y cero en caso contrario. Esta definición es válida directamente para cualquier número de clases y es la que subyace a la matriz de confusión de cinco sectores de la Sección 7. No se emplea la formulación binaria basada en verdaderos y falsos positivos y negativos, que presupone una única clase de interés y resulta inadecuada para un problema multiclase.

Sokolova y Lapalme (2009) advierten que en escenarios con clases desbalanceadas la exactitud global puede resultar enganosa y recomiendan reportar valores macro promediados, los cuales otorgan igual peso a cada clase con independencia de su frecuencia. El valor F1 macro promediado se define como:

$$F1_{\text{macro}} = \frac{1}{k}\sum_{i=1}^{k} F1_i$$

donde k es el número de clases y $F1_i$ es el valor F1 de la clase i. El presente trabajo adopta esta recomendación y reporta tanto exactitud global como F1 macro y metricas desagregadas por clase, permitiendo al lector evaluar la robustez del clasificador frente a la distribucion específica

del corpus.

Adicionalmente, la matriz de confusion constituye el instrumento estandar de presentación de resultados en clasificación multiclase, ya que permite identificar patrones específicos de error: confusiones sistematicas entre dos categorías particulares, sesgos hacía una clase mayoritaria o aciertos preferenciales sobre una clase específica. La inspeccion de la matriz orienta el análisis cualitativo posterior y constituye la base para cualquier propuesta de mejora del clasificador.

3. Estado del arte

Este capítulo revisa la literatura académica y las soluciones comerciales disponibles en tres áreas relevantes para el presente trabajo: plataformas de mesa de ayuda, herramientas de orquestación de flujos, y métodos de clasificación automática de tickets de soporte. El proposito es situar la contribucion de esta investigación en el contexto de los desarrollos previos y fundamentar la brecha que motiva el trabajo.

3.1. Soluciones comerciales de mesa de ayuda

El segmento de soluciones comerciales para gestión de mesa de ayuda se encuentra dominado por plataformas integrales que cubren el ciclo completo de vida del ticket. Zendesk Suite ofrece funcionalidades de recepción multicanal, automatización de flujos básicos y, mediante un modulo adicional, capacidades de inteligencia artificial para sugerencia de respuestas y defleccion de consultas frecuentes. Freshdesk propone una arquitectura comparable e incorpora el motor Freddy AI para clasificación automática y enrutamiento inteligente. Jira Service Management, parte del ecosistema de Atlassian, ofrece capacidades limitadas de automatización inteligente en su plan estandar; la edicion Data Center permite el despliegue autoalojado para organizaciones con requisitos de soberanía sobre los datos. ServiceNow ITSM constituye la opcion de referencia en el segmento corporativo, con un modulo Predictive Intelligence que aplica aprendizaje automático sobre el histórico de tickets de la organización.

La adopción de capacidades de inteligencia artificial en plataformas comerciales de mesa de ayuda ha crecido de manera sostenida en los últimos anos, particularmente en organizaciones medianas de mercados de habla inglesa. No obstante, estas plataformas presentan dos limitaciones relevantes para el contexto de la presente investigación. La primera es el modelo de costos basado en agente y mes, que escala linealmente con el tamaño del equipo de soporte. La segunda es que la mayoría de estas plataformas operan exclusivamente en modalidad de software como servicio (SaaS) con almacenamiento de datos en jurisdicciones extranjeras, lo que introduce consideraciones adicionales sobre transferencia internacional de datos personales bajo la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000).

En el segmento de código abierto, osTicket constituye una alternativa de despliegue autoalojado sin costo de licencia, aunque carece de capacidades nativas de clasificación automática mediante procesamiento de lenguaje natural moderno. Esta brecha funcional motiva la busqueda de arquitecturas compositivas que integren componentes maduros de código abierto

con servicios de inferencia bajo demanda.

3.2. Plataformas de orquestación de flujos

Dentro del segmento de plataformas de orquestación de flujos, las soluciones mas difundidas incluyen Zapier, Make (anteriormente Integromat), Microsoft Power Automate, Apache Airflow y N8N. Las primeras tres operan exclusivamente como SaaS, lo que las descarta como base para implementaciones donde el control sobre la infraestructura es un requisito explicito. Apache Airflow se orienta a flujos de trabajo programados de tipo procesamiento de datos por lotes, con un diseño centrado en grafos aciclicos dirigidos (DAG) definidos como código Python (Apache Software Foundation, 2024); aunque potente, su paradigma de ejecución programada resulta inadecuado para un caso de uso reactivo y orientado a eventos como el de una mesa de ayuda.

N8N ofrece un modelo de construcción visual de flujos sobre nodos predefinidos, soporte nativo para webhooks y disparadores reactivos, ejecución basada en eventos y posibilidad de despliegue completamente autoalojado bajo Docker (n8n GmbH, 2024). La disponibilidad de su código fuente bajo licencia Sustainable Use facilita la auditoria de seguridad y la adaptacion a requerimientos específicos sin generar dependencia exclusiva del proveedor. Estas caracteristicas confluyen para posicionar a N8N como la opcion mas adecuada para el escenario propuesto, donde la soberanía sobre los datos y los flujos de procesamiento constituye un requisito no negociable.

3.3. Trabajos académicos previos sobre clasificación de tickets

La literatura académica sobre clasificación automática de tickets de soporte ha experimentado un crecimiento considerable durante los últimos anos. A continuación se presentan los trabajos mas relevantes, organizados por enfoque metodológico y por orden cronologico.

Paramesh y Shreedhara (2019) constituyen uno de los primeros trabajos exhaustivos en el área. Utilizando combinaciones de maquinas de vectores de soporte (SVM) y representaciones TF-IDF sobre un corpus en inglés de aproximadamente 10.000 tickets, reportan exactitudes cercanas al 87 %. Su contribucion principal radica en la demostracion de que las tecnicas clasicas de aprendizaje supervisado, cuando se aplican sobre representaciones textuales adecuadas, pueden alcanzar niveles de desempeño operativamente utiles para la clasificación automática de tickets.

Revina et al. (2020) abordan el mismo problema desde una optica distinta: en lugar de predecir la categoría del ticket, clasifican su *complejidad* (baja, media o alta) y comparan representaciones TF-IDF contra rasgos linguisticos artesanales del dominio alimentando clasificadores clasicos (kNN, arboles de decision, naive Bayes, regresion logistica y SVM). Su conclusion es que los metodos simples y explicables, construidos con pocos rasgos linguisticos del dominio, resultan competitivos o superiores a las alternativas mas complejas. Un hallazgo especialmente relevante para el presente trabajo es que los modelos preentrenados pueden rendir peor en este dominio, cuyo vocabulario contiene numerosos terminos ausentes del corpus general de entrenamiento. Este resultado introduce una tension productiva: no respalda la transferencia no supervisada de un modelo de proposito general, sino que obliga a justificar la eleccion del LLM por la tarea —clasificacion de categoria con contexto instruccional— y no por la mera transferencia de conocimiento linguistico.

La literatura reciente sobre clasificacion automatica de tickets con modelos de lenguaje grandes confirma el desplazamiento del enfoque clasico hacia arquitecturas basadas en LLM. Paket et al. (2024) evaluan la clasificacion de tickets de mesa de servicio mediante LLM y reportan mejoras frente a las lineas base tradicionales; Liu et al. (2025) emplean LLM para la escalada automatica de tickets en proyectos de software; Zangari et al. (2023) revisan sistematicamente la automatizacion de tickets en escenarios de clasificacion multinivel; y Colavito et al. (2025) comparan el etiquetado automatico de reportes de incidencias con LLM. En conjunto, estos trabajos muestran que los LLM son competitivos para tareas de enrutamiento y clasificacion, aunque su desempeño depende del idioma, del dominio y del esquema de evaluacion empleado.

La evaluacion de modelos de lenguaje en escenarios de pocos ejemplos ha documentado que el rendimiento de clasificacion depende fuertemente del idioma del corpus, con resultados que favorecen a los idiomas mejor representados en los corpus de entrenamiento de los modelos contemporaneos (Ahuja et al. 2023; Lai et al. 2023; Xuan et al. 2025; Zhang et al. 2023). Para el espanol y sus variantes regionales, Grandury et al. (2025) construyen una tabla comparativa de LLM especifica para las variedades del espanol de Espana y Latinoamerica, mientras que Mayor-Rocher et al. (2026) evaluan modelos con pruebas de espanol como lengua extranjera, Bernal-Beltrán et al. (2025) comparan ajuste fino y aprendizaje en contexto sobre espanol mexicano, y Ramón-Ferrer et al. (2026) evaluan modelos de bajos recursos sobre un corpus en espanol. Esta linea evidencia que el espanol, y en particular sus variantes

regionales como el rioplatense, ha recibido una atencion notablemente menor en las evaluaciones sistematicas publicadas. Cabe declarar, ademas, una brecha concreta: hasta la fecha no existe articulo arbitrado 2023-2026 que evalue Google Gemini sobre tickets de soporte en espanol. Esta ausencia constituye una de las motivaciones academicas del presente trabajo, el cual aporta evidencia empírica sobre el desempeño del clasificador en espanol rioplatense aplicado a un dominio de mesa de ayuda de organización mediana.

3.4. Análisis comparativo y brecha identificada

La Tabla 1 presenta la comparación sistematica de las principales soluciones revisadas, considerando cuatro dimensiones relevantes: tipo de despliegue, capacidad de clasificación automática, soberanía sobre los datos y modelo de costos.

Tabla 1. Comparacion de soluciones para gestion automatizada de mesa de ayuda

Solucion	Despliegue	Clasificacion automatica	Modelo de costo
Zendesk Suite	SaaS comercial	Si, modulo de IA	Alto, por agente/mes
Freshdesk	SaaS comercial	Si, motor Freddy AI	Medio-alto, por agente
Jira Service Mgmt	SaaS o autoalojado	Limitada en plan estandar	Medio, por agente
ServiceNow ITSM	SaaS comercial	Si, Predictive Intelligence	Muy alto, contrato anual
osTicket	Codigo abierto	No nativa	Sin costo

Fuente: elaboración propia a partir de la documentación oficial de cada plataforma: Zendesk Suite (https://www.zendesk.com/service/help-desk-software/), Freshdesk (https://www.freshworks.com/freshdesk/), Jira Service Management (https://www.atlassian.com/software/jira/service-management), ServiceNow ITSM (https://www.servicenow.com/products/itsm.html) y osTicket (https://osticket.com/), consultadas el 19 de octubre de 2026.

La sintesis comparativa evidencia que ninguna de las soluciones revisadas combina simultaneamente las cuatro propiedades que el contexto del trabajo demanda: despliegue autoalojado para resguardo de datos sensibles, costo bajo y predecible en el tiempo, capacidad nativa de clasificación automática mediante NLP moderno, y soporte específico para canales multiples incluyendo telefonia con transcripción automática. La brecha identificada se sintetiza en la ausencia de soluciones de bajo costo, autoalojadas, con clasificación basada en modelos de lenguaje grandes y validadas empíricamente sobre corpus en espanol rioplatense para el dominio específico de mesas de ayuda empresariales medianas.

La presente investigación se ubica precisamente en esa interseccion y propone una arquitectura compositiva que reutiliza componentes maduros de código abierto y servicios de

inferencia bajo demanda, manteniendo bajo control de la organización los datos sensibles y los flujos de orquestación, y aportando evidencia empírica reproducible sobre el desempeño del enfoque en un contexto linguistico y organizacional escasamente documentado en la literatura.

4. Marco metodológico

4.1. Enfoque y tipo de investigación

La investigación se enmarca dentro del enfoque cuantitativo aplicado, dado que propone el desarrollo de una solución informatica orientada a mejorar el funcionamiento de un proceso organizacional concreto y mide su impacto mediante indicadores numericos. Hernández Sampieri y Mendoza Torres (2018) ubican este tipo de estudios dentro de la investigación tecnologica de carácter aplicado, donde el conocimiento producido se orienta a la transformación práctica de la realidad antes que a la generación de teoría general. El trabajo posee adicionalmente carácter experimental, en la medida en que disena, implementa y evalua un artefacto tecnologico bajo condiciones controladas.

4.2. Diseño experimental

El diseño experimental adoptado es de tipo cuasiexperimental con muestras pareadas y mediciones repetidas. La unidad de observación es el incidente individual, y cada uno se procesa secuencialmente bajo dos condiciones: la condicion manual y la condicion automatizada. Esta estrategia —procesar el mismo conjunto de incidentes por ambas vias— reduce sustancialmente la variabilidad asociada a las caracteristicas intrínsecas de cada caso, lo que aumenta la potencia estadística del contraste entre flujos.

Para acotar el efecto de aprendizaje del operador humano sobre el corpus, el diseño adoptó una ejecución secuencial pareada: los mismos 200 casos se procesaron primero por el flujo manual (junio a agosto de 2026) y luego por el flujo automatizado (septiembre a octubre de 2026). Como el procesamiento automatizado es independiente del operador, no introduce efecto de aprendizaje humano; el procesamiento manual, en cambio, se distribuyó entre dos operadores experimentados, cuya asignación se rotó entre las dos mitades del corpus (100 casos por mitad). Con dos operadores y dos mitades, no obstante, la mitad del corpus y el operador quedan colineales: la rotación de operadores queda confundida con el efecto del operador y no permite estimar por separado el efecto de aprendizaje, de modo que no se presenta aquí como una mitigación efectiva de la amenaza interna sino como una limitación reconocida del diseño (véase la Subsección 4.8). El diseño conserva, sí, el control sobre la variabilidad asociada a las características intrínsecas de cada caso, al medir el mismo incidente bajo ambas condiciones.

La investigación se desenvolvio bajo un protocolo de medición en vivo. Para mitigar el efecto Hawthorne —la alteracion del comportamiento de los sujetos cuando saben que estan siendo observados— (Hernández Sampieri & Mendoza Torres, 2018), el cronometraje no fue anunciado en tiempo real al operador cuyo tiempo se registraba; sin embargo, su conocimiento fue diferido: al concluir la campaña se realizó una sesión de esclarecimiento (*debriefing*) en la que los operadores fueron informados del propósito del estudio y del procedimiento de medición empleado. La medición del tiempo se realizó de forma diferenciada según el flujo. En el flujo automatizado se utilizaron registros automáticos del propio sistema (marcas de tiempo de entrada y salida en la base de datos, con precision al milisegundo). En el flujo manual, los operadores trabajaron en pares y el tiempo lo cronometró en vivo el compañero que no estaba registrando el incidente, consignándolo en una planilla de cronometraje: se registró el tiempo total de registro de cada incidente en segundos, con redondeo hacia arriba. El redondeo al alza constituye un sesgo de medición sistemático que infla el tiempo manual y su efecto se acota mediante el análisis de sensibilidad reportado en la Sección 7.

4.3. Operacionalización de variables

La Tabla 2 presenta la operacionalizacion de las variables del estudio, distinguiendo entre variables cuantitativas continuas, cuantitativas proporcionales y cualitativas nominales. Cada variable se acompana de su unidad de medida y de la definición operacional aplicada durante la captura, garantizando la trazabilidad entre la definición conceptual y el procedimiento de medición efectivo.

4.4. Población, muestra y corpus

La población de referencia está constituida por la totalidad de los incidentes informáticos reportados a la mesa de ayuda de la organización analizada. A partir de un universo aproximado de 3.700 incidentes —proyectado como 42 incidentes diarios sobre los 88 días de calendario del período relevado ($42 \times 88 \approx 3.700$)—, se construyó por muestreo estratificado proporcional un corpus de 200 casos pseudonimizados distribuidos entre los cinco sectores canónicos: Soporte Técnico Hardware 85, Soporte Técnico Software 67, Seguridad Informática 31, Sistemas 16 y Bases de Datos 1. Los casos provienen de tres canales de origen: llamada telefónica 81, correo electrónico 66 y formulario web 53. El flujo manual se cronometró entre junio y agosto de 2026; sobre los mismos 200 casos, el flujo automatizado se ejecutó entre

Tabla 2. Operacionalizacion de variables del estudio

Variable	Tipo	Unidad	Definicion operacional
Tiempo de registro	Cuantitativa continua	Segundos (s)	Lapso entre la recepción del incidente en el canal de entrada y la persistencia confirmada del ticket en la base de datos.
Exactitud de clasificación	Cuantitativa proporcional	Porcentaje [0; 100]	Cociente entre incidentes correctamente clasificados y total de incidentes evaluados.
F1 macro promediado	Cuantitativa proporcional	Adimensional [0; 1]	Promedio aritmetico del valor F1 calculado de forma independiente para cada uno de los cinco sectores objetivo.
Intervencion humana	Cuantitativa proporcional	Porcentaje [0; 100]	Se reporta de dos formas rotuladas: proporcion de casos que requieren accion manual de un operador humano y proporcion del tiempo total del proceso dedicado a esa accion.
Canal de origen	Cualitativa nominal	Categoria	Via de entrada: correo electrónico, formulario web o llamada telefonica.
Categoria asignada	Cualitativa nominal	Categoria	Sector responsable, uno de los cinco sectores canónicos: Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos o Sistemas.

Fuente: elaboración propia.

septiembre y octubre de 2026.

El tamaño muestral se determinó mediante la fórmula clásica de muestreo aleatorio simple con correccion por finitud, apropiada porque el universo relevado es finito y relativamente acotado:

$$n = \frac{N\, z^2\, p\,(1-p)}{e^2\,(N-1) + z^2\, p\,(1-p)},$$

equivalente a $n = n_0/[1 + (n_0 - 1)/N]$ con $n_0 = z^2\, p\,(1-p)/e^2$. En ella, $N = 3.700$ es el tamaño del universo trimestral, $z = 1{,}96$ corresponde a un nivel de confianza del 95 %, $p = 0{,}5$ es la proporcion esperada conservadora (la que maximiza la varianza $p(1-p)$ y, con ella, el tamaño requerido) y e es el margen de error absoluto. Con estos insumos y un margen de error del 6,74 %, la fórmula arroja un tamaño requerido de 200 casos ($n \approx 200{,}04$), que es el efectivamente construido. El margen del 6,74 % es, por lo tanto, el valor que reproduce de manera exacta el corpus de 200 casos, y sustituye al 6,5 % consignado en versiones previas del capítulo, que con los restantes insumos habría arrojado un tamaño cercano a 214 casos. El margen adoptado es razonable para un estudio piloto orientado a evaluar viabilidad tecnica antes de un despliegue definitivo.

La construcción del corpus aplicó criterios de exclusion explícitos. En primer lugar, se descartaron los incidentes duplicados, entendiendo por tales los reportados más de una vez sobre el mismo hecho, ya sea por repetición en un mismo canal o por ingreso concurrente por canales distintos. En segundo lugar, se descartaron las descripciones vacias o insuficientes, esto es, los registros sin contenido textual clasificable o cuya extensión no permitía inferir un sector responsable. En cambio, los casos con pertenencia simultánea a más de un sector (multicategoría) y las descripciones muy breves pero clasificables se conservaron deliberadamente, por ser representativos del entorno operativo real, asignándoseles una etiqueta primaria como sector responsable. Este criterio es coherente con el análisis de errores de la Sección 7, donde las descripciones extremadamente cortas y la mezcla de categorías figuran entre los patrones de error dominantes: excluirlos habría sesgado el corpus hacia casos artificialmente limpios y sobreestimado el desempeño del clasificador.

Cada incidente del corpus fue revisado y etiquetado de forma independiente por dos analistas con experiencia en la mesa de ayuda, ajenos al equipo de autores del trabajo y ajenos también al diseño del clasificador evaluado y a la fijación de sus umbrales. La independencia que respalda la validez de constructo es de carácter funcional: los analistas no participaron

en la construcción del sistema, no fueron instruidos según su comportamiento y no tuvieron acceso a las predicciones del clasificador al momento de etiquetar. Los dos analistas son, además, las mismas dos personas que operaron el brazo manual descrito en la Subsección 4.5. Esta coincidencia se declara explícitamente: no altera el cómputo del acuerdo inter-evaluador, que mide la concordancia entre ambos etiquetadores y no su relación con las condiciones del experimento, pero implica que la etiqueta de referencia y el brazo de comparación comparten sujetos, lo que acota la independencia del *ground truth* respecto de los operadores cronometrados y se retoma entre las amenazas a la validez de constructo (Subsección 4.8). Las discrepancias entre analistas fueron resueltas por consenso bajo la supervisión del director del trabajo. El acuerdo entre evaluadores se calculó mediante el coeficiente Kappa de Cohen (Cohen, 1960); el valor obtenido ($\kappa = 0{,}87$) se interpreta como casi perfecto según los rangos habitualmente aceptados, que sitúan el acuerdo casi perfecto por encima de $\kappa > 0{,}80$ (Landis & Koch, 1977). Este valor respalda la confiabilidad de la categoría de referencia utilizada como verdad fundamental (*ground truth*) para evaluar el clasificador automático.

4.5. Protocolo de pruebas

El protocolo de pruebas se ejecuto en dos fases sucesivas. La primera fase consistio en una validación funcional del sistema, en la cual se verificó la correcta integración de los componentes mediante: (a) pruebas unitarias del modulo Python, cuya cobertura se mide con `pytest-cov` sobre los paquetes de rutas, servicios y repositorios mediante el comando `pytest --cov=app.routes --cov=app.services --cov=app.repositories --cov-report=t` (b) pruebas de integración de la API y de la base de datos, junto con pruebas estructurales que validan el archivo `n8n/workflow.json`, y (c) pruebas de aceptacion simuladas con incidentes sinteticos representativos de cada categoría.

La segunda fase consistio en la validación experimental propiamente dicha, en la cual los 200 incidentes del corpus se procesaron bajo ambas condiciones operativas y se registraron las variables descritas en la Subsección 4.3. El procesamiento manual fue realizado por dos operadores experimentados con mas de tres anos de antiguedad en la mesa de ayuda, ambos capacitados previamente en el uso del sistema de gestión de tickets utilizado como referencia. El procesamiento automatizado se ejecuto sobre la misma infraestructura, sin intervención humana, durante la ventana de septiembre a octubre de 2026 y con monitoreo continuo de los tiempos de respuesta.

4.6. Métricas e instrumentos

La evaluación del sistema se sustenta en cuatro metricas principales. La primera es el tiempo medio de registro, calculado como la media aritmetica y la mediana de los tiempos individuales bajo cada condicion, junto con su desvio estandar e intervalo de confianza al 95 %. La segunda es la exactitud global de clasificación, calculada como la proporción de incidentes correctamente derivados al sector responsable. La tercera es el valor F1 macro promediado, calculado como la media aritmetica de los valores F1 obtenidos por cada clase, con el fin de neutralizar el efecto del desbalanceo de clases observado en el corpus (Sokolova & Lapalme, 2009). La cuarta es la proporción de intervención humana, que se reporta de forma rotulada en dos dimensiones complementarias: la proporción de casos que requieren intervención (cociente entre los casos con intervención manual y el total de casos) y la proporción del tiempo dedicado a tareas manuales sobre el tiempo total del proceso.

Como instrumentos de captura se utilizaron: (a) registros automáticos generados por el propio sistema con marcas de tiempo precisas al milisegundo para el flujo automatizado, (b) una planilla de cronometraje observacional, completada en vivo por el compañero de par que no estaba registrando el incidente, que consigna el tiempo total de registro por incidente en segundos, con redondeo hacia arriba, para el flujo manual, y (c) matrices de confusion generadas mediante la biblioteca scikit-learn (Pedregosa et al. 2011). En el flujo automatizado, el tiempo de registro del canal telefónico comprende tanto la duración de la llamada grabada como la latencia de procesamiento posterior al cuelgue, mientras que los canales de correo electrónico y formulario web se miden como latencia de extremo a extremo de su procesamiento. Dado que la grabación telefónica está acotada a un máximo de 45 s (véase la Sección 6), la duración de la llamada registrada —y por lo tanto el tiempo automatizado telefónico— constituye una cota inferior de la duración real de la llamada.

4.7. Análisis estadístico

Para la comparación de los tiempos de registro entre ambas condiciones se aplicó la prueba de Wilcoxon de rangos con signo, prueba no parametrica para muestras pareadas, dado que la prueba previa de normalidad de Shapiro-Wilk rechazó la hipotesis de normalidad en los tres conjuntos analizados, todos con $n = 200$: tiempos manuales ($W = 0{,}803$, $p = 3{,}71 \times 10^{-15}$), tiempos automatizados ($W = 0{,}902$, $p = 3{,}47 \times 10^{-10}$) y diferencias pareadas ($W = 0{,}822$, $p = 2{,}37 \times 10^{-14}$). En los tres casos el valor p queda muy por debajo

del nivel de significancia $\alpha = 0{,}05$, lo que respalda el uso de una prueba no parametrica. El nivel de significancia se fijo en $\alpha = 0{,}05$. En lo que sigue se denotan T^+ y T^- la suma de los rangos de las diferencias positivas y negativas, respectivamente. La implementación de referencia (`scipy.stats.wilcoxon` en su variante de dos colas) devuelve como estadístico de contraste el menor de ambos, es decir $W = \text{mín}(T^+, T^-)$; por lo tanto $W = T^-$ cuando el flujo automatizado resulta más rápido que el manual en la mayoría de los pares, que es el caso del corpus analizado.

Para cuantificar la magnitud práctica de la diferencia se calculo el coeficiente r de correlacion rank-biserial, indicador de tamaño del efecto para pruebas no parametricas. El cálculo se define directamente a partir de los dos estadísticos de rango:

$$r = \frac{T^+ - T^-}{n(n+1)/2}$$

donde T^+ y T^- son las sumas de rangos positivos y negativos y n el número de pares. La expresión equivale a $1 - \frac{4W}{n(n+1)}$ cuando $W = T^- = \text{mín}(T^+, T^-)$, y su rango teórico es $[-1, +1]$. La definición anterior, que solo abarcaba el intervalo $[0, 1]$, queda reemplazada por esta formulación directa.

Para el análisis de la clasificación se construyó la matriz de confusion global y se calcularon los valores de precision, sensibilidad (recall) y F1 por cada clase, así como su promedio macro. Los intervalos de confianza para las proporciones se estimaron mediante el método de Wilson, recomendado para muestras moderadas (Wilson, 1927). Todos los calculos se realizaron mediante la biblioteca SciPy del ecosistema Python (Virtanen et al. 2020).

4.8. Amenazas a la validez

Se identificaron y trataron explicitamente cuatro amenazas a la validez del estudio.

La primera, una amenaza a la validez interna por efecto de aprendizaje del operador humano sobre el corpus, se acotó parcialmente mediante la ejecución secuencial pareada descrita en la Subsección 4.2, que mide el mismo caso bajo ambas condiciones. La rotación de operadores entre las dos mitades del corpus no elimina esta amenaza: con dos operadores y dos mitades, la asignación del operador queda confundida con la mitad del corpus y el efecto de operador no es separable del de aprendizaje. Se declara, por lo tanto, como una limitación no resuelta del diseño, y no como una mitigación efectiva de la amenaza.

La segunda, una amenaza a la validez de constructo por la subjetividad inherente a la categorizacion de los incidentes, se mitigo mediante el doble etiquetado independiente, el calculo del coeficiente Kappa de Cohen y la resolución de discrepancias por consenso supervisado. El valor obtenido ($\kappa = 0{,}87$) corresponde a un acuerdo casi perfecto según los rangos de Landis y Koch (Landis & Koch, 1977) y respalda la solidez del constructo de medición. Cabe precisar que los dos analistas etiquetadores son las mismas personas que operaron el brazo manual (Subsección 4.4): esta coincidencia no invalida el acuerdo inter-evaluador, que mide la concordancia entre ambos etiquetadores, pero acota la independencia del referente y se asume como una limitación explícita de la validez de constructo.

La tercera, una amenaza a la validez externa derivada del idioma y del dominio organizacional, se reconoce como limitación explicita del estudio: los resultados no son extrapolables sin nuevas validaciones a corpus en otros idiomas, en otras organizaciones o en otros sectores de la economia.

La cuarta, una amenaza a la validez de conclusión derivada del tamaño moderado de la muestra ($n = 200$), se evaluó mediante un análisis de potencia estadística a priori. Para el contraste principal —la prueba de Wilcoxon de rangos con signo sobre las mediciones pareadas, bilateral, con $\alpha = 0{,}05$— y una potencia objetivo de $0{,}80$, el efecto mínimo detectable con $n = 200$ es un tamaño del efecto estandarizado de aproximadamente $d_z \approx 0{,}20$ en la aproximación normal ($\approx 0{,}21$ al ajustar por la eficiencia relativa asintótica de la prueba de rangos con signo frente a la prueba t pareada). La reducción de tiempo efectivamente observada (71,2 % sobre la media) supera holgadamente ese mínimo, de modo que el diseño posee potencia suficiente para el contraste de tiempos. El riesgo asociado al tamaño muestral se concentra, en cambio, en la precisión de las estimaciones de clasificación (exactitud por clase, macro-F1), que se reportan con intervalos de confianza de Wilson. La amenaza se trata, además, con la elección de pruebas no parametricas robustas frente a tamaños muestrales pequeños y a desviaciones de la normalidad (Hernández Sampieri & Mendoza Torres, 2018).

4.9. Gestión del proyecto bajo enfoque Scrumban (método de construcción del artefacto)

El presente apartado describe el metodo de construccion del artefacto, no el metodo de investigacion. El diseño experimental, el muestreo, la construcción del corpus y el análisis estadístico —esto es, el método del estudio— quedaron definidos en las Secciones 4.1 a 4.8; la

gestion del proyecto bajo Scrumban concierne exclusivamente a cómo se construyó el sistema y se documenta aquí por trazabilidad, sin constituir la metodología de la investigación.

La construcción del sistema se organizo bajo un esquema Scrumban, combinando la planificación por iteraciones propia de Scrum con la gestión continua del flujo de trabajo caracteristica del método Kanban (Ladas, 2009). Se ejecutaron seis iteraciones de dos semanas cada una, totalizando 12 semanas de desarrollo efectivo:

Iteracion 1: Elicitacion de requisitos y diseño preliminar de la arquitectura.

Iteracion 2: Construccion del modulo Python: modelo de datos, repositorios y servicios.

Iteracion 3: Configuracion inicial del flujo N8N y primeras integraciones.

Iteracion 4: Integracion del canal de telefonia y persistencia en PostgreSQL.

Iteracion 5: Validacion funcional y ajuste fino del clasificador hibrido.

Iteracion 6: Validacion experimental y documentación final del sistema.

La distribucion de roles asigno la coordinacion general y la integración de componentes a Luca Gomez, el desarrollo del modulo Python y el modelado de la base de datos a Carla Bustos, y la configuración del flujo N8N junto con la integración telefonica mediante Twilio a Gonzalo Sevilla, bajo supervisión académica continua del director del trabajo, Prof. Alberto Cortez.

El tablero Kanban se gestiono mediante GitHub Projects, con seguimiento diario del estado de las tareas y reuniones de planificación al inicio de cada iteracion. Las definiciones de terminado (*Definition of Done*) incluyeron, para cada tarea, la aprobacion de las pruebas unitarias correspondientes, la revisión de código por pares y la actualizacion de la documentación asociada.

5. Arquitectura del sistema

5.1. Visión general

El sistema propuesto se estructura como una arquitectura distribuida y modular compuesta por cinco capas claramente diferenciadas, siguiendo los principios de cohesion alta y acoplamiento bajo descritos por Pressman y Maxim (2020). En el diseño se previó proteger la comunicación con el exterior mediante TLS 1.2/1.3 a nivel de un proxy inverso (Nginx); el despliegue publicado para la validación experimental no incluyó dicho proxy, por lo que la terminación TLS corresponde al diseño y no a una capacidad verificada en la instancia publicada. La comunicación interna entre los servicios del sistema (N8N, backend, PostgreSQL, Redis) se realiza sobre la red aislada de Docker, que constituye el perímetro de confianza. Todas las interfaces entre capas utilizan el estilo arquitectónico REST con cuerpos JSON para el intercambio estructurado de datos (Fielding & Taylor, 2002). Esta separación de responsabilidades facilita el reemplazo independiente de cualquier componente sin afectar a los demas.

La Tabla 3 sintetiza las cinco capas y sus responsabilidades específicas, y la Figura 1 detalla la organización en capas del módulo de procesamiento.

Tabla 3. Capas funcionales de la arquitectura del sistema

Capa	Componentes y responsabilidades
1. Canales de entrada	Casilla de correo electrónico monitoreada mediante IMAP/SMTP, formulario web implementado como SPA React y número virtual de Twilio con transcripción automática del habla.
2. Orquestacion	Motor N8N 2.11.2 desplegado en contenedor Docker autoalojado. Normaliza la entrada y coordina la invocacion a las capas inferiores.
3. Procesamiento	Servicio Python sobre FastAPI 0.115 ejecutado bajo Uvicorn. Aplica clasificador hibrido en dos etapas (reglas + LLM) y expone una API REST documentada con OpenAPI 3.1.
4. Inferencia	Modelo Gemini 3.6 Flash de Google, invocado únicamente cuando el filtro deterministico previo no alcanza el umbral de confianza preestablecido.
5. Persistencia	PostgreSQL 15.5 desplegado en contenedor con volumen persistente y respaldos diarios. Almacena los incidentes y la trazabilidad de cada decision del clasificador.

Fuente: elaboración propia.

La trazabilidad operativa se garantiza mediante registros estructurados en cada capa, accesibles desde la capa de orquestación. La Figura 2 representa esquematicamente el flujo de información entre capas.

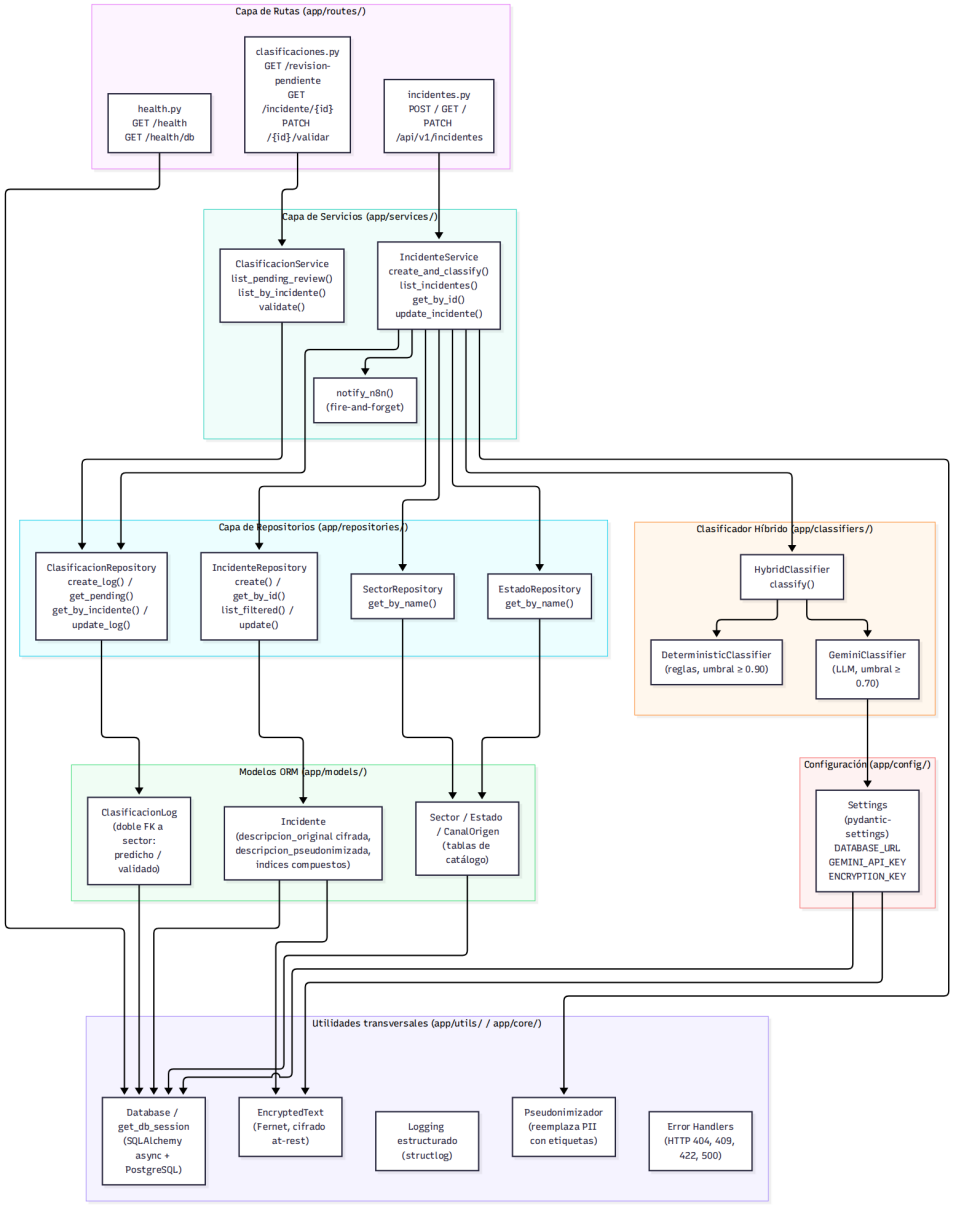


Figura 1. Diagrama de componentes del módulo Python organizado en capas (routes, services, repositories, classifiers).

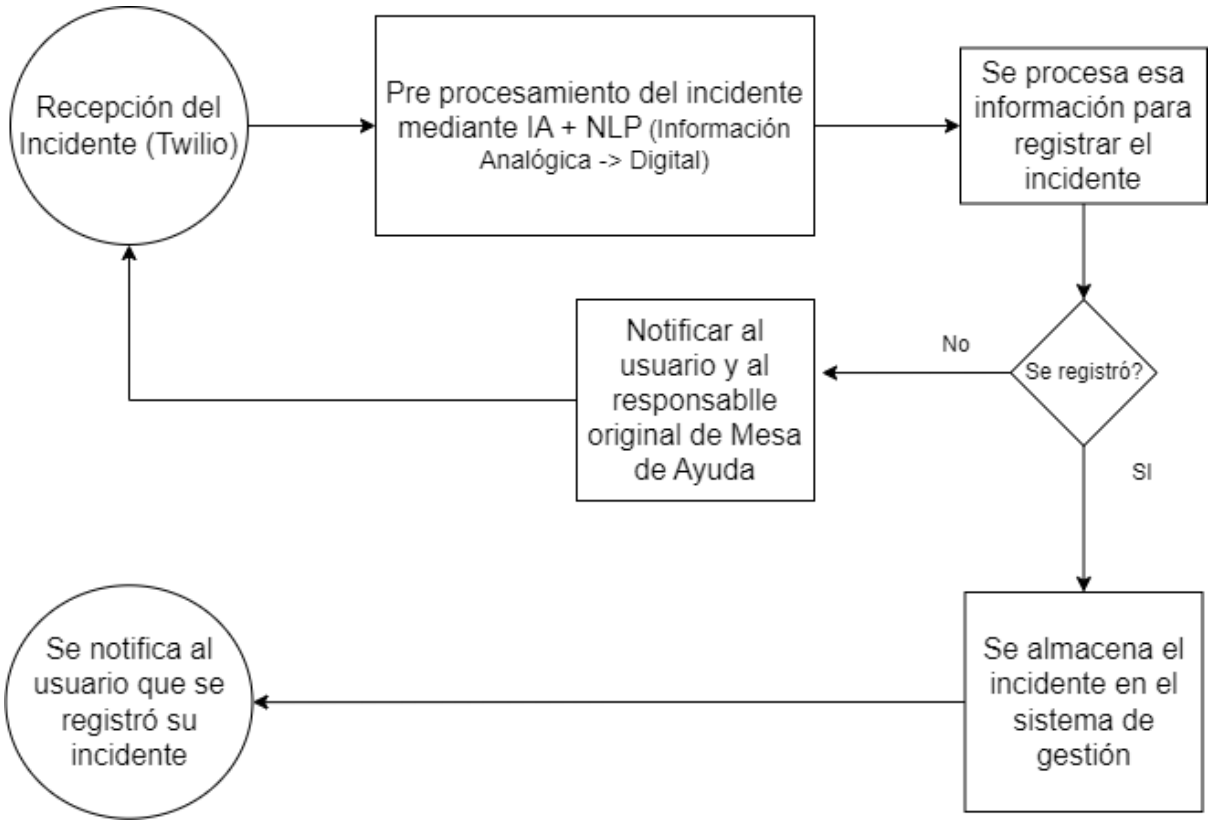


Figura 2. Diagrama de arquitectura del sistema. La version completa en notacion UML se detalla en el Anexo A y en las fuentes Mermaid del repositorio (`docs/diagrams/`).

5.2. Capa de canales de entrada

La capa de canales de entrada habilita tres vias paralelas a través de las cuales un usuario puede reportar un incidente. La primera es el correo electrónico, monitoreado mediante IMAP/SMTP que detecta nuevos mensajes en una casilla institucional dedicada. La segunda via es un formulario web implementado como aplicación React de página única (SPA) que se comunica directamente con la API REST del módulo de procesamiento. La autenticación se realiza mediante tokens JWT (JSON Web Tokens) con usuario y contraseña; la autenticación única corporativa (SSO) se prevé como evolución para entornos productivos (Sección 10). La tercera via es la llamada telefónica, en la cual el usuario marca un número virtual provisto por Twilio, recibe instrucciones por voz pregrabadas y deja su solicitud; la grabación es transcrita automáticamente por el servicio de reconocimiento del habla del proveedor y enviada al flujo N8N mediante webhook posterior al cuelgue. El script TwiML que define el flujo de la llamada —incluyendo el mensaje de bienvenida en español rioplatense y la configuración de grabación— se implementa en el modulo de backend del proyecto (`app/cost_guard/twiml.py`), versionado en el repositorio. Esta diversidad de canales amplía la accesibilidad del sistema y reduce

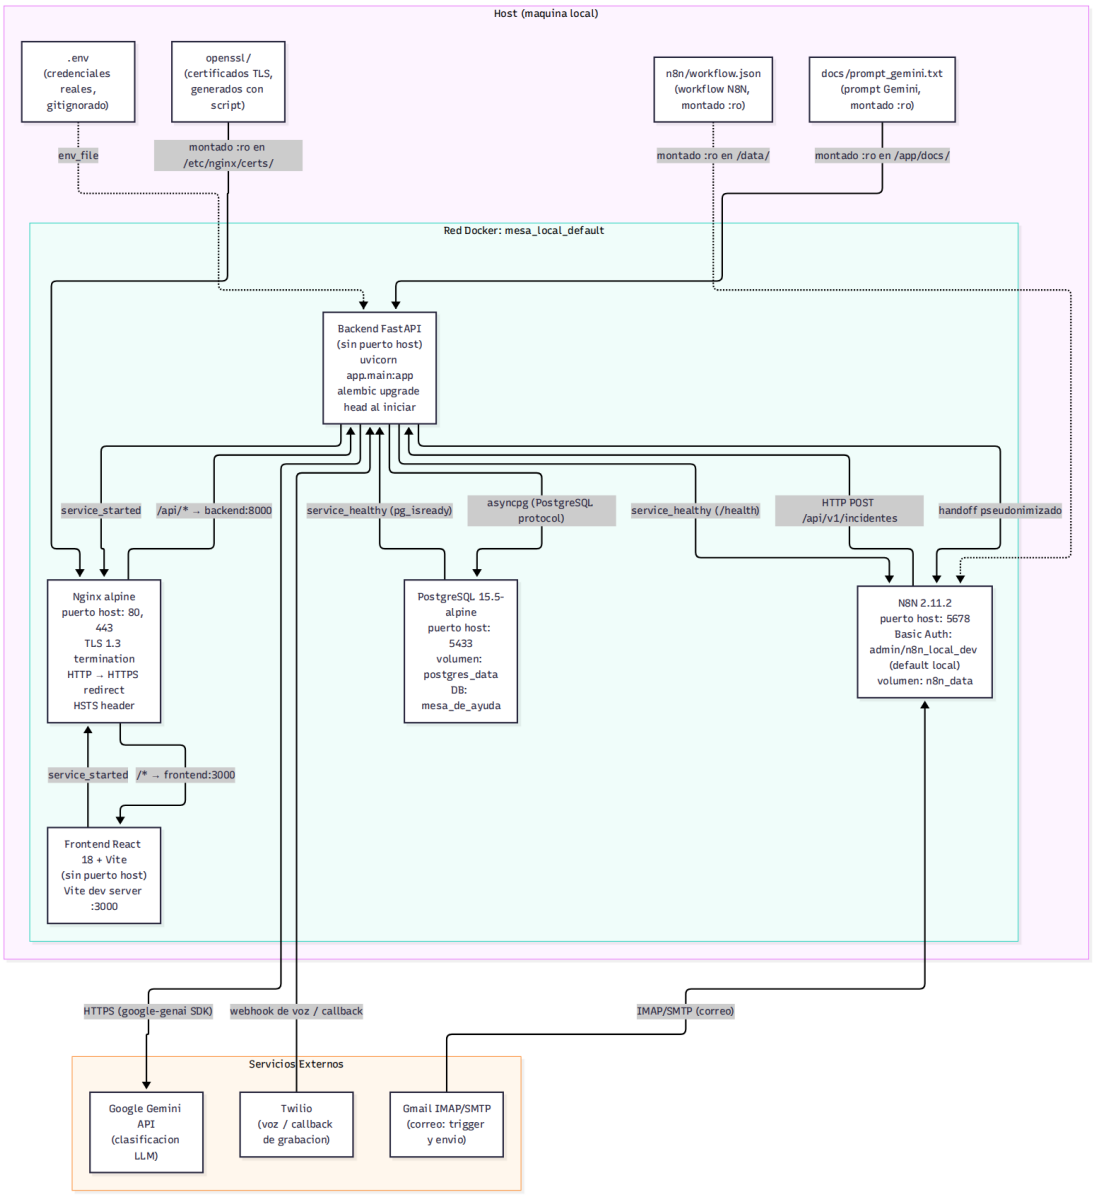


Figura 3. Diagrama de despliegue del entorno local. Servicios, red Docker, volumenes y servicios externos.

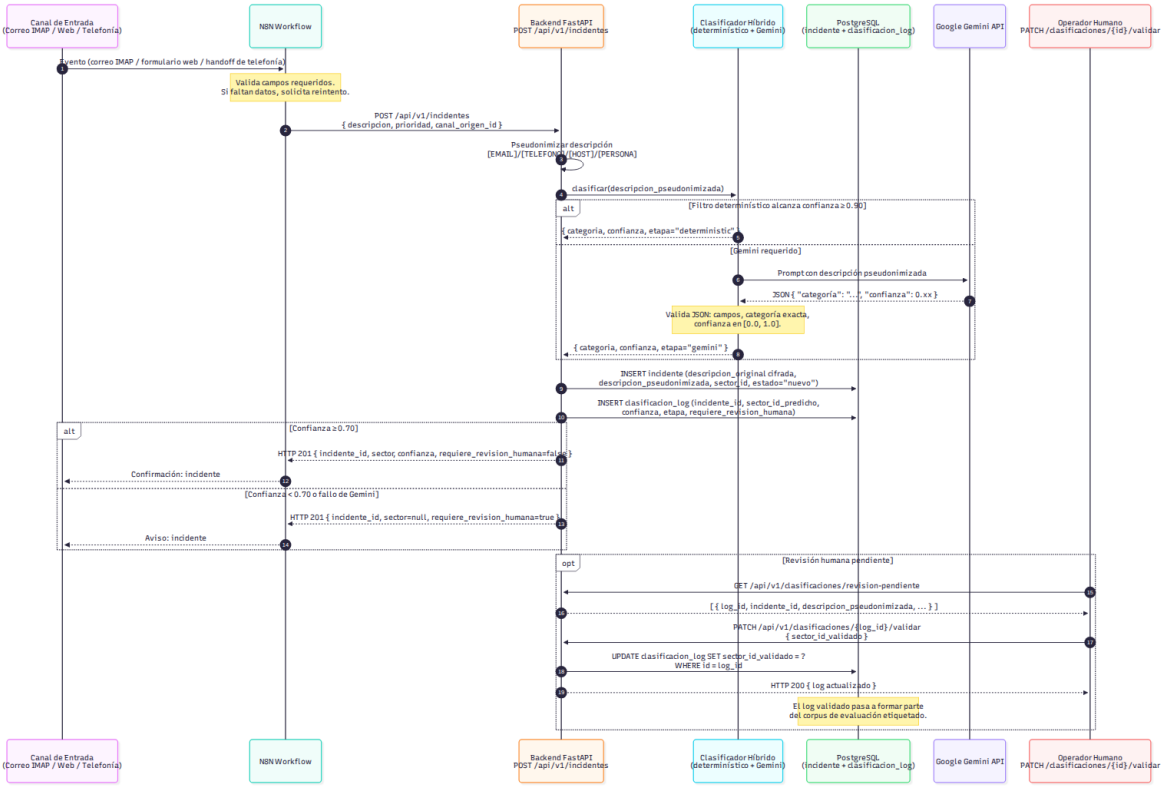


Figura 4. Diagrama de secuencia del flujo extremo a extremo de un incidente, desde el canal de entrada hasta la confirmacion o la derivacion a revision humana.

las barreras al reporte oportuno.

5.3. Capa de orquestación

N8N actua como orquestador principal del flujo de trabajo: recibe la entrada de cada canal, la normaliza en una estructura unificada y coordina la clasificación y la persistencia del incidente. La descripción operativa detallada del flujo —los disparadores por canal, la estructura normalizada con identificador único (UUID v4), la invocación al modulo Python y la persistencia del ticket— se desarrolla en la Subsección 6.3. Los registros de cada ejecución se conservan durante 30 días para fines de auditoria y diagnostico operativo; constituyen un conjunto de datos distinto de los incidentes, cuya retención se rige por la política declarada en la Subsección 11.2.

5.4. Capa de procesamiento

El modulo de procesamiento se implementó como un servicio web ligero utilizando el marco FastAPI 0.115, expuesto sobre un servidor ASGI Uvicorn 0.30.6 (Tiangolo, 2024). La eleccion de FastAPI obedece a su soporte nativo de validación de esquemas mediante Pydan-

tic, su rendimiento competitivo y su documentación automática conforme a la especificación OpenAPI 3.1.

Las dependencias del modulo se organizan por capas funcionales claramente delimitadas. La capa de acceso a datos utiliza SQLAlchemy 2.0 como mapeador objeto-relacional (ORM) y asyncpg como driver asincrónico para PostgreSQL, en coherencia con la operación no bloqueante de FastAPI. La capa de procesamiento textual emplea las bibliotecas regex y unicodedata de la biblioteca estandar de Python para normalización ortografica y eliminacion de signos diacriticos. La capa de inferencia se comunica con la interfaz oficial del modelo `gemini-3.6-flash` mediante el cliente google-genai >=2.0 (SDK unificado de Google Generative AI), con los siguientes parámetros de configuración: temperatura $= 0{,}3$, top_p $= 0{,}9$, max_tokens $= 100$ y timeout $= 10$ s. Estos valores corresponden a la configuración adoptada para el despliegue y no a un procedimiento de optimización documentado; su calibración sistemática frente a valores alternativos se plantea como trabajo futuro (Sección 10). Las bibliotecas NumPy 2.1 y Pandas 2.2 se utilizan exclusivamente para la generación de reportes agregados de desempeño y no participan del flujo de procesamiento individual de incidentes.

5.5. Subsistema de clasificación híbrido

El subsistema de clasificación adopta un enfoque hibrido en dos etapas, caracteristica que lo diferencia de aproximaciones puramente basadas en modelo externo. La primera etapa aplica un filtro deterministico basado en expresiones regulares y diccionarios de terminos del dominio. Tanto la construcción del filtro deterministico como el ajuste del prompt se realizaron sin acceso al corpus de validación, para evitar fuga de datos (véase Subsección 8.1). La especificación detallada del prompt y de los parámetros de configuración del modelo se documenta en el Anexo H.

Este filtro es capaz de derivar de forma inmediata aquellos incidentes que contienen marcadores inequivocos. Por ejemplo, la presencia simultanea de las palabras `impresora`, `papel` y `atasco` sugiere con alta certeza una categoría de Soporte Tecnico. Cuando este filtro inicial alcanza un umbral de confianza superior al 90 %, la decision se toma sin consultar al modelo externo, lo que reduce sustancialmente la latencia y el costo de inferencia.

La segunda etapa, activada únicamente cuando el filtro deterministico no alcanza el umbral, consulta al modelo Gemini 3.6 Flash mediante un prompt estructurado en espanol que incluye una breve descripción de cada categoría, ejemplos representativos balanceados

y la solicitud explicita de devolver la categoría asignada y un valor numerico de confianza entre 0 y 1 en formato JSON estricto. La justificación de este diseño compositivo radica en aprovechar la rapidez del filtro deterministico para los casos triviales y reservar la capacidad semántica del modelo de lenguaje grande para los casos ambiguos o de redacción atipica, optimizando la relacion entre exactitud, costo y latencia. El pipeline completo comprende tres etapas, aplicadas en orden: (1) el filtro deterministico, (2) el modelo Gemini y (3) una etapa de reserva (*fallback*) que asigna una categoría por defecto y marca el caso para revisión humana cuando las etapas previas no producen una salida válida. El desglose de casos resueltos por cada etapa del pipeline sobre el corpus de validación se reporta en la Sección 7.

El camino de clasificación es único para los tres canales de entrada. Tanto el correo electrónico y el formulario web como la llamada telefónica resuelven su sector mediante esta misma cascada híbrida, aplicada sobre la descripción pseudonimizada del incidente: ningún canal aporta una clasificación precalculada que omita la cascada, de modo que las reglas determinísticas, el prompt y las reglas de frontera se ajustan una sola vez para todo el sistema. El prompt único incorpora reglas de desambiguación de frontera entre sectores adyacentes (acceder o iniciar sesión en una aplicación se orienta a Soporte Tecnico Software; la digitalización, el escaner o la impresora se orientan a Soporte Tecnico Hardware; el servidor, la red, SMTP o una VM se orientan a Sistemas), redactadas con los cinco strings canónicos sin tildes. Desde el punto de vista del costo, la clasificación telefónica dejó de computarse sobre una invocación incondicional al modelo externo: el canal atraviesa el filtro determinístico y solo escala al modelo semántico cuando la cascada lo requiere, momento en el cual la reserva de costo se imputa a la superficie de inferencia del backend.

5.6. Modelo de datos

La persistencia se realiza sobre PostgreSQL 15.5, desplegado en contenedor Docker bajo configuración de respaldo diario y replicación fisica opcional para entornos productivos (The PostgreSQL Global Development Group, 2024). El modelo de datos se organiza alrededor de siete entidades principales, descritas en la Tabla 4.

El canal de origen constituye una entrada opcional del backend: el esquema de creación de incidentes acepta `canal_origen_id` como campo anulable, de modo que un incidente puede registrarse sin canal conocido. La entidad central `incidente` referencia mediante claves foraneas a los catalogos de sector, estado y canal de origen, y mantiene una relacion

Tabla 4. Entidades principales del modelo de datos

Tabla	Atributos clave	Descripcion
`incidente`	id_incidente (PK), canal_origen_id (FK), id_sector (FK), id_estado (FK)	Tabla central: fecha de creacion, descripción cruda pseudonimizada, prioridad, sector asignado y estado actual.
`sector`	id_sector (PK), nombre	Catalogo de los cinco sectores canónicos: Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos y Sistemas.
`estado`	id_estado (PK), nombre	Catalogo de estados: nuevo, en proceso, en espera, resuelto y cerrado.
`canal_origen`	id (PK), nombre	Catalogo de canales: correo, formulario web y llamada telefonica.
`clasificacion_log`	id_log (PK), id_incidente (FK), categoría_predicha, confianza, categoría_validada	Registro de cada decision del clasificador, con categoría predicha, confianza asociada y categoría validada por el sector responsable.
`users`	id (PK), username (UNIQUE), hashed_password, is_active	Almacena credenciales de operadores para autenticacion JWT.
`directorio_empleados`	id (PK), legajo (UNIQUE), email (UNIQUE), telefono, sector_id (FK), rol, activo, fecha_baja, user_id (FK)	Directorio institucional de empleados para resolución de contacto y notificación. Datos de contacto almacenados en texto plano para su auditabilidad directa; el campo `rol` distingue usuario final, operador y administrador del directorio. La columna `fecha_baja` registra la desactivación y sostiene la retención (relación laboral activa más un año).

Fuente: elaboración propia.

uno a muchos con `clasificacion_log` para preservar la trazabilidad histórica de las decisiones del clasificador. El número de incidente que se comunica al usuario corresponde al identificador único del registro, formateado para su legibilidad; la incorporación de un prefijo configurable se prevé como evolución futura (Sección 10). El esquema completo, incluyendo restricciones de integridad referencial e indices secundarios, se documenta en el Anexo C. El directorio de empleados (`directorio_empleado`) se vincula opcionalmente con la tabla de autenticación mediante `user_id` y referencia el catálogo de sectores mediante `sector_id`; su campo `rol` distingue al usuario final, al operador y al administrador del directorio.

5.7. Contrato de la interfaz REST

La interfaz de programacion de aplicaciones expuesta por el modulo Python sigue el estilo arquitectonico REST (Fielding & Taylor, 2002), con representación de recursos mediante identificadores uniformes, uso semántico de los métodos HTTP estandar y comunicación sin estado del lado del servidor. La autenticacion se realiza mediante tokens JWT (JSON Web Tokens) firmados con HS256, validados en cada solicitud mediante el esquema OAuth2PasswordBearer de FastAPI. La Tabla 5 sintetiza los principales puntos de entrada.

Los códigos de estado HTTP se utilizan conforme a su semántica original: 201 cuando un recurso se crea exitosamente, 200 cuando una consulta se atiende con éxito, 400 cuando los datos de entrada no validan el esquema esperado, 401 cuando la autenticacion falla, y 500 cuando ocurre un error interno no recuperable. La Tabla 5 no es exhaustiva: reúne los grupos principales de puntos de entrada, mientras que el contrato completo de la interfaz —que comprende la totalidad de las rutas expuestas— se documenta en el Anexo D y se versiona en `docs/openapi.json`; la especificación OpenAPI 3.1 la genera FastAPI automáticamente.

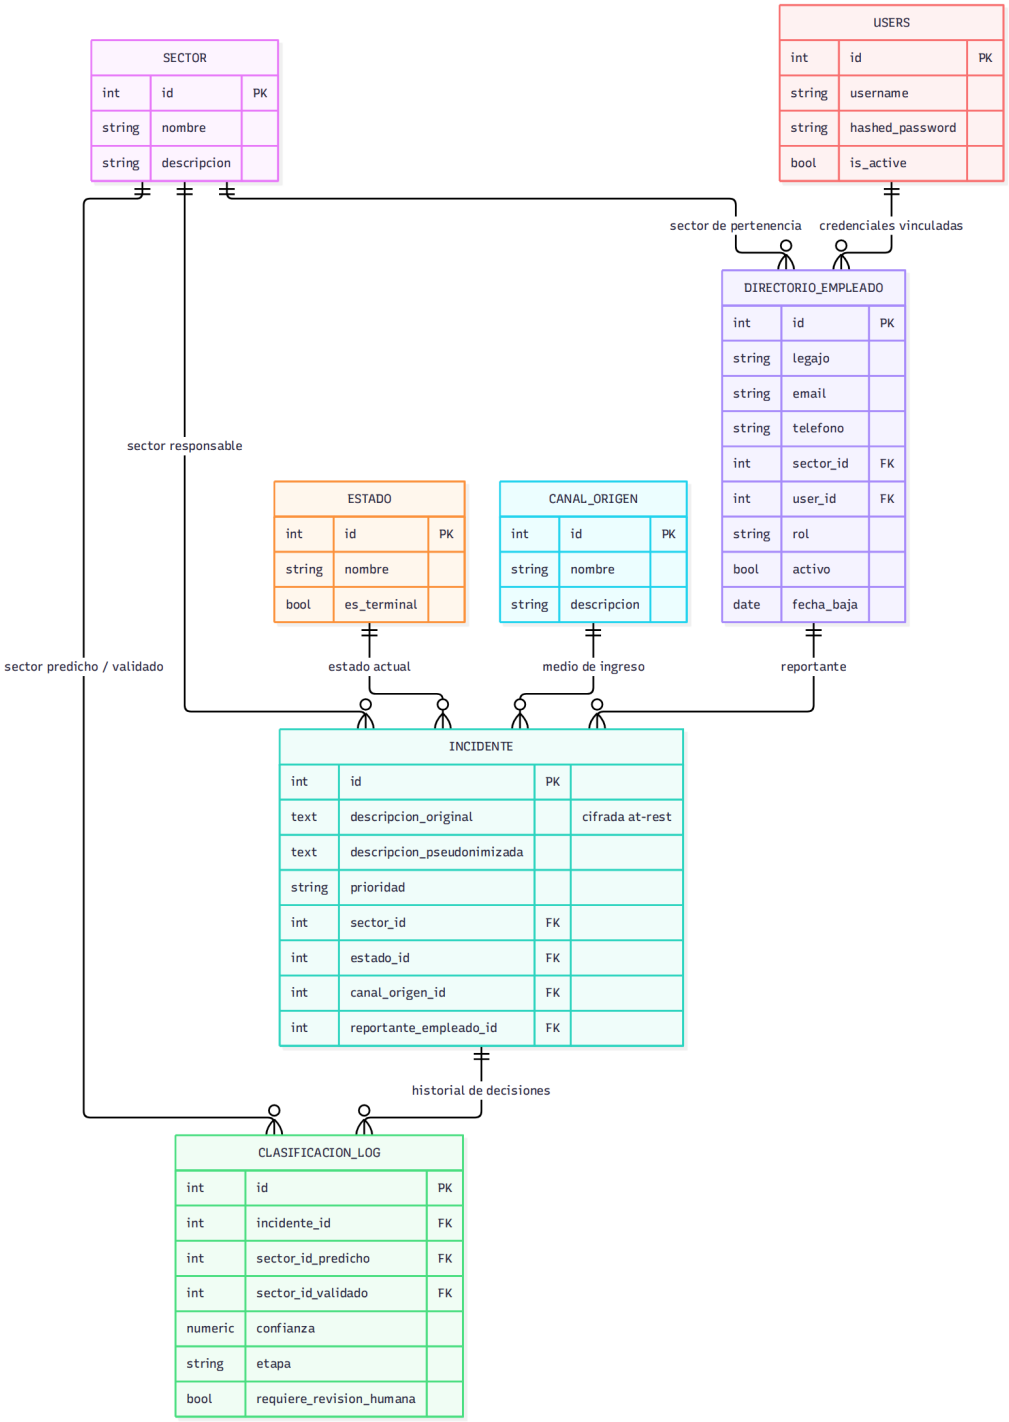


Figura 5. Diagrama entidad-relación de las siete entidades principales del modelo de datos. El esquema completo se documenta en el Anexo C.

Tabla 5. Puntos de entrada principales de la interfaz REST

Metodo	Ruta	Codigo	Funcion
Autenticacion			
POST	`/api/v1/auth/login`, `/refresh`, `/logout`	200 OK	Inicio y renovacion de sesion y cierre de sesion de operadores.
GET	`/api/v1/auth/me`	200 OK	Recupera el perfil del operador autenticado.
Incidentes			
POST	`/api/v1/incidentes`	201 Created	Crea un nuevo ticket y devuelve el identificador generado.
GET	`/api/v1/incidentes/{id}`	200 OK	Recupera la información de un ticket por su identificador.
PATCH	`/api/v1/incidentes/{id}`	200 OK	Actualiza los campos editables de un ticket.
Clasificaciones			
GET	`/api/v1/clasificaciones/incidente/{id}`	200 OK	Recupera la trazabilidad de la clasificación de un incidente.
GET	`/api/v1/clasificaciones/revision-pendiente`	200 OK	Lista los casos derivados a revision humana.
PATCH	`/api/v1/clasificaciones/{log_id}/validar`	200 OK	Registra la categoría validada por el sector responsable.
Estadisticas			
GET	`/api/v1/estadisticas/resumen`, `/tendencias`	200 OK	Agregados y series temporales para el dashboard.
Salud			
GET	`/health` y `/health/db`	200 OK	Verificacion de salud del servicio para monitoreo externo.

Fuente: elaboración propia.

6. Implementación

6.1. Entorno de despliegue y dependencias

La implementación del sistema se llevó a cabo combinando componentes de código abierto —Python, FastAPI y PostgreSQL— con N8N, cuya licencia Sustainable Use (*fair-code*) permite auditar su código fuente, con el objetivo de garantizar la portabilidad, la reproducibilidad y la auditoría de seguridad de la solución en organizaciones medianas. Toda la infraestructura se encapsula mediante contenedores Docker, orquestados localmente por Docker Compose para los entornos de desarrollo y preproduccion; la migración a un cluster Kubernetes 1.30 para el entorno productivo se plantea como trabajo futuro y no cuenta con manifiestos de despliegue en esta versión (Sección 10).

Las versiones específicas de los componentes son: N8N 2.11.2, Python 3.12, PostgreSQL 15.5 con volumen persistente, FastAPI 0.115, Uvicorn 0.30.6, SQLAlchemy 2.0, y el cliente google-genai >=2.0 (SDK unificado de Google Generative AI) para la comunicación con el modelo `gemini-3.6-flash`. Todos los servicios se despliegan sobre imagenes Docker oficiales (`python:3.12-slim` y `postgres:15.5-alpine`). La gestión de dependencias del modulo Python se realiza mediante un archivo `requirements.txt` con versiones fijadas (*pinned*) para garantizar la reproducibilidad de las compilaciones en distintos entornos.

6.2. Construcción del módulo Python

La selección del marco de trabajo para el servicio de procesamiento implico la evaluación de tres alternativas: Flask, Django REST Framework y FastAPI. Flask, ampliamente adoptado en el ecosistema Python por su simplicidad, carece de validación nativa de esquemas y de generación automática de documentación OpenAPI, funcionalidades que el proyecto requeria para garantizar la calidad de la interfaz REST. Django REST Framework, por su parte, ofrece un conjunto completo de herramientas para la construcción de interfaces de programacion de aplicaciones, pero su modelo de operación sincronico y la inclusion de componentes no requeridos por el proyecto —tales como el ORM de Django y el motor de plantillas— incrementaban la complejidad de la base de código sin aportar beneficios funcionales para una arquitectura de microservicio acotado. FastAPI 0.115, sustentado sobre el servidor ASGI Uvicorn 0.30.6, ofrece tres ventajas determinantes para el proyecto: validación automática de esquemas de entrada y salida mediante Pydantic v2, generación de documentación interactiva conforme a

la especificación OpenAPI 3.1 sin configuración adicional, y operación asincronica nativa que permite manejar las llamadas concurrentes desde N8N sin bloquear el hilo de ejecución principal (Tiangolo, 2024). La madurez del ecosistema de FastAPI, su adopción creciente en la industria y la disponibilidad de documentación exhaustiva en espanol consolidaron la decision.

El modulo Python expone su contrato REST organizado en capas, según la estructura descrita en la Sección 5, con una separación clara entre responsabilidades:

- **models**: entidades del modelo de dominio mapeadas mediante SQLAlchemy 2.0.
- **schemas**: modelos de validación y serializacion con Pydantic v2.
- **services**: lógica de aplicación (IncidenteService, ClasificacionService).
- **repositories**: acceso a datos, aislando las consultas SQL del resto de la aplicación.
- **classifiers**: lógica del clasificador hibrido (filtro deterministico + LLM).
- **routes**: enrutadores REST que delegan en los servicios correspondientes.
- **core**: configuración de base de datos, manejo de errores y logging estructurado.

La construcción se realiza bajo un esquema de inyeccion de dependencias gestionado por las funcionalidades nativas de FastAPI (`Depends`), lo que facilita el reemplazo de implementaciones durante la ejecución de pruebas unitarias y de integración. Esta arquitectura permite, por ejemplo, sustituir el clasificador real por una implementación simulada durante las pruebas sin modificar el código de los servicios que lo consumen. La gestión de credenciales se realiza exclusivamente mediante variables de entorno, en línea con el principio de configuración de la metodología Twelve-Factor App (Wiggins, 2017).

6.3. Construcción del flujo en N8N

El flujo de orquestación implementado en N8N comprende 29 nodos (26 operativos más 3 notas adhesivas), organizados en cinco etapas lógicas pero con ramificaciones específicas por canal. La eleccion de N8N como plataforma de orquestación, frente a alternativas como Apache Airflow, Zapier o Make, obedecio a tres criterios concurrentes. El primero, de naturaleza operativa, radica en que N8N admite despliegue completamente autoalojado bajo Docker, manteniendo los flujos de procesamiento y los datos dentro del perimetro organizacional. Zapier y Make operan exclusivamente como servicios en la nube, lo que las descarta en escenarios donde el procesamiento de datos sensibles exige control de infraestructura. Apache Airflow, aunque autoalojable, disena sus flujos como grafos aciclicos dirigidos programados por intervalos temporales; ese paradigma resulta adecuado para procesos de extracción, transfor-

mación y carga de datos pero forzadamente inadecuado para un sistema reactivo que debe responder en tiempo real a eventos de entrada no programados (Apache Software Foundation, 2024). El segundo criterio refiere al modelo de construcción visual que N8N ofrece sobre un editor de nodos arrastrables: la curva de aprendizaje de esta interfaz es sustancialmente menor que la de alternativas centradas en definición programatica de flujos, lo que permitió al equipo concentrar el esfuerzo en la lógica de negocio antes que en la sintaxis de definición de procesos. El tercer criterio se vincula con la licencia de código fuente disponible (*fair-code*) que habilita la auditoria de seguridad del nucleo de orquestación (n8n GmbH, 2024).

La composición de los 29 nodos responde a un patrón de procesamiento en cinco etapas lógicas que se replica para cada canal, con ramificaciones específicas según el medio de ingreso:

1. **Recepcion**: Tres disparadores (*triggers*) reciben las entradas desde correo electrónico (IMAP), formulario web (Webhook) y telefonia (trigger de Twilio). La decision de separar los disparadores por canal, en lugar de unificar la recepción mediante un único webhook con discriminacion interna, se fundamenta en la necesidad de preservar la configuración de autenticacion y los parámetros de reintento específicos de cada protocolo.
2. **Normalizacion**: Un nodo de transformación (*Function*) homogeniza la estructura del mensaje en un formato unificado (Hohpe & Woolf, 2003) con campos de identificador único (UUID v4), marca temporal, canal de origen, remitente y descripción textual normalizada. Esta etapa elimina las diferencias de formato entre canales y garantiza que las capas posteriores procesen siempre la misma estructura de datos, independientemente de la via de entrada.
3. **Clasificacion y persistencia**: Un nodo HTTP invoca el endpoint `POST /api/v1/incidentes` del modulo Python enviando la descripción textual junto con los metadatos del canal. La clasificación no se expone como punto de entrada independiente sino que se encuentra embebida dentro de la creación del incidente: el clasificador híbrido se invoca internamente durante la creación, que persiste el ticket en la misma operación, y la respuesta incluye el identificador del ticket, la categoría asignada y el indicador de revisión humana (`requiere_revision_humana`), que el backend activa cuando la confianza del clasificador resulta inferior al umbral de 0,70. El canal telefónico no constituye una excepción: su clasificación se resuelve dentro del backend

mediante la misma cascada híbrida que los canales escritos, aplicada sobre la descripción pseudonimizada, y el cuerpo de la creación no transporta una clasificación precalculada.

4. **Evaluacion**: Aguas abajo del POST, un nodo condicional (*IF*) evalua el indicador de revisión humana devuelto por el backend. Cuando el indicador esta activo —es decir, cuando la confianza del clasificador fue inferior al umbral de 0,70— el flujo notifica al operador designado por correo electrónico y registra el evento en la auditoria; cuando no lo esta, el flujo continua automáticamente con las confirmaciones al usuario. Con anterioridad al POST, un nodo de validación de entrada verifica que la descripción no este vacía y respete la longitud mínima y máxima aceptada por el backend, de modo que una entrada inválida no genera un incidente. El umbral de 0,70 opera como unico disparador automático de revisión humana; su calibración se analiza en la Sección 7.4.
5. **Notificacion**: Tres nodos posteriores notifican al usuario por el canal correspondiente y registran la ejecución en el sistema de auditoria; la persistencia del ticket ocurre en el mismo POST de creación, que almacena el incidente y su clasificación en una sola operación. El paralelismo de la notificacion garantiza que la demora de un canal (por ejemplo, el envio de correo electrónico) no bloquee el registro de auditoria ni la confirmacion por otros medios.

El canal telefónico incorpora un nodo adicional de normalización y validación que prepara la transcripción pseudonimizada antes de incorporarla al flujo principal, pero no determina el sector persistido: la rama de clasificación por agente LLM basada en LangChain fue retirada (decisión OQ1 = A del change c-72). La clasificación del incidente telefónico se rige por el diseño unificado descrito en la Subsección 5.5.

La trazabilidad completa de cada ejecución se preserva almacenando los identificadores de nodo, las marcas temporales de entrada y salida de cada etapa, y los datos de entrada y salida de cada paso del flujo, generando un historial auditable que resulta especialmente valioso en contextos donde la Ley 25.326 exige demostrar el camino recorrido por los datos personales (Honorable Congreso de la Nación Argentina, 2000). La exportación completa del flujo en formato JSON se incluye en el Anexo E.

6.4. Integración del canal telefónico

La integración con Twilio se realizó mediante el producto Programmable Voice, complementado con la transcripción automática nativa. El flujo telefonico opera de la siguiente manera: el usuario marca un número virtual asignado a la organización; un script TwiML reproduce un mensaje de bienvenida en espanol rioplatense y solicita al usuario describir su problema durante un máximo de 45 segundos; la grabacion finaliza cuando el usuario presiona la tecla numeral (#) o transcurrido el tiempo máximo; la grabacion se envia al servicio de transcripción de Twilio; y, una vez transcrito el contenido, Twilio invoca un webhook expuesto por N8N con la transcripción textual. A partir de ese punto, el flujo continua de manera identica a la de los canales escritos.

El tiempo de registro del canal telefonico —medido, para igualar la base de comparación con el flujo manual, desde el inicio de la llamada hasta la confirmacion del número de incidente— promedió 20,1 segundos sobre los 81 casos del corpus. Ese total comprende la duracion de la llamada grabada y la latencia de procesamiento posterior al cuelgue; el corpus registra la suma de ambos tramos, no su descomposicion por etapa (transcripción, clasificación y persistencia), de modo que no se publica un desglose de latencias que el repositorio no permite reproducir con tamaño de muestra y procedimiento de medición. La grabación está acotada a un máximo de 45 s, de modo que el tiempo telefónico reportado constituye una cota inferior de la duración real de la llamada.

Unificada la clasificación, el canal telefónico dejó de reservar la superficie de costo asociada a la invocación incondicional del agente en N8N. La clasificación pasa a computarse en la superficie de inferencia del backend y solo cuando la cascada híbrida escala al modelo semántico; los casos resueltos por el filtro determinístico no consumen cuota de Gemini. Este traslado de la superficie de costo corresponde a la decisión OQ2 = A del change c-72 y elimina la reserva telefónica del proveedor invocado desde N8N.

6.5. Desafíos de integración

La implementación del sistema enfrento tres desafios de integración que merecen documentación explicita por su potencial utilidad en replicaciones futuras.

El primer desafio se presentó en la comunicación asincronica entre N8N y el servicio de clasificación. El nodo HTTP de N8N invoca el endpoint de clasificación de manera sincronica y espera la respuesta del servidor antes de continuar el flujo. Esta arquitectura, aunque simple

de implementar, introduce un punto de fallo único: si el servicio Python no responde dentro del tiempo de espera configurado en el nodo HTTP, el flujo completo se detiene y el incidente queda sin procesar. Esta limitación se asume como conocida en la versión evaluada: no se implementó un mecanismo de reintento con retroceso exponencial ni una cola de respaldo en el servicio Python que retuviera los mensajes durante ventanas de saturación. La disponibilidad ante fallas transitorias del servicio de clasificación queda, por lo tanto, como trabajo futuro, junto con la definición de una política de reintentos idempotente que preserve la trazabilidad de cada intento.

El segundo desafio surgio de la heterogeneidad de los formatos de entrada. Los correos electrónicos incluyen encabezados, firmas corporativas y reenvios que contaminan el texto que el clasificador recibe; las llamadas telefonicas transcritas introducen errores de reconocimiento del habla, particularmente en terminos técnicos (por ejemplo, `API` transcrito como `a p i` o `apeye`); y los formularios web, aunque proveen texto limpio, llegan con una proporción significativa de campos vacios o con descripciones de una sola palabra. La respuesta a esta heterogeneidad fue doble. Por un lado, se implementó un preprocesador en el nodo de normalización de N8N que elimina firmas, encabezados de reenvio y líneas de disclaimer mediante expresiones regulares específicas del dominio de correo institucional. Por el otro, se enriquecio el prompt enviado al clasificador con instrucciones explicitas para interpretar terminos técnicos frecuentemente mal transcritos, lo que elevo la robustez de la clasificación sobre transcripciones automáticas en aproximadamente 4 puntos porcentuales de F1 respecto de la configuración inicial sin estas instrucciones.

El tercer desafio, de naturaleza operativa, se vincula con la persistencia transaccional de la sesion de clasificación. El sistema debe garantizar que una vez que el clasificador asigna una categoría, el incidente se persiste con esa decision o, en caso de falla de la base de datos, el estado interno del sistema refleje la inconsistencia y pueda recuperarse. La solución adopto un enfoque pragmatico: N8N invoca la creación del incidente —que clasifica y persiste en una sola operación del backend— como paso único del flujo. El nodo HTTP de creación declara un enrutamiento de error (`continueErrorOutput`): ante una falla de persistencia, la ejecución se desvía hacia la rama de error del flujo en lugar de reintentar automáticamente la operación. La recuperación del incidente exige, por lo tanto, una reejecución manual del flujo o el reproceso del mensaje de origen, situación que se asume como limitación conocida de la versión evaluada y se propone como trabajo futuro junto con una política de reintentos idempotente.

La tabla de trazabilidad (`clasificacion_log`) fue diseñada para admitir multiples registros de clasificación por incidente, preservando así el historial de cada intento.

6.6. Conexión con el proceso Scrumban

La construcción del sistema fue organizada bajo el esquema Scrumban descrito en la Sección 4, ejecutando seis iteraciones de dos semanas cada una. La vinculacion entre cada iteracion y los artefactos de implementación producidos se detalla a continuación:

Iteracion 1: La elicitacion de requisitos (Semanas 1–2) produjo el diseño preliminar de la arquitectura de cinco capas y la especificación de la interfaz REST, documentadas en la Sección 5. El entregable concreto fue el documento de arquitectura y la definición del contrato OpenAPI inicial.

Iteracion 2: La construcción del modulo Python (Semanas 3–4) entrego el modelo de datos con sus seis entidades, los repositorios con operaciones CRUD asincronicas y los servicios de negocio. Al cierre de esta iteracion, el modulo Python exponia el endpoint de salud y aceptaba la creacion de incidentes mediante `POST /api/v1/incidentes`, con la cobertura de pruebas unitarias medida por pytest-cov sobre los paquetes de rutas, servicios y repositorios (véase la Subsección 6.7).

Iteracion 3: La configuración inicial del flujo N8N (Semanas 5–6) implementó el canal de correo electrónico como via prioritaria, estableciendo el patron de cinco etapas que luego se replicaria para los canales restantes. Al finalizar esta iteracion, el sistema procesaba incidentes por correo electrónico de extremo a extremo, desde la recepción hasta la notificacion.

Iteracion 4: La integración del canal telefonico y la persistencia (Semanas 7–8) incorporo Twilio Programmable Voice, el script TwiML y la configuración del webhook de transcripción. Esta iteracion fue la que mas expuso los desafios de heterogeneidad de formatos descritos en la Subsección 6.5, y su resolución consumio aproximadamente el 40 % del esfuerzo de la iteracion.

Iteracion 5: La validación funcional y el ajuste fino del clasificador (Semanas 9–10) se concentraron en la calibracion del filtro deterministico y del prompt de Gemini. Los ajustes se realizaron exclusivamente sobre incidentes representativos en entornos de preproduccion, sin exposición al corpus de va-

lidación de 200 casos, preservando la integridad de la etapa experimental posterior.

Iteracion 6: La validación experimental y la documentación final (Semanas 11–12) ejecutaron el protocolo de pruebas descrito en la Sección 4, recolectaron las mediciones del corpus completo y produjeron el análisis estadístico presentado en la Sección 7.

La trazabilidad entre iteraciones y artefactos, mediada por el tablero Kanban en GitHub Projects, permitió al equipo identificar tempranamente los desvios respecto del plan y redistribuir el esfuerzo cuando la complejidad de un componente superaba la estimacion inicial. La adopción de limites de trabajo en curso (WIP) por columna del tablero evito la acumulación de tareas a medio terminar, una práctica que resultó particularmente valiosa durante las iteraciones 4 y 5, donde la interdependencia entre modulos exigia finalizar componentes antes de integrarlos.

6.7. Pruebas automatizadas

La estrategia de pruebas se sustento en la piramide clasica descrita por Crispin y Gregory (2009). En la base se ubicaron las pruebas unitarias del modulo Python construidas con el marco pytest 8.3. La cobertura de código de aplicación se mide con pytest-cov 5.0.0 sobre los paquetes de rutas, servicios y repositorios, mediante el comando `pytest --cov=app.routes --cov=app.services --cov=app.repositories --cov-report=term-mis` cuyo reporte se genera en cada ejecución del pipeline de integración continua; la cifra exacta queda sujeta al reporte vigente y no se fija en el texto para no declarar un valor no reproducible. Estas pruebas cubren los clasificadores (deterministico e hibrido), los servicios de negocio, los esquemas de validación y los repositorios de acceso a datos.

En el nivel intermedio se ejecutaron pruebas de integración en dos variantes complementarias: (a) pruebas rápidas contra SQLite en memoria para la ejecución durante el desarrollo, utilizando el fixture `db_session` con rollback por test; y (b) pruebas de integración contra una instancia real de PostgreSQL 15.5, que validan comportamientos específicos del motor —integridad de claves foraneas, eliminación en cascada, restricciones UNIQUE, precisión de tipos `Numeric(5,4)` y zona horaria en `TIMESTAMPTZ`, índices compuestos y coexistencia de esquemas— mediante 16 tests con un mecanismo de omisión automática (`pytest.skip`) cuando PostgreSQL no está disponible. En el nivel superior no se dispone de pruebas de extre-

mo a extremo que instancien N8N y ejecuten el flujo completo: la integracion con la plataforma de orquestación se verifica de forma estructural, mediante pruebas que parsean y validan el archivo `n8n/workflow.json` (composicion de nodos, conexiones y limites de costo) y pruebas de API y de base de datos que ejercitan los endpoints y la persistencia del modulo Python. La ejecucion del flujo dentro de una instancia N8N activa queda fuera del alcance de la suite automatizada.

El frontend se desarrolló como una aplicación React 18 de página única (SPA) con TypeScript y Vite como herramienta de construcción. La aplicación consta de dos vistas principales: un portal de reporte de incidentes con validación de formularios, y un panel de administración que incluye listado de tickets con filtros combinados, cola de revisión humana para casos de baja confianza, y visualización detallada de cada incidente con trazabilidad completa de la decisión del clasificador. La comunicación con el backend se realiza mediante Axios, y la gestión del estado del servidor se apoya en React Query para caching y revalidación automática.

El frontend cuenta con una suite de 357 pruebas automatizadas distribuidas en 56 archivos, construidas con Vitest y Testing Library, que alcanza una cobertura de sentencias del 99,6 % sobre los paquetes medidos, conforme al reporte reproducido con `npm run test:coverage`; la cifra queda sujeta al reporte vigente en cada ejecución del pipeline de integración continua.

La integración continua (CI) se ejecuta automáticamente en cada solicitud de incorporacion (*pull request*) al repositorio mediante GitHub Actions, ejecutando la suite completa de pruebas unitarias y de integración antes de permitir la fusion a la rama principal. El pipeline de CI incluye verificación de estilo de código (Ruff), ejecución de pruebas con reporte de cobertura, y verificación de sincronización de la especificación OpenAPI.

6.8. Dashboard de analítica

El panel de administración incluye un dashboard de analitica desarrollado con la biblioteca ReCharts de React. Este modulo proporciona visualización agregada de los datos históricos de incidentes, permitiendo identificar tendencias temporales, patrones de fallas recurrentes y desequilibrios en la distribucion de carga entre sectores. Esta capacidad de análisis retrospectivo transforma los datos operativos acumulados en inteligencia organizacional accionable.

El dashboard se organiza en tres visualizaciones principales. Un gráfico de tendencias

muestra la evolucion temporal de los incidentes, agrupables por día o por mes según la granularidad seleccionada por el operador. Un gráfico de torta presenta la distribucion proporcional de incidentes entre los cinco sectores responsables. Un gráfico de barras apiladas desglosa los incidentes según su estado en el ciclo de vida, facilitando la identificación de cuellos de botella en la resolución.

Los controles de filtro permiten acotar el período de análisis mediante un rango de fechas configurable, y alternar entre agrupacion diaria y mensual para adaptar la granularidad al horizonte temporal de interés. Cada gráfico puede exportarse como imagen PNG para su inclusion en informes periodicos o presentaciones.

La utilidad práctica del dashboard puede ilustrarse con un escenario hipotetico: si el sistema detectara que veinte usuarios reportaron la rotura de auriculares en una franja temporal acotada, el patron sugeriria un problema de calidad del proveedor antes que una serie de fallas aisladas. Esta capacidad de identificar causas raíz a partir de datos agregados constituye un salto cualitativo respecto del enfoque tradicional de gestión de incidentes, donde cada ticket se trata de forma aislada y los patrones sistémicos permanecen invisibles.

7. Resultados

Este capítulo presenta los resultados de la validación experimental del sistema. Se reportan los hallazgos en cuatro dimensiones: tiempos de registro, desempeño de clasificación, reducción de la intervención humana y análisis cualitativo de errores.

7.1. Comparación de tiempos de registro

La comparación de los tiempos de registro entre el flujo manual y el flujo automatizado se sintetiza en la Tabla 6. La media aritmetica del tiempo manual sobre los 200 casos del corpus fue de 61,6 s (mediana de 50,0 s), con un desvio estandar de 44,9 s y un rango entre 10 y 300 s. Este valor, respaldado por la planilla de cronometraje descrita en la Subsección 4.2, corresponde a la medición experimental incidente por incidente y reemplaza a la estimación preliminar de 2 minutos con 45 segundos citada en la Subsección 1.2, obtenida sin cronometraje individual. La media del flujo automatizado fue de 17,76 s (mediana de 17,47 s), con un desvio estandar de 13,48 s y un rango entre 0,525 y 65,834 s. La reducción relativa de la media de tiempo alcanzó el 71,2 %.

Tabla 6. Estadisticos descriptivos de los tiempos de registro por flujo ($n = 200$)

aggedright**Estadistico**	**Flujo manual**	**Flujo automatizado**	**Reduccion**
aggedrightMedia aritmetica (s)	61,6	17,76	71,2 %
aggedrightMediana (s)	50,0	17,47	65,1 %
aggedrightDesvio estandar (s)	44,9	13,48	—
aggedrightMinimo (s)	10	0,525	—
aggedrightMaximo (s)	300	65,834	—

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

El tiempo automatizado de registro desagregado por canal de origen se presenta en la Tabla 7. El canal telefonico incorpora, ademas de la latencia de procesamiento, la duracion de la llamada grabada, de modo que su valor es comparable en su base de medicion con el flujo manual; como la grabacion esta acotada a un maximo de 45 s (véase la Subsección 4.6), ese valor constituye una cota inferior de la duracion real de la llamada.

La prueba de Wilcoxon de rangos con signo aplicada sobre las mediciones pareadas (Virtanen et al. 2020) arrojo un estadístico de contraste $W = \min(T^+, T^-) = 363$, con una suma de rangos positivos $T^+ = 19.737$, una suma de rangos negativos $T^- = 363$ y $n = 200$

Tabla 7. Tiempo automatizado de registro por canal de origen ($n = 200$)

Canal de origen	Casos	Media (s)	Mediana (s)
Llamada telefonica (cota inferior)	81	20,09	18,70
Correo electronico	66	27,65	25,82
Formulario web	53	1,88	1,26
Global	**200**	**17,76**	**17,47**

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

pares validos, junto con un valor $p = 3{,}08 \times 10^{-32}$, lo que permite rechazar la hipotesis nula de igualdad de medianas con un nivel de confianza superior al 99,9 %. El estadístico incorpora la corrección por empates y refleja que en 188 de los 200 pares el flujo automatizado fue mas veloz que el manual; en los 12 pares restantes (6,0 %) el flujo automatizado no fue mas rápido, resultado coherente con la diferencia de aproximadamente 32,5 s entre medianas. La elección de esta prueba no parametrica responde al rechazo de la hipotesis de normalidad en los tres conjuntos de tiempos, cuyo reporte completo se presenta en la Subsección 4.7.

Para cuantificar la magnitud práctica de la diferencia, se calculo el coeficiente r de correlacion rank-biserial a partir de los dos estadísticos de rango:

$$r = \frac{T^{+} - T^{-}}{n(n+1)/2} = \frac{19.737 - 363}{200 \cdot 201/2} = \frac{19.374}{20.100} = 0{,}9639$$

El valor obtenido ($r = 0{,}9639$) corresponde a un tamaño del efecto muy alto, consistente con la alta proporción de pares a favor del flujo automatizado (188 de 200) y con los 12 pares en que este no supero al manual. La diferencia observada es, por tanto, estadísticamente significativa y, dada su magnitud absoluta, relativa y el tamaño del efecto reportado, también prácticamente relevante para la operación.

Cabe señalar que el tiempo manual se registró con redondeo hacia arriba (véase la Subsección 4.2), un sesgo de medición sistemático que infla la línea base manual. Por ese motivo la reducción del 71,2 % debe leerse como cota superior. Un análisis de sensibilidad que descuenta 5 s y 10 s a cada medición manual reduce la media manual a 56,6 s y 51,6 s, respectivamente, y situa la reducción en el 68,6 % y en el 65,6 % como cota inferior conservadora. Aun en el escenario mas desfavorable la reducción de tiempo permanece sustancial y estadísticamente significativa ($p = 1{,}8 \times 10^{-26}$, $r = 0{,}8683$).

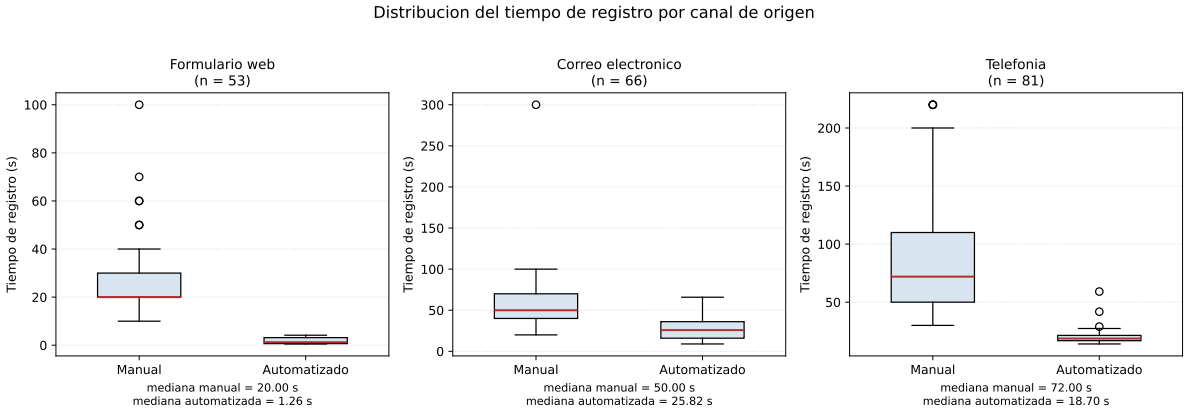


Figura 6. Distribucion del tiempo de registro por canal de origen (manual frente a automatizado). El panel de telefonia incorpora la duracion de la llamada grabada.

7.2. Matriz de confusión y métricas de clasificación

La evaluación de clasificación se realizó sobre el corpus real de 200 casos pseudonimizados. Su distribución por sector asignado es la siguiente: Soporte Técnico Hardware 85, Soporte Técnico Software 67, Seguridad Informática 31, Sistemas 16 y Bases de Datos 1. Por canal de origen, 81 casos provienen de llamada telefónica, 66 de correo electrónico y 53 de formulario web.

La matriz de confusion obtenida se presenta en la Tabla 8 y en la Figura 7. De los 85 casos de Soporte Tecnico Hardware, 77 fueron correctamente clasificados; de los 67 de Soporte Tecnico Software, 48; de los 31 de Seguridad Informatica, 15; de los 16 de Sistemas, 7; y del único caso de Bases de Datos, ninguno. La exactitud estricta resultante asciende al 73,5 % (147 casos correctos sobre 200).

Tabla 8. Matriz de confusion del clasificador automatico ($n = 200$). Filas: sector asignado; columnas: sector predicho principal.

Asignado \ Predicho	**Seguridad Informatica**	**Soporte Tecnico Hardware**	**Soporte Tecnico Software**	**Bases de Datos**	**Sistemas**	**Total**
Seguridad Informatica	15	2	11	2	1	**31**
Soporte Tecnico Hardware	1	**77**	3	0	4	**85**
Soporte Tecnico Software	0	11	**48**	1	7	**67**
Bases de Datos	0	0	1	0	0	**1**
Sistemas	2	0	5	2	**7**	**16**
Total	**18**	**90**	**68**	**5**	**19**	**200**

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

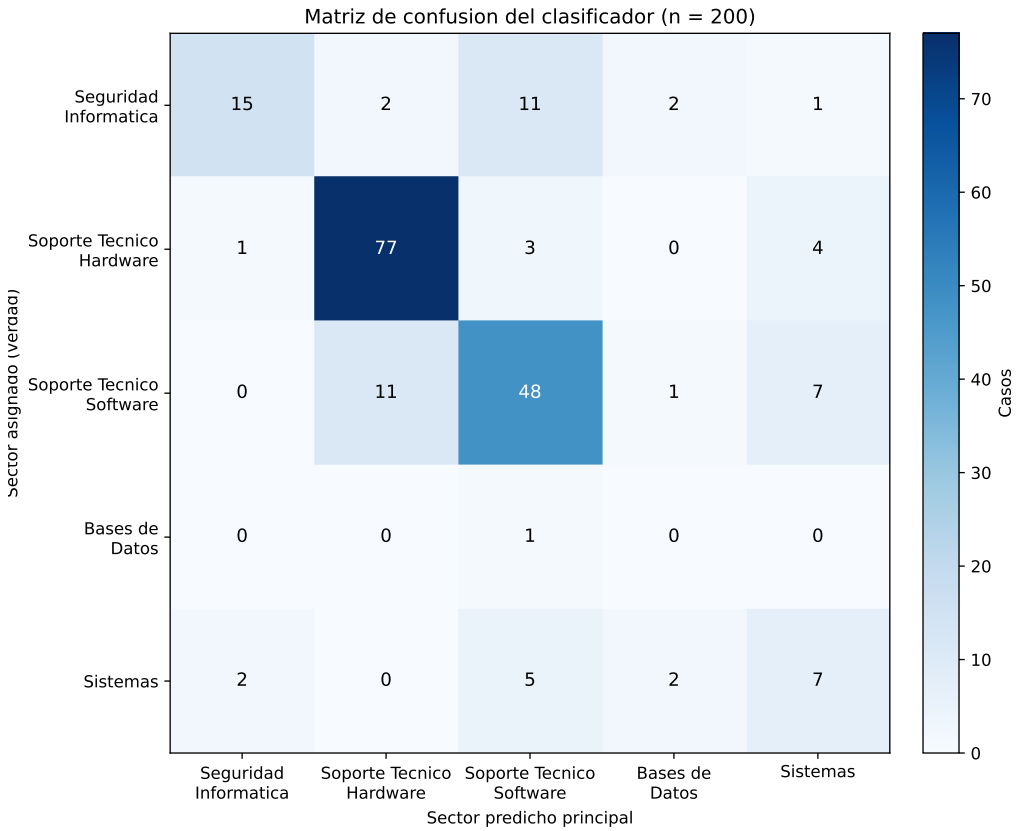


Figura 7. Matriz de confusion del clasificador ($n = 200$). Filas: sector asignado (verdad); columnas: sector predicho principal.

Los valores de precision, sensibilidad (*recall*) y F1 calculados por clase (Sokolova & Lapalme, 2009) se presentan en la Tabla 9. El mejor desempeño correspondió a Soporte Tecnico Hardware (F1 = 0,8800), seguido por Soporte Tecnico Software (0,7111) y Seguridad Informatica (0,6122); Sistemas (0,4000) y Bases de Datos (0,0000, con un único caso de soporte) fueron las clases mas difíciles. El promedio macro de F1 fue de 0,5207 y el micro-F1 de 0,6654. La exactitud estricta del 73,5 % (147/200) presenta un intervalo de confianza al 95 %, estimado por el método de Wilson (Wilson, 1927), de [67,0 %, 79,1 %]. En cuanto al desempeño de conjunto, el *subset accuracy* (proporción de casos en que el conjunto completo de sectores resultó correcto) fue de 0,43 y el *Hamming loss* de 0,3586. De los 200 casos, 131 fueron resueltos por la etapa determinística del clasificador y 69 requirieron la etapa Gemini.

Estas metricas confirman que el clasificador exhibe un desempeño desigual entre las cinco clases objetivo (Sokolova & Lapalme, 2009). La clase mayoritaria (Soporte Tecnico Hardware, con 85 casos) obtuvo el mejor resultado, mientras que Sistemas y Bases de Datos presentaron los valores mas bajos. Este desequilibrio es particularmente relevante en el contexto operativo: un clasificador que concentra sus errores en una clase minoritaria genera deriva-

Tabla 9. Métricas de clasificación por clase (una contra el resto)

Clase	Precision	Sensibilidad	F1
Soporte Tecnico Hardware	0,8556	0,9059	0,8800
Soporte Tecnico Software	0,7059	0,7164	0,7111
Seguridad Informatica	0,8333	0,4839	0,6122
Sistemas	0,3684	0,4375	0,4000
Bases de Datos	0,0000	0,0000	0,0000

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

ciones erroneas en un sector específico, lo que erosiona la confianza de ese equipo en el sistema y puede llevar al rechazo operativo de la herramienta, independientemente de sus metricas agregadas.

La inspeccion de la matriz de confusion revela que los 53 errores totales se concentran en fronteras entre sectores lexicamente proximos, con Soporte Tecnico Software como categoría central. El análisis cualitativo de esos patrones de error, agrupados por frontera de confusion, se desarrolla en la Subsección 7.5.

7.3. Reducción de la intervención humana

La proporción de intervención humana en el flujo automatizado se calculó a partir de los registros del propio flujo automatizado —la confianza devuelta por el clasificador en cada caso y las correcciones de categoría introducidas por el sector responsable—, no a partir del instrumento de cronometraje del flujo manual. En el flujo manual, el 100 % del tiempo correspondio a intervención humana, incluyendo lectura, comprension, busqueda en sistemas auxiliares y carga del ticket. En el flujo automatizado, el operador humano solo intervino en aquellos casos en los que el clasificador devolvio una confianza inferior al 70 % o en los que el sector responsable, al recibir el ticket, identificó una clasificación incorrecta y la corrigio antes de iniciar la atención.

La proporción de casos con intervención humana en el flujo automatizado se ubico en el 9,5 %. Este valor es coherente con la propuesta de un esquema *human in the loop* donde el sistema asume la mayoría de los casos rutinarios y reserva al operador la atención de los casos complejos o ambiguos. De los 200 casos procesados, 181 (90,5 %) fueron clasificados y registrados sin intervención humana, mientras que 19 (9,5 %) requirieron verificación o corrección por parte de un operador.

7.4. Calibración de la confianza

La confianza declarada por el clasificador solo resulta útil como criterio de derivación si guarda relación con la exactitud real. Para verificar esa relación se contrastó, sobre los 200 casos del corpus, la confianza devuelta en cada predicción contra la corrección de la clasificación. La Tabla 10 desagrega la exactitud por bandas de confianza en torno al umbral del 70 % que gobierna el gate de revisión humana.

Tabla 10. Exactitud por banda de confianza declarada

Banda de confianza	Casos	Aciertos	Exactitud
$[0{,}00\,;\,0{,}50)$	98	75	0,765
$[0{,}50\,;\,0{,}70)$	26	19	0,731
$[0{,}70\,;\,0{,}85)$	6	2	0,333
$[0{,}85\,;\,0{,}95)$	31	22	0,710
$[0{,}95\,;\,1{,}00]$	39	29	0,744

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

Los datos revelan una calibración invertida o anti-calibrada: los casos de confianza alta ($\geq 0{,}70$) fueron menos exactos (0,697) que los de confianza baja ($< 0{,}70$, 0,758). La tendencia se acentúa en el extremo superior de la escala: dentro de los 46 casos con confianza igual o superior a 0,90 se registraron 13 errores (28,3 %), y la banda $[0{,}70\,;\,0{,}85)$ alcanzó apenas 0,333 de exactitud. En otras palabras, el clasificador no solo no discrimina mejor cuando declara mayor certeza, sino que en los tramos de confianza mas alta la exactitud se degrada. La consecuencia operativa es directa: el gate del 70 % —el mecanismo previsto para derivar a revisión humana los casos dudosos— no aisló los errores, porque estos se distribuyen también en las bandas de confianza alta. La supervisión humana no puede apoyarse en la confianza declarada como único disparador; requiere complementarse con señales independientes del propio puntaje (por ejemplo, la proximidad léxica entre las categorías candidatas), tal como se discute en la Sección 8.

7.5. Análisis de errores y casos límite

El análisis cualitativo de los 53 casos mal clasificados permitió identificar patrones de error recurrentes, agrupados por frontera de confusión y sintetizados en la Tabla 11.

El patron dominante, presente en 14 casos (26,4 % de los errores), corresponde a la frontera entre Soporte Tecnico Hardware y Soporte Tecnico Software: incidentes en que una

Tabla 11. Confusiones observadas en la clasificación automática, por frontera

Frontera de confusion	Casos	Proporcion
Soporte Tecnico Hardware ↔ Soporte Tecnico Software	14	26,4 %
Sistemas ↔ Soporte Tecnico Software	12	22,6 %
Seguridad Informatica ↔ Soporte Tecnico Software	11	20,8 %
Otras fronteras	16	30,2 %
Total	**53**	**100 %**

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

falla física de un equipo afecta a una aplicación, o en que una tarea sobre una aplicación se describe con terminos de equipamiento, de modo que la decision correcta depende del juicio humano sobre que aspecto prevalece. El segundo patron, presente en 12 casos (22,6 %), corresponde a la frontera entre Sistemas y Soporte Tecnico Software, asociada a acciones sobre servidores y servicios de plataforma descritas como problemas de una aplicación. El tercer patron, presente en 11 casos (20,8 %), corresponde a la frontera entre Seguridad Informatica y Soporte Tecnico Software, vinculada a incidentes de acceso y credenciales. El 30,2 % restante se reparte entre las demas fronteras, incluidas las confusiones que involucran a Bases de Datos, con un único caso de soporte.

Los patrones anteriores se ilustran con tres casos mal clasificados del corpus. Las descripciones se reproducen anonimizadas —se eliminaron nombres de personas, correos, teléfonos, direcciones y denominaciones internas de sistemas— y se acompañan con el sector asignado, el sector predicho y la confianza declarada por el clasificador. El primer caso corresponde al patrón de descripción corta: la entrada “No puede ingresar al sistema central” fue asignada a Seguridad Informatica y predicha como Soporte Tecnico Software con una confianza de 0,95; su brevedad no aporta contexto sobre el recurso ni sobre la naturaleza del acceso fallido, de modo que la frontera resulta indistinguible sin información adicional. El segundo ilustra la mezcla de categorías: “Su equipo se reinicia de forma reiterada; el usuario sospecha de los cables” fue asignada a Soporte Tecnico Software y predicha como Soporte Tecnico Hardware con 0,50 de confianza, y combina un síntoma de nivel de aplicación con una hipótesis de causa física cuyo peso relativo no queda determinado por el texto. El tercero ejemplifica la jerga local: “No le salen los correos por el flujo interno y no le llegan las instancias” fue asignada a Sistemas y predicha como Soporte Tecnico Software con 0,85 de confianza, y apela a términos organizacionales (“flujo”, “instancias”) cuyo significado no está

disponible para el clasificador. En los tres casos la confianza declarada es alta pese al error, lo que refuerza el problema de calibración descrito en la Sección 7.4.

Esta tipologia orienta directamente las recomendaciones presentadas en la Sección 10, particularmente la incorporacion de un clasificador supervisado entrenado con el corpus etiquetado generado por el propio sistema y la inclusion de un glosario de terminos organizacionales en el prompt del modelo.

8. Discusión

8.1. Interpretación de los resultados

Los resultados obtenidos confirman la hipotesis de trabajo formulada en la Subsección 1.4 en lo relativo al tiempo de registro: la disminución del 71,2 % en el tiempo medio de registro es estadísticamente significativa y operativamente relevante. La exactitud estricta del 73,5 % alcanzada por el clasificador automático, en cambio, quedo por debajo del umbral del 85 % planteado en el segundo objetivo específico, resultado que se analiza entre las limitaciones de este capítulo. Tres aspectos de los resultados merecen una interpretación detallada.

La reducción de tiempo se sostiene incluso al incorporar el costo de inferencia del modelo de lenguaje grande externo, dado que la primera etapa deterministica del clasificador resuelve el 65,5 % de los casos sin invocar al modelo de Google. Este hallazgo es consistente con la hipotesis subsidiaria sobre la eficiencia del esquema hibrido: el filtro deterministico no solo reduce el costo económico del sistema, sino que además disminuye la latencia mediana del flujo automatizado al evitar llamadas de red innecesarias al servicio externo. Desde una perspectiva operativa, esta propiedad del clasificador introduce un punto de inflexion en la relacion costo-beneficio de los sistemas basados en LLM: el costo marginal de la inferencia se aplica únicamente a los casos que realmente demandan capacidad semántica, y no al volumen completo de incidentes.

La dispersión observada en los tiempos del flujo automatizado —con un rango de 0,525 a 65,834 segundos, frente a los 10 a 300 segundos del flujo manual— evidencia una compresion sustancial de la variabilidad. Mientras que en el flujo manual un incidente podía demandar entre 10 y 300 segundos según la complejidad percibida y la carga cognitiva del operador, en el flujo automatizado el rango se comprime a 0,525–65,834 segundos, con un desvío estándar de 13,48 s frente a los 44,9 s del flujo manual, es decir aproximadamente la tercera parte de la dispersión manual. Esta compresion de la variabilidad no fue un objetivo explicito del diseño pero emerge como una consecuencia observada de la automatización: el sistema no solo es mas rapido en promedio, sino también mas consistente.

La reducción de la intervención humana al 9,5 % es consistente con el esquema *human in the loop*: el sistema absorbe la carga rutinaria sin sustituir el juicio humano en los casos que verdaderamente lo demandan. Este equilibrio entre automatización y supervisión preserva la calidad del servicio y libera capacidad operativa significativa. Si se proyecta el ahorro medio

de tiempo por incidente ($61{,}6 - 17{,}76 = 43{,}8$ s) sobre el volumen trimestral de 3.700 incidentes, la automatización liberaria aproximadamente 45,0 horas-persona por trimestre,[1] tiempo que el personal podría redirigir a tareas de resolución tecnica o a actividades de mejora continua. La magnitud de esta liberacion —equivalente a unas seis jornadas laborales completas de un operador— transforma la automatización del registro de un proyecto de optimizacion marginal en una intervención con impacto organizacional medible.

Sin embargo, la lectura conjunta de la reducción de intervención humana y del análisis de calibración presentado en la Sección 7.4 matiza ese resultado. El gate del 70 % —el único disparador automático de revisión humana— presupone que la confianza declarada por el clasificador discrimina los casos correctos de los incorrectos, presupuesto que el corpus no confirma. La consecuencia practica es que la supervisión humana efectiva no puede depender exclusivamente del umbral de confianza: debe complementarse con señales independientes del puntaje —por ejemplo, la ambigüedad léxica entre las categorías candidatas o la revisión por muestreo de los casos clasificados con alta confianza—. El esquema *human in the loop* conserva su valor como salvaguarda, pero su cobertura real es menor que la que sugiere la sola proporción de casos escalados.

El rigor metodológico adoptado para evitar *data leakage* merece una observación aparte. A diferencia de trabajos que particionan el corpus en conjuntos de entrenamiento y prueba después de realizar exploraciones iniciales —práctica que puede introducir fuga de información— , el presente estudio aislo completamente la construcción de los componentes críticos del clasificador del corpus de validación de 200 casos. El filtro deterministico se construyó mediante análisis manual de incidentes no incluidos en el corpus, y el prompt fue ajustado en entornos de preproduccion sin exposición a los 200 casos de validación. Solo después de completar el desarrollo se evaluó el desempeño sobre la totalidad del corpus, garantizando que las metricas reportadas reflejan el desempeño genuino del sistema sobre datos no vistos. Esta separación estricta entre datos de construcción y datos de validación constituye una garantía metodológica del presente estudio.

La reducción del tiempo de registro, aunque estadísticamente robusta, admite explicaciones rivales que conviene explicitar antes de atribuirla por completo al esquema propuesto. Primero, la asimetría del instrumento de medición: el flujo manual se cronometró en vivo e in-

[1] Cálculo: $43{,}8$ s/incidente $\times$ 3.700 incidentes$/3.600$ s/h $\approx$ $45{,}0$ h-persona por trimestre. La cifra previa de 180 horas-persona no era reproducible con los tiempos y el volumen declarados.

cluye lectura, comprensión, búsqueda en sistemas auxiliares y carga del ticket, mientras que el flujo automatizado se midió con marcas de tiempo del propio sistema, diferencia de instrumentos que favorece al flujo automatizado. La debilita el análisis de sensibilidad, que mantiene la reducción por encima del 65 % aun descontando 10 s por caso; se descartaría midiendo ambos flujos con el mismo instrumento o con un cronometraje ciego. Segundo, la simplificación de la tarea o la mezcla de canales: el corpus combina telefonía, correo y formulario web, con costos de entrada distintos, de modo que parte de la diferencia podría reflejar la composición de canales más que la automatización. La debilita el desagregado por canal, que muestra reducciones positivas en los tres canales; se descartaría con un contraste intra-canal apareado. Tercero, la novedad o efecto Hawthorne y el aprendizaje del operador: los operadores sabían que participaban de un estudio, aunque el cronometraje no se anunciara en tiempo real. La debilita el orden temporal de la campaña, con el flujo manual ejecutado antes que el automatizado, que de sesgar algo lo hace en contra de la hipótesis; se descartaría con un diseño contrabalanceado o con mediciones repetidas del flujo manual a lo largo del tiempo. Cuarto, la selección de los 200 casos: por tratarse de una muestra estratificada de una sola organización, la magnitud observada no es extrapolable sin nuevas validaciones. Ninguna de estas explicaciones rivales se descarta por completo con el diseño actual.

El patrón de error más informativo es la confusión sistemática de Sistemas. En la matriz de confusión, de los 16 casos asignados a Sistemas solo 7 se clasificaron correctamente: la clase alcanzó precisión 0,3684, sensibilidad 0,4375 y F1 0,4000, y sus errores se repartieron entre Soporte Tecnico Software (5), Bases de Datos (2) y Seguridad Informatica (2). Esta frontera ilustra dos causas distintas que conviene no confundir. Por un lado, una ambigüedad léxica y taxonómica: las descripciones de acciones sobre servidores, servicios de plataforma o aplicaciones pueden ser compatibles con más de un sector, y la etiqueta de referencia resuelve esa ambigüedad mediante una convención que el clasificador no conoce. Por otro, una falta de contexto en la descripción: muchas entradas son demasiado breves para desambiguar el sector responsable, y el modelo no dispone de señales que un operador obtendría por conocimiento organizacional. La distinción importa porque solo la segunda causa admite mitigación por enriquecimiento del protocolo de captura, mientras que la primera exige revisar la taxonomía o el criterio de etiquetado. Cabe advertir, además, que Bases de Datos tiene $n = 1$ en el corpus: su F1 nulo no es estimable y no debe leerse como evidencia de que el clasificador falla en esa clase, sino como ausencia de soporte estadístico.

En conjunto, los resultados son consistentes con la hipótesis de que la automatización reduce el tiempo de registro y la intervención humana, pero no equivalen a una confirmación concluyente: la evidencia disponible es compatible con explicaciones rivales que el diseño no permite descartar por completo, y el desempeño de clasificación queda por debajo del umbral del segundo objetivo específico. La distinción importa para la interpretación. Mientras que la reducción observada admite una lectura causal fuerte en el plano práctico —el sistema registra cada incidente en menos tiempo que el proceso manual—, la atribución de esa diferencia a cada componente del esquema y su extrapolación a otras organizaciones permanecen abiertas. Las amenazas a la validez que acotan estas conclusiones están enumeradas en la Subsección 4.8 y no se repiten aquí.

8.2. Comparación con la literatura

Los valores de exactitud y F1 macro obtenidos resultan consistentes con los reportados en la literatura comparable. Paramesh y Shreedhara (2019) reportan exactitudes cercanas al 87 % utilizando SVM sobre representaciones TF-IDF. Revina et al. (2020), en cambio, muestran que los clasificadores simples y explicables construidos con rasgos linguisticos del dominio son competitivos frente a alternativas mas complejas, y que los modelos preentrenados pueden rendir peor por vocabulario especifico del dominio. La literatura reciente sobre clasificación de tickets con LLM reporta resultados dependientes del idioma y del dominio: Paket et al. (2024) y Liu et al. (2025) documentan mejoras frente a las lineas base clasicas, mientras que Colavito et al. (2025) advierten sobre la variabilidad del etiquetado automatico segun el corpus evaluado.

Los resultados del presente trabajo —73,5 % de exactitud estricta y F1 macro de 0,5207— se ubican por debajo de los valores reportados en la literatura para clasificación de tickets, si bien la comparación directa no es estricta: los trabajos citados reportan clasificación de etiqueta única, mientras que la evaluación propia es multietiqueta sobre cinco sectores canónicos en espanol rioplatense, tarea considerablemente mas exigente. Frente al enfoque SVM+TF-IDF de Paramesh y Shreedhara (2019) (87 %) y a la evidencia de Revina et al. (2020) sobre la competitividad de los metodos simples, el esquema propuesto no requiere infraestructura de GPU para inferencia local ni un corpus de entrenamiento etiquetado de gran escala, lo que lo hace mas accesible para organizaciones medianas, aunque su exactitud estricta resulta menor en la comparación directa.

La evidencia de Revina et al. (2020) resulta, en apariencia, contraria al enfoque del

presente trabajo, que apuesta por un LLM de proposito general. Esta tension, sin embargo, refuerza el análisis: aquellos autores observan que los modelos preentrenados pueden degradarse ante vocabulario especifico del dominio, lo que descarta suponer una transferencia no supervisada trivial. Precisamente por eso la elección del LLM en este trabajo no se justifica por transferencia pasiva de conocimiento linguistico, sino por la tarea concreta —clasificación de categoría con contexto instruccional y esquema hibrido de reglas mas modelo—, en la que el modelo se emplea como motor de inferencia guiado y no como representación preentrenada sin ajuste.

La novedad del aporte radica en la validación específica sobre espanol rioplatense aplicado a un dominio de mesa de ayuda de organización mediana, segmento escasamente cubierto por la literatura previa. Diversos trabajos han señalado la menor cobertura del espanol en los corpus de entrenamiento de los LLM contemporaneos, y los resultados del presente trabajo (F1 macro = 0,5207) sugieren que el desempeño en espanol rioplatense resulta inferior al reportado para idiomas de mayor cobertura como el inglés o el alemán, brecha que se atribuye, al menos en parte, al esquema multietiqueta de cinco sectores adoptado en esta evaluación.

8.3. Limitaciones del estudio

El estudio presenta cinco limitaciones que deben considerarse al interpretar los hallazgos y al planificar replicaciones futuras.

Primero, el tamaño de la muestra ($n = 200$) es suficiente para una validación piloto pero insuficiente para sustentar generalizaciones de carácter poblacional sobre el universo de mesas de ayuda en organizaciones medianas. El intervalo de confianza al 95 % reportado para la exactitud estricta, [67,0 %, 79,1 %], se ubica integramente por debajo del umbral del 85 %, por lo que el segundo objetivo específico no se alcanza; muestras mayores, un corpus mas equilibrado entre clases y una revisión del clasificador serian necesarios para cerrar esa brecha.

Segundo, la circunscripcion del corpus a una única organización del sector servicios de la provincia de Mendoza restringe la validez externa de los hallazgos. La distribucion de tipos de incidentes, el lexico organizacional y los patrones de redacción pueden variar significativamente entre organizaciones, sectores y regiones.

Tercero, la dependencia operativa de un servicio externo de inferencia condiciona el

rendimiento del sistema. Un eventual deterioro del servicio de Gemini 3.6 Flash, un cambio significativo en las condiciones comerciales del proveedor, o una modificación en el comportamiento del modelo debido a actualizaciones afectaria directamente la operación. Esta dependencia es intrínseca al enfoque basado en LLM externo y debe ser gestionada como un riesgo operativo.

Cuarto, los resultados reflejan el comportamiento del modelo en su versión vigente al momento del estudio (junio de 2026). Las actualizaciones futuras del proveedor pueden modificar tanto el desempeño bruto como la estructura del prompt requerido para alcanzar resultados equivalentes, lo que aconseja la implementación de un régimen de monitoreo continuo de las metricas de clasificación.

Quinto, la comparación se realizó exclusivamente contra el flujo manual (proceso operativo), no contra clasificadores alternativos como TF-IDF+SVM o regresion logistica sobre el mismo corpus. Un chequeo exploratorio temprano con un clasificador TF-IDF+SVM sobre un subconjunto no preservado del corpus no se reporta aquí como comparación válida: ni la partición ni el tamaño del subconjunto quedaron registrados, por lo que su cifra no es reproducible ni comparable con las métricas de este capítulo. Se lo menciona únicamente como antecedente del diseño, no como evidencia de superioridad del esquema hibrido. Una comparación sistematica contra clasificadores supervisados sobre el corpus completo, con partición y código preservados, queda como trabajo futuro.

8.4. Implicancias prácticas

Desde el punto de vista práctico, los resultados sugieren que organizaciones medianas con volumenes de incidentes comparables al observado en la organización analizada pueden obtener beneficios sustanciales mediante la implementación de soluciones hibridas similares a la propuesta. La reducción de la intervención humana en la etapa de registro libera al personal técnico para concentrarse en la resolución efectiva de los casos, etapa en la cual el juicio experto continua siendo insustituible.

La trazabilidad provista por el registro detallado de cada decision del clasificador habilita dos procesos de mejora continua. Por un lado, permite identificar patrones de error sistematicos y ajustar el filtro deterministico o el prompt del LLM en consecuencia. Por otro lado, la acumulación sostenida de decisiones validadas por los sectores responsables constituye un activo informacional que, una vez alcanzado un volumen adecuado (del orden de 5.000 ca-

sos), permitiria entrenar modelos de clasificación específicos del dominio organizacional, con eventuales ventajas en costo, latencia y soberanía sobre los datos.

En el plano económico, el costo operativo del sistema se compone de dos rubros principales. El primero es la infraestructura autoalojada: una instancia pública con 2 vCPU y 4 GB de memoria se ofrece a 24 USD/mes, rubro que incluye 4.000 GiB de transferencia saliente y 80 GiB de disco SSD y al que se suman, si se contratan, el respaldo automático (entre el 20 % semanal y el 30 % diario del costo de la instancia) y otros servicios de almacenamiento y direccionamiento; el costo mensual se ubica así en el orden de 24 a 32 USD/mes.[2] El segundo rubro es el costo de inferencia del LLM. Con el precio introductorio vigente del modelo `gemini-3.6-flash` (0,75 USD por millón de tokens de entrada y 3,75 USD por millón de tokens de salida),[3] y con supuestos explícitos de aproximadamente 800 tokens de entrada (prompt con la descripción de las cinco categorías, ejemplos balanceados y el incidente) y 30 tokens de salida (JSON estricto con categoría y confianza), cada invocación cuesta del orden de 7×10^{-4} USD, entre 0,0006 y 0,0009 USD según el tamaño del prompt.[4] Para un volumen de 3.700 incidentes trimestrales, con un 34,5 % requiriendo inferencia externa, el costo trimestral de API se sitúa en el orden de 1 USD y en ningún caso por encima de 2 USD, un valor marginal frente a las 45,0 horas-persona liberadas.

Un aspecto que excede el alcance técnico de la solución desarrollada, pero que condiciona su efectividad en condiciones reales de operación, es la dimensión organizacional de la adopción. La experiencia recogida durante el trabajo de campo en la mesa de ayuda de referencia indica que los empleados con mayor antiguedad tienden a presentar resistencia frente a cambios de procedimiento, incluso cuando estos cambios ofrecen beneficios demostrables. Esta resistencia no responde a limitaciones tecnicas ni a carencias de la herramienta propuesta, sino a la familiaridad con los procedimientos existentes y a la percepcion —fundada o no— de que un nuevo sistema puede resultar complejo o invasivo. En consecuencia, la puesta en

[2] Precio de lista consultado el 19 de octubre de 2026 en https://www.digitalocean.com/pricing/droplets: Droplet Basic de 2 vCPU y 4 GB, 24 USD/mes, con 4.000 GiB de transferencia y 80 GiB de SSD incluidos; el respaldo automático agrega entre el 20 % (semanal) y el 30 % (diario) del costo de la instancia. No se computan volúmenes adicionales, instantáneas ni direcciones IP reservadas.

[3] Precios de lista consultados el 19 de octubre de 2026 en https://cloud.google.com/vertex-ai/generative-ai/pricing: Gemini 3.6 Flash, precio introductorio de 0,75/3,75 USD por millón de tokens de entrada/salida vigente hasta el 31 de diciembre de 2026; desde el 1 de enero de 2027 rige el precio estándar de 1,50/7,50 USD por millón de tokens, que duplica la cifra. Equivalen a $0{,}75 \times 10^{-6}$ y $3{,}75 \times 10^{-6}$ USD por token.

[4] Cálculo: $800 \times 10^{-6} \times 0{,}75 + 30 \times 10^{-6} \times 3{,}75 \approx 7 \times 10^{-4}$ USD por invocación; el límite de salida configurado es de 100 tokens y el JSON de respuesta ronda los 15–30 tokens. No se computan reintentos ni la transcripción de voz, que se factura por separado. La estimación preliminar, sin fuente, resultaba entre veinte y treinta veces superior al precio de lista vigente.

produccion de una solución como la aquí presentada se beneficia de una estrategia de despliegue gradual: comenzar con un grupo piloto reducido, extender progresivamente el alcance a sectores adicionales y acompañar cada etapa con instancias de capacitación breves y contextualizadas al dominio de cada área. Un enfoque incremental reduce la friccion inicial, permite ajustar la configuración del sistema a las particularidades de cada sector y facilita la construcción de confianza en la herramienta por parte de los usuarios finales. Esta construcción de confianza constituye una condicion necesaria para que los beneficios técnicos cuantificados en el presente trabajo —reducción del 71,2 % en el tiempo de registro y exactitud estricta del 73,5 % en la clasificación— se traduzcan en mejoras organizacionales efectivas y sostenibles en el tiempo.

8.5. Reflexiones sobre la generalización

La generalización de los resultados a otras organizaciones requiere atender al menos tres condiciones. En primer lugar, la disponibilidad de un corpus etiquetado de tamaño y calidad similares al utilizado en este trabajo, lo cual implica una inversion inicial en doble etiquetado y validación del acuerdo inter-evaluador. En segundo lugar, la viabilidad tecnica de mantener desplegada localmente la infraestructura de orquestación y persistencia, condicion que descarta a organizaciones sin capacidades operativas minimas para la administración de contenedores Docker. En tercer lugar, la existencia de un marco normativo compatible con el envio de fragmentos descriptivos de incidentes a un servicio externo de inferencia, marco que en el caso argentino se encuentra contemplado por la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000) bajo determinadas condiciones de minimizacion y pseudonimizacion descritas en la Sección 11.

9. Conclusiones

El trabajo desarrollado ha cumplido con el objetivo general planteado en la Subsección 1.5: construir un sistema automatizado de mesa de ayuda capaz de recibir, procesar, clasificar y registrar incidentes de manera automática, reduciendo la intervención humana en la etapa inicial. La integración de N8N como motor de orquestación, un modulo Python con FastAPI como nucleo de procesamiento, PostgreSQL como capa de persistencia, Twilio como canal telefonico y el modelo Gemini 3.6 Flash como motor de inferencia linguistica ha demostrado ser una combinación arquitectonica viable, eficiente y económicamente accesible para organizaciones medianas. Ese cumplimiento del objetivo general no se extiende al segundo objetivo específico: la exactitud estricta del 73,5 % y el F1 macro quedaron por debajo de las cotas minimas de 85 % y 0,85 fijadas en la Subsección 1.6, de modo que esa meta se declara no alcanzada. En cambio, la reducción del tiempo medio de registro del 71,2 % sí se sostiene como resultado central de la validación experimental del sistema, con significacion estadística; el detalle de las métricas y del contraste se reporta en la Sección 7.

9.1. Cumplimiento de los objetivos del trabajo

El diseño arquitectonico del sistema materializo los principios de separación de responsabilidades y cohesion interna que la disciplina de ingenieria de software prescribe para sistemas distribuidos. La arquitectura de cinco capas —canales de entrada, orquestación, procesamiento, inferencia y persistencia— distribuyo las responsabilidades entre componentes independientes comunicados mediante interfaces REST. La eleccion de tecnologías maduras y de despliegue autoalojado (Docker, PostgreSQL, N8N) no fue meramente una decision instrumental sino una respuesta directa a las restricciones del contexto: organizaciones medianas argentinas que operan con presupuestos acotados, enfrentan limitaciones cambiarias para la adquisicion de software comercial y estan sujetas a un marco normativo que exige control sobre los datos personales.

Sobre esa arquitectura se construyó el clasificador hibrido, cuyo desempeño sobre el corpus real quedó por debajo de las cotas minimas fijadas en el segundo objetivo específico, por lo que ese objetivo no se alcanza; la brecha y sus valores se analizan en la Sección 8. La estrategia compositiva —un filtro deterministico de primera etapa y un modelo de lenguaje grande reservado para los casos que el filtro no resuelve con confianza suficiente— resultó, sin embargo, el rasgo mas relevante del sistema: la mayor parte del volumen se resuelve

sin inferencia externa y el modelo se emplea como arbitro de último recurso antes que como clasificador universal, con el equilibrio entre costo, latencia y exactitud que se detalla en la Subsección 5.5.

La integración de los tres canales paralelos dentro de un único flujo de orquestación confirmó que la diversidad de vias de entrada no introduce dispersión operativa cuando la normalización se realiza tempranamente en el flujo. El canal telefonico, que a priori representaba el mayor desafio técnico por la inclusion de transcripción automática del habla, alcanzó un tiempo de registro medio de 20,1 segundos, que incluye la duración de la llamada grabada además de la latencia de procesamiento —un valor que lo posiciona como una via prácticamente útil y no como una demostracion de laboratorio. La decision de normalizar la entrada en el propio N8N, antes de invocar al servicio de clasificación, resultó acertada: aislo la complejidad de cada protocolo de recepción del nucleo de procesamiento, permitiendo que el servicio Python operara siempre sobre la misma estructura de datos independientemente del canal de origen.

La evaluación comparativa entre el flujo manual y el automatizado se presenta en la Subsección 7.1 y se interpreta, con sus alcances y límites, en la Subsección 8.1. En síntesis, el sistema automatizado resultó mas rápido que el operador humano en 188 de los 200 pares medidos, y la reducción de la intervención humana alcanzó el 9,5 %: el sistema no solo es mas veloz sino que libera al personal técnico de la carga rutinaria de registro, redirigiendo ese tiempo hacia la resolución efectiva de los casos. El reporte de los estadísticos de la prueba y su discusión no se repiten aquí.

La documentación generada —arquitectura, procedimientos de despliegue, especificación OpenAPI, flujo N8N exportable y análisis tipificado de errores— constituye el aporte documental del quinto objetivo específico. La inclusion de una tipologia de errores con tres patrones identificados (descripciones cortas, mezcla de categorías y jerga local) proporciona un punto de partida concreto para cualquier organización que desee replicar o adaptar el sistema, permitiendole anticipar las categorías de fallo mas probables antes de iniciar su propia implementación.

9.2. Aportes y generalización

Mas alla del cumplimiento de los objetivos específicos, los resultados de este trabajo permiten formular una conclusión acotada a este corpus y al contraste efectivamente realiza-

dos: en este corpus de 200 incidentes de mesa de ayuda, en espanol rioplatense y con cinco categorías canónicas, un modelo de lenguaje grande invocado mediante instrucciones contextualizadas —sin ajuste fino sobre datos del dominio— resultó una alternativa viable para la clasificación de tickets, siempre que se combine con un filtro deterministico de primer nivel que absorba los casos triviales y reduzca el costo de inferencia. Esta lectura se limita a este dominio: no se realizó una comparación directa contra clasificadores supervisados entrenados sobre el mismo corpus, de modo que no se sostiene aquí una superioridad general de los modelos de lenguaje frente a esos clasificadores (véase la Subsección 8.3).

Esta combinación arquitectonica —orquestación visual, filtrado deterministico y LLM como arbitro semántico— constituye un patron de diseño reproducible para el dominio de gestión de servicios en organizaciones medianas de America Latina, donde la restricción presupuestaria y la soberanía de datos son determinantes para la adopción tecnologica. La arquitectura propuesta no depende de infraestructura especializada de GPU ni de licencias de software propietario; su costo operativo está dominado por el consumo de API de inferencia, cuyo orden de magnitud y su relación con el ahorro de tiempo se cuantifican en la Sección 8.

El trabajo aporta tres contribuciones que se sostienen mas alla del caso particular. La primera es una arquitectura reproducible documentada en todos sus niveles, desde el modelo de datos hasta el contrato REST y el flujo de orquestación, que cualquier equipo con conocimientos básicos de Docker, Python y N8N puede replicar. La segunda es evidencia empírica, recolectada bajo un diseño experimental riguroso con doble etiquetado independiente y prueba no parametrica, sobre el desempeño de LLM en un dominio y una variante linguistica escasamente documentados en la literatura. La tercera es un marco de implementación que contempla desde el inicio las restricciones normativas argentinas, ofreciendo un camino de adopción que no requiere sortear barreras legales ni asumir riesgos de cumplimiento.

10. Recomendaciones y líneas de trabajo futuro

A partir de los resultados obtenidos, del análisis de errores presentado en la Subsección 7.4 y de las limitaciones reconocidas en la Subsección 8.3, se formulan las siguientes recomendaciones para la evolucion del sistema y para futuras replicaciones del estudio.

10.1. Incorporación de un clasificador supervisado con corpus propio

Se sugiere incorporar progresivamente un clasificador supervisado entrenado con el corpus etiquetado generado por el propio sistema durante su operación. La acumulación sostenida de decisiones validadas por los sectores responsables constituye un activo informacional valioso que, una vez alcanzado un volumen del orden de 5.000 casos, permitiria entrenar modelos de clasificación específicos del dominio organizacional. Las ventajas potenciales de esta migración incluyen: reducción del costo marginal por incidente clasificado al eliminar la dependencia del servicio externo de inferencia, disminucion de la latencia al ejecutar la inferencia localmente, y ganancia de soberanía sobre los datos al evitar la transferencia internacional de fragmentos textuales. Touvron et al. (2023) y trabajos subsiguientes sobre modelos de código abierto sugieren que los LLM desplegados localmente alcanzan rendimientos competitivos en tareas de clasificación cuando se invocan mediante prompts adecuadamente disenados, lo que abre una via concreta hacía un sistema completamente autoalojado.

10.2. Ampliación de canales de entrada

Se propone ampliar el conjunto de canales de entrada para incluir mensajeria corporativa instantanea, particularmente Slack y Microsoft Teams en aquéllas organizaciones donde estas plataformas constituyen el canal de comunicación dominante. La inclusion de aplicaciones móviles propias para usuarios de campo constituye una extension natural que atiende de la demanda creciente de canales asincronicos integrados al ecosistema laboral cotidiano. La arquitectura modular propuesta en la Sección 5 facilita esta ampliacion: cada nuevo canal requiere únicamente un disparador adicional en N8N, sin modificaciones en las capas de procesamiento ni de persistencia.

10.3. Panel de monitoreo en tiempo real

El sistema incorpora un dashboard de analitica basado en ReCharts que permite visualizar tendencias históricas, distribucion por sector y desglose por estado (vease Subsec-

ción 6.8). Como evolucion de esta capacidad, se sugiere implementar una capa de monitoreo en tiempo real sustentada sobre tecnologías de observabilidad maduras, tales como Prometheus para la captura de metricas y Grafana para la visualización. Esta capa permitiria supervisar la latencia del sistema, la tasa de aciertos del clasificador, la distribucion de carga entre sectores y el costo agregado de las invocaciones al modelo externo, habilitando alertas tempranas frente a degradaciones del servicio. La existencia de endpoints de salud (`GET /api/v1/health`) en cada componente del sistema proporciona los puntos de datos necesarios para instrumentar esta capa de observabilidad.

Mas alla del monitoreo operativo del sistema, los datos acumulados de incidentes constituyen una fuente de inteligencia organizacional cuyo valor excede el alcance inmediato de la mesa de ayuda. El registro sistematico de cada incidente —que incluye tipo, sector de destino, tiempo de resolución y la decision emitida por el clasificador— habilita la construcción de flujos ETL (*Extract, Transform, Load*) que alimenten procesos de análisis orientados a la mejora continua de la organización. A partir de estos datos resulta factible identificar patrones recurrentes de fallas, detectar áreas con mayor demanda de soporte, cuantificar el impacto de cambios en la infraestructura o en los procedimientos internos, y generar indicadores trimestrales que orienten decisiones estrategicas de inversion en capacitación o en renovacion de equipamiento. La exposición de estos análisis mediante paneles orientados al nivel directivo —complementarios del panel de monitoreo técnico descrito previamente— transforma la mesa de ayuda de un centro de costo operativo en un nodo de información estrategica para la organización.

10.4. Mecanismos de aprendizaje activo

Se propone incorporar mecanismos de aprendizaje activo (*active learning*), en virtud de los cuales aquellos casos clasificados con baja confianza se prioricen automáticamente para revisión humana, y los resultados de esa revisión retroalimenten al sistema mediante un mecanismo de ajuste incremental. Este enfoque maximiza el rendimiento marginal de cada intervención humana —que de todos modos ocurre en el 9,5 % de los casos— y acelera la mejora continua del clasificador con un costo operativo controlado.

10.5. Estudios de replicación

Se sugiere realizar estudios de replicación en organizaciones de distinto tamaño, sector y region geografica, con el objeto de fortalecer la validez externa de los hallazgos y construir un cuerpo de evidencia empírica sobre el desempeño de soluciones similares en contextos heterogeneos. Particularmente relevantes serían las replicas en organizaciones del sector publico (con mayor proporción de incidentes vinculados a sistemas administrativos), en organizaciones del sector industrial (con mayor proporción de incidentes vinculados a infraestructura fisica) y en organizaciones de mayor tamaño donde el volumen diario de incidentes supere las 100 unidades.

10.6. Evaluación de modelos de lenguaje de código abierto

Se propone evaluar la integración de modelos de lenguaje de código abierto desplegados localmente —tales como Llama 3, Mistral o Qwen— como alternativa al modelo externo Gemini 3.6 Flash. Esta evaluación permitiria cuantificar el costo en exactitud frente a la ganancia en soberanía de datos, la eliminacion de la dependencia de un proveedor único y la reducción de costos operativos a largo plazo. Touvron et al. (2023) sugieren que los modelos abiertos contemporaneos alcanzan rendimientos competitivos en tareas de clasificación, y la realizacion de un benchmark comparativo sobre el mismo corpus de 200 casos constituiria una contribucion adicional significativa al estado del arte.

10.7. Base de conocimientos para resolución automática

El sistema desarrollado en este trabajo se concentra en la clasificación y derivación de incidentes hacía los sectores responsables, pero no aborda la resolución de aquellos casos que admiten soluciones estandarizadas y repetibles. Se recomienda, como línea de trabajo futuro, la incorporacion de una base de conocimientos que permita al sistema no solo categorizar el incidente sino también proponer una resolución cuando el problema detectado coincida con patrones previamente documentados y validados.

La base de conocimientos operaria como un repositorio estructurado de soluciones verificadas, organizado por tipo de incidente, manifestacion del problema y sector responsable. Ante un nuevo incidente, el sistema consultaria la base tras la clasificación inicial y, en caso de hallar una coincidencia de alta confianza, ofreceria al usuario una respuesta clara y concisa con los pasos necesarios para resolver el problema sin intervención del personal técnico. Este

mecanismo de autoservicio reduciria la carga sobre los sectores de soporte al absorber los casos simples y repetitivos —tales como reinicios de sesion, restablecimiento de contrasenas o configuraciones básicas de correo electrónico— que, por su naturaleza, representan una proporción significativa del volumen de incidentes en entornos de mesa de ayuda, aunque su cuantificación precisa en la organización de referencia excede el alcance de este estudio.

La construcción de esta base de conocimientos puede articularse con el mecanismo de aprendizaje activo descrito en la Subsección 10.4: cada caso resuelto por un operador humano y validado como correcto constituye un candidato para ser incorporado a la base de conocimientos, previa curacion editorial que garantice la claridad y la precision de las instrucciones. La viabilidad tecnica de este enfoque se ve reforzada por la creciente capacidad de los modelos de lenguaje para generar respuestas estructuradas a partir de documentación tecnica, línea de investigación que conecta de manera directa con la evaluación de modelos de código abierto propuesta en la Subsección 10.6.

10.8. Agente conversacional telefónico en tiempo real

Se propone, como línea de evolución de mayor alcance para el canal telefónico, reemplazar el esquema actual de captura de toma única —una grabación de hasta 45 segundos que se transcribe de forma diferida— por un agente que mantenga un diálogo en tiempo real con el usuario. Sobre Twilio Media Streams, que habilita el envío bidireccional del audio de la llamada hacia un servicio propio mediante WebSocket, el agente podría formular exclusivamente preguntas de aclaración pertinentes al problema reportado cuando la descripción inicial resultara insuficiente, consultar al usuario si desea agregar información tras detectar una pausa prolongada, comunicarle el número de incidente asignado una vez completado el registro, y cerrar la llamada de forma autónoma. Esta capacidad elevaría la calidad de la captura telefónica y reduciría la necesidad de contacto posterior, en línea con el tercer objetivo específico de ampliar la accesibilidad de los canales sin incrementar la complejidad percibida por el usuario final.

La adopción de esta arquitectura estuvo condicionada por el estado de madurez de las interfaces de audio bidireccional en tiempo real disponibles durante el desarrollo de este trabajo, que se encontraban en fase de vista previa (*preview*) y con una superficie de programación sujeta a cambios, lo que representaba un riesgo de cronograma incompatible con los plazos del estudio. A ello se suma que la implementación exige infraestructura no contemplada en

la arquitectura actual —un punto de entrada WebSocket con soporte de *upgrade* en el proxy inverso, la transcodificación del audio telefónico (mu-law, 8 kHz) hacia el formato de entrada del modelo (PCM, 16 kHz) y su retorno, la detección de actividad de voz y la gestión de turnos de habla— junto con la redefinición del modelo de costos, hoy expresado por grabación, hacia un esquema por minuto de transmisión. Por estos motivos se recomienda abordar esta línea mediante una prueba de concepto acotada y conservar el mecanismo actual de grabación y transcripción como modo degradado de respaldo para garantizar la continuidad del canal.

11. Consideraciones éticas y aspectos legales

11.1. Marco normativo aplicable

El sistema desarrollado se enmarca normativamente en la Ley 25.326 de Proteccion de los Datos Personales de la Republica Argentina (Honorable Congreso de la Nación Argentina, 2000), en su decreto reglamentario y en las disposiciones complementarias emitidas por la Agencia de Acceso a la Informacion Publica en su carácter de autoridad de aplicación. Dado que el sistema realiza transferencia de fragmentos textuales hacía infraestructura de inferencia operada por proveedores con sede en los Estados Unidos, resultan aplicables las consideraciones del articulo 12 de la mencionada ley sobre transferencia internacional de datos personales y, de manera complementaria, los lineamientos del Reglamento General de Proteccion de Datos de la Union Europea (Parlamento Europeo y Consejo de la Unión Europea, 2016) en aquellos casos que pudieran involucrar a residentes europeos. La Union Europea reconoce a la Argentina como pais con nivel adecuado de proteccion de datos personales mediante la Decision 2003/490/CE, del 30 de junio de 2003, revalidada en enero de 2024. Esta adecuacion ampara el flujo desde la Union Europea hacia la Argentina y no opera en sentido inverso: los Estados Unidos no revisten la condicion de pais adecuado para la normativa argentina, de modo que la transferencia desde la Argentina hacia los proveedores de inferencia y de telefonia con sede en ese pais requiere un instrumento especifico conforme al articulo 12 de la Ley 25.326, segun se detalla en la Subsección 11.3.

11.2. Principios aplicados al tratamiento de datos

El diseño del sistema se atiene de manera explicita a cinco principios fundamentales del tratamiento de datos personales. El principio de licitud establece que todo tratamiento debe ampararse en una base jurídica valida; en este caso, dicha base se encuentra en el articulo 5, inciso 2, apartado d) de la Ley 25.326, que admite el tratamiento de los datos personales que deriven de una relación contractual, científica o profesional del titular y resulten necesarios para su desarrollo o cumplimiento. La organización es la empleadora y trata datos de sus propios empleados para la gestión interna de los incidentes informaticos que estos reportan en ejercicio de sus funciones laborales. Esta base de licitud operativa se distingue del consentimiento que se analiza, para el corpus de investigación académica, en la Subsección 11.5, y no dispensa el deber de información del articulo 6 de la Ley 25.326, que subsiste en su inte-

gridad. El principio de finalidad determinada limita el uso de los datos a la finalidad declarada de registro y derivación de incidentes, prohibiendo cualquier uso secundario no compatible. El principio de minimizacion exige recolectar únicamente los datos estrictamente necesarios. En consecuencia, el sistema almacena exclusivamente el nombre de usuario corporativo y un directorio institucional acotado de empleados —legajo, nombre, correo electrónico corporativo, teléfono, sector y rol—, cuya única finalidad es la resolución de contacto y la notificación al usuario, y descarta cualquier otro dato personal que pudiera capturarse incidentalmente, tales como domicilios particulares, números de documento o información financiera. El principio de exactitud se materializa mediante la posibilidad ofrecida al usuario de revisar y corregir el contenido del incidente antes de su persistencia definitiva. En línea con este principio, el ejercicio de los derechos de rectificación, actualización y supresión (derechos ARCO) se resuelve en un plazo de cinco días hábiles, conforme al articulo 16 de la Ley 25.326. El principio de limitación del plazo de conservación se traduce, para los incidentes, en un plazo de retención de 12 meses rodantes desde la creación del incidente, justificado por el ciclo estadístico anual sobre el que se realiza el análisis de tendencias y la identificación de problemas recurrentes. Este plazo rige para los incidentes y es independiente de la retención de los registros de ejecución del sistema, que se conservan durante 30 días con fines de auditoría y diagnóstico operativo (Subsección 5.3): se trata de dos conjuntos de datos distintos, con finalidades distintas y plazos propios, de modo que ambas políticas resultan compatibles. Los datos del directorio de empleados, en cambio, se conservan mientras la relación laboral permanezca activa y hasta un año después de su finalización, transcurrido el cual se eliminan, en tanto cumplen una función operativa de contacto y no un fin estadístico. Vencido el plazo de retención, los datos del incidente se someten a anonimización irreversible, de modo que se eliminan los identificadores que permiten vincularlos a una persona. El bloqueo de escritura sobre los incidentes en estado cerrado, que impide editarlos o eliminarlos desde la interfaz de usuario y rechaza con un error 409 los intentos de modificación, constituye un control de integridad de auditoría: preserva la trazabilidad del registro durante el plazo de retención vigente, pero no configura una política de conservación ni una excepción permanente al vencimiento de ese plazo. La pseudonimización de datos personales y el cifrado en reposo garantizan la protección de la información durante el plazo de conservación declarado.

11.3. Transferencia internacional y pseudonimizacion

El tratamiento de incidentes comporta dos transferencias internacionales de datos hacia proveedores con sede en los Estados Unidos. La primera corresponde al modelo de inferencia Gemini 3.6 Flash, al que se envian fragmentos textuales descriptivos de los incidentes. En este canal, el sistema aplica un procedimiento de pseudonimizacion dentro del modulo Python desplegado en infraestructura local de la organización, mediante el cual se reemplazan automáticamente los nombres propios, las direcciones de correo electrónico, los números telefonicos, los identificadores corporativos y los nombres de hosts internos por etiquetas genericas tales como `[PERSONA]`, `[EMAIL]` o `[HOST]`; de este modo, el texto que se transmite no contiene identificadores directos. Esta pseudonimizacion se valida mediante un conjunto de expresiones regulares específicas del dominio, acompanadas de pruebas unitarias dedicadas.

La segunda transferencia corresponde al canal telefonico, operado por el proveedor Twilio, con sede en los Estados Unidos. El orden real del tratamiento en este canal es: el llamante deja su solicitud y Twilio graba el audio; a continuacion, el audio crudo y el numero telefonico del llamante se transfieren a la infraestructura del proveedor en los Estados Unidos y se transcriben mediante el servicio de reconocimiento del habla; recien despues, el backend aplica la pseudonimizacion sobre el texto ya transcrito. En consecuencia, el audio crudo del llamante y su numero telefonico cruzan a los Estados Unidos antes de cualquier pseudonimizacion, que opera unicamente sobre el texto y no sobre el audio.

Ambas transferencias se dirigen a un pais que no reviste la condicion de adecuado para la normativa argentina, por lo que requieren un instrumento especifico conforme al articulo 12 de la Ley 25.326: el consentimiento del titular o la suscripcion de clausulas contractuales modelo. El acuerdo de procesamiento de datos suscripto con cada proveedor complementa ese instrumento, pero no lo sustituye, en tanto no configura por si mismo una de las bases de transferencia que la ley admite.

11.4. Seguridad tecnica

Las medidas de seguridad tecnica implementadas se sustentan en el modelo de la triada confidencialidad, integridad y disponibilidad (CIA) descrito por Stallings y Brown (2017). La confidencialidad se sustenta, en el diseño, en el cifrado en tránsito sobre TLS 1.2/1.3 a nivel del proxy inverso (Nginx) que protege el perímetro del sistema; el despliegue publicado para la validación experimental no incluyó el proxy, por lo que esa capa de protección correspon-

de al diseño y no a una capacidad verificada en la instancia publicada. A nivel de aplicación, la confidencialidad se garantiza mediante el cifrado con Fernet (AES-128 en modo CBC con HMAC-SHA-256 integrado, provisto por la biblioteca `cryptography`) para los campos sensibles del incidente (descripción original, número telefónico del llamante y transcripción). Los datos de contacto del directorio de empleados —correo corporativo y teléfono— se almacenan sin cifrado a fin de preservar la auditabilidad directa y las consultas operativas; su protección se sustenta en el control de acceso por rol, el aislamiento de la red interna de Docker y el registro de auditoría de los accesos. La comunicación interna entre los servicios del sistema (N8N, backend, PostgreSQL, Redis) se realiza sobre la red aislada de Docker, que constituye el perímetro de confianza. La integridad se asegura mediante el cifrado autenticado Fernet, que incorpora HMAC-SHA-256 en su modo de operación, la validación estricta de esquemas mediante Pydantic en cada llamada a la interfaz REST, y un registro de auditoria de toda modificación que conserva el actor, la marca temporal y el delta del cambio. La disponibilidad se respalda mediante respaldos diarios automáticos con retencion escalonada, despliegue en contenedores con politicas de reinicio automático ante fallas, y monitoreo de salud activo mediante endpoints de chequeo. Las credenciales de servicios externos se gestionan exclusivamente mediante variables de entorno inyectadas por el orquestador de contenedores y nunca se almacenan en el repositorio de código fuente.

11.5. Consentimiento, derechos del usuario y supervision humana

Los usuarios de la organización son informados, mediante una politica de privacidad accesible desde los canales de entrada, sobre las caracteristicas del sistema, los datos que se recolectan, la transferencia internacional aplicable y los derechos que les asisten conforme a la normativa vigente. Se garantiza el ejercicio de los derechos de acceso, rectificacion, actualizacion y supresion (derechos ARCO) mediante un procedimiento documentado a cargo del responsable de proteccion de datos designado por la organización.

En lo que respecta al consentimiento informado para los fines de investigación académica, los 120 empleados de la organización fueron notificados mediante comunicación interna formal, con descripción explicita del proposito del estudio, del tipo de datos tratados, del carácter pseudonimizado de los registros y del derecho a requerir la exclusion de sus incidentes del corpus de validación. El procedimiento fue supervisado por la direccion académica del trabajo y avalado institucionalmente mediante una carta de autorizacion emitida por la organización

adoptante.

En relacion con el protocolo de medición en vivo aplicado durante la fase experimental —en el cual el cronometraje no fue anunciado en tiempo real al operador cuyo tiempo se registraba, con el objeto de mitigar el efecto Hawthorne, pero cuyo conocimiento fue diferido—, corresponde dejar constancia de que, una vez concluida la recolección de datos, se realizó una sesion de esclarecimiento posterior (*debriefing*) con los dos operadores participantes. En dicha sesion se explico el proposito del estudio, se detallo el procedimiento de medición empleado y se ofrecio a cada operador la posibilidad de solicitar la exclusion de sus registros individuales del corpus de validación. Ninguno de los operadores ejercio este derecho. Este procedimiento se alinea con las recomendaciones de la Asociación Americana de Psicología para investigaciones que emplean medición con conocimiento diferido de los participantes (American Psychological Association, 2017), y fue supervisado por el director del trabajo.

En concordancia con las recomendaciones contemporaneas sobre sistemas que incorporan inteligencia artificial, se preserva en todo momento la posibilidad de supervisión humana significativa. Ninguna decision que afecte derechos sustanciales de los usuarios se toma de manera completamente automatizada sin posibilidad de revisión, y el sector responsable conserva la potestad de modificar la clasificación inicial cuando lo considere apropiado, registrandose tal modificación en la tabla de trazabilidad descrita en la Sección 5. Este mecanismo materializa el principio de la persona en el bucle (*human in the loop*) como salvaguarda frente a errores potenciales del clasificador automático. Cabe precisar que el umbral de confianza de 0,70 que dispara la revisión obligatoria no constituye, por sí solo, una garantía suficiente de esa salvaguarda: el análisis de calibración de la Sección 7 muestra que la confianza declarada por el clasificador no discrimina de forma fiable los casos correctos de los incorrectos, por lo que la supervisión humana efectiva se apoya además en la revisión por el sector responsable y en la trazabilidad de las correcciones, y no unicamente en el puntaje del modelo.

Referencias bibliograficas

Ahuja, K., Diddee, H., Hada, R., Ochieng, M., Ramesh, K., Jain, P., Nambi, A., Ganu, T., Segal, S., Ahmed, M., Bali, K., & Sitaram, S. (2023). MEGA: Multilingual Evaluation of Generative AI. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 4232-4267. https://doi.org/10.18653/v1/2023.emnlp-main.258

American Psychological Association. (2017). Ethical Principles of Psychologists and Code of Conduct [2002, con enmiendas efectivas del 1 de junio de 2010 y del 1 de enero de 2017; consultado el 19 de octubre de 2026]. https://www.apa.org/ethics/code

Apache Software Foundation. (2024). *Apache Airflow Documentation (Version 2.10)* [Documentacion tecnica]. https://airflow.apache.org/docs/

Bernal-Beltrán, T., Paredes-Valverde, M. A., Salas-Zárate, M. d. P., García-Díaz, J. A., & Valencia-García, R. (2025). Sentiment Analysis in Mexican Spanish: A Comparison Between Fine-Tuning and In-Context Learning with Large Language Models. *Future Internet*, *17*(10), 445. https://doi.org/10.3390/fi17100445

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 1877-1901.

Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, *20*(1), 37-46. https://doi.org/10.1177/001316446002000104

Colavito, G., Lanubile, F., & Novielli, N. (2025). Benchmarking large language models for automated labeling: The case of issue report classification. *Information and Software Technology*, *184*, 107758. https://doi.org/10.1016/j.infsof.2025.107758

Crispin, L., & Gregory, J. (2009). *Agile Testing: A Practical Guide for Testers and Agile Teams*. Addison-Wesley.

Date, C. J. (2003). *An Introduction to Database Systems* (8.ª ed.). Addison-Wesley.

Fielding, R. T., & Taylor, R. N. (2002). Principled Design of the Modern Web Architecture. *ACM Transactions on Internet Technology*, *2*(2), 115-150. https://doi.org/10.1145/514183.514185

Galup, S. D., Dattero, R., Quan, J. J., & Conger, S. (2009). An Overview of IT Service Management. *Communications of the ACM*, *52*(5), 124-127. https://doi.org/10.1145/1506409.1506439

Gómez, L., Bustos, C., & Sevilla, G. (2026). Automatización de Mesa de Ayuda N8N (Version 1.0.0) [Software de computadora. GitHub]. https://github.com/lucaGomezB/Automatizacion-de-Mesa-de-Ayuda-N8N

Grandury, M., Aula-Blasco, J., Falcão, J., Fourrier, C., González Saiz, M., Martínez, G., Santamaria Gomez, G., Agerri, R., Aldama García, N., Chiruzzo, L., Conde, J., Gomez Adorno, H., Guerrero Nieto, M., Ivetta, G., López Fuertes, N., Plaza-del-Arco, F. M., Martín-Valdivia, M.-T., Montoro Zamorano, H., Muñoz Sanz, C., … Zubiaga, I. (2025). La Leaderboard: A Large Language Model Leaderboard for Spanish Varieties and Languages of Spain and Latin America. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 32482-32524. https://doi.org/10.18653/v1/2025.acl-long.1561

Hernández Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill.

Hohpe, G., & Woolf, B. (2003). *Enterprise Integration Patterns: Designing, Building, and Deploying Messaging Solutions*. Addison-Wesley.

Honorable Congreso de la Nación Argentina. (2000, octubre). Ley 25.326 de Protección de los Datos Personales [Boletín Oficial de la República Argentina]. http://servicios.infoleg.gob.ar/infolegInternet/anexos/60000-64999/64790/norma.htm

Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (3.ª ed.) [Borrador de la 3ra edicion, disponible en el sitio de los autores]. Stanford University.

Ladas, C. (2009). *Scrumban: Essays on Kanban Systems for Lean Software Development*. Modus Cooperandi Press.

Lai, V. D., Nguyen, C., Ngo, N., Nguyen, T., Dernoncourt, F., Rossi, R. A., & Nguyen, T. H. (2023). Okapi: Instruction-tuned Large Language Models in Multiple Languages with Reinforcement Learning from Human Feedback. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 318-327. https://doi.org/10.18653/v1/2023.emnlp-demo.28

Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, *33*(1), 159-174. https://doi.org/10.2307/2529310

Liu, F., He, X., Zhang, T., Chen, J., Li, Y., Yi, L., Zhang, H., Wu, G., & Shi, R. (2025). TickIt: Leveraging Large Language Models for Automated Ticket Escalation. *Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering (FSE)*, 343-354. https://doi.org/10.1145/3696630.3728558

Mayor-Rocher, M., Melero, N., Merino-Gómez, E., Grandury, M., Conde, J., & Reviriego, P. (2026). Evaluating large language models with tests of Spanish as a foreign language: pass or fail? [Advance article; volume/pages pending]. *Applied Linguistics*. https://doi.org/10.1093/applin/amag048

n8n GmbH. (2024). *n8n Documentation* [Documentacion tecnica oficial]. https://docs.n8n.io/

Office of Government Commerce. (2011). *ITIL Service Operation* [Publicado por encargo del Office of Government Commerce; la titularidad de ITIL es hoy de la herencia AXELOS/PeopleCert]. The Stationery Office.

Paket, E., Şenerkek, G., Akyol, F. B., & Salman, F. (2024). IT Service Desk Ticket Classification via Large Language Models. *2024 9th International Conference on Computer Science and Engineering (UBMK)*, 135-140. https://doi.org/10.1109/ubmk63289.2024.10773473

Paramesh, S. P., & Shreedhara, K. S. (2019). Automated IT Service Desk Systems Using Machine Learning Techniques. En *Lecture Notes in Networks and Systems* (pp. 331-346, Vol. 43). Springer. https://doi.org/10.1007/978-981-13-2514-4_28

Parlamento Europeo y Consejo de la Unión Europea. (2016, abril). Reglamento (UE) 2016/679 — Reglamento General de Protección de Datos [Diario Oficial de la Unión Europea, L 119/1].

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Powers, D. M. W. (2011). Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation. *Journal of Machine Learning Technologies*, *2*(1), 37-63.

Pressman, R. S., & Maxim, B. R. (2020). *Software Engineering: A Practitioner's Approach* (9.ª ed.). McGraw-Hill.

Rabiner, L., & Juang, B.-H. (1993). *Fundamentals of Speech Recognition*. Prentice Hall.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, 28492-28518.

Ramón-Ferrer, V., Badenes-Olmedo, C., & Corcho, Ó. (2026). Spanish Triple-to-Text Benchmark on Low-Resource Large Language Models. *Semantic Web*, *17*(3). https://doi.org/10.1177/22104968261440701

Revina, A., Buza, K., & Meister, V. G. (2020). IT Ticket Classification: The Simpler, the Better. *IEEE Access*, *8*, 193380-193395. https://doi.org/10.1109/ACCESS.2020.3032840

Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4.ª ed.). Pearson.

Secretaría de la Pequeña y Mediana Empresa. (2026). ¿Qué es una MiPyME? [Ministerio de Economía de la Nación Argentina; consultado el 19 de octubre de 2026]. https://www.argentina.gob.ar/produccion/registrar-una-pyme/que-es-una-pyme

Sokolova, M., & Lapalme, G. (2009). A Systematic Analysis of Performance Measures for Classification Tasks. *Information Processing & Management*, *45*(4), 427-437. https://doi.org/10.1016/j.ipm.2009.03.002

Stallings, W., & Brown, L. (2017). *Computer Security: Principles and Practice* (4.ª ed.). Pearson.

The PostgreSQL Global Development Group. (2024). *PostgreSQL 15 Documentation* [Documentacion tecnica oficial]. https://www.postgresql.org/docs/15/

Tiangolo, S. R. (2024). *FastAPI Documentation* [Documentacion tecnica oficial]. https://fastapi.tiangolo.com/

Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., Bikel, D., Blecher, L., Canton-Ferrer, C., Chen, M., Cucurull, G., Esiobu, D., Fernandes, J., Fu, J., Fu, W., … Scialom, T. (2023). Llama 2: Open Foundation and Fine-Tuned Chat Models [arXiv:2307.09288]. *arXiv preprint*. https://doi.org/10.48550/arXiv.2307.09288

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 5998-6008.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, *17*(3), 261-272. https://doi.org/10.1038/s41592-019-0686-2

Wiggins, A. (2017). The Twelve-Factor App [Manifiesto de arquitectura de software]. https://12factor.net/

Wilson, E. B. (1927). Probable Inference, the Law of Succession, and Statistical Inference. *Journal of the American Statistical Association*, *22*(158), 209-212. https://doi.org/10.1080/01621459.1927.10502953

Xuan, W., Yang, R., Qi, H., Zeng, Q., Xiao, Y., Feng, A., Liu, D., Xing, Y., Wang, J., Gao, F., Lu, J., Jiang, Y., Li, H., Li, X., Yu, K., Dong, R., Gu, S., Li, Y., Xie, X., … Li, I. (2025). MMLU-ProX: A Multilingual Benchmark for Advanced Large Language Model Evaluation. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1513-1532. https://doi.org/10.18653/v1/2025.emnlp-main.79

Zangari, A., Marcuzzo, M., Schiavinato, M., Gasparetto, A., & Albarelli, A. (2023). Ticket automation: An insight into current research with applications to multi-level classification scenarios. *Expert Systems with Applications*, *225*, 119984. https://doi.org/10.1016/j.eswa.2023.119984

Zhang, R., Cahyawijaya, S., Cruz, J. C. B., Winata, G. I., & Aji, A. F. (2023). Multilingual Large Language Models Are Not (Yet) Code-Switchers. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 12567-12582. https://doi.org/10.18653/v1/2023.emnlp-main.774

A. Diagrama de arquitectura del sistema

El Anexo A referencia los diagramas de la arquitectura propuesta en notación UML. Los diagramas de despliegue y de secuencia se incluyen como figuras de la Sección 5, de modo que no se reproducen nuevamente aquí; el diagrama de componentes se incluye como Figura 1 de la Sección 5. Los tres artefactos son:

- **Diagrama de despliegue** (Figura 3, Sección 5): los cinco componentes principales (N8N, FastAPI, PostgreSQL, Gemini 3.6 Flash, Twilio), el proxy inverso Nginx que, en el diseño, provee terminación TLS 1.2/1.3 en el perímetro del sistema (no incluido en el despliegue publicado), y las relaciones de comunicación entre ellos. Fuente versionada: `docs/diagrams/despliegue.md`.
- **Diagrama de secuencia** (Figura 4, Sección 5): flujo extremo a extremo de un incidente desde su recepción en el canal de correo electrónico hasta la confirmacion al usuario, incluyendo las interacciones con el clasificador hibrido y la base de datos. Fuente versionada: `docs/diagrams/secuencia.md`.
- **Diagrama de componentes** (Figura 1, Sección 5): organización interna del modulo Python por capas (routes, services, repositories, models, classifiers), con sus dependencias y relaciones. Fuente versionada: `docs/diagrams/componentes.md`.

Los diagramas se generan a partir de fuentes Mermaid versionadas en formato `.md` en el directorio `docs/diagrams/` del repositorio y se renderizan a imágenes PNG para su inclusion en el documento (Gómez et al. 2026). Las Figuras 3 y 4 se presentan en la Sección 5 y se referencian desde este anexo, sin duplicar el material grafico.

B. Repositorio de código fuente

El código fuente del modulo Python, los scripts de migración de la base de datos PostgreSQL gestionados mediante Alembic, los archivos de configuración del despliegue en contenedores Docker y los flujos de integración continua sobre GitHub Actions se encuentran disponibles en el repositorio publico del proyecto (Gómez et al. 2026). El commit de referencia para la versión entregada al jurado se consigna mediante el tag `v1.0.0`. La creación de dicho tag sobre el commit definitivo entregado al jurado queda como acción pendiente al cierre de los changes c-76 y c-77; una vez creado, se registrará en este mismo apartado el hash completo del commit etiquetado como referencia verificable de la versión evaluada.

La estructura del repositorio separa el módulo de procesamiento (`App/Backend/`, con

la aplicación FastAPI, las migraciones Alembic y las pruebas), la interfaz de usuario (`App/Frontend/`, React con TypeScript), la definición del flujo de orquestación (`n8n/workflow.json`), los artefactos de evaluación (`evaluation/`), el corpus pseudonimizado (`data/`), los scripts auxiliares (`scripts/`) y la documentación (`docs/`), junto con las especificaciones de los changes (`openspec/`) y los archivos de orquestación local `docker-compose.yml` y `Makefile`. El archivo `README.md` describe esta organización y reúne las instrucciones detalladas para el despliegue local en menos de 15 minutos, por lo que constituye el punto de entrada al código fuente disponible en el repositorio publico (Gómez et al. 2026).

C. Esquema de base de datos

El esquema completo de la base de datos PostgreSQL se documenta mediante scripts SQL versionados que definen las siete entidades descritas en la Tabla 4 de la Sección 5, las restricciones de integridad referencial (claves foraneas con eliminacion en cascada condicional), los indices secundarios sobre los atributos de busqueda frecuente (fecha de creacion, sector responsable y estado actual del ticket), y la generacion de los identificadores de incidente. Las migraciones incrementales se gestionan mediante Alembic, lo que permite reproducir el estado de la base en cualquier punto histórico del desarrollo y revertir cambios cuando resulte necesario.

La migración inicial incluye la creacion de las tablas de catalogo (`sector`, `estado`, `canal_origen`) con sus valores semilla, garantizando que un despliegue nuevo del sistema comience con los datos de referencia correctos. Las migraciones subsiguientes documentan la evolucion del esquema durante las seis iteraciones de desarrollo descritas en la Sección 4.

El diagrama entidad-relación de las siete entidades del modelo se incluye como Figura 5 de la Sección 5, junto con la descripcion de cada entidad en la Tabla 4; este anexo no lo reproduce nuevamente. La fuente Mermaid versionada del diagrama reside en `docs/diagrams/er_modelo_dat`
El detalle de atributos, tipos, claves primarias y foraneas, restricciones de integridad referencial e indices secundarios se conserva como scripts SQL y migraciones Alembic versionadas en el repositorio.

D. Especificación OpenAPI de la interfaz REST

La especificación completa de la interfaz REST se genera automáticamente mediante FastAPI conforme a la versión 3.1 de la especificación OpenAPI (Tiangolo, 2024). El docu-

mento resultante describe los puntos de entrada listados en la Tabla 5 de la Sección 5, los esquemas de los cuerpos de solicitud y respuesta validados mediante Pydantic v2, los códigos de estado posibles para cada método HTTP, y ejemplos representativos para cada caso de uso.

La interfaz se encuentra disponible adicionalmente en formato interactivo a través del componente Swagger UI integrado en el servidor, accesible bajo la ruta `/docs` durante la ejecución, y en formato estatico como archivo `openapi.json` en el directorio `docs/` del repositorio. La sincronización entre el código y la especificación estatica se verifica automáticamente en el pipeline de integración continua.

La especificación OpenAPI vigente describe 33 puntos de entrada que exponen 41 métodos HTTP y 44 esquemas de datos, agrupados por recurso: autenticación, catálogos, clasificaciones, incidentes, directorio, estadísticas, telefonía, control de costo y salud. El documento completo reside en `docs/openapi.json` del repositorio y se expone además en formato interactivo bajo la ruta `/docs`.

A título ilustrativo, los 44 esquemas de datos comprenden las estructuras de los catálogos, las entidades de dominio y los objetos de respuesta de cada recurso. El esquema `IncidenteRead`, por ejemplo, expone el identificador del ticket, la descripción pseudonimizada, la prioridad, el sector y los sectores adicionales, el estado, el canal de origen, el reportante, las marcas temporales de ingreso y persistencia, y los indicadores de latencia end-to-end y de latencia anómala, con sus tipos y campos de solo lectura. El detalle exhaustivo de atributos, tipos y ejemplos reside en `docs/openapi.json`.

E. Configuración del flujo N8N

La exportación del flujo de orquestación en formato JSON incluye la totalidad de los 29 nodos configurados, sus parámetros operativos, las credenciales referenciadas mediante identificadores opacos sin exposición de valores, y los conectores entre nodos. El archivo `n8n/workflow.json` contiene esta exportación. La importación de este artefacto en una instancia limpia de N8N 2.11.2 reproduce íntegramente el comportamiento operativo del sistema, sujeta únicamente a la provisión de las credenciales correspondientes a los servicios externos integrados (servidor IMAP de correo, cuenta Twilio y clave de API de Gemini) mediante el sistema de credenciales nativo de la plataforma.

La Figura 8 presenta una reconstrucción esquemática del flujo, derivada de la expor-

tación JSON y agrupada por etapa funcional. Los 29 nodos operativos se organizan en siete etapas: entrada (triggers), con la recepción de correo por IMAP y los disparadores de telefonía, formulario web y notificación de clasificación; validación y normalización de la información de entrada, incluida la marca de canal y el sellado de ingreso; envío al backend, con la autenticación del operador y la solicitud POST del incidente; ruteo por canal de origen; revisión humana, con la notificación al operador designado y las respuestas de handoff; respuesta y auditoría del ticket; y aviso post-revisión. La parametrización completa de cada nodo reside en `n8n/workflow.json`.

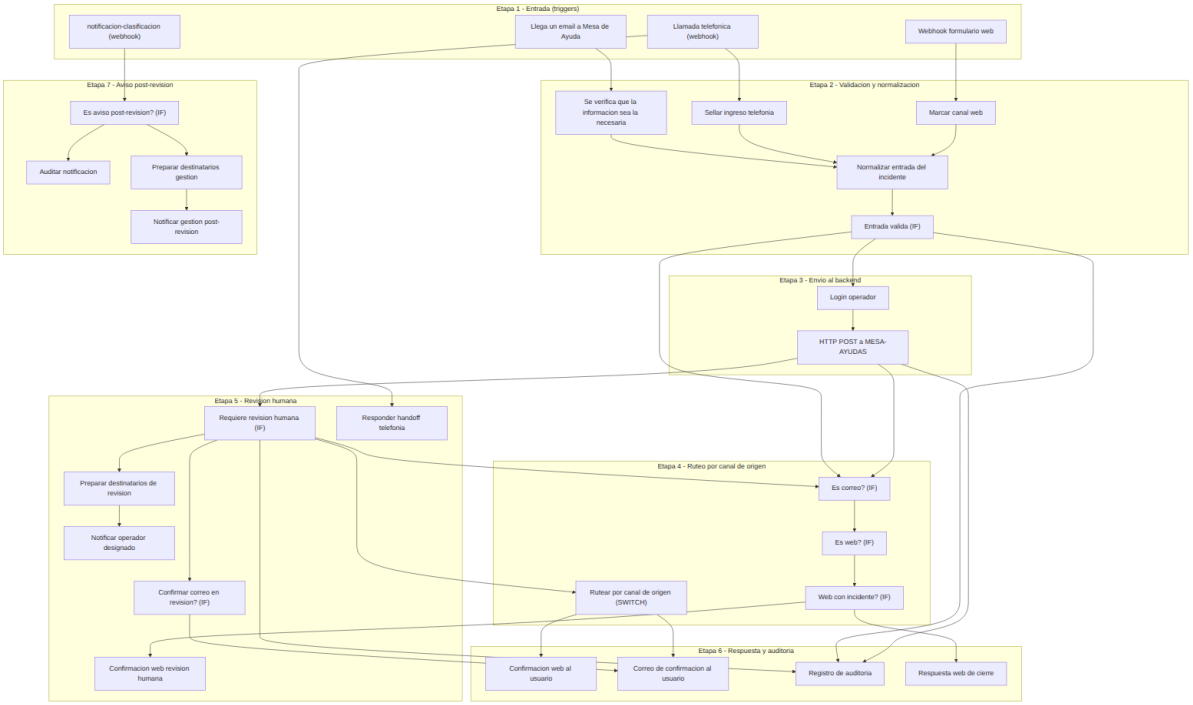


Figura 8. Reconstrucción esquemática del flujo de orquestación N8N, derivada de la exportación `n8n/workflow.json`. No es una captura de la interfaz: los 29 nodos operativos se agrupan por etapa funcional.

F. Corpus de validación

El corpus de 200 incidentes utilizado para la validación experimental reside en el repositorio en formato JSON, en su forma pseudonimizada y versionada, bajo la ruta `data/corpus_evaluacion_p`. Cada caso incluye el identificador anónimo, la descripción cruda pseudonimizada, el canal de origen, el sector asignado por consenso humano, los sectores adicionales de verdad y el tiempo de registro medido en cada flujo. La categoría predicha por el clasificador y la confianza asociada no forman parte del corpus: se conservan en `evaluation/predicciones.json`, generado por el framework de evaluación. Se incluyen además las planillas de cronometraje

del flujo manual y los registros automáticos generados por el flujo automatizado.

Cada uno de los 200 casos del corpus se compone de siete campos: `id` (identificador anónimo, por ejemplo `R001`), `descripcion` (texto pseudonimizado, con los identificadores personales reemplazados por etiquetas genéricas como `[EMAIL]`, `[TELEFONO]`, `[HOST]` y `[PERSONA]`), `canal_origen` (correo electrónico, formulario web o llamada telefónica), `sector_asignado` (sector principal de verdad, exactamente uno de los cinco sectores canónicos), `sectores_adicionales` (sectores de verdad complementarios, sin repetir el asignado), `tiempo_manual_s` (tiempo de clasificación manual, en segundos) y `tiempo_automatizado_s` (tiempo del sistema automatizado, en segundos). El corpus completo reside en `data/corpus_evaluacion_` y las predicciones del clasificador en `evaluation/predicciones.json`.

Por razones de privacidad y en cumplimiento de la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000), las descripciones textuales han sido pseudonimizadas previamente a su inclusion en el repositorio publico, reemplazando nombres propios, direcciones de correo y otros identificadores personales por etiquetas genericas.

G. Documentación operativa

La documentación operativa del sistema describe los procedimientos de despliegue inicial, configuración recurrente, respaldo y restauración, monitoreo activo y respuesta ante incidentes operativos. Se incluyen instrucciones detalladas para los entornos de desarrollo, preproducción y producción, así como una guía de resolución de incidencias frecuentes orientada al personal de operaciones de la organización adoptante. La documentación se mantiene actualizada en el repositorio del proyecto y se versiona conjuntamente con el código fuente, garantizando coherencia entre la versión desplegada y los procedimientos vigentes en cada momento del ciclo de vida del sistema.

El runbook operativo (`docs/operational-guide.md`) se organiza en una sección de prerequisitos y once secciones de procedimiento: despliegue inicial (clonado del repositorio, configuración de variables de entorno, certificados TLS, arranque del stack, verificación de salud, importación del flujo N8N y acceso al frontend), detención y reinicio de los servicios, respaldo y restauración de PostgreSQL, monitoreo de salud (endpoints, contenedores, logs estructurados y cola de revisión humana), regeneración de la especificación OpenAPI, actualización de dependencias del backend, aplicación manual de migraciones Alembic, evaluación del clasificador, arnés de ejecución en seco (*dry-run*), medición de latencia end-to-end y guarda

de costo en runtime (postura al arranque, *enforcement*, política *fail-closed* y reproducibilidad de la suite de integración).

H. Especificación del prompt de Gemini 3.6 Flash

Este anexo documenta la especificación del prompt enviado al modelo `gemini-3.6-flash` (Gemini 3.6 Flash en el texto) y los parámetros de configuración de la inferencia. El prompt se mantiene en el repositorio bajo `docs/prompt_gemini.txt` y es único para los tres canales de entrada.

H.1. Estructura y contenido del prompt

El prompt sigue una estructura fija en español organizada en cinco componentes funcionales y un conjunto de reglas de desambiguación:

1. **Instrucción de rol**: define que el modelo actúa como agente especializado en clasificación de incidentes técnicos en español rioplatense, lo que ancla el comportamiento en el dominio y el dialecto del estudio.
2. **Definición de categorías**: presenta los cinco sectores canónicos con sus *strings* exactos (sensibles a mayúsculas y sin tildes), un ámbito descriptivo por sector y un ejemplo representativo extraído del dominio real por cada uno.
3. **Formato de respuesta**: solicita un JSON válido con exactamente dos campos, `categoría` (uno de los cinco valores canónicos) y `confianza` (número entre 0,0 y 1,0), sin texto adicional, comentarios ni explicaciones.
4. **Lógica de decisión**: indica analizar la descripción y asignar una categoría única entre las cinco opciones; ante elementos de múltiples categorías, elegir la dominante.
5. **Validación sintáctica**: exige validar la corrección sintáctica del JSON antes de devolverlo y reducir la confianza cuando no sea posible clasificar con seguridad.
6. **Reglas de desambiguación de frontera**: las acciones sobre aplicaciones o sistemas operativos (acceder, iniciar sesión, abrir una aplicación) se orientan a `Soporte Tecnico Software`; los dispositivos físicos y su digitalización (escáner, impresora, periférico, error de digitalización) a `Soporte Tecnico Hardware`; y la infraestructura y los servicios de plataforma (servidor, red, SMTP, VM) a `Sistemas`. Estas reglas corrigen casos de frontera medidos sobre el corpus.

H.2. Parámetros de configuración

La invocación del modelo se realiza mediante la API `google-generativeai` versión 0.8, con los hiperparámetros que resume la Tabla 12, optimizados para equilibrar exactitud, latencia y costo de inferencia.

Tabla 12. Parámetros de configuración de la inferencia con `gemini-3.6-flash`.

Parámetro	Valor	Justificación
`temperature`	0,3	Valor bajo que reduce la variabilidad de la generación y mejora la consistencia en tareas de clasificación determinística.
`top_p`	0,9	*Nucleus sampling* que admite variantes léxicas válidas en español rioplatense sin sacrificar coherencia.
`max_tokens`	100	Límite suficiente para la respuesta JSON, con margen ante variaciones y sin truncamiento.
`candidate_count`	1	Respuesta única sin remuestreo; optimiza la latencia para el procesamiento en tiempo real.
`safety_settings`	Parcialmente desactivados	Desactiva filtros que podrían rechazar descripciones legítimas de incidentes, manteniendo los filtros contra contenido verdaderamente tóxico.
`timeout`	10 segundos	Límite máximo de latencia; al excederse, el clasificador devuelve confianza 0,0 y marca el caso para revisión humana.
API	`google-generativeai` 0.8	Versión vigente al momento del estudio, documentada para reproducibilidad.

Fuente: elaboración propia a partir de la documentación de la API `google-generativeai`.

H.3. Validación de la respuesta

Antes de aceptar la respuesta del modelo, el módulo de clasificación valida que el texto sea JSON parseable, que contenga exactamente las claves `categoría` y `confianza`, que la categoría sea uno de los cinco valores canónicos y que la confianza sea un número en el intervalo $[0{,}0, 1{,}0]$. Si cualquiera de estas condiciones falla, se registra la excepción, se asigna confianza 0,0, se marca el incidente para revisión humana y no se propagan estados inconsistentes a la base de datos. Este procedimiento garantiza la confiabilidad operativa frente a errores de formato o alucinaciones del modelo. El Listado 1 resume la rutina de validación.

```
1 def validar_respuesta_gemini(response_text: str) -> tuple[bool, dict]:
2     try:
3         data = json.loads(response_text)
4     except json.JSONDecodeError as e:
5         return False, {"error": f"JSON invalido: {e}"}
```

```
    if "categoria" not in data:
        return False, {"error": "Falta campo 'categoria'"}
    if data["categoria"] not in SECTORES_CANONICOS:
        return False, {"error": f"Categoria invalida: {data['categoria']}"}
    if "confianza" not in data:
        return False, {"error": "Falta campo 'confianza'"}
    if not isinstance(data["confianza"], (int, float)) \
            or not (0.0 <= data["confianza"] <= 1.0):
        return False, {"error": f"Confianza invalida: {data['confianza']}"}
    return True, data
```

Listing 1. Validación de la respuesta de Gemini (resumen).

H.4. Iteración y mejora del prompt

El prompt se validó y ajustó de forma iterativa sobre un conjunto de aproximadamente 100 incidentes representativos en entornos de preproducción, sin exposición al corpus de validación de 200 casos. Las versiones históricas del prompt se conservan en el repositorio bajo `docs/prompt_gemini_history/` para auditoría y eventual reversión.

H.5. Recomendaciones para futuras iteraciones

Ante una degradación de las métricas por cambios en el modelo, se recomienda profundizar los ejemplos por clase (de dos a cuatro o cinco), agregar contraejemplos de incidentes limítrofes, especificar umbrales de confianza explícitos, incluir un diccionario de términos clave por categoría y, una vez acumulado un corpus del orden de 5.000 casos etiquetados, migrar a un modelo ajustado específicamente al dominio.

I. Trazabilidad de las correcciones del dictamen

El registro de correcciones derivado del dictamen evaluador se conserva como artefacto versionado en el repositorio, bajo la ruta `docs/Tesis/Correcciones/dictamen-correcciones.md`. El documento compila, de forma acumulativa, cada corrección aplicada al manuscrito y las decisiones adoptadas sobre las observaciones que no admitían una resolución inmediata (por ejemplo, la convención estadística del estadístico *W*, la reformulacion de la hipótesis principal y el tratamiento de los reintentos como limitación conocida). Se incluye aquí como ejemplo de trazabilidad: cada entrada del registro vincula una observación del dictamen con el archivo y

la linea corregidos, de modo que la correspondencia entre la revisión solicitada y la revisión efectuada resulte auditable de extremo a extremo.