UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL MENDOZA

Tecnicatura Universitaria en Programación

Automatización inteligente del registro de incidentes en mesas de ayuda empresariales mediante orquestación de flujos con N8N y procesamiento de lenguaje natural basado en modelos de lenguaje grandes

Trabajo Final de Carrera presentado para obtener el título de

Técnico Universitario en Programación

Autores

Luca Gomez · Carla Bustos · Gonzalo Sevilla

Directores

Prof. Alberto Cortez y Prof. Ariel Enferrel

Mendoza, República Argentina

14 de noviembre de 2026

Versión 1.4.0

Resumen

La digitalización eleva la criticidad de la gestión de incidentes, pero en muchas organizaciones medianas el registro inicial es manual, con demoras, errores de clasificación y uso ineficiente de recursos.

Esta investigación diseña, implementa y valida un sistema automatizado de mesa de ayuda que integra N8N, FastAPI, Gemini 3.6 Flash, PostgreSQL y telefonía con Twilio. Recibe solicitudes por correo, formulario web y teléfono y las deriva a uno de los cinco sectores mediante un clasificador híbrido de reglas y un modelo de lenguaje grande.

El estudio es cuantitativo y cuasiexperimental, de muestras pareadas, sobre los 200 casos (muestra por conveniencia). El doble etiquetado independiente de la campaña complementaria alcanzó un kappa de 0,5569 (moderado).

El tiempo medio de registro se redujo significativamente, de 61,6 s a 17,76 s (71,2 %). Dentro de la muestra, la exactitud estricta fue de 73,5 % y el macro-F1 de umbral, 0,6508. Fuera de la muestra, sobre el corpus arbitrado, la exactitud estricta cruda fue de 0,6893 (ponderada, 0,7489), por debajo del umbral, y el híbrido superó a la línea de base clásica. Por sub-hipótesis, una se corrobora (tiempo), una resulta no concluyente (intervención humana: de 147 revisados, 25 cambiaron, 17,0 %) y una se refuta (exactitud y macro-F1).

Los hallazgos respaldan la viabilidad técnica; la económica y operativa es condicional: con una referencia común el balance neto es positivo, pero la muestra solo fija su signo con 5 minutos por derivación. Se aporta una arquitectura reproducible y evidencia en español rioplatense.

Palabras clave: automatización, mesa de ayuda, procesamiento de lenguaje natural, modelo de lenguaje grande, N8N, FastAPI, clasificación de tickets, español rioplatense, human in the loop

Abstract

Digitalization raises the criticality of incident management, yet in many medium-sized organizations initial registration is manual, with delays, classification errors, and inefficient use of resources.

This thesis designs, implements, and validates an automated help desk system integrating N8N, FastAPI, the Gemini 3.6 Flash model, PostgreSQL, and a Twilio telephony channel. It receives requests through email, web form, and phone calls with automatic transcription, and routes each incident to one of the five canonical sectors using a hybrid classifier of rules and a large language model.

The study is quantitative and quasi-experimental, with paired samples over 200 cases (convenience sample). The independent double labeling of the complementary campaign reached a kappa of 0.5569 (moderate).

Results show a significant reduction in mean registration time, from 61.6 s to 17.76 s (71.2 %). As in-sample estimates, strict classification accuracy was 73.5 % and the threshold macro-F1 was 0.6508. Out of sample, on the arbitrated corpus, strict accuracy was 0.6893 (weighted, 0.7489), below the threshold, and the hybrid outperformed the classical baseline. Per sub-hypothesis, one is corroborated (registration time), one is inconclusive (human intervention: of 147 reviewed cases, 25 changed, 17.0 %), and one is refuted (accuracy and macro-F1).

The findings support technical feasibility; economic and operational feasibility are conditional: on a common reference, the estimated net balance is positive, but the sample only fixes its sign at 5 minutes per misrouting. A reproducible architecture and evidence in Rioplatense Spanish are provided.

Keywords: automation, help desk, natural language processing, large language model, N8N, FastAPI, ticket classification, Rioplatense Spanish, human in the loop

Índice general

Glosario de siglas y acrónimos **10**
1 Introducción **11**
1.1 Contextualización 11
1.2 Planteamiento del problema 11
1.3 Pregunta de investigación 12
1.4 Hipótesis de trabajo 13
1.5 Objetivo general 14
1.6 Objetivos específicos 14
1.7 Justificación 16
1.8 Alcance y delimitaciones 17
2 Marco teórico **19**
2.1 Gestión de servicios de tecnologías de la información 19
2.2 Mesa de ayuda y modelo ITIL 19
2.3 Automatización de procesos y orquestación de flujos 20
2.4 Human-in-the-loop y grados de autonomía 21
2.5 Procesamiento de lenguaje natural y modelos de lenguaje grandes 22
2.6 Reconocimiento automático del habla 25
2.7 Bases de datos relacionales y persistencia transaccional 25
2.8 Métricas de evaluación de clasificadores multiclase 26
2.9 Acuerdo entre anotadores y fiabilidad de la referencia 27
2.10 Clasificación multietiqueta 27
2.11 Pruebas estadísticas para el contraste de hipótesis 28
3 Estado del arte **29**
3.1 Soluciones comerciales de mesa de ayuda 30
3.2 Plataformas de orquestación de flujos 31
3.3 Trabajos académicos previos sobre clasificación de tickets 31
3.4 Calibración de la confianza y cascadas de modelos 34
3.5 Análisis comparativo y brecha identificada 34
4 Marco metodológico **36**
4.1 Enfoque y tipo de investigación 36
4.2 Diseño experimental 36
4.3 Operacionalización de variables 37
4.4 Población, muestra y corpus 37
4.5 Protocolo de pruebas 41
4.6 Métricas e instrumentos 44
4.7 Análisis estadístico 46
4.8 Amenazas a la validez 51
4.9 Gestión del proyecto bajo enfoque Scrumban (método de construcción del artefacto) 53
5 Arquitectura del sistema **55**
5.1 Visión general 55
5.2 Capa de canales de entrada 55
5.3 Capa de orquestación 58
5.4 Capa de procesamiento 58
5.5 Subsistema de clasificación híbrido 59
5.6 Modelo de datos 61
5.7 Contrato de la interfaz REST 63
6 Implementación **65**
6.1 Entorno de despliegue y dependencias 65
6.2 Construcción del módulo Python 65
6.3 Construcción del flujo en N8N 66
6.4 Integración del canal telefónico 68
6.5 Desafíos de integración 69
6.6 Conexión con el proceso Scrumban 70
6.7 Pruebas automatizadas 71
6.8 Dashboard de analítica 73
7 Consideraciones éticas y aspectos legales **76**

7.1 Marco normativo aplicable ... 76
7.2 Principios aplicados al tratamiento de datos ... 76
7.3 Transferencia internacional y pseudonimización ... 77
7.4 Seguridad técnica ... 79
7.5 Consentimiento, derechos del usuario y supervisión humana ... 79
7.6 Cumplimiento normativo y alineación con estándares ... 81
7.6.1 Marco de referencia adoptado ... 81
7.6.2 Estado de alineación con ISO/IEC 27002:2022 ... 82
7.6.3 Perfil de alineación con NIST CSF 2.0 ... 82
7.6.4 Brechas principales y hoja de ruta ... 82
7.6.5 Alineación con el marco legal ... 83
8 Resultados ... **84**
8.1 Comparación de tiempos de registro ... 84
8.2 Matriz de confusión y métricas de clasificación ... 86
8.3 Derivación e intervención humana en la campaña complementaria ... 89
8.4 Calibración de la confianza ... 90
8.5 Sensibilidad al ajuste del clasificador con el corpus ... 93
8.6 Sesgo del vocabulario y dependencia de la referencia ... 94
8.7 Análisis de errores y casos límite ... 95
8.8 Resultados de la campaña complementaria de medición ... 97
8.9 Validación fuera de muestra ... 100
8.10 Comparación con esquemas alternativos ... 101
8.11 Capacidad del tramo compartido bajo carga concurrente ... 105
8.12 Sensibilidad a la referencia de verdad ... 107
9 Discusión ... **109**
9.1 Interpretación de los resultados ... 109
9.2 Comparación con la literatura ... 114
9.3 Limitaciones del estudio ... 116
9.4 Implicancias prácticas ... 119
9.5 Balance neto de la automatización ... 120
9.6 Reflexiones sobre la generalización ... 123
10 Conclusiones ... **124**
10.1 Cumplimiento de los objetivos del trabajo ... 124
10.2 Aportes y generalización ... 127
11 Recomendaciones y líneas de trabajo futuro ... **129**
11.1 Calibración del gate de confianza ... 129
11.2 Incorporación de un clasificador supervisado con corpus propio ... 130
11.3 Medición de la frontera `Sistemas–Soporte Tecnico Software` ... 131
11.4 Medición continua de la intervención humana en operación ... 131
11.5 Validación sobre un corpus independiente ... 132
11.6 Mecanismos de aprendizaje activo ... 132
11.7 Estudios de replicación ... 133
11.8 Evaluación de modelos de lenguaje de código abierto ... 133
11.9 Cola de respaldo y alta asincrónica ... 134
11.10 Ampliaciones de producto no derivadas de una limitación medida ... 134
Referencias bibliográficas ... **135**
Anexos ... **139**
A Diagrama de arquitectura del sistema ... **139**
B Repositorio de código fuente ... **139**
C Esquema de base de datos ... **146**
D Especificación OpenAPI de la interfaz REST ... **146**
E Configuración del flujo N8N ... **147**
F Corpus de validación ... **147**
G Documentación operativa ... **151**
H Especificación del prompt de Gemini 3.6 Flash ... **151**
H.1 Estructura y contenido del prompt ... 151
H.2 Parámetros de configuración ... 152
H.3 Validación de la respuesta ... 152

H.4 Iteración y mejora del prompt 154
H.5 Recomendaciones para futuras iteraciones 154
I Trazabilidad de las correcciones de los dictámenes 154
I.1 Nota de versiones 154
I.2 Revisiones que originaron las correcciones 155

Índice de tablas

1 Trabajos académicos previos sobre clasificación de tickets 33
2 Comparación de soluciones para gestión automatizada de mesa de ayuda 34
3 Operacionalización de variables del estudio 38
4 Capas funcionales de la arquitectura del sistema 56
5 Entidades principales del modelo de datos 61
6 Puntos de entrada principales de la interfaz REST 63
7 Estado de alineación con los controles de ISO/IEC 27002:2022, agrupados por tema 82
8 Perfil de alineación con las funciones de NIST CSF 2.0 82
9 Estadísticos descriptivos de los tiempos de registro por flujo ($n = 200$) 85
10 Tiempo de registro por canal de origen: flujos manual y automatizado, reducción y contraste intra-canal ($n = 200$) 85
11 Matriz de confusión del clasificador automático ($n = 200$). Filas: sector asignado; columnas: sector predicho principal. 87
12 Exactitud estricta y laxa por etapa del pipeline y por canal de origen 87
13 Métricas de clasificación por clase con intervalo de confianza al 95 % (una contra el resto) 89
14 Exactitud por banda de confianza declarada y por etapa del pipeline 91
15 Calibración y discriminación de la confianza de la etapa Gemini, dentro y fuera de la muestra 92
16 Sensibilidad de la exactitud al vocabulario ajustado con el corpus 94
17 Etapa determinística con tres vocabularios 95
18 Exactitud estricta del clasificador congelado según el origen de la referencia 95
19 Confusiones observadas en la clasificación automática, por frontera, con los aciertos laxos entre los errores estrictos 96
20 Tiempo del brazo manual de la campaña complementaria por operador y reducción frente al brazo automatizado de la misma campaña 98
21 Validación fuera de muestra del clasificador congelado `hybrid-v3` sobre el corpus independiente 102
22 Matriz de confusión y métricas por clase del corpus arbitrado completo ($n = 206$) 103
23 Comparación de la línea de base clásica con el híbrido `hybrid-v3` sobre los 206 casos fuera de muestra arbitrados 103
24 Contraste pareado del híbrido frente al brazo de modelo de lenguaje solo, por bloque 105
25 Latencia, throughput y tasa de error por nivel de concurrencia y por capa 106
26 Sensibilidad de la exactitud estricta y la macro-F1 a referencias alternativas plausibles 107
27 Exactitud mínima de equilibrio y balance neto trimestral según la tasa de derivación errónea manual y el costo por derivación 121
28 Cumplimiento de los objetivos del trabajo y evidencia de respaldo 125
29 Configuración evaluada, configuración entregada y configuración de la campaña complementaria 145
30 Parámetros de configuración de la inferencia con `gemini-3.6-flash` 153

Índice de figuras

1 Diagrama de arquitectura del sistema 56
2 Diagrama de despliegue del entorno local. Servicios, redes Docker (edge, data interna, automation y host_access), volúmenes y servicios externos. 57
3 Diagrama entidad-relación de las siete entidades principales 62
4 Panel de administración del sistema 74
5 Dashboard de analítica del panel de administración 74
6 Distribución del tiempo de registro por canal de origen (manual frente a automatizado), para la corrida telefónica del 5 y 6 de octubre de 2026. El panel de telefonía incorpora la duración de la llamada grabada. 86
7 Diagrama de secuencia del flujo extremo a extremo de un incidente (parte A) 140
8 Diagrama de secuencia del flujo extremo a extremo (parte B) 141

9 Diagrama de componentes del módulo Python organizado en capas (parte A) 142
10 Diagrama de componentes del módulo Python (parte B) 143
11 Cronograma de la construcción, las campañas y la versión del modelo 144
12 Reconstrucción esquemática del flujo de orquestación N8N (parte A) 148
13 Reconstrucción esquemática del flujo de orquestación N8N (parte B) 149
14 Reconstrucción esquemática del flujo de orquestación N8N (parte C) 150

Glosario de siglas y acrónimos

ACID Atomicity, Consistency, Isolation, Durability
AES Advanced Encryption Standard
AI Artificial Intelligence
API Application Programming Interface

ARCO Acceso, Rectificación, Cancelación y Oposición
ASGI Asynchronous Server Gateway Interface
ASR Automatic Speech Recognition

AUROC Area Under the Receiver Operating Characteristic curve
BERT Bidirectional Encoder Representations from Transformers
BPA Business Process Automation
Brier puntaje de Brier (error cuadrático de la confianza)
CBC Cipher Block Chaining
CE Comunidad Europea
CI Continuous Integration
CIA Confidentiality, Integrity, Availability
CMDB Configuration Management Database
CONEAU Comisión Nacional de Evaluación y Acreditación Universitaria
CoT *Chain of Thought* (cadena de razonamiento)
CRUD Create, Read, Update, Delete
CSF Cybersecurity Framework
DAG Directed Acyclic Graph
DT Decision Tree (árbol de decisión)
E2E End-to-End (extremo a extremo)

ECE Expected Calibration Error
ETL Extract, Transform, Load
FK Foreign Key
GB Gigabyte
GET método HTTP de lectura
GPT Generative Pre-trained Transformer
GPU Graphics Processing Unit
HITL Human In The Loop
HMAC Hash-based Message Authentication Code
HTTP Hypertext Transfer Protocol
IA Inteligencia Artificial
IC Intervalo de Confianza
IDF Inverse Document Frequency
IMAP Internet Message Access Protocol

IP Internet Protocol
iPaaS *Integration Platform as a Service* (plataforma de integración como servicio)
ISO International Organization for Standardization
ITIL Information Technology Infrastructure Library
ITSM Information Technology Service Management
JSON JavaScript Object Notation
JWT JSON Web Token
KMS Key Management Service
kNN *k-Nearest Neighbors* (k vecinos más cercanos)
LLM Large Language Model
LR Logistic Regression (regresión logística)

MDE Minimum Detectable Effect
MFA Multi-Factor Authentication
MVCC Multi-Version Concurrency Control
N8N plataforma de orquestación de flujos (*nodemation*)
NB Naive Bayes

NIST National Institute of Standards and Technology
NLBSE Natural Language-Based Software Engineering

NLP Natural Language Processing

ORM Object-Relational Mapper

PABAK Prevalence-Adjusted Bias-Adjusted Kappa
PAM Privileged Access Management
PATCH método HTTP de actualización parcial
PCM Pulse Code Modulation
PK Primary Key
PNG Portable Network Graphics

POST método HTTP de creación
RAG Retrieval-Augmented Generation
REST Representational State Transfer
RGPD Reglamento General de Protección de Datos
RTO Recovery Time Objective
SaaS *Software as a Service* (software como servicio)
SAST Static Application Security Testing
SBOM Software Bill of Materials
SDK Software Development Kit
SHA Secure Hash Algorithm
SIEM Security Information and Event Management
SLA Service Level Agreement
SMTP Simple Mail Transfer Protocol
SPA Single Page Application
SPOC Single Point of Contact
SQL Structured Query Language
SSD Solid-State Drive
SSO Single Sign-On
SVM Support Vector Machine
TF Term Frequency
TF-IDF Term Frequency-Inverse Document Frequency
TI Tecnologías de la Información

TLS Transport Layer Security
TOTP Time-based One-Time Password
TSO The Stationery Office
UI User Interface
URL Uniform Resource Locator
USD United States Dollar

UTC Coordinated Universal Time
UUID Universally Unique Identifier
VM Virtual Machine

1. Introducción

1.1. Contextualización

La evolución de las tecnologías de la información ha transformado profundamente la dinámica operativa de las organizaciones contemporáneas. En la actualidad los sistemas informáticos constituyen el soporte fundamental para la ejecución de procesos administrativos, productivos y de comunicación, y esa dependencia tecnológica ha incrementado de manera correlativa la importancia de los servicios de soporte técnico, particularmente aquellos relacionados con la gestión de incidentes informáticos. La disciplina que da marco a esa actividad —la gestión de servicios de tecnologías de la información (ITSM)— se desarrolla en la Sección 2, donde se define su alcance y su relación con la mesa de ayuda.

No obstante, en muchas organizaciones medianas el proceso de registro inicial de incidentes continúa realizándose manualmente, lo que introduce demoras, inconsistencias y una marcada dependencia del criterio individual del operador.

El contexto argentino presenta características particulares que acentúan esta problemática. Las organizaciones medianas del país —segmento que la Secretaría de la Pequeña y Mediana Empresa encuadra por tramos según el sector y parámetros como el personal ocupado o el volumen de ventas anuales (Secretaría de la Pequeña y Mediana Empresa, 2026)— operan con presupuestos de tecnología acotados. Además, enfrentan restricciones cambiarias que encarecen la adopción de soluciones comerciales internacionales. La combinación de estas restricciones con una demanda creciente de servicios digitales configura un escenario en el que las soluciones basadas en componentes de código abierto y servicios de inferencia bajo demanda resultan particularmente atractivas desde el punto de vista económico y operativo.

1.2. Planteamiento del problema

La presente investigación se desarrolla en el marco de una organización mediana del sector servicios con sede en la provincia de Mendoza, República Argentina, cuya plantilla asciende a aproximadamente 120 usuarios internos distribuidos en cinco áreas funcionales. El área de operaciones desempeña simultáneamente tareas vinculadas a la gestión operativa cotidiana y a la atención de incidentes informáticos reportados por los usuarios. Esa doble carga obliga al personal responsable a interrumpir actividades críticas para registrar manualmente fallas de hardware, inconvenientes de software o solicitudes de asistencia técnica.

Las mediciones preliminares realizadas durante una semana laboral representativa evi-

denciaron un volumen promedio de 42 incidentes diarios, un tiempo medio de registro manual de 2 minutos con 45 segundos por incidente y una tasa de derivación errónea inicial cercana al 15 %. Aquel valor de 2 minutos con 45 segundos constituyó una estimación a priori, obtenida del promedio de una semana completa de operación sin cronometraje individual por caso, y sirvió para dimensionar el problema. La tasa de derivación errónea del 15 % comparte esa naturaleza preliminar y no fue re-medida, por lo que el saldo neto se declara condicional (Subsección 9.5). La campaña experimental posterior midió el tiempo de registro incidente por incidente con cronometraje en vivo, consignado en la planilla descrita en la Subsección 4.2. Arrojó una media de 61,6 s sobre los 200 casos del corpus, sustancialmente inferior a la estimación preliminar. El tiempo que el personal podría redirigir a tareas de mayor valor agregado si la etapa de registro estuviera automatizada se cuantifica en la Subsección 9.1.

El registro manual de incidentes implica además la lectura de correos electrónicos, la interpretación de descripciones textuales heterogéneas, la clasificación del problema según el área responsable y la carga manual de la información en un sistema de tickets. Este procedimiento requiere tiempo, interrumpe las tareas del personal técnico y puede generar errores de clasificación que prolongan la cadena de resolución cuando un ticket es derivado a un área incorrecta. La dispersión de los canales de comunicación —correo, llamada telefónica y formularios internos— agrava la situación al obligar al personal a monitorear múltiples fuentes simultáneamente.

Este escenario es coherente con la caracterización general de la gestión de servicios de TI (Galup et al., 2009) (véase Subsección 2.1). Que los procesos de soporte no automatizados tiendan a degradarse cuando crece el volumen de solicitudes, con mayor impacto en organizaciones medianas donde el personal combina múltiples roles, es una inferencia de los autores de esta tesis y no una afirmación de esa fuente. Estos indicadores justifican la búsqueda de una alternativa tecnológica que reduzca el costo operativo, mejore la calidad de la derivación temprana y disminuya la variabilidad asociada al criterio individual.

1.3. Pregunta de investigación

A partir del problema descrito, esta investigación se orienta a responder la siguiente pregunta: ¿reduce la automatización del registro inicial de incidentes mediante orquestación de flujos y procesamiento de lenguaje natural el tiempo de registro respecto del proceso manual, y alcanza la exactitud de clasificación el umbral objetivo definido para una mesa de ayuda

empresarial mediana?

La pregunta se descompone en tres interrogantes subsidiarios que guían el diseño experimental y la selección de métricas. Primero, ¿cuál es la magnitud de la reducción del tiempo de registro que puede obtenerse mediante la automatización, y resulta esa reducción estadísticamente significativa? Segundo, ¿alcanza el clasificador automático el umbral objetivo de exactitud global del 85 % y un valor F1 macro no inferior a 0,85, y cómo se distribuyen los errores entre las categorías objetivo? Tercero, ¿permite la arquitectura propuesta integrar canales múltiples de recepción sin degradar la latencia ni la calidad de la clasificación?

1.4. Hipótesis de trabajo

La hipótesis principal de este trabajo se desdobla en tres sub-hipótesis contrastables, cada una con su propio contraste y su criterio de falsación, y no se enuncia como una conjunción indivisible de mecanismo y umbral de desempeño. La primera sostiene que la automatización reduce el tiempo de registro. Su contraste es el no paramétrico de Wilcoxon sobre las *diferencias pareadas* de los tiempos de registro. La H_0 establece que las diferencias pareadas $D_i = t_{\text{manual},i} - t_{\text{automatizado},i}$ se distribuyen de forma simétrica respecto de cero, es decir, que la automatización no altera el tiempo de registro. La H_1 establece que las diferencias tienden a ser positivas, es decir, que el tiempo manual supera al automatizado. El criterio de falsación es no rechazar H_0. El contraste y su veredicto se reportan en la Sección 8.

La segunda postula que la proporción de casos del flujo automatizado que requieren acción manual de un operador no supera 0,15. Esa cota es el complemento del umbral de exactitud fijado a priori en el segundo objetivo específico. Se contrasta con el intervalo de Wilson de la proporción mediante una regla de tres vías: el resultado es compatible si el límite superior del intervalo queda por debajo de 0,15, refutado si la estimación puntual alcanza o supera 0,15, y no concluyente si la estimación queda por debajo de 0,15 pero su límite superior no. La regla es asimétrica: la rama de refutación se decide con la estimación puntual y no con el intervalo, de modo que basta que aquella alcance la cota. El denominador de 147 casos revisados se adoptó después de conocer los datos; el cociente sobre los 200 casos se conserva como aplicación prefijada de la regla. El contraste y su veredicto se reportan en la Subsección 8.3.

La tercera postula que la exactitud y el F1 macro alcanzan el umbral de desempeño (exactitud no inferior al 85 % y F1 macro de umbral no inferior a 0,85). Se verifica contra la

exactitud observada y su intervalo de confianza de Wilson, sin invocar la zona de rechazo del contraste de tiempos. Su criterio de falsación es una exactitud observada por debajo del 85 % o un intervalo de confianza que no supera el umbral. El contraste y su veredicto se reportan en la Sección 8.

Como hipótesis subsidiarias se plantea, en primer lugar, que la integración de múltiples canales de entrada dentro de un único flujo automatizado mejora la accesibilidad del sistema y reduce la dispersión operativa sin introducir cuellos de botella adicionales. En segundo lugar, que un esquema híbrido de clasificación basado en reglas determinísticas y modelo de lenguaje grande resulta más eficiente —en términos de la relación entre exactitud, latencia y costo de inferencia— que un esquema construido exclusivamente sobre modelo externo. La razón es que una proporción sustancial de los incidentes presenta marcadores léxicos inequívocos que no requieren consulta al modelo de lenguaje. La de eficiencia se contrastó formalmente frente a un esquema de modelo de lenguaje solo: el ahorro de llamadas y de costo resultó concluyente y favorable al híbrido, mientras que la no inferioridad de la exactitud con el margen prerregistrado quedó indeterminada, de modo que el contraste se informa como no concluyente (Tabla 24). La de integración multicanal se contrasta en su dimensión de capacidad bajo carga concurrente, con un test de carga reproducible y de costo cero sobre el tramo en que convergen los canales (Subsección 4.5); la complejidad operativa percibida no se mide en este trabajo.

1.5. Objetivo general

Evaluar la viabilidad y el desempeño de la automatización del registro inicial de incidentes de una mesa de ayuda empresarial mediana mediante la orquestación de flujos con N8N y el procesamiento de lenguaje natural en Python. El desarrollo y la implementación del sistema constituyen el medio para esa evaluación. Esta abarca la recepción, el procesamiento, la clasificación y el registro automáticos de incidentes. Considera la reducción del tiempo de registro, la calidad de la clasificación y la proporción de intervención humana en la etapa inicial, y mantiene la supervisión técnica y la trazabilidad de las decisiones tomadas por el sistema.

1.6. Objetivos específicos

El primer objetivo específico consiste en diseñar una arquitectura distribuida y modular que integre un motor de orquestación de flujos, un módulo de procesamiento de lenguaje natural, un canal de telefonía con transcripción automática del habla y una base de datos rela-

cional. Esa arquitectura debe garantizar comunicación sincrónica entre componentes mediante interfaces de programación de aplicaciones de tipo REST sobre HTTP cifrado.

El segundo objetivo específico se orienta a implementar un clasificador automático que asigne cada incidente a uno de los cinco sectores canónicos —Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos o Sistemas— sobre un corpus controlado de 200 casos representativos del entorno operativo. El umbral de desempeño —exactitud global no inferior al 85 % y F1 macro no inferior a 0,85— constituye el criterio de éxito de este objetivo, fijado a priori por los autores y verificable contra la exactitud observada y su intervalo de confianza; su grado de cumplimiento se declara en la Subsección 10.1. Ese umbral no se toma de un piso numérico de la literatura —los trabajos relevados no permiten fijar uno común—, sino que se fundamenta en tres criterios convergentes. Primero, la literatura de clasificación de tickets toma como referencia a los clasificadores supervisados clásicos, entre los que SVM tuvo buen desempeño en todas las muestras de Paramesh y Shreedhara (2019) (Tabla 1). Segundo, el costo organizacional de una derivación errónea se mide, sobre los artefactos de la campaña complementaria de medición, en un tramo activo de tiempo-persona del orden de 70 s (intervalo de confianza del 95 % [33; 107] s), no los 10 a 15 minutos de reasignación que se suponían; su descomposición y su procedencia constan en el memo de números canónicos (Sección 3.31) y su alcance se declara allí. Por lo tanto, una exactitud inferior al 85 % resultaría en tiempos de resolución comparables a los del flujo manual para un volumen de errores inaceptable; el umbral es, además, más exigente que la paridad con la tasa de error manual medida (82,78 %), de modo que por debajo de esa paridad el flujo automatizado sería peor en las dos dimensiones —más error y más costo de corrección, en el orden de 0,5 horas-persona por trimestre por cada punto de exactitud perdido—. Tercero, situar el umbral en el 85 % deja margen para que, si la exactitud verdadera del clasificador lo supera, el límite inferior de su intervalo de confianza pueda ubicarse por encima de la frontera de interés en lugar de quedar solapado con ella.

El tercer objetivo específico plantea integrar tres canales de entrada paralelos —correo electrónico, formulario web y llamada telefónica con transcripción automática— dentro de un único flujo automatizado que normalice la entrada y centralice el procesamiento.

El cuarto objetivo específico consiste en evaluar comparativamente el flujo manual y el flujo automatizado en términos de tiempo medio de registro, dispersión, exactitud de clasificación y proporción de intervención humana, mediante un diseño cuasiexperimental con

muestras pareadas, prueba estadística no paramétrica y reporte de intervalos de confianza al 95 %. El diseño experimental sigue las recomendaciones de Hernández Sampieri y Mendoza Torres (2018) para investigaciones tecnológicas de carácter aplicado.

El quinto objetivo específico se orienta a documentar la arquitectura, los procedimientos de despliegue y los resultados experimentales para que una tercera parte pueda replicarlos, y a proponer una hoja de ruta de evolución que oriente futuras mejoras y replicaciones del estudio en organizaciones de características comparables.

Como sexto objetivo específico se plantea analizar los errores de clasificación y calibrar la confianza de las predicciones, tipificando los patrones de error y caracterizando las bandas de confianza para interpretar el desempeño más allá de las métricas agregadas. Su cumplimiento es verificable contra el reporte de evaluación del repositorio y la Subsección 8.7 de la Sección 8.

1.7. Justificación

La justificación del trabajo se sostiene en tres dimensiones complementarias.

Desde la dimensión organizacional, la automatización propuesta busca liberar capacidad operativa del personal técnico, reducir el tiempo de registro y la variabilidad del criterio individual. La evidencia recogida en una organización mediana argentina cuantifica el ahorro bruto de registro y el punto de equilibrio frente al costo de las derivaciones erróneas (Subsección 9.5), con el que otras organizaciones pueden estimar, con sus propias tasas, el retorno de una inversión similar.

Desde la dimensión tecnológica, la solución combina componentes de código abierto —Python, FastAPI y PostgreSQL— con N8N, una plataforma de orquestación de flujos cuyo código fuente se distribuye bajo licencia Sustainable Use (*fair-code*) y admite despliegue completamente autoalojado (n8n GmbH, 2024). Esto permite una implementación reproducible en organizaciones de tamaño mediano sin requerir grandes inversiones de capital ni dependencia exclusiva de proveedores comerciales. Esta propiedad es particularmente relevante en el contexto argentino, donde las restricciones de acceso a divisas y los costos de suscripción en moneda extranjera constituyen barreras significativas para la adopción de soluciones comerciales internacionales. Además, el despliegue autoalojado de la totalidad de los componentes —con excepción del servicio de inferencia— otorga a la organización control pleno sobre sus datos operativos, en línea con el control sobre los datos personales y su tratamiento conforme

a la normativa de protección de datos (Honorable Congreso de la Nación Argentina, 2000).

Desde la dimensión académica, el trabajo aporta evidencia empírica sobre el desempeño de modelos de lenguaje grandes aplicados a la clasificación de tickets en español rioplatense, dominio escasamente documentado en la literatura comparativa disponible. En los trabajos de clasificación automática de tickets relevados (Tabla 1) el idioma del corpus no se informa en la mayoría de los casos; entre los que lo consignan, ninguno declara un corpus en español. Esa ausencia se limita al alcance revisado y no se presenta como una constatación sobre toda la literatura. Las evaluaciones de LLM que incorporan el español lo hacen con corpus genéricos, no específicos del dominio de mesas de ayuda (Grandury et al., 2025; Mayor-Rocher et al., 2026). Este trabajo contribuye a cerrar esa brecha mediante la validación de un clasificador híbrido sobre un corpus de 200 casos en español rioplatense. La validación es dentro de la muestra. El doble etiquetado independiente, a cargo de los etiquetadores $\texttt{E1}$ y $\texttt{E2}$, arrojó $\kappa = 0{,}5569$ (moderado, con intervalo).

El relevamiento propio de la documentación pública de los proveedores (consultada el 19-10-2026) muestra que plataformas comerciales como Zendesk Suite, Freshdesk o ServiceNow ITSM operan como software como servicio, con datos en jurisdicciones extranjeras y costos por agente y mes que escalan con el equipo (Freshworks, 2026; ServiceNow, 2026; Zendesk, 2026). La propuesta desarrollada en esta investigación utiliza herramientas de despliegue autoalojado, lo que facilita su adopción en organizaciones medianas y simplifica el cumplimiento de la normativa argentina de protección de datos personales.

1.8. Alcance y delimitaciones

El alcance del trabajo se circunscribe a la etapa de recepción, clasificación y registro inicial de incidentes, sin abarcar la resolución técnica de los mismos, la cual permanece bajo responsabilidad del personal humano. El sistema contempla tres canales de entrada (correo electrónico, formulario web y llamada telefónica con transcripción automática) y cinco sectores de derivación (Seguridad Informática, Soporte Técnico Hardware, Soporte Técnico Software, Bases de Datos y Sistemas). La validación experimental se realiza sobre un corpus en idioma español rioplatense recolectado en una organización mediana del sector servicios con sede en la provincia de Mendoza, de aproximadamente 120 usuarios internos distribuidos en cinco áreas funcionales.

Quedan fuera del alcance los siguientes aspectos, los cuales se proponen como líneas

de trabajo futuro en la Sección 11. Primero, la integración con sistemas externos de inventario de activos informáticos o con sistemas de gestión de configuración. Segundo, un modelo de aprendizaje supervisado afinado con el corpus acumulado en operación, dado que el volumen actual de datos etiquetados resulta insuficiente para esa estrategia; la línea de base clásica se usa solo como referencia de comparación y no es el modelo supervisado que el alcance excluye. Tercero, la implementación de paneles de monitoreo avanzados con visualización en tiempo real de métricas operativas. Cuarto, la automatización de la etapa de resolución técnica, que trasciende el alcance del presente trabajo.

Las delimitaciones del estudio son tres. La primera es la restricción geográfica a una única organización de la provincia de Mendoza, que limita la validez externa de los hallazgos. La segunda es la dependencia operativa del servicio externo de inferencia gemini-3.6-flash, cuyo rendimiento y condiciones comerciales escapan al control de los investigadores. La tercera es la naturaleza temporal de los resultados, que reflejan el comportamiento del modelo, integrado el 24-09-2026 y vigente en las corridas del 2 y del 7 de octubre de 2026 y en la corrida telefónica del 5 y 6 de octubre (Subsección 4.5). Ese comportamiento está sujeto a modificaciones futuras por parte del proveedor.

2. Marco teórico

Este capítulo establece los fundamentos conceptuales sobre los cuales se construye la investigación. Se abordan once ejes temáticos que proporcionan el andamiaje teórico necesario para comprender el diseño, la implementación y la evaluación del sistema propuesto.

2.1. Gestión de servicios de tecnologías de la información

La gestión de servicios de tecnologías de la información (ITSM) es una disciplina que articula procesos, personas y tecnologías para alinear la operación tecnológica con los objetivos del negocio (Galup et al., 2009); la noción de mesa de ayuda como punto único de contacto es propia de ITIL (Cabinet Office, 2011). Este enfoque rompe con la concepción anterior que entendía a la informática como un área de soporte estrictamente reactivo y la posiciona, en cambio, como un proveedor de servicios sujeto a acuerdos de nivel de servicio explícitos.

Dentro de este marco general, la gestión de incidentes constituye uno de los procesos operativos centrales. Su objetivo principal consiste en restaurar el servicio afectado en el menor tiempo posible, minimizando el impacto adverso en la operación del negocio. El proceso comprende cuatro etapas secuenciales: la recepción y registro inicial, la clasificación y priorización, la asignación al área responsable y, finalmente, la resolución y cierre. Los autores de esta tesis infieren que los procesos manuales de soporte tienden a degradarse cuando el volumen de solicitudes crece de manera no lineal o cuando el personal debe alternar entre tareas operativas heterogéneas, situación que coincide con la observada en el entorno empresarial analizado en el presente trabajo.

2.2. Mesa de ayuda y modelo ITIL

El marco de buenas prácticas ITIL (Information Technology Infrastructure Library), en su edición de operaciones de servicio (Cabinet Office, 2011), fue publicado por The Stationery Office (TSO) por encargo del Cabinet Office; su titular histórico es el Office of Government Commerce. Establece la distinción conceptual entre incidente —definido como una interrupción no planificada del servicio o una reducción de su calidad— y solicitud de servicio —definida como un pedido formal de información, asesoramiento, acceso a un componente o ejecución de una operación estandarizada—. Esta distinción resulta especialmente relevante para el diseño del clasificador propuesto en este trabajo, ya que orienta la categorización inicial y condiciona la priorización subsiguiente.

El marco ITIL postula adicionalmente tres principios operativos que guían el diseño de la solución propuesta. El primero es la centralización de la recepción mediante un punto único de contacto (SPOC, por su sigla en inglés), que en el sistema propuesto se materializa a través del flujo unificado de orquestación que normaliza las entradas de los tres canales. El segundo es la operación bajo acuerdos de nivel de servicio (SLA), que cuantifican la calidad esperada en términos de tiempo de respuesta y tiempo de resolución. El tercero es la mejora continua del proceso, que en el sistema propuesto se habilita mediante la trazabilidad de cada decisión del clasificador y la retroalimentación de los sectores responsables.

Los modelos tradicionales de mesa de ayuda se basan en la interacción manual entre el usuario y el operador, lo que implica tiempos de respuesta variables y una dependencia directa del personal disponible. Cuando el volumen de incidentes excede la capacidad del equipo o cuando los operadores deben alternar simultáneamente entre tareas operativas y de soporte, la calidad del servicio se degrada de manera observable. La automatización del registro inicial constituye, en consecuencia, una intervención que aborda el cuello de botella en el punto de mayor sensibilidad del proceso, sin requerir la reestructuración completa del modelo operativo.

2.3. Automatización de procesos y orquestación de flujos

Se entiende aquí por automatización de procesos empresariales (BPA, por su sigla en inglés) la reducción de la intervención humana en tareas repetitivas mediante la ejecución automática de acciones definidas a partir de eventos específicos. Russell y Norvig (2021) ubican a la automatización inteligente dentro del paradigma de los agentes orientados a objetivos, en el cual un sistema reactivo percibe eventos del entorno, decide acciones según una política preestablecida y actúa modificando el estado del entorno. Esta caracterización ofrece un marco conceptual robusto para el diseño de sistemas que combinan reglas determinísticas con decisiones derivadas de modelos probabilísticos, como el clasificador híbrido propuesto en este trabajo.

Se entiende aquí por plataformas de integración como servicio (iPaaS) las herramientas de orquestación que posibilitan integrar distintos servicios, procesar información y ejecutar acciones automáticas en función de condiciones predefinidas. Estas plataformas se caracterizan por ofrecer modelos visuales de construcción de flujos, soporte nativo para webhooks y disparadores reactivos, y capacidad de transformación de datos entre sistemas heterogéneos. n8n GmbH (2024) documenta las capacidades de N8N, la herramienta seleccionada para este

trabajo, que se distingue dentro del segmento por su modelo de licencia de código fuente disponible y su despliegue completamente autoalojado, decisivo cuando el tratamiento de datos sensibles exige mantener la información dentro del perímetro organizacional.

El paradigma de orquestación se diferencia conceptualmente del paradigma de coreografía. Hohpe y Woolf (2004) establecen que la orquestación centraliza la lógica de control en un componente único, lo que simplifica la trazabilidad de cada ejecución pero introduce un punto de coordinación cuya disponibilidad condiciona al sistema completo. La coreografía, en cambio, distribuye la coordinación entre los participantes mediante eventos publicados en un bus común, lo que aumenta la robustez frente a fallos parciales pero dificulta la observabilidad. El presente trabajo adopta el enfoque de orquestación por simplicidad operativa y por la prioridad otorgada a la trazabilidad auditable de cada decisión del sistema, en línea con los requisitos de la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000).

2.4. Human-in-the-loop y grados de autonomía

El paradigma *human-in-the-loop* (HITL) designa los esquemas en los que una persona interviene en el ciclo de decisión de un sistema automático para etiquetar, corregir, validar o supervisar sus salidas. Mosqueira-Rey et al. (2023) ofrecen una revisión del estado del arte del aprendizaje con intervención humana que sistematiza los esquemas en los que las anotaciones y las correcciones se incorporan al ciclo de aprendizaje o de decisión. Los autores de esta tesis infieren que el diseño debe reservar a la persona un rol activo ante la ambigüedad semántica y la responsabilidad sobre las consecuencias de la decisión. En línea con el paradigma *HitAI*, Zanzotto (2019, p. 243) reclama retribuir a quienes aportan el conocimiento que usan los sistemas. Amershi et al. (2019) formulan guías de interacción que exigen transparencia sobre la confianza del sistema y control del usuario, Shneiderman (2020) propone combinar alta automatización con supervisión significativa, y Wu et al. (2022) muestran que la descomposición de tareas con puntos de control humano hace al sistema inspeccionable.

Los grados de autonomía se ordenan según la proporción de decisiones delegadas y la granularidad de la revisión. La *revisión total* somete cada salida a validación humana; la *revisión selectiva* delega las decisiones de alta confianza y deriva a la persona solo las que caen por debajo de un umbral; y la *operación autónoma con auditoría* ejecuta sin intervención previa y conserva un registro trazable para revisión posterior. El sistema propuesto adopta una revisión selectiva acotada por etapa: la regla `requiere_revision_humana = (confianza`

$<0,70)$ se evalúa solo sobre la salida de la etapa Gemini; la reserva deriva siempre a revisión y la etapa determinística no deriva por su confianza (Subsección 5.5). Desde el 13 de octubre de 2026, posterior a la campaña 2026-10, el backend deriva además a revisión al reportante no identificado. La calibración de la confianza del modelo condiciona la cobertura efectiva de la salvaguarda (Sección 9).

2.5. Procesamiento de lenguaje natural y modelos de lenguaje grandes

El procesamiento de lenguaje natural (NLP) constituye un área de la inteligencia artificial orientada a la interpretación del lenguaje humano por parte de sistemas informáticos. Jurafsky y Martin (2026) abordan, entre otros temas, el modelado estadístico de secuencias, la representación distribuida de palabras y las arquitecturas neuronales profundas. Mediante estas técnicas resulta posible analizar texto o audio transcrito, identificar palabras clave, determinar la intención del usuario y clasificar contenido en categorías predefinidas.

La evolución del campo durante la última década ha estado dominada por la arquitectura Transformer (Vaswani et al., 2017), cuyo mecanismo de atención permite a los modelos capturar dependencias de largo alcance sin las limitaciones de las redes neuronales recurrentes. El mecanismo de atención multi-cabeza permite ponderar simultáneamente distintas partes de la secuencia de entrada, lo que resulta útil para clasificar descripciones textuales cuya información relevante puede aparecer en cualquier posición.

Sobre esta arquitectura se construyeron los modelos de lenguaje grandes (LLM) contemporáneos, los cuales exhiben capacidades robustas de clasificación en escenarios de pocos ejemplos (*few-shot*) o sin ejemplos (*zero-shot*), fenómeno conocido como aprendizaje en contexto. Brown et al. (2020) demostraron que modelos suficientemente grandes pueden generalizar a tareas nuevas a partir de instrucciones expresadas en lenguaje natural, sin requerir ajuste fino sobre datos específicos del dominio. Esta capacidad es particularmente relevante para el contexto de esta investigación, donde el volumen de datos etiquetados resulta insuficiente para entrenar un clasificador supervisado tradicional desde cero.

La forma en que se formula la instrucción condiciona el resultado tanto como la capacidad del modelo. El aprendizaje en contexto admite dos configuraciones principales: el planteamiento *zero-shot*, en el que la instrucción describe la tarea sin ejemplos, y el *few-shot*, en el que se incorporan unos pocos casos resueltos dentro del propio mensaje para orientar la respuesta. La evaluación multilingüe de Ahuja et al. (2023), que compara estrategias de

prompting entre idiomas, muestra que la estrategia elegida puede modificar el rendimiento de manera sustancial, sobre todo en idiomas con pocos recursos, por lo que el diseño del *prompt* constituye una decisión de ingeniería y no un detalle accesorio.

Los LLM generan, junto con la etiqueta asignada, una estimación de confianza que no necesariamente coincide con la probabilidad empírica de acierto. La calibración designa el grado de correspondencia entre la confianza declarada por el modelo y su corrección observada: un modelo bien calibrado acierta con una frecuencia próxima a la confianza que expresa. La calibración se mide agrupando las predicciones por nivel de confianza y contrastando la confianza media con la exactitud observada, en diagramas de fiabilidad y en el error de calibración esperado (ECE), y puede corregirse a posteriori, por ejemplo con escalado de temperatura (Guo et al., 2017). Cuando el modelo se consulta como servicio de caja negra, con entrada y salida solo textuales, la confianza no proviene de probabilidades internas sino que el modelo la verbaliza. En modelos ajustados con retroalimentación humana, esa confianza puede estar mejor calibrada que las probabilidades condicionales en las tareas evaluadas (Tian et al., 2023), pero es sobreconfiada: concentra los valores en el extremo alto de la escala y predecir cuáles de sus respuestas son fallas sigue siendo un desafío, dependiente de cómo se la elicita (Xiong et al., 2024). En el sistema propuesto este concepto fundamenta el umbral operativo de revisión humana, ya que las clasificaciones de la etapa semántica con confianza inferior a 0,70 se derivan a supervisión; la fiabilidad de ese umbral depende tanto de la exactitud como de la calibración del modelo.

Una limitación central de los modelos generativos es la alucinación, es decir, la producción de contenido plausible en su forma pero falso o no sustentado en la entrada (Ji et al., 2023). En una tarea de clasificación la alucinación puede manifestarse como la asignación de una categoría inexistente o como una justificación inventada a partir de indicios débiles. Como el desempeño de los LLM generativos en el etiquetado automático varía de forma marcada entre conjuntos de datos (Colavito et al., 2025), sus etiquetas no pueden aceptarse sin validarlas contra una referencia. Esta exigencia motiva dos decisiones del sistema: restringir el espacio de salida a las cinco categorías canónicas y validar cada clasificación contra las etiquetas válidas antes de persistirla.

El rendimiento de los LLM tampoco es uniforme entre idiomas ni entre variedades de un mismo idioma: sobre 29 idiomas, el desempeño de 36 modelos cae de forma marcada en los de menos recursos (Xuan et al., 2025). El ajuste por instrucciones de los modelos abiertos se

concentró en el inglés y unos pocos idiomas (Lai et al., 2023), y ante textos con alternancia de idiomas los LLM multilingües rinden por debajo de modelos ajustados más pequeños (Zhang et al., 2023). Para el español, Grandury et al. (2025) proponen una tabla de clasificación abierta para sus variedades y las lenguas de España y América Latina, y Mayor-Rocher et al. (2026), con pruebas de español como lengua extranjera, observan que los modelos comprenden bien el idioma pero no alcanzan la competencia gramatical nativa. Esta sensibilidad resulta directamente relevante para el presente trabajo, cuyo corpus está redactado en español rioplatense, una variedad escasamente representada en los conjuntos de evaluación internacionales.

La evaluación de un LLM no se agota en una medida única de exactitud. Los benchmarks multilingües de Xuan et al. (2025) y Ahuja et al. (2023) abarcan múltiples tareas y desagregan sus resultados por idioma, porque una cifra global puede ocultar un desempeño dispar entre categorías. Esta advertencia, que este capítulo desarrolla en la Sección 2.8 para el caso de clasificadores multiclase, fundamenta la decisión metodológica de reportar, además de la exactitud global, métricas por clase y el valor F1 macro promediado.

En la clasificación de texto, la representación clásica que precede a los modelos neuronales es TF-IDF (*term frequency-inverse document frequency*): cada término se pondera por su frecuencia en el caso y por su rareza en el corpus, de modo que los términos frecuentes en un caso y poco frecuentes en el conjunto pesan más que los ubicuos (Jurafsky & Martin, 2026). Sobre esa representación, la regresión logística modela la probabilidad de cada clase como una función logística de una combinación lineal de los rasgos y se ajusta minimizando una función de pérdida con regularización, lo que la vuelve un clasificador lineal interpretable y económico (Jurafsky & Martin, 2026). La unión de TF-IDF y regresión logística constituye la línea de base supervisada clásica que el marco metodológico describe como referencia frente al clasificador híbrido.

En una mesa de ayuda, el NLP permite clasificar incidentes y derivarlos al sector correspondiente sin intervención manual, mejorando la velocidad de respuesta y reduciendo la carga operativa del registro. La elección entre un clasificador supervisado entrenado sobre corpus específico, un modelo de lenguaje grande de propósito general invocado mediante instrucciones, o un esquema híbrido en cascada (Chen et al., 2024; Varshney & Baral, 2022) depende de la disponibilidad de datos etiquetados, del presupuesto de inferencia y de los requerimientos de soberanía sobre los datos. En ese esquema en cascada, el componente más económico resuelve los casos cuya señal de fiabilidad alcanza un umbral y deriva los restantes al más

costoso.

2.6. Reconocimiento automático del habla

Los sistemas de reconocimiento automático del habla (ASR) permiten convertir audio en texto mediante modelos entrenados sobre grandes corpus de habla anotada, cuyo marco clásico describen Rabiner y Juang (1993), mientras que la generación contemporánea se apoya en redes neuronales profundas cuyo exponente reciente con alta robustez multilingüe es el modelo Whisper (Radford et al., 2023). El sistema propuesto no integra un motor de ASR: la transcripción efectiva del canal telefónico la provee un servicio externo (Subsección 6.4), por lo que la noción de reconocimiento automático del habla se conserva únicamente como marco conceptual de ese canal.

2.7. Bases de datos relacionales y persistencia transaccional

La persistencia de los incidentes en una base de datos relacional permite garantizar las propiedades de atomicidad, consistencia, aislamiento y durabilidad (ACID) propias del modelo transaccional clásico (Date, 2004). PostgreSQL, el motor seleccionado para este trabajo, ofrece soporte completo del estándar SQL, extensiones para tipos de datos avanzados como JSON binario y arreglos, y un modelo de concurrencia basado en control multiversional (MVCC) que resulta adecuado para cargas mixtas de lectura y escritura (The PostgreSQL Global Development Group, 2024).

La elección de un motor relacional se comprende mejor al contrastarla con alternativas concretas. Un motor de documentos como MongoDB almacena registros con esquema flexible y favorece la evolución de la estructura sin migraciones, pero no impone las relaciones entre incidentes, sectores, estados y canales de origen; la integridad referencial queda delegada a la aplicación. Un motor clave-valor en memoria como Redis ofrece latencias de acceso muy bajas y resulta adecuado para caché o contadores efímeros, pero no está orientado a la persistencia duradera ni a consultas relacionales complejas. El dominio de este trabajo exige precisamente esas propiedades: las relaciones entre incidentes, sectores, estados y canales se modelan como tablas vinculadas mediante claves foráneas con integridad referencial declarativa. Las operaciones de registro y actualización requieren las garantías ACID de la transacción clásica, el dashboard de analítica se apoya en consultas relacionales de agregación sobre múltiples tablas y la trazabilidad de cada decisión del sistema demanda un registro duradero y auditable. Esta combinación de requisitos justifica la elección de PostgreSQL, en línea con los requisitos

normativos identificados en la sección de consideraciones éticas y legales (Sección 7).

2.8. Métricas de evaluación de clasificadores multiclase

La evaluación de clasificadores multiclase requiere métricas que capturen tanto el desempeño global como el desempeño por clase. Powers (2011) describe el conjunto canónico de métricas derivadas de la matriz de confusión, entre las cuales destacan la exactitud global (*accuracy*), la precisión por clase, la sensibilidad o exhaustividad (*recall*) por clase, y la medida F1 como media armónica de las dos anteriores.

La exactitud global se define como la proporción de predicciones correctas sobre el total de casos evaluados:

$$\text{Exactitud} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[\hat{y}_i = y_i]$$

donde N es el número de casos, $\hat{y}_i$ la clase predicha para el caso i, y_i su clase verdadera y $\mathbb{1}[\cdot]$ la función indicadora, que vale uno cuando la predicción coincide con la etiqueta y cero en caso contrario. Válida para cualquier número de clases, es la que subyace a la matriz de confusión de cinco sectores de la Sección 8; no se emplea la formulación binaria de verdaderos y falsos positivos y negativos, que presupone una única clase de interés y resulta inadecuada en un problema multiclase.

Sokolova y Lapalme (2009) advierten que en escenarios con clases desbalanceadas la exactitud global puede resultar engañosa y recomiendan reportar valores macro promediados, los cuales otorgan igual peso a cada clase con independencia de su frecuencia. El valor F1 macro promediado, en la variante que emplea este trabajo (media aritmética de los F1 por clase), se define como:

$$F1_{\text{macro}} = \frac{1}{k}\sum_{i=1}^{k} F1_i$$

donde k es el número de clases y $F1_i$ es el valor F1 de la clase i. Opitz y Burst (2019) documentan que circulan dos fórmulas del F1 macro (esta y la del F1 de la precisión y la sensibilidad macro promediadas) y que no son equivalentes. El presente trabajo adopta esta recomendación y reporta exactitud global, F1 macro y métricas desagregadas por clase, para que el lector evalúe la robustez del clasificador frente a la distribución específica del corpus.

Adicionalmente, la matriz de confusión es el instrumento estándar de presentación de resultados en clasificación multiclase, porque permite identificar patrones de error: confusiones entre dos categorías, sesgos hacia una clase mayoritaria o aciertos preferenciales sobre una

clase. Su inspección orienta el análisis cualitativo posterior y fundamenta cualquier propuesta de mejora del clasificador.

Cuando el clasificador declara además una confianza, dos medidas complementan a las anteriores. El puntaje de Brier es el error cuadrático medio entre la confianza declarada y el acierto, codificado como uno si la predicción es correcta y cero si no, de modo que mide conjuntamente el nivel y la resolución de la confianza: cuanto menor, mejor (Brier, 1950). El área bajo la curva de características operativas del receptor (AUROC) de la confianza es la probabilidad de que un caso acertado reciba una confianza mayor que uno errado, con los empates contados como 0,5 (Sokolova & Lapalme, 2009); mide la capacidad de ordenar o discriminar los aciertos de los errores y vale 0,5 cuando la señal no discrimina. El error de calibración esperado (ECE) y el puntaje de Brier dependen del nivel de la confianza; el AUROC, de su orden, y por eso se informan en conjunto.

2.9. Acuerdo entre anotadores y fiabilidad de la referencia

Cuando la etiqueta de referencia de un corpus la producen personas, su calidad depende del acuerdo entre anotadores. El coeficiente kappa de Cohen mide la concordancia observada por encima de la esperada por azar para dos anotadores sobre una misma escala categórica (Cohen, 1960). Su valor se interpreta con rangos convencionales: por debajo de 0,20, leve; hasta 0,40, aceptable; hasta 0,60, moderado; hasta 0,80, sustancial; y por encima, casi perfecto (Landis & Koch, 1977). La estimación se acompaña de un intervalo de confianza, cuya aproximación asintótica describe Fleiss et al. (1969). Un acuerdo moderado no invalida el uso de la referencia, pero acota la confianza que merecen las métricas que se calculan contra ella, porque una parte del desacuerdo entre el clasificador y la etiqueta puede provenir de la etiqueta y no del clasificador.

2.10. Clasificación multietiqueta

En la clasificación multietiqueta cada caso puede pertenecer a más de una clase a la vez, a diferencia de la clasificación multiclase, en la que las clases son mutuamente excluyentes (Tsoumakas & Katakis, 2007). Esta distinción afecta tanto la forma de la referencia como las métricas: la exactitud estricta y el F1 macro monoetiqueta no capturan por sí solos los aciertos parciales, por lo que se complementan con la exactitud de subconjunto (*subset accuracy*), la pérdida de Hamming (*Hamming loss*) y el micro-F1, calculados sobre el conjunto de etiquetas verdadero y el predicho de cada caso. En dominios donde un incidente puede corresponder

a más de un sector responsable, ignorar la estructura multietiqueta sesga la evaluación hacia los casos de etiqueta única.

2.11. Pruebas estadísticas para el contraste de hipótesis

El contraste de hipótesis sobre datos que no satisfacen el supuesto de normalidad requiere pruebas no paramétricas. La prueba de Wilcoxon de rangos con signo compara dos mediciones pareadas a partir del orden de sus diferencias y no de su magnitud, por lo que es robusta frente a distribuciones asimétricas y a valores extremos (Wilcoxon, 1945). Para una proporción, el intervalo de Wilson acota la estimación con una cobertura cercana a la nominal incluso con muestras pequeñas o proporciones extremas (Wilson, 1927). Cuando no existe una fórmula cerrada para la distribución de un estadístico, el bootstrap percentil aproxima su intervalo remuestreando los casos con reposición (Efron & Tibshirani, 1994). Para comparar dos clasificadores sobre los mismos casos, la prueba de McNemar contrasta las discordancias entre ambos y no sus aciertos totales (McNemar, 1947). Estas pruebas sustentan los contrastes que el marco metodológico describe y que los resultados reportan con sus intervalos.

3. Estado del arte

Este capítulo revisa la literatura académica y las soluciones comerciales disponibles en cuatro áreas relevantes para el presente trabajo: plataformas de mesa de ayuda, herramientas de orquestación de flujos, métodos de clasificación automática de tickets de soporte, y calibración de la confianza y cascadas de modelos. El propósito es situar la contribución de esta investigación en el contexto de los desarrollos previos y fundamentar la brecha que motiva el trabajo.

Protocolo de revisión. La revisión que sustenta este capítulo y los fundamentos del marco teórico se construyó con una búsqueda estructurada cuya fecha de corte es el 21 de octubre de 2026, sobre seis fuentes: Scopus, IEEE Xplore, ACM Digital Library, ACL Anthology, Google Scholar y arXiv. Las cadenas, formuladas en inglés, combinaron términos de dominio y de método: A1, *(”help desk” OR ”service desk” OR ”IT support”) AND (”ticket classification” OR ”incident classification”) AND (”machine learning” OR ”natural language processing” OR ”large language model”)*; A2, *(”large language model” OR ”LLM”) AND (”ticket” OR ”incident”) AND (”classification” OR ”routing”)*; A3, *(”Spanish” OR ”español”) AND (”large language model” OR ”LLM”) AND (”evaluation” OR ”benchmark”)*; A4, *(”Gemini” OR ”Google Gemini”) AND (”ticket” OR ”incident” OR ”help desk”)*; y B1, *(”human-in-the-loop” OR ”human in the loop” OR ”human-AI interaction”) AND (”machine learning” OR ”large language model”)*. Criterios de inclusión: publicación arbitrada 2023-2026 para el estado del arte moderno (A1-A4), idioma español o multilingüe y evaluación empírica; para los fundamentos de human-in-the-loop (B1) no se impuso restricción temporal. Criterios de exclusión: literatura no arbitrada, notas de prensa y material comercial sin respaldo metodológico. Una extensión posterior (grupo C), ejecutada el 25 de octubre de 2026 (su fecha de corte propia), agregó sobre las mismas seis bases dos cadenas: C1, *(”calibration” OR ”confidence estimation” OR ”confidence elicitation” OR ”uncertainty”) AND (”large language model” OR ”LLM” OR ”language model” OR ”neural network”) AND (”classification” OR ”few-shot” OR ”verbalized” OR ”overconfidence”)*; y C2, *(”cascade” OR ”cascading” OR ”routing” OR ”hybrid” OR ”rule-based”) AND (”large language model” OR ”LLM” OR ”natural language processing” OR ”NLP”) AND (”classification” OR ”cost” OR ”efficiency”)*. Se incluyeron publicaciones arbitradas, sin restricción temporal, sobre calibración o estimación de confianza de clasificadores y modelos de lenguaje (C1) o sobre cascadas y enrutamiento de modelos con criterio de costo y exactitud (C2), con evaluación empírica o método

de referencia; se excluyeron los preprints sin versión arbitrada y el material no arbitrado. De las que cumplían se eligieron, hasta seis, las más próximas al escenario de este trabajo (un modelo consultado como servicio y una cascada de dos etapas). Cada consulta quedó registrada, con base, cadena, fecha y resultado, en la bitácora de búsqueda del proyecto, consistente con lo aquí declarado.

Una limitación del protocolo de revisión que se declara, y no se oculta, es la ausencia de búsquedas en repositorios regionales (SciELO, Redalyc y JAIIO), que podrían haber reforzado la brecha declarada para la literatura argentina.

3.1. Soluciones comerciales de mesa de ayuda

El relevamiento propio de la documentación pública de los proveedores, consultada el 19-10-2026, muestra que las soluciones comerciales de gestión de mesa de ayuda examinadas son integrales y cubren el ciclo completo de vida del ticket. Zendesk Suite ofrece funcionalidades de recepción multicanal, automatización de flujos básicos y, mediante un módulo adicional, capacidades de inteligencia artificial para sugerencia de respuestas y deflección de consultas frecuentes. Freshdesk propone una arquitectura comparable e incorpora el motor Freddy AI para clasificación automática y enrutamiento inteligente. Jira Service Management, parte del ecosistema de Atlassian, ofrece capacidades limitadas de automatización inteligente en su plan estándar; la edición Data Center permite el despliegue autoalojado para organizaciones con requisitos de soberanía sobre los datos. ServiceNow ITSM constituye la opción de referencia en el segmento corporativo, con un módulo Predictive Intelligence que aplica aprendizaje automático sobre el histórico de tickets de la organización.

El relevamiento propio de la documentación pública de los proveedores, consultada el 19-10-2026, también muestra que sus ofertas comerciales incorporan capacidades de inteligencia artificial descritas para organizaciones medianas, principalmente en mercados de habla inglesa. No obstante, estas plataformas presentan dos limitaciones relevantes para el contexto de la presente investigación. La primera es el modelo de costos basado en agente y mes, que escala linealmente con el tamaño del equipo de soporte. La segunda es que la mayoría de estas plataformas operan exclusivamente en modalidad de software como servicio (SaaS) con almacenamiento de datos en jurisdicciones extranjeras, lo que introduce consideraciones adicionales sobre transferencia internacional de datos personales bajo la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000).

En el segmento de código abierto, osTicket constituye una alternativa de despliegue autoalojado sin costo de licencia, aunque carece de capacidades nativas de clasificación automática mediante procesamiento de lenguaje natural moderno. Esta brecha funcional motiva la búsqueda de arquitecturas compositivas que integren componentes maduros de código abierto con servicios de inferencia bajo demanda.

3.2. Plataformas de orquestación de flujos

Dentro de las plataformas de orquestación de flujos relevadas para este trabajo (consulta 19-10-2026) se incluyen Zapier, Make (anteriormente Integromat), Microsoft Power Automate, Apache Airflow y N8N. Las primeras tres operan exclusivamente como SaaS, lo que las descarta como base para implementaciones donde el control sobre la infraestructura es un requisito explícito. Apache Airflow se orienta a flujos de trabajo programados de tipo procesamiento de datos por lotes, con un diseño centrado en grafos acíclicos dirigidos (DAG) definidos como código Python (Apache Software Foundation, 2024); aunque potente, su paradigma de ejecución programada resulta inadecuado para un caso de uso reactivo y orientado a eventos como el de una mesa de ayuda.

N8N ofrece un modelo de construcción visual de flujos sobre nodos predefinidos, soporte nativo para webhooks y disparadores reactivos, ejecución basada en eventos y posibilidad de despliegue completamente autoalojado bajo Docker (n8n GmbH, 2024). La disponibilidad de su código fuente bajo licencia Sustainable Use facilita la auditoría de seguridad y la adaptación a requerimientos específicos sin generar dependencia exclusiva del proveedor. Estas características, verificadas en el relevamiento propio de la documentación pública de la plataforma, consultada el 19-10-2026, confluyen para posicionar a N8N como la opción más adecuada para el escenario propuesto, donde la soberanía sobre los datos y los flujos de procesamiento constituye un requisito no negociable.

3.3. Trabajos académicos previos sobre clasificación de tickets

La literatura académica sobre clasificación automática de tickets de soporte ha experimentado un crecimiento considerable durante los últimos años. La Tabla 1 sistematiza los trabajos más relevantes de esta subsección, organizados por enfoque metodológico y por orden cronológico.

Paramesh y Shreedhara (2019) comparan Naive Bayes multinomial, regresión logística, k vecinos más cercanos y SVM sobre tickets reales de una mesa de servicio de infraestruc-

tura de TI, y reportan buen desempeño de SVM en todas las muestras. La versión arbitrada del mismo trabajo, Paramesh et al. (2018) (IEEE CSITSS 2018, pp. 221-227), reporta una exactitud de 90,60 % con árbol de decisión y de 91,81 % con RandomForest.

Revina et al. (2020) abordan el mismo problema desde otra óptica: clasifican la *complejidad* del ticket (baja, media o alta) y no su categoría. Con 30 y 60 tickets etiquetados, concluyen que los métodos simples y explicables, con pocos rasgos lingüísticos del dominio, son competitivos frente a alternativas más complejas. Excluyen además, por decisión de diseño y no como resultado medido, los *word embeddings* preentrenados, con el argumento de que el vocabulario del dominio contiene numerosos términos ausentes de los corpus generales; esa tensión con el enfoque basado en LLM se retoma en la Subsección 9.2.

La literatura reciente sobre clasificación de tickets no respalda un desplazamiento generalizado hacia los LLM generativos. En las comparaciones directas relevadas, los modelos tipo BERT superan a los LLM en 172 clases en turco (Paket et al., 2024) y, ajustados con pocos datos, son más consistentes y menos costosos que los LLM *zero-shot*. Colavito et al. (2025) reportan un macro-F1 de 0,74 a 0,87 para los modelos tipo BERT y de 0,79 a 0,88 para los LLM en NLBSE'23, y de 0,79 a 0,82 para BERT frente a un máximo de 0,68 para los LLM en NLBSE'24. Cabe precisar que los corpus de Colavito y colaboradores son conjuntos de incidencias (*issues*) de GitHub y no tickets de mesa de ayuda, de modo que la comparación con el problema de este trabajo es de una tarea afín y no idéntica.

La evaluación de modelos de lenguaje en escenarios de pocos ejemplos ha documentado que el rendimiento de clasificación depende fuertemente del idioma del corpus, con resultados que favorecen a los idiomas con más recursos en el benchmark multilingüe MEGA, que incluye tareas de clasificación (Ahuja et al., 2023). En un plano más general, el desempeño multilingüe también disminuye en los idiomas con menos recursos (Xuan et al., 2025). Para el español y sus variantes regionales, Grandury et al. (2025) construyen una tabla comparativa de LLM específica para las variedades del español de España y Latinoamérica, mientras que Mayor-Rocher et al. (2026) evalúan modelos con pruebas de español como lengua extranjera, Bernal-Beltrán et al. (2025) comparan ajuste fino y aprendizaje en contexto sobre español mexicano, y Ramón-Ferrer et al. (2026) evalúan modelos de bajos recursos sobre un corpus en español. Esta línea sugiere, como inferencia de los autores a partir de las obras citadas, que el español, y en particular sus variantes regionales como el rioplatense, ha recibido una atención notablemente menor en las evaluaciones sistemáticas publicadas. Cabe acotar, además, una

Tabla 1. Trabajos académicos previos sobre clasificación de tickets

Trabajo	Enfoque	Corpus/idioma	Métrica reportada	Condición
Paramesh & Shreedhara (2019)	NB, LR, kNN y SVM	tickets reales de infraestructura TI; tamaño e idioma: no reportado en el alcance revisado	no reportado en el alcance revisado (texto cerrado); cualitativo: SVM con buen desempeño; compañero arbitrado de dos de los tres autores (IEEE CSITSS 2018, pp. 221-227): árbol de decisión 90,60 % y RandomForest 91,81 %	clasificación clásica supervisada
Revina et al. (2020)	complejidad baja/media/alta; TF-IDF vs. rasgos lingüísticos; kNN, DT, NB, LR, SVM, semisupervisado	28.243 y 4.684 tickets (30 y 60 etiquetados); inglés predominante	exactitud 1,000 (árbol de decisión, rasgos lingüísticos) frente a 0,433 como máximo con TF-IDF (primer conjunto)	comparación de represen-taciones y selección de rasgos
Zangari et al. (2023)	revisión + BERT; inyección de jerarquía de etiquetas	20.000 reclamos + 35.000 issues; idioma no consignado en el resumen del artículo (acceso abierto)	mejor embedding: $>$28 % en F1 sobre el estándar; ML-BERT: hasta 5,7 % en F1 y 5,4 % en exactitud (bugs)	clasificación multinivel, dos datasets
Paket et al. (2024)	LLM (Titan, Llama, Mistral) vs. BERT; zero-shot, fine-tuning, RAG	turco, 172 clases	no reportado en el resumen (texto completo cerrado; resumen vía OpenAlex); cualitativo: BERT supera a los LLM	clasificación multiclase de 172 clases
Liu et al. (2025) (TickIt)	escalada de tickets con LLM; fine-tuning supervisado guiado por categoría	tickets de nube (ByteDance), 160 de prueba; idioma: no reportado en el alcance revisado	F1 0,862 (ajuste fino supervisado + CoT) frente a 0,801 como máximo con modelos pequeños	escalada online, dinámica y por relaciones
Colavito et al. (2025)	benchmark de 22 LLM generativos + 2 BERT de base	dos datasets de issues de GitHub (NLBSE'23 y NLBSE'24, 1.500 issues); no son tickets de mesa de ayuda; idioma: no reportado en el alcance revisado	macro-F1: BERT-like NLBSE'23 0,74 (RoBERTa) y 0,82-0,87 (SETFIT); NLBSE'24 0,79 (RoBERTa) y 0,82 (SETFIT); LLM zero-shot 0,79-0,88 (NLBSE'23) y hasta 0,68 (NLBSE'24); BERT ajustado más consistente	zero-shot vs. fine-tuning

Fuente: elaboración propia sobre las obras citadas (resumen y texto abierto; consulta 26-10-2026).

brecha concreta en el alcance revisado: en las fuentes consultadas hasta la fecha de corte del protocolo de revisión de este capítulo (21 de octubre de 2026), con las cadenas de búsqueda allí declaradas, no se identificó artículo arbitrado 2023-2026 que evalúe Google Gemini sobre tickets de soporte en español. Esta ausencia relativa al alcance revisado constituye una de las

motivaciones académicas del presente trabajo.

3.4. Calibración de la confianza y cascadas de modelos

Guo et al. (2017) mostraron, en experimentos que incluyen clasificación de documentos, que las redes neuronales modernas tienden a la sobreconfianza y que esta se corrige a posteriori con un parámetro de temperatura. En la clasificación por instrucciones, Zhao et al. (2021) hallaron en GPT-3 y GPT-2 sesgos hacia ciertas etiquetas, que una calibración contextual de la distribución de salida reduce. Para modelos consultados solo por texto, Tian et al. (2023) hallaron, en preguntas y respuestas, mejor calibración de la confianza verbalizada que de las probabilidades condicionales, y Xiong et al. (2024) observaron sobreconfianza, valores concentrados en el extremo alto de la escala y que predecir las fallas sigue siendo un desafío.

En las cascadas, Varshney y Baral (2022) consultan modelos de capacidad creciente solo si la confianza de predicción del anterior no alcanza un umbral, con mejoras de eficiencia y exactitud en clasificación de comprensión del lenguaje natural; Chen et al. (2024) proponen una cascada de LLM de costo creciente con una función de puntaje aprendida y un umbral para aceptar o escalar. En las fuentes consultadas con C1 y C2 hasta el 25 de octubre de 2026 no se identificó trabajo arbitrado que evalúe una cascada de reglas determinísticas y un LLM con confianza verbalizada sobre tickets de soporte en español; la ausencia es relativa al alcance revisado.

3.5. Análisis comparativo y brecha identificada

La Tabla 2 compara las principales soluciones revisadas en tres dimensiones: modalidad de despliegue, clasificación automática y modelo de costo.

Tabla 2. Comparación de soluciones para gestión automatizada de mesa de ayuda

Solución	Despliegue	Clasificación automática	Modelo de costo
Zendesk Suite	SaaS comercial	Sí, módulo de IA	Alto, por agente/mes
Freshdesk	SaaS comercial	Sí, motor Freddy AI	Medio-alto, por agente
Jira Service Mgmt	SaaS o autoalojado	Limitada en plan estándar	Medio, por agente
ServiceNow ITSM	SaaS comercial	Sí, Predictive Intelligence	Muy alto, contrato anual
osTicket	Código abierto	No nativa	Sin costo

Fuente: elaboración propia a partir de la documentación oficial de cada plataforma (Atlassian, 2026; Freshworks, 2026; osTicket, 2026; ServiceNow, 2026; Zendesk, 2026), consultada el 19 de octubre de 2026 (Jira Service Management y osTicket, verificadas además el 9 de noviembre; la página de producto de ServiceNow no respondió a la verificación automatizada y se reemplazó por su documentación oficial, consultada el 14 de noviembre).

La síntesis comparativa evidencia que ninguna de las soluciones revisadas combina simultáneamente las tres propiedades que la tabla releva y que el contexto del trabajo demanda: despliegue autoalojado para resguardo de datos sensibles, costo bajo y predecible en el tiempo, y capacidad nativa de clasificación automática mediante NLP moderno. La brecha identificada, en el alcance revisado en este capítulo y hasta la fecha de corte declarada, se sintetiza en la ausencia de soluciones de bajo costo, autoalojadas, con clasificación basada en modelos de lenguaje grandes y validadas empíricamente sobre corpus en español rioplatense para el dominio específico de mesas de ayuda empresariales medianas.

La presente investigación se ubica precisamente en esa intersección y propone una arquitectura compositiva que reutiliza componentes maduros de código abierto y servicios de inferencia bajo demanda. Esa arquitectura mantiene bajo control de la organización los datos sensibles y los flujos de orquestación, y aporta evidencia empírica reproducible sobre el desempeño del enfoque en un contexto lingüístico y organizacional escasamente documentado en la literatura. Suma, además, un canal telefónico con transcripción automática como rasgo propio, sin pretensión comparativa.

4. Marco metodológico

4.1. Enfoque y tipo de investigación

La investigación se enmarca dentro del enfoque cuantitativo aplicado, dado que propone el desarrollo de una solución informática orientada a mejorar el funcionamiento de un proceso organizacional concreto y mide su impacto mediante indicadores numéricos. Hernández Sampieri y Mendoza Torres (2018) ubican este tipo de estudios dentro de la investigación tecnológica de carácter aplicado, donde el conocimiento producido se orienta a la transformación práctica de la realidad antes que a la generación de teoría general. El trabajo es además cuasiexperimental: diseña, implementa y evalúa un artefacto tecnológico con asignación no aleatoria de casos y control parcial de las condiciones.

4.2. Diseño experimental

El diseño experimental adoptado es de tipo cuasiexperimental con muestras pareadas y mediciones repetidas. La unidad de observación es el incidente individual, y cada uno se procesa secuencialmente bajo dos condiciones: la condición manual y la condición automatizada. Procesar el mismo conjunto por ambas vías reduce la variabilidad de las características intrínsecas de cada caso y aumenta la potencia estadística del contraste entre flujos.

Para acotar el efecto de aprendizaje del operador humano sobre el corpus, el diseño adoptó una ejecución secuencial pareada: los mismos 200 casos se procesaron primero por el flujo manual (junio a agosto de 2026) y luego por el flujo automatizado (septiembre a octubre de 2026; Figura 11). El procesamiento manual se distribuyó entre dos operadores experimentados, rotados entre las dos mitades del corpus (100 casos por mitad). Con dos operadores y dos mitades, ambos quedan colineales: la rotación confunde el efecto de aprendizaje con el del operador, por lo que no se presenta como mitigación efectiva sino como limitación reconocida del diseño (véase la Subsección 4.8); sí conserva el control sobre la variabilidad intrínseca de cada caso, al medir el mismo incidente bajo ambas condiciones. El conjunto de las dos corridas de 2026 se denomina en adelante *campaña 2026-10*, y sostiene los valores de referencia del estudio. Para cerrar las mediciones pendientes se instrumentó una *campaña complementaria de medición*, con sujetos independientes y su propio protocolo (Subsección 4.5); esa denominación distingue a la campaña nueva en el resto del documento. El plan de la campaña complementaria fija para cada caso su `posicion`, su `mitad` y el `brazo_primero` que, con intención de contrabalancear el orden, se procesaría primero. En la ejecución, sin embargo, el

brazo manual precedió al automatizado en los 200 casos (manual: 5 de noviembre, de 09:20 a 18:49 UTC-3; automatizado: del 5 de noviembre, 23:47 UTC, al 6 de noviembre, 22:45 UTC). El contrabalanceo planificado no se ejecutó y el efecto de orden queda sin estimar (Subsección 4.8).

La investigación se desenvolvió bajo un protocolo de medición en vivo. Los dos operadores del brazo manual de la campaña 2026-10 son los analistas originales que fijaron la referencia (Subsección 4.4); trabajaron en pares y se cronometraron mutuamente, por lo que sabían que la campaña registraba tiempos, aunque no se anunció el inicio de cada cronometraje. El propósito comparativo (el contraste con un flujo automatizado) se ocultó, a lo sumo, al operador externo (`A1`); el operador que es también autor del trabajo (`T1`) lo conocía por esa condición, por lo que para él no hubo enmascaramiento. La sesión de esclarecimiento (*debriefing*) alcanzó solo a `A1`. Así se atenuó, sin eliminarlo, el efecto Hawthorne —la alteración del comportamiento de los sujetos cuando saben que están siendo observados— (McCambridge et al., 2014), que subsiste como amenaza residual (Sección 9). La atenuación es menor para `A1`: en el cronometraje mutuo, su observador fue `T1`, autor del trabajo. En el flujo manual, el compañero de par que no registraba el incidente cronometró en vivo el tiempo total, consignado en segundos con redondeo hacia arriba. De los 200 valores, 199 son múltiplos de 5 s y 180 de 10 s, resolución efectiva del instrumento que vincula los descuentos de 5 s y 10 s del análisis de sensibilidad con el procedimiento. El redondeo al alza constituye un sesgo de medición sistemático que infla el tiempo manual y su efecto se acota mediante el análisis de sensibilidad reportado en la Sección 8.

4.3. Operacionalización de variables

La Tabla 3 presenta la operacionalización de las variables del estudio, distinguiendo entre variables cuantitativas continuas, cuantitativas proporcionales y cualitativas nominales. Cada variable se acompaña de su unidad de medida y de la definición operacional aplicada durante la captura, garantizando la trazabilidad entre la definición conceptual y el procedimiento de medición efectivo.

4.4. Población, muestra y corpus

La población de referencia está constituida por la totalidad de los incidentes informáticos reportados a la mesa de ayuda de la organización analizada. El universo aproximado es de 2.646 incidentes, proyectado como 42 incidentes diarios sobre los 63 días hábiles del período

Tabla 3. Operacionalización de variables del estudio

Variable	Tipo	Unidad	Definición operacional
Tiempo de registro	Cuantitativa continua	Segundos (s)	Lapso entre la recepción del incidente en el canal de entrada y la persistencia confirmada del ticket en la base de datos.
Exactitud de clasificación	Cuantitativa proporcional	Porcentaje [0; 100]	Cociente entre incidentes correctamente clasificados y total de incidentes evaluados.
F1 macro promediado	Cuantitativa proporcional	Adimensional [0; 1]	Promedio aritmético del F1 de cada sector; el de umbral excluye los de soporte unitario.
Intervención humana	Cuantitativa proporcional	Porcentaje [0; 100]	Se reporta de dos formas rotuladas: proporción de casos que requieren acción manual de un operador humano y proporción del tiempo total del proceso dedicado a esa acción. La fuente por caso es el export de intervenciones de la campaña complementaria de medición, que registra el origen de cada intervención (`gate`, `muestreo`, `rederivacion` o `completado_manual`).
Costo de derivación errónea c	Cuantitativa continua	Segundos, tiempo-persona	Tiempo-persona adicional que una derivación errónea consume respecto de una correcta. Distingue un régimen corto (corrección en la compuerta de revisión) y uno largo (rediagnóstico del sector receptor y reasignación), y se descompone en un tramo activo medido y un tramo anclado.
Canal de origen	Cualitativa nominal	Categoría	Vía de entrada: correo electrónico, formulario web o llamada telefónica.
Categoría asignada	Cualitativa nominal	Categoría	Sector responsable, uno de los cinco sectores canónicos: `Seguridad Informatica`, `Soporte Tecnico Hardware`, `Soporte Tecnico Software`, `Bases de Datos` o `Sistemas`.

Fuente: elaboración propia.

relevado, del 16 de junio al 10 de septiembre de 2026 ($42 \times 63 \approx 2.646$). De ese universo se tomó un corpus de 200 casos pseudonimizados mediante un muestreo no probabilístico por conveniencia (disponibilidad): los 200 casos son los incidentes cronometrados en la campaña manual. No hubo estratificación ni asignación proporcional. La composición por sector es la observada y no una asignación: Soporte Técnico Hardware 85, Soporte Técnico Software 67, Seguridad Informática 31, Sistemas 16 y Bases de Datos 1. La distribución del universo por sector no está disponible, por lo que no puede afirmarse que el corpus la reproduzca. Bases de Datos quedó con un único caso, no estimable por clase, y en replicaciones convendría sobremuestrear las clases minoritarias. Los casos provienen de tres canales de origen: llamada telefónica 81, correo electrónico 66 y formulario web 53. El flujo manual se cronometró entre junio y agosto de 2026, una sub-ventana del período relevado, sobre la operación normal de la mesa; sobre los mismos 200 casos, el flujo automatizado se ejecutó entre septiembre y octubre de 2026.

La fórmula clásica de muestreo aleatorio simple con corrección por finitud se usa para informar el margen de error implicado por el tamaño del corpus, no como diseño muestral. Es apropiada porque el universo relevado es finito y relativamente acotado:

$$n = \frac{N\, z^2\, p\,(1-p)}{e^2\,(N-1) + z^2\, p\,(1-p)},$$

equivalente a $n = n_0/[1 + (n_0 - 1)/N]$ con $n_0 = z^2\, p\,(1-p)/e^2$. En ella, $N \approx 2.646$ es el tamaño del universo trimestral, $z = 1{,}96$ corresponde a un nivel de confianza del 95 %, $p = 0{,}5$ es la proporción esperada conservadora (la que maximiza la varianza $p(1-p)$ y, con ella, el tamaño requerido) y e es el margen de error absoluto. El tamaño del corpus se fijó por disponibilidad operativa: los 200 casos son los incidentes efectivamente cronometrados en la campaña manual, no un tamaño derivado a priori de la fórmula. Con esos insumos y ese tamaño fijo, el margen de error implicado bajo corrección por finitud es del 6,66 %, cifra que la fórmula reproduce recíprocamente con $n \approx 200{,}0$ y que resulta razonable para un estudio piloto de viabilidad técnica previo a un despliegue definitivo. Ese margen presupone un muestreo aleatorio que no se realizó: es una referencia y no una garantía de representatividad.

La construcción del corpus aplicó criterios de exclusión explícitos. En primer lugar, se descartaron los incidentes duplicados, entendiendo por tales los reportados más de una vez sobre el mismo hecho, ya sea por repetición en un mismo canal o por ingreso concurrente por

canales distintos. En segundo lugar, se descartaron las descripciones vacías o insuficientes, esto es, los registros sin contenido textual clasificable o cuya extensión no permitía inferir un sector responsable. En cambio, los casos con pertenencia simultánea a más de un sector (multicategoría) y las descripciones muy breves pero clasificables se conservaron deliberadamente por ser representativos del entorno operativo real, con una etiqueta primaria como sector responsable. Esto es coherente con el análisis de errores de la Sección 8, donde las descripciones muy cortas y la mezcla de categorías figuran entre los patrones de error dominantes: excluirlos habría sesgado el corpus hacia casos artificialmente limpios y sobreestimado el desempeño del clasificador.

Cada incidente del corpus fue revisado y etiquetado de forma independiente por dos analistas con experiencia en la mesa de ayuda: uno externo al equipo de autores y otro que es también autor del trabajo (`T1` en el registro de sujetos de la campaña). La independencia que respalda la validez de constructo es de carácter funcional: los analistas no fueron instruidos según el comportamiento del sistema y no tuvieron acceso a las predicciones del clasificador al momento de etiquetar; la coincidencia analista-autor acota esa independencia y se retoma entre las limitaciones (Sección 9). Los dos analistas son, además, quienes operaron el brazo manual de la campaña 2026-10 (Subsección 4.2): esta coincidencia no altera el cómputo del acuerdo inter-evaluador, pero implica que la etiqueta de referencia y el brazo de comparación comparten sujetos, lo que acota la independencia del *ground truth* respecto de los operadores cronometrados (Subsección 4.8). Las discrepancias entre analistas fueron resueltas por consenso bajo la supervisión del director del trabajo. Las planillas de ese doble etiquetado original no se conservaron. El valor de 0,87 informado en versiones anteriores de esta tesis no puede respaldarse con registros y por eso no se presenta como evidencia de fiabilidad (véase Subsección I.1). La fiabilidad de la referencia se estima con el doble etiquetado independiente de la campaña complementaria, a cargo de `E1` y `E2`, distintos entre sí, de los dos analistas originales, de los autores y de los operadores del brazo manual. Se hizo sobre una planilla única y sin acceso al consenso, a las predicciones ni a las etiquetas del par. Su kappa de Cohen (Cohen, 1960) es $\kappa = 0{,}5569$, moderado según los rangos de Landis y Koch (1977), con un IC del 95 % [0,4725; 0,6413] (Sección 8). Su tabla primaria se conserva con su SHA-256 en `evaluation/data/campana/doble_etiquetado.csv` (400 registros). La referencia del brazo manual de esa campaña es el consenso de `E1` y `E2`; los casos discordantes se excluyen y se informan aparte.

Corpus independiente de validación. Los 150 casos del corpus independiente provienen de una compañía financiera del ámbito laboral de uno de los autores. Los incidentes ocurrieron entre el 2 de noviembre de 2025 y el 12 de febrero de 2026, y se incorporaron a los casos crudos el 12 y el 13 de noviembre de 2026. La selección fue dirigida: se priorizaron las descripciones asociables a las categorías con cobertura insuficiente en el corpus de ajuste. El diseño prefijó cuotas de 50 casos de correo, 40 de formulario web y 60 de telefonía, con sobremuestreo de `Bases de Datos` (objetivo de al menos 10 casos) y ponderación de la exactitud global por la composición del corpus de 200; la composición observada fue de 50, 40 y 60 casos por canal, respectivamente. Los 150 casos se etiquetaron de forma ciega e independiente por dos etiquetadores, `E3` y `E4`, sin acceso a las predicciones del clasificador. Los 56 casos de refuerzo (`I151..I206`) comparten el origen y el criterio de selección; 40 de ellos corresponden a `Sistemas`. El refuerzo se reunió y etiquetó el 13 de noviembre de 2026 (ventana de etiquetado de 12:12 a 18:12, hora local), después de conocer el desempeño en `Sistemas` y sin cuota prefijada de antemano; su composición por sector es `Sistemas` 40, `Soporte Tecnico Software` 8, `Seguridad Informatica` 4, `Bases de Datos` 2 y `Soporte Tecnico Hardware` 2. La regla de arbitraje no es mayoritaria: cuando `E3` y `E4` difieren, la referencia la fija un tercer etiquetador, `E5`, que fijó 64 de las 206 referencias. Seis casos quedaron con tres etiquetas distintas y se analizan como rango en la Subsección 8.12.

4.5. Protocolo de pruebas

El protocolo se ejecutó en dos fases. La primera validó funcionalmente el sistema y verificó la integración de los componentes mediante tres tipos de pruebas. Las primeras son pruebas unitarias del módulo Python, cuya cobertura se mide con `pytest-cov` sobre los paquetes de rutas, servicios y repositorios mediante el comando `pytest-m"notintegration"--cov=app.routes--cov=app.services--cov=app.repositories--cov-report=term-missing`. Las segundas son pruebas de integración de la API y de la base de datos, junto con pruebas estructurales que validan el archivo `n8n/workflow.json`. Las terceras son pruebas de aceptación simuladas con incidentes sintéticos representativos de cada categoría.

La segunda fase consistió en la validación experimental propiamente dicha, en la cual los 200 incidentes del corpus se procesaron bajo ambas condiciones operativas y se registraron las variables descritas en la Subsección 4.3. El procesamiento manual lo realizaron dos

operadores experimentados, con más de tres años de antigüedad en la mesa de ayuda y capacitados en el sistema de tickets de referencia. El automatizado de la campaña 2026-10 se ejecutó sin intervención humana en la captura y con el gate de revisión aplicable, en la ventana de septiembre a octubre de 2026; la procedencia de cada conjunto de datos se declara al final de esta sección.

Procedencia de los datos del brazo automatizado. Los datos del brazo automatizado provienen de tres corridas con configuraciones distintas del clasificador. Los tiempos de correo y formulario (119 casos) se midieron el 2-10-2026. El autor Luca Gomez ejecutó el arnés de ingesta `scripts/corpus_ingest/ingest_via_n8n.py` con sus valores por defecto (`--source json` y `--insecure`, sobre la URL base por defecto `https://localhost` a través del proxy inverso). El arnés envió cada caso por el canal real del flujo N8N (un correo nuevo al buzón dedicado o un envío al webhook del formulario), con la descripción pseudonimizada como texto. El tiempo va del envío a la persistencia del incidente. En el correo incluye la espera de la recogida por el disparador IMAP, configurado para sondear el buzón una vez por minuto (el intervalo efectivo no se midió sobre N8N 2.11.2, por lo que no consta). El host SMTP del arnés reside en `scripts/corpus_ingest/ingest.env`, excluido del control de versiones, por lo que no consta. Regían el vocabulario original del filtro (89 patrones), el *prompt* sin reglas de frontera y el cortocircuito por confianza determinística $\geq 0{,}90$ (`hybrid-v1`), que fuera de línea resuelven por reglas 72 de los 200 casos (Tabla 16). Esos 119 valores constan en el corpus y su registro primario pseudonimizado se versiona en `data/corpus_resultados_web_correo.json`, que reúne 118 de los 119 casos de correo y formulario del 2-10-2026 con las marcas de tiempo de la base (ingreso y persistencia); `R001` es el único caso sin registro. Ese registro respalda la existencia y la procedencia de los incidentes, no la medición de extremo a extremo: aporta las marcas de tiempo de la base y no el tiempo del corpus, que incluye el envío. El archivo `data/corpus_resultados.json` corresponde a otra corrida y no los respalda. Los 81 tiempos telefónicos, en cambio, coinciden con su registro, `data/corpus_resultados_telefonia.json`. Esos 81 tiempos se midieron en una corrida realizada el 5 y 6 de octubre de 2026 (25 casos el 5 y 56 el 6, con unas 2 y 3 horas de trabajo, respectivamente; las horas de reloj exactas no constan), en un entorno aislado. El autor Luca Gomez recitó las llamadas desde un *softphone* VoIP de navegador e interpretó parafraseando la descripción pseudonimizada, con la grabación acotada a 45 s, sobre la compu-

tadora SF20GM7. El autor confirma que las únicas repeticiones fueron R126 y R002; el texto no se apoya en el sidecar para acreditarlas, porque este consolida una fila por caso. La versión desplegada que procesó los 56 casos del 6 de octubre (imagen de `backend-corpus` y flujo importado en `n8n-corpus`) no consta. La corrida no tiene configuración única: los 25 casos del 5 de octubre son anteriores a dos cambios del sistema, la ampliación del vocabulario y la clasificación unificada con la cascada del *backend* (Sección I), contemporáneos de las llamadas del 6. Todas las llamadas son anteriores al cortocircuito evaluado. Las métricas de clasificación provienen de una ejecución fuera de línea del *framework* sobre el corpus JSON, generada el 7-10-2026 a las 22:22 UTC con `hybrid-v3`, que versiona el commit `bf5e099` (Tabla 29; evidencia: `evaluation/evidence/predicciones_hybrid-v3_2026-10-07.json`; hash del corpus `1fd17d7e...`, cuya entrada no difiere en descripciones ni etiquetas de la previa al recálculo). El 19-10-2026 los tiempos telefónicos se recalcularon sumando la duración de la grabación a la latencia posterior al cuelgue, para igualar la base con el tiempo manual, que incluye escuchar la llamada. Como las corridas de tiempos invocaban al modelo más que la configuración evaluada, no favorecen al flujo automatizado frente a ella (inferencia, no medición).

Protocolo de la campaña complementaria de medición. La campaña complementaria de medición se ejecutó con un plan explícito por caso (`plan_campana.csv`), que fija la `posicion`, la `mitad` y el `brazo_primero` planificado de cada incidente; en la ejecución el brazo manual precedió al automatizado en los 200 casos (Subsección 4.2). El brazo manual lo operaron dos operadores experimentados, `O1` y `O2`, distintos de los etiquetadores, de los analistas originales y de los autores, que registraron el tiempo por incidente en la planilla única `brazo_manual.csv`. La tarea manual de esta campaña difiere de la de la campaña 2026-10: cada operador recibió una hoja con el identificador y la descripción de cada caso y registró el instante en que tomó el caso y el instante en que asignó el sector. El tiempo medido es, por lo tanto, el de la decisión de sector. En la campaña 2026-10, en cambio, el cronometraje incluyó la lectura, la comprensión, la búsqueda y la carga del ticket, y la escucha en telefonía. Los tiempos por operador de la campaña complementaria se presentan en la Tabla 20; no son comparables con los de la campaña 2026-10 ni reemplazan el contraste principal. La intervención humana sobre el flujo automatizado se instrumentó mediante un export de intervenciones (Sección I): cada acción manual queda registrada por caso con su origen (`gate`, `muestreo`,

`rederivacion` o `completado_manual`) en `intervenciones.csv`. La campaña corrió con el clasificador congelado en la configuración evaluada (`hybrid-v3`; Tabla 29), con la regla del reportante activa y una salida en vivo que difiere de la caché en 13 casos; sus métricas son comparables con las de la campaña 2026-10 solo calculadas sobre la caché, y sus tiempos alimentan el análisis del efecto de posición.

Test de carga del tramo compartido. Para contrastar la dimensión de capacidad de la hipótesis subsidiaria de integración multicanal se midió el tramo en que convergen los canales con un test de carga reproducible y de costo cero. Se cargaron dos capas por separado: el punto de convergencia del backend (alta autenticada de un incidente) y el *webhook* del canal web de N8N, que además ejercita la orquestación. Se aplicaron 1, 5, 10 y 20 solicitudes concurrentes, con 40 solicitudes por nivel y 3 repeticiones, y se registraron la latencia medida por el cliente (p50, p95 y p99), el throughput y la tasa de error, sin descartar solicitudes fallidas. La regla de decisión de tres vías se fijó antes de observar datos y no se reajustó: la capacidad es «sostenida» si en todos los niveles la tasa de error es cero, el p95 no supera 5000 ms y el throughput no decrece más del 10 % respecto del nivel anterior; «no sostenida» si algún nivel viola alguna de las tres condiciones; y «no concluyente» si la corrida queda incompleta. Como control secundario, que se informa pero no decide, se calculó el cociente entre el p95 con 20 y con 1 solicitudes concurrentes (cota prerregistrada de 20). La corrida se hizo en un entorno desechable, con una base propia aislada de la operativa, una clave del modelo de lenguaje ficticia y un presupuesto de inferencia nulo, con descripciones que las reglas determinísticas resuelven sin invocar al modelo; se verificó en el registro de clasificación de cada incidente creado que ninguno escaló, de modo que no se emitió ninguna llamada paga. Los canales de correo, cuyo sondeo periódico no admite inyección concurrente, y de telefonía, que es de pago, quedaron fuera de la inyección; medir en el punto donde los tres convergen es lo que justifica esa exclusión. La medición se hizo en una sola máquina.

4.6. Métricas e instrumentos

La evaluación del sistema se sustenta en cuatro métricas principales. La primera es el tiempo medio de registro: media aritmética y mediana de los tiempos individuales por condición, con su desvío estándar muestral, mínimo, máximo y reducción relativa. La segunda es la exactitud global de clasificación, calculada como la proporción de incidentes correctamente

derivados al sector responsable. La tercera es el valor F1 macro promediado, media aritmética de los valores F1 de cada clase estimable (variante que Opitz y Burst (2019) distinguen del F1 de la precisión y la sensibilidad macro promediadas), que neutraliza el desbalanceo de clases del corpus (Sokolova & Lapalme, 2009). La cuarta es la proporción de intervención humana, en dos dimensiones rotuladas: casos que requieren intervención y tiempo dedicado a tareas manuales. El denominador del tiempo es el tiempo de registro automatizado más la duración de la intervención, no el tiempo total de atención (Subsección 8.3). No se midió en la campaña 2026-10, por ausencia de registro primario. Se mide en la campaña complementaria con el export de intervenciones, que registra el origen de cada acción por caso. Sobre esa campaña se calculan dos métricas que la campaña 2026-10 no midió: la exactitud del brazo manual —derivaciones correctas frente a la referencia del doble etiquetado nuevo—, con su contraste frente al automatizado, y la tasa de intervención humana del flujo automatizado con su intervalo de confianza.

Se utilizaron tres instrumentos de captura. El primero son los registros automáticos generados por el propio sistema, con marcas de tiempo precisas al milisegundo para el flujo automatizado. El segundo es una planilla de cronometraje observacional para el flujo manual, completada en vivo por el compañero de par que no registraba el incidente, con el tiempo total por incidente en segundos y redondeo hacia arriba. El tercero son las matrices de confusión generadas mediante la biblioteca scikit-learn (Pedregosa et al., 2011). En el flujo automatizado, el tiempo de registro del canal telefónico comprende tanto la duración de la llamada grabada como la latencia de procesamiento posterior al cuelgue, mientras que los canales de correo electrónico y formulario web se miden como latencia de extremo a extremo de su procesamiento. Dado que la grabación telefónica está acotada a un máximo de 45 s (véase la Sección 6), la duración de la llamada registrada —y por lo tanto el tiempo automatizado telefónico— constituye una cota inferior de la duración real de la llamada.

Costo de la derivación errónea c. El costo c se define como el tiempo-persona adicional que una derivación errónea consume respecto de una correcta, y no como el tiempo calendario hasta que el caso llega al sector correcto. Se distinguen dos regímenes: el corto, en el que el error se detecta y corrige en la compuerta de revisión, y el largo, en el que el error escapa y el sector receptor lo rediagnostica y lo devuelve. Su medición es un análisis secundario, offline y de solo lectura sobre dos artefactos ya versionados de la campaña complementaria:

las duraciones por caso de `intervenciones.csv`, con el indicador `cambio_sector`, y los tiempos de decisión de sector del brazo manual (`brazo_manual.csv`), estos últimos como proxy del rediagnóstico. El tramo activo se estima con un intervalo bootstrap percentil al 95 %, con semilla fija; el tramo de reanudación tras la interrupción no se mide en este corpus y se declara sin cota disponible. El método, la descomposición por régimen, el intervalo compuesto y su comparación con la banda canónica constan en el memo de números canónicos (Sección 3.31), que es la fuente de verdad numérica; el umbral del 85 % y el balance neto no se modifican.

4.7. Análisis estadístico

Para la comparación de los tiempos de registro entre ambas condiciones se aplicó la prueba de Wilcoxon de rangos con signo (Wilcoxon, 1945), prueba no paramétrica para muestras pareadas. Se la eligió porque la prueba previa de normalidad de Shapiro-Wilk (Shapiro & Wilk, 1965) rechazó la hipótesis de normalidad en los tres conjuntos analizados, todos con $n = 200$: tiempos manuales ($W = 0{,}803$, $p = 3{,}71 \times 10^{-15}$), tiempos automatizados ($W = 0{,}902$, $p = 3{,}47 \times 10^{-10}$) y diferencias pareadas ($W = 0{,}822$, $p = 2{,}37 \times 10^{-14}$). En los tres casos el valor p queda muy por debajo del nivel de significancia $\alpha = 0{,}05$, lo que respalda el uso de una prueba no paramétrica. En lo que sigue se denotan T^+ y T^- la suma de los rangos de las diferencias positivas y negativas, respectivamente. La implementación de referencia (`scipy.stats.wilcoxon` en su variante de dos colas) devuelve como estadístico de contraste el menor de ambos, es decir $W = \min(T^+, T^-)$; por lo tanto $W = T^-$ cuando el flujo automatizado resulta más rápido que el manual en la mayoría de los pares, que es el caso del corpus analizado. Los p de tiempos son bilaterales, conservadores frente a la H_1 direccional; el unilateral global (`alternative=greater`) es $1{,}54 \times 10^{-32}$.

Para cuantificar la magnitud práctica de la diferencia se calculó el coeficiente r de correlación rank-biserial (Kerby, 2014), indicador de tamaño del efecto para pruebas no paramétricas. El cálculo se define directamente a partir de los dos estadísticos de rango, $r = (T^+ - T^-)/[n(n+1)/2]$, donde n es el número de pares. La expresión equivale a $1 - \frac{4W}{n(n+1)}$ cuando $W = T^- = \min(T^+, T^-)$, y su rango teórico es $[-1, +1]$.

Para el análisis de la clasificación se construyó la matriz de confusión global y se calcularon los valores de precisión, sensibilidad (recall) y F1 por cada clase, así como su promedio macro. La referencia de verdad es multietiqueta (107 de los 200 casos, 53,5 %) y el clasifica-

dor emite una etiqueta principal: las métricas primarias son monoetiqueta (exactitud estricta y macro-F1 de umbral) y las secundarias, multietiqueta (subset accuracy, Hamming loss y micro-F1) (Tsoumakas & Katakis, 2007). Estas se calculan sobre el conjunto predicho de cada caso (la etiqueta principal más los sectores adicionales que emite la etapa determinística, en 8 casos), y la Hamming loss se normaliza por la unión de las etiquetas verdaderas y predichas del caso (equivalente a $1-$ Jaccard), no por las cinco clases. Como métrica secundaria operativa se calculó además la exactitud laxa (sector predicho principal dentro del conjunto de verdad del caso), distinta de la estricta, que sigue siendo la primaria; ambas se desagregaron por etapa y por canal con intervalo de Wilson, y la confianza se analizó por etapa, porque cada una emite una magnitud distinta. Las proporciones por clase se acotaron con el método de Wilson (Wilson, 1927); el F1 por clase y las métricas de conjunto, con el bootstrap percentil de Efron y Tibshirani (1994) a nivel de caso (2000 remuestreos, semilla fija). La clase de soporte unitario (Bases de Datos, $n = 1$) se declara no estimable y se excluye del macro-F1 de umbral, contra el cual se evalúa el criterio de 0,85. Todos los cálculos se realizaron mediante la biblioteca SciPy del ecosistema Python (Virtanen et al., 2020).

Análisis de la campaña complementaria de medición. Sobre la campaña complementaria de medición se agregan los siguientes contrastes. El kappa del doble etiquetado nuevo se informa con intervalo de confianza, estimado por dos vías: la aproximación asintótica de Fleiss et al. (1969) y el bootstrap percentil a nivel de caso (2000 remuestreos, semilla fija). Las proporciones por operador se acotan con el método de Wilson, y la exactitud agregada del brazo manual, con el bootstrap percentil por caso. La exactitud del brazo manual se contrasta con la del brazo automatizado mediante la prueba de McNemar sobre los casos con predicción de ambas vías, tomando como referencia el consenso del doble etiquetado nuevo. El análisis de orden se limita al efecto de *posición* del caso en la secuencia, estimado por correlación de rangos de Spearman; el contraste entre los grupos `brazo_primero` no estima el efecto de orden, porque ambos grupos recibieron el brazo manual primero (Subsección 4.2). Para cada contraste se informa el efecto mínimo detectable (MDE) que reporta el análisis de la campaña, sin fijar valores a priori. La segunda sub-hipótesis se contrasta contra la cota de 0,15 con una regla de tres vías. La regla es asimétrica: la rama de refutación se decide con la estimación puntual y no con el intervalo, de modo que basta que aquella alcance o supere la cota. El resultado es compatible si el límite superior del intervalo de Wilson queda por debajo de 0,15,

refutado si la estimación puntual alcanza o supera 0,15, y no concluyente si la estimación queda por debajo de 0,15 pero su límite superior no. Aplicada a la proporción prefijada, sobre los 200 casos (25/200 = 12,5 %; IC de Wilson [8,6 %, 17,8 %]), la regla da un resultado no concluyente. En la campaña complementaria, la revisión humana alcanzó 66 casos de correo, 81 de telefonía y ninguno de los 53 del formulario web. Sobre los 147 revisados, 25 cambiaron la derivación (17,0 %; IC de Wilson [11,8 %, 23,9 %]). Sobre ese denominador la estimación puntual supera la cota y la regla, aplicada literalmente, daría *refutada*. Pero el denominador se adoptó después de conocer los datos, el intervalo contiene 0,15 y la prueba binomial unilateral contra 0,15 (H_1: proporción mayor que 0,15) da $p = 0{,}28$, y la bilateral, 0,49. Por eso no se sostiene una refutación. La sub-hipótesis resulta *no concluyente, con estimación puntual por encima de la cota*. El cociente sobre los 200 casos se informa como aplicación prefijada de la regla y como dato secundario.

Línea de base supervisada clásica. Para situar el desempeño del clasificador híbrido frente a un enfoque supervisado convencional se entrenó una línea de base: la unión de una representación TF-IDF de palabras (unigramas y bigramas) y de caracteres (de dos a cinco), seguida de una regresión logística regularizada, con la implementación de scikit-learn (Pedregosa et al., 2011). Se fijaron dos variantes antes de medir: con re-ponderación balanceada de las clases, que es la variante primaria, y sin re-ponderación, como sensibilidad. El modelo se entrenó con los 200 casos del corpus de ajuste y se probó sobre los 206 casos fuera de muestra de la referencia arbitrada, sin exclusión de los casos discordantes. Los casos de prueba no intervinieron en el entrenamiento ni en la elección de las variantes, y el modelo usa una semilla fija y no requiere red. Se calcularon las mismas métricas que para el clasificador híbrido. La comparación es pareada, porque ambos sistemas se evalúan sobre los mismos casos: se aplicó la prueba de McNemar exacta bilateral (McNemar, 1947) y se estimó la diferencia de exactitudes con un intervalo bootstrap percentil pareado de 10.000 remuestreos (Efron & Tibshirani, 1994). Esta línea de base no es el brazo que usa solo el modelo de lenguaje, de modo que no contrasta la hipótesis de eficiencia del esquema híbrido, y tampoco es un modelo supervisado afinado: no se buscaron hiperparámetros ni se probaron otros modelos.

Calibración y punto de operación del gate de confianza. Para medir si la confianza declarada sirve como criterio de derivación a revisión se calcularon, por etapa y por corpus, tres

cantidades sobre el acierto estricto de cada caso. El error de calibración esperado (ECE) agrupa los casos en 10 bandas de igual ancho de la confianza en $[0\,;\,1]$ y promedia, ponderada por el número de casos de cada banda, la distancia absoluta entre la confianza media y la exactitud de la banda (Guo et al., 2017); la sobreconfianza es la confianza media menos la exactitud. El puntaje de Brier (Brier, 1950) es el error cuadrático medio entre la confianza y el acierto (0 o 1). El AUROC de la confianza es la probabilidad de que un caso acertado tenga más confianza que uno errado, con empates contados como 0,5 (Sokolova & Lapalme, 2009): mide el orden de la señal (discriminación) y vale 0,5 si no discrimina, mientras que el ECE y el Brier dependen del nivel (calibración). Los intervalos son bootstrap percentil por caso (2000 remuestreos, semilla fija). El punto de operación se eligió con una regla fijada antes de calcular las salidas. Para la etapa Gemini, los umbrales candidatos son 0,70 (el vigente), 0,86, 0,91, 0,96, 0,99 y derivar todo lo escalado, con la regla de aceptar si la confianza es igual o superior al umbral. El umbral seleccionado es el menor cuya exactitud selectiva (la de los casos aceptados) alcanza un piso, con al menos 10 casos aceptados, y se elige solo con los 200 casos del corpus de ajuste. El piso primario es 0,85, el criterio del segundo objetivo específico, y el secundario es 0,8278, la exactitud estricta del brazo manual. Si existe un umbral seleccionado, se evalúa fuera de la muestra, en los 103 casos con consenso de `E3` y `E4`, con un resultado de tres vías: confirmado, no confirmado o no estimable. Si ningún umbral lo alcanza, el resultado es que la confianza no sostiene un umbral con el piso fijado, y el barrido fuera de la muestra se informa solo como descripción, sin elegir umbral con esos datos. Con la misma regla se evaluaron dos señales alternativas recomputadas sin costo: el acuerdo entre el sector que habrían propuesto las reglas y el de Gemini, y el puntaje de correctitud de las reglas. Una regresión isotónica ajustada en los 200 casos se aplicó fuera de la muestra solo para corregir el nivel (ECE y Brier). El análisis es posterior a la campaña y no es ciego: antes de fijar las reglas se había tabulado la distribución de las confianzas y los aciertos por nivel en ambos corpus, y las reglas se fijaron por principio, a partir de las recomendaciones de la Subsección 11.1, y no por lo que esa tabulación sugería. Es una amenaza a la validez del prerregistro, y se informan todos los resultados, favorables o no.

Sensibilidad a la referencia de verdad. La sensibilidad a la referencia se evalúa con una simulación Monte Carlo calibrada al kappa 0,6055 de `E3`/`E4` (Subsección 2.9): kernel 5×5 fila-estocástico con suavizado de Laplace 0,5, mezcla $Q_\lambda = (1-\lambda)Q + \lambda m$ con λ calibrado por

bisección, $B = 2000$ réplicas con semilla 20261021 y cotas distribution-free con δ de Wilson. El método supone independencia condicional de las etiquetas dada la referencia, se rotula como sensibilidad y no como verdad latente, y el detalle está en la Subsección 8.12.

Sesgo del vocabulario y dependencia de la referencia. Para acotar el sesgo de haber ajustado el vocabulario del filtro con el mismo corpus, se repite la etapa determinística sobre los 206 casos arbitrados, sin invocar al modelo. El vocabulario se deriva de fuentes externas al corpus (las definiciones canónicas de los cinco sectores y un glosario público de ciberseguridad (INCIBE, 2017)) y se fija, con su huella SHA-256, antes de medir. Su independencia es procedimental: quien lo derivó no leyó las descripciones del corpus ni el vocabulario vigente, el prerregistro no es ciego y no se afirma que sus términos no aparezcan en el corpus. La exactitud estricta del clasificador congelado se desagrega además entre el consenso de `E3` y `E4` (142 casos) y lo arbitrado por `E5` (64 casos). El subconjunto en que los tres coinciden es vacío por construcción, porque `E5` solo etiquetó los casos discordantes. Ambas mediciones son sensibilidad, no exactitud corregida ni causalidad de la referencia (Subsección 8.6).

Brazo de modelo de lenguaje solo. Para contrastar la hipótesis subsidiaria de eficiencia se midió un brazo que clasifica cada caso únicamente con Gemini 3.6 Flash, con el mismo *prompt* congelado y sin la etapa determinística (temperatura 0,3, una sola corrida), y se lo comparó caso a caso con el híbrido congelado. El diseño es pareado. El bloque primario son los 103 casos fuera de muestra con consenso de `E3` y `E4`; los 200 casos dentro de la muestra se informan como bloque secundario y no deciden, porque las reglas del híbrido se ajustaron con ellos y ese bloque no es una prueba limpia: favorece al híbrido. La calidad se compara con la exactitud estricta, la prueba de McNemar exacta bilateral y la diferencia de exactitudes con intervalo bootstrap percentil pareado (10.000 remuestreos, semilla 20261021). La eficiencia se mide con las llamadas al modelo y con el costo de inferencia estimado a partir de los *tokens* registrados, en dos escenarios de precio, y se expresa como la razón entre el híbrido y el brazo de modelo solo, con su intervalo. Antes de observar datos del brazo se fijó una regla de decisión de tres vías sobre el bloque primario. El margen de no inferioridad es de 0,05, es decir, cinco puntos porcentuales o una derivación equivocada más cada 20 incidentes; se fijó por lo que se considera operativamente tolerable y no por lo observado, y no se reajustó. El híbrido es no inferior si el límite inferior del intervalo de la diferencia (híbrido menos modelo solo) supera

$-0{,}05$, inferior si el límite superior queda por debajo de ese valor e indeterminado en otro caso. El ahorro es material si los límites superiores de los intervalos de las razones de costo y de llamadas son menores que 0,90. El veredicto es «sostenida» si hay no inferioridad y ahorro material, «no sostenida» si el híbrido es inferior o el ahorro no es material, y «no concluyente» si la exactitud es indeterminada con el ahorro cumplido. Como control de deriva se calculó la concordancia de la nueva corrida con la predicción cacheada del híbrido en los casos que este escaló al modelo, con un umbral de 0,90; el control no separa la deriva del modelo del azar de muestreo a temperatura 0,3. El análisis no es ciego: los autores ya conocían las exactitudes del híbrido, lo que es una amenaza a la validez. Hubo una desviación del prerregistro: 112 casos del bloque dentro de la muestra fallaron en la primera tanda sin llegar al modelo (fallo técnico del proveedor, sin respuesta) y se reintentaron. La decisión de reintentar se tomó después de ver los resultados, lo que se declara como amenaza a la validez; el bloque primario no tuvo fallos técnicos y su veredicto no depende del reintento.

Diseño de la validación fuera de muestra. El análisis fuera de muestra informa tres lecturas de la exactitud estricta: la cruda sobre el corpus arbitrado completo, rotulada como primaria, y la ponderada por la composición por sector del corpus de ajuste y la de los 150 casos del diseño original, rotuladas como complementarias; el veredicto sobre el umbral de 0,85 se lee con las tres. La calibración de la etapa Gemini sobre el corpus arbitrado se informa como complemento descriptivo, sin seleccionar ni confirmar un umbral, porque la regla prerregistrada elige solo con los 200 casos de ajuste. El orden del prerregistro de la calibración se demuestra con las fechas de autor de los commits (`git log --format='%h %ai %ci'`), porque las fechas de commit quedaron igualadas por un rebase.

4.8. Amenazas a la validez

Se identificaron y trataron explícitamente ocho amenazas a la validez del estudio.

La primera, una amenaza a la validez interna por efecto de aprendizaje del operador humano sobre el corpus, se acotó parcialmente mediante la ejecución secuencial pareada descrita en la Subsección 4.2. Como se anticipó allí, la rotación de operadores entre las dos mitades no elimina la amenaza (el efecto de operador queda confundido con la mitad del corpus) y se declara como limitación no resuelta del diseño, no como una mitigación efectiva. En la campaña complementaria el efecto de orden tampoco se resolvió (el brazo manual precedió

al automatizado en los 200 casos y el contraste entre grupos `brazo_primero` no lo estima); solo se estima el efecto de posición, significativo para uno de los dos operadores y acotado por su efecto mínimo detectable (Sección 8).

La segunda, una amenaza a la validez de constructo por la subjetividad de la categorización, se abordó mediante el doble etiquetado independiente, el Kappa de Cohen y la resolución de discrepancias por consenso supervisado. La subjetividad de la categorización se estimó con el doble etiquetado independiente de la campaña complementaria, cuyo kappa fue $\kappa = 0{,}5569$ (moderado, según los rangos de Landis y Koch (Landis & Koch, 1977)). Ese valor indica que la referencia tiene fiabilidad limitada, y esa limitación se asume. Los analistas etiquetadores son las mismas personas que operaron el brazo manual y uno de ellos es autor del trabajo (Subsección 4.4): esa coincidencia no invalida el acuerdo inter-evaluador, pero acota la independencia del referente y se asume como limitación explícita. Esa misma coincidencia acota la atenuación del efecto Hawthorne en el brazo manual: para el operador que es autor del trabajo el enmascaramiento del propósito comparativo no existió, de modo que el sesgo de novedad u observación no se distribuye por igual entre los dos operadores. Su dirección no se declara, por falta de evidencia sobre cuál fue más rápido.

La tercera, una amenaza a la validez externa derivada del idioma y del dominio organizacional, se reconoce como limitación explícita del estudio: los resultados no son extrapolables sin nuevas validaciones a corpus en otros idiomas, en otras organizaciones o en otros sectores de la economía.

La cuarta, una amenaza a la validez de conclusión derivada del tamaño moderado de la muestra ($n = 200$), se evaluó mediante un análisis de potencia estadística a priori (Cohen, 1988). El contraste principal es la prueba de Wilcoxon de rangos con signo sobre las mediciones pareadas, bilateral, con $\alpha = 0{,}05$, y se fijó una potencia objetivo de $0{,}80$. Con $n = 200$, el efecto mínimo detectable es un tamaño del efecto estandarizado d_z (media de las diferencias pareadas sobre su desvío) de aproximadamente $0{,}20$ en la aproximación normal ($0{,}21$ con la eficiencia relativa asintótica $0{,}864$ de la prueba de rangos frente a la t pareada (Hodges & Lehmann, 1956)). El d_z observado, $1{,}00$, lo supera más de cuatro veces; por canal es de 1,37 (telefonía), 0,73 (correo) y 1,61 (formulario web), frente a mínimos de 0,31, 0,34 y 0,38 (0,33, 0,37 y 0,41 con el ajuste). Por lo tanto, el diseño posee potencia suficiente para el contraste de tiempos. El riesgo se concentra, en cambio, en la precisión de las estimaciones de clasificación (exactitud por clase, macro-F1), que se reportan con intervalos de confianza (Wilson para las

proporciones, bootstrap percentil para F1). La amenaza se trata, además, con pruebas no paramétricas robustas frente a tamaños muestrales pequeños y a desviaciones de la normalidad (Hernández Sampieri & Mendoza Torres, 2018).

La quinta, una amenaza a la validez externa por sesgo de selección, deriva de que los 200 casos no son una muestra probabilística: son los incidentes cronometrados en la campaña manual (Subsección 4.4). No se estimó en qué difieren de los demás incidentes del período en sector, canal o complejidad. La dirección y la magnitud de ese sesgo quedan sin estimar. Por eso las cifras valen para este corpus y no se extrapolan al universo de incidentes de la organización.

La sexta, una amenaza a la validez de constructo y a la validez externa, proviene de las llamadas del canal telefónico. Un autor que conocía el caso y el sistema recitó las 81 llamadas parafraseando la descripción pseudonimizada. Un locutor así habla más claro y más breve que un usuario real, lo que favorece el tiempo medido. Pudo favorecer también la transcripción, aunque el canal telefónico obtuvo la exactitud más baja (0,654). Hubo dos configuraciones del sistema (25 casos el 5 de octubre y 56 el 6) y la versión del día 6 no consta (Subsección 4.5). No se estimó la magnitud del sesgo, y las cifras telefónicas no se extrapolan a usuarios reales.

La séptima, una amenaza a la validez externa por sesgo de selección del refuerzo, proviene de que los 56 casos de refuerzo se reunieron después de conocer el desempeño en `Sistemas` y sin cuota prefijada de antemano, lo que alteró la composición del corpus arbitrado. Su dirección perjudica al clasificador, porque concentra el refuerzo en la clase de peor desempeño; se mitiga con las lecturas complementarias ponderada y sobre los 150 casos del diseño original, que aíslan el efecto del refuerzo.

La octava, una amenaza a la validez de conclusión, combina la dependencia de un único árbitro, `E5`, que fijó 64 de las 206 referencias con una regla no mayoritaria, con la inestabilidad de la confianza de Gemini entre corridas: sobre los casos comunes, la confianza difiere en 7 casos. Ambas acotan la precisión de las estimaciones fuera de muestra y se declaran sin mitigación.

4.9. Gestión del proyecto bajo enfoque Scrumban (método de construcción del artefacto)

Este apartado describe el método de construcción del artefacto, no el de investigación. El diseño experimental, el muestreo, el corpus y el análisis estadístico se definieron en las Sec-

ciones 4.1 a 4.8, mientras que la gestión bajo Scrumban concierne solo a cómo se construyó el sistema y se documenta por trazabilidad.

La construcción del sistema siguió un esquema Scrumban, que combina la planificación por iteraciones de Scrum con el flujo continuo de Kanban (Ladas, 2009), con iteraciones de duración y número variables; su detalle y relación con las campañas figuran en la Subsección 6.6 y la Figura 11.

La distribución de roles asignó la coordinación general, la integración de componentes y la telefónica (Twilio) a Luca Gomez, y la implementación inicial del módulo Python, la base de datos, el frontend y el flujo N8N a Gonzalo Sevilla; Carla Bustos revisó la tesis y colaboró en los anexos y la corroboración de fuentes. La dirección académica correspondió a los directores de la portada, el Prof. Alberto Cortez y el Prof. Ariel Enferrel.

El tablero Kanban se gestionó en Jira con seguimiento diario y planificación por iteración; la coordinación del grupo, en GitHub Projects. La definición de terminado (*Definition of Done*) exigió pruebas unitarias aprobadas, revisión por pares y documentación actualizada.

5. Arquitectura del sistema

5.1. Visión general

El sistema propuesto se estructura como una arquitectura distribuida y modular compuesta por cinco capas claramente diferenciadas, siguiendo los principios de cohesión alta y acoplamiento bajo descritos por Pressman y Maxim (2020). En el diseño se previó proteger la comunicación con el exterior mediante TLS 1.2/1.3 a nivel de un proxy inverso (Nginx); la terminación TLS 1.2/1.3 se verifica de forma automatizada sobre el despliegue de referencia de la release v1.2.2 (prueba de humo de la Subsección 6.7, cuyo runbook se cita en el Anexo G; despliegue de referencia en el Anexo A), con certificado autofirmado de referencia. La campaña experimental usó dos despliegues, y la distinción es relevante. La medición telefónica del 5 y 6 de octubre de 2026 corrió sobre el perfil Compose aislado `corpus`, que no incluye el proxy inverso. La ingesta del brazo automático del 2 de octubre lo hizo sobre el stack base, que sí incluye Nginx con el certificado autofirmado de referencia. En ningún caso las mediciones de la Sección 8 dependen de TLS. En producción, el adoptante debe proveer un certificado emitido por una CA (autoridad certificadora). La comunicación interna entre los servicios del sistema (N8N, backend, PostgreSQL) se realiza sobre la red aislada de Docker, que constituye el perímetro de confianza. Todas las interfaces entre capas utilizan el estilo arquitectónico REST con cuerpos JSON para el intercambio estructurado de datos (Fielding & Taylor, 2002). Esta separación de responsabilidades facilita el reemplazo independiente de cualquier componente sin afectar a los demás.

La Tabla 4 sintetiza las cinco capas y sus responsabilidades específicas, y las Figuras 9 y 10 (Anexo A) detallan la organización en capas del módulo de procesamiento.

La trazabilidad operativa se garantiza mediante registros estructurados en cada capa, accesibles desde la capa de orquestación. La Figura 1 representa esquemáticamente el flujo de información entre capas. El despliegue del entorno local —servicios, redes Docker (edge, data interna, automation y host_access), volúmenes y servicios externos— se detalla en la Figura 2, y el flujo extremo a extremo de un incidente, desde el canal de entrada hasta la confirmación o la derivación a revisión, en las Figuras 7 y 8 (Anexo A).

5.2. Capa de canales de entrada

La capa de canales de entrada habilita tres vías paralelas a través de las cuales un usuario puede reportar un incidente. La primera es el correo electrónico, monitoreado mediante

Tabla 4. Capas funcionales de la arquitectura del sistema

Capa	Componentes y responsabilidades
1. Canales de entrada	Casilla de correo electrónico monitoreada mediante IMAP/SMTP, formulario web implementado como SPA React y número virtual de Twilio cuya grabación se transcribe en el backend con la Gemini API.
2. Orquestación	Motor N8N 2.11.2 desplegado en contenedor Docker autoalojado. Normaliza la entrada y coordina la invocación a las capas inferiores.
3. Procesamiento	Servicio Python sobre FastAPI 0.115 (configuración evaluada; Tabla 29) ejecutado bajo Uvicorn. Aplica clasificador híbrido en dos etapas (reglas + LLM) y expone una API REST documentada con OpenAPI 3.1.
4. Inferencia	Modelo Gemini 3.6 Flash de Google, invocado únicamente cuando el filtro determinístico previo no resuelve el caso (Subsección 5.5).
5. Persistencia	PostgreSQL 15.5 desplegado en contenedor con volumen persistente y respaldos diarios. Almacena los incidentes y la trazabilidad de cada decisión del clasificador.

Fuente: elaboración propia.

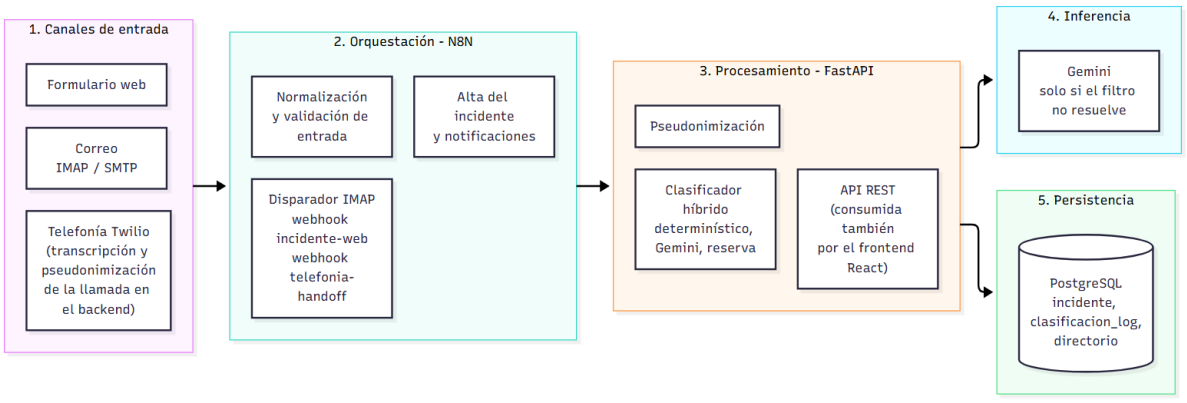


Figura 1. Diagrama de arquitectura del sistema: cinco capas y tres canales de entrada (correo, formulario web y telefonía), en la configuración entregada (release `v1.3.0`). Fuente versionada: `docs/diagrams/arquitectura_sistema.md` (Anexo A).

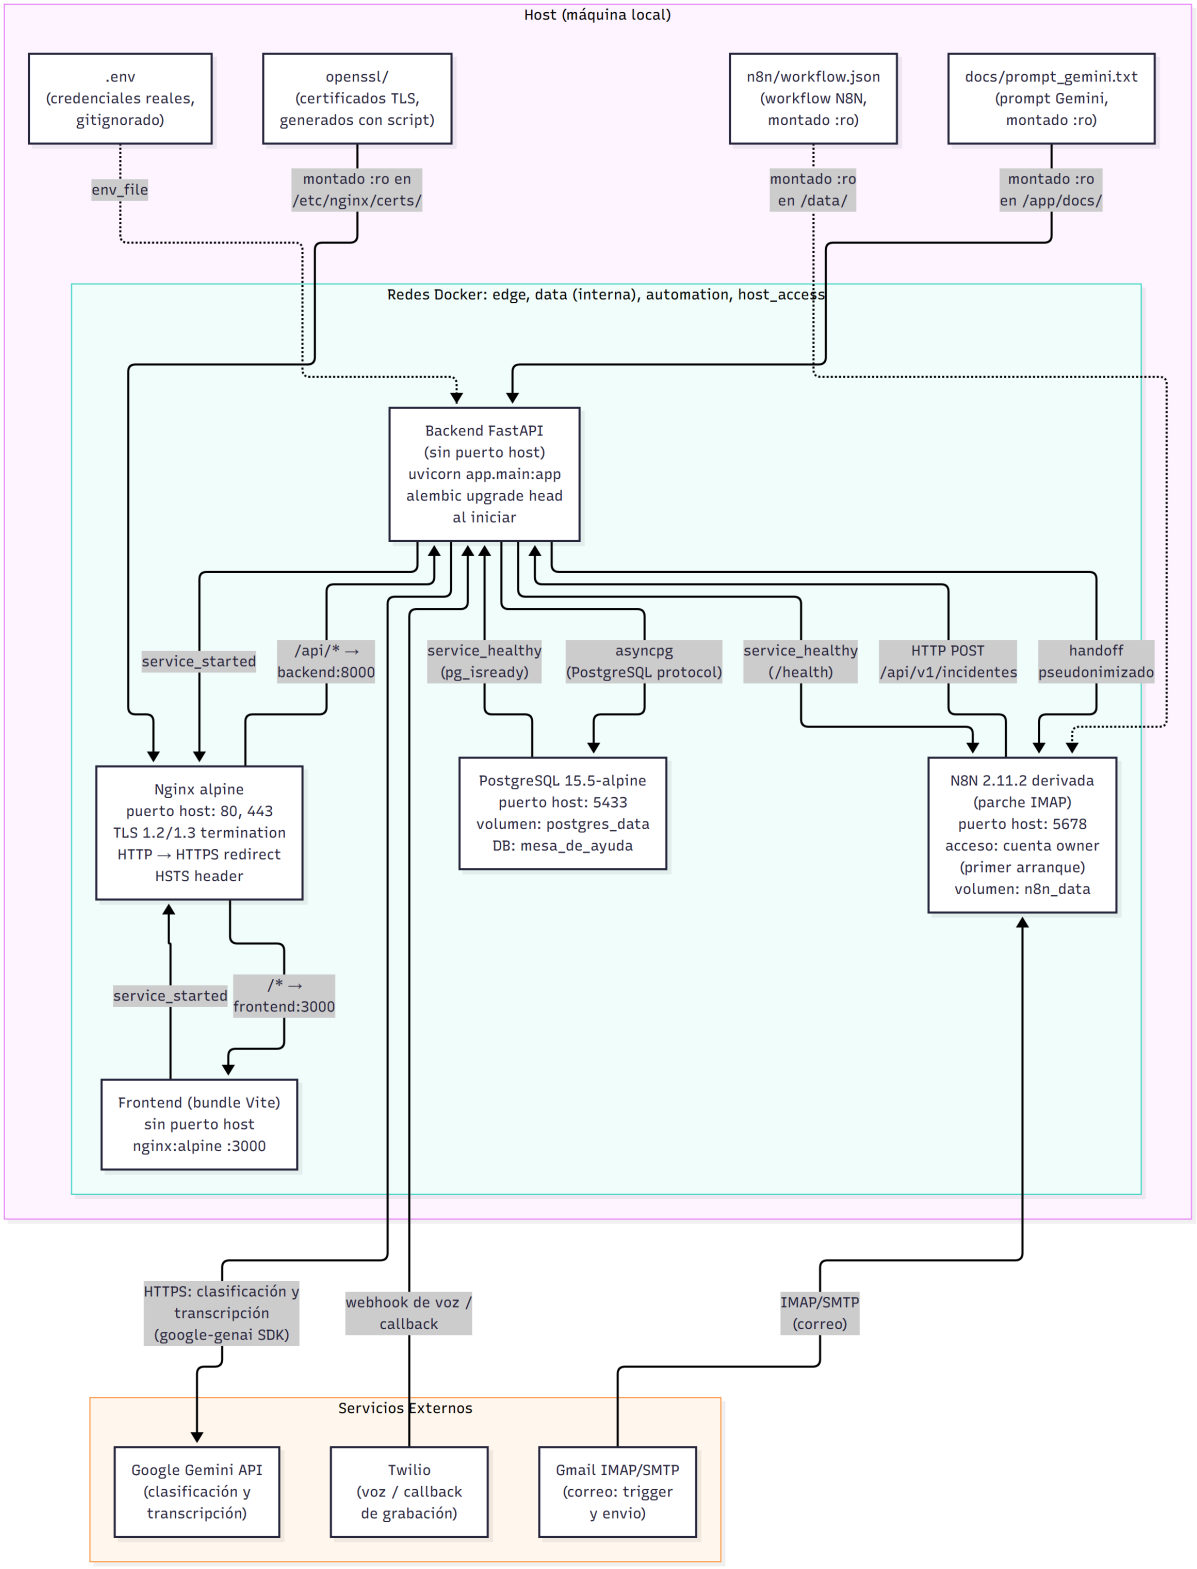


Figura 2. Diagrama de despliegue del entorno local. Servicios, redes Docker (edge, data interna, automation y host_access), volúmenes y servicios externos.

IMAP/SMTP que detecta nuevos mensajes en una casilla institucional dedicada. La segunda vía es un formulario web implementado como aplicación React de página única (SPA) que se comunica directamente con la API REST del módulo de procesamiento. La autenticación se realiza mediante tokens JWT (JSON Web Tokens) con usuario y contraseña; la autenticación única corporativa (SSO) se prevé como evolución para entornos productivos (Sección 11). La tercera vía es la llamada telefónica, en la cual el usuario marca un número virtual provisto por Twilio, recibe instrucciones por voz pregrabadas y deja su solicitud; Twilio graba la llamada y notifica la grabación al backend, que la transcribe con la Gemini API y la entrega al flujo N8N. El script TwiML que define el flujo de la llamada —incluyendo el mensaje de bienvenida en español rioplatense y la configuración de grabación— se implementa en el módulo de backend del proyecto (`app/cost_guard/twiml.py`), versionado en el repositorio. Esta diversidad de canales amplía la accesibilidad del sistema y reduce las barreras al reporte oportuno.

5.3. Capa de orquestación

N8N actúa como orquestador principal del flujo de trabajo: recibe la entrada de cada canal, la normaliza en una estructura unificada y coordina la clasificación y la persistencia del incidente. La descripción operativa detallada del flujo —los disparadores por canal, la estructura normalizada con identificador único (UUID v4), la invocación al módulo Python y la persistencia del ticket— se desarrolla en la Subsección 6.3. Los registros de cada ejecución se conservan durante 30 días para fines de auditoría y diagnóstico operativo; constituyen un conjunto de datos distinto de los incidentes, cuya retención se rige por la política declarada en la Subsección 7.2.

5.4. Capa de procesamiento

El módulo de procesamiento se implementó como un servicio web ligero utilizando el marco FastAPI 0.115, expuesto sobre un servidor ASGI Uvicorn 0.30.6 (versiones de la configuración evaluada; Anexo B, Tabla 29) (Ramírez, 2024). La elección de FastAPI obedece a su soporte nativo de validación de esquemas mediante Pydantic, su rendimiento competitivo y su documentación automática conforme a la especificación OpenAPI 3.1.

Las dependencias del módulo se organizan por capas funcionales claramente delimitadas. La capa de acceso a datos utiliza SQLAlchemy 2.0 como mapeador objeto-relacional (ORM) y asyncpg como driver asincrónico para PostgreSQL, en coherencia con la operación no bloqueante de FastAPI. La capa de procesamiento textual emplea las bibliotecas regex

y unicodedata de la biblioteca estándar de Python para normalización ortográfica y eliminación de signos diacríticos. La capa de inferencia se comunica con la interfaz oficial del modelo `gemini-3.6-flash` mediante el cliente google-genai >=2.20.0 de la configuración evaluada (SDK unificado de Google Generative AI), con los siguientes parámetros de configuración: temperatura $= 0{,}3$, top_p $= 0{,}9$, max_tokens $= 100$ y timeout $= 30$ s por intento del backend al modelo, con un presupuesto total de 60 s por clasificación. Estos valores corresponden a la configuración adoptada para el despliegue y no a un procedimiento de optimización documentado; su calibración sistemática frente a valores alternativos se plantea como trabajo futuro (Sección 11). Las bibliotecas NumPy 2.1 y Pandas 2.2 se utilizan exclusivamente para la generación de reportes agregados de desempeño y no participan del flujo de procesamiento individual de incidentes.

5.5. Subsistema de clasificación híbrido

El subsistema de clasificación adopta un enfoque híbrido en dos etapas, característica que lo diferencia de aproximaciones puramente basadas en modelo externo. La primera etapa aplica un filtro determinístico basado en expresiones regulares y diccionarios de términos del dominio. La procedencia de los datos empleados para construir el filtro determinístico, redactar las reglas de frontera del prompt y fijar el punto de operación se declara en la Subsección 9.1. La especificación detallada del prompt y de los parámetros de configuración del modelo se documenta en el Anexo H.

Este filtro resuelve de inmediato los incidentes con marcadores léxicos inequívocos y emite dos magnitudes en $[0; 1]$ que no son probabilidades de acierto. La primera es la *confianza*, índice de fuerza de señal —margen del sector ganador sobre el segundo, ponderado por la cantidad de patrones coincidentes— que vale 0 con menos de dos patrones. La segunda es el *puntaje de correctitud* (`score_correctitud`), que ordena la correctitud esperada. El filtro decide sin consultar al modelo (cortocircuito) cuando la señal es dominante —sin empate ni ausencia de coincidencias— y el puntaje alcanza el punto de operación 0,5166; la confianza no interviene y esos casos no se derivan a revisión por su confianza. El punto se derivó por validación cruzada de cinco pliegues sobre el corpus, maximizando la cobertura sin que la precisión del filtro fuera inferior a la del modelo sobre el conjunto que resuelve (0,7385 frente a 0,6769 sobre los 130 casos con predicción de ambas etapas, ambas estimadas dentro de la muestra; Subsección 8.5). Equivale a resolver los 131 casos con señal dominante.

La segunda etapa, activada únicamente cuando el filtro determinístico no resuelve el caso, consulta al modelo Gemini 3.6 Flash. El prompt estructurado en español incluye una breve descripción de cada categoría, un único ejemplo representativo por sector y la solicitud explícita de devolver la categoría asignada y un valor numérico de confianza entre 0 y 1 en formato JSON estricto. El diseño compositivo reserva la capacidad semántica del modelo para los casos que el filtro no resuelve; en el contraste medido, el híbrido usó cerca de un tercio de las llamadas y del costo estimado de inferencia frente al esquema solo de modelo, con la latencia medida del lado del cliente solo como cota inferior (Tabla 24). El pipeline completo comprende tres etapas, aplicadas en orden: (1) el filtro determinístico, (2) el modelo Gemini y (3) una etapa de reserva (*fallback*) que, cuando el modelo no responde o no produce una salida válida, fija la confianza en 0,0 y marca siempre el caso para revisión humana. La regla `requiere_revision_humana = (confianza <0,70)` se evalúa solo sobre la salida de la etapa Gemini; la etapa de reserva deriva siempre a revisión, con confianza 0,0, y la etapa determinística no deriva por su confianza. Desde el 13 de octubre de 2026, posterior a la campaña 2026-10, el backend deriva además a revisión el incidente cuyo reportante no se identifica en el directorio de empleados, condición independiente de la clasificación. El desglose de casos resueltos por cada etapa del pipeline sobre el corpus de validación se reporta en la Sección 8.

El camino de clasificación es único para los tres canales de entrada. Tanto el correo electrónico y el formulario web como la llamada telefónica resuelven su sector mediante esta misma cascada híbrida, aplicada sobre la descripción pseudonimizada del incidente: ningún canal aporta una clasificación precalculada que omita la cascada, por lo que las reglas determinísticas, el prompt y las reglas de frontera se ajustan una sola vez para todo el sistema. El prompt único incorpora reglas de desambiguación de frontera entre sectores adyacentes (acceder o iniciar sesión en una aplicación se orienta a Soporte Técnico Software; la digitalización, el escáner o la impresora se orientan a Soporte Técnico Hardware; el servidor, la red, SMTP o una VM se orientan a Sistemas). Desde el punto de vista del costo, la clasificación telefónica dejó de computarse sobre una invocación incondicional al modelo externo: el canal atraviesa el filtro determinístico y solo escala al modelo semántico cuando la cascada lo requiere.

5.6. Modelo de datos

La persistencia se realiza sobre PostgreSQL 15.5, desplegado en contenedor Docker bajo configuración de respaldo diario y replicación física opcional para entornos productivos (The PostgreSQL Global Development Group, 2024). El modelo de datos se organiza alrededor de siete entidades principales, descritas en la Tabla 5 y en el diagrama entidad-relación de la Figura 3.

Tabla 5. Entidades principales del modelo de datos de la configuración entregada (release `v1.3.0`); el atributo `reportante_empleado_id`, el cuarto rol del directorio y el cifrado del contacto son posteriores a la campaña 2026-10.

Tabla	Atributos clave	Descripción
`incidente`	id (PK), descripcion_original (cifrada), descripcion_pseudonimizada, prioridad, sector_id (FK), estado_id (FK), canal_origen_id (FK), reportante_empleado_id (FK), requiere_revision_humana	Tabla central: descripción original cifrada en reposo y descripción pseudonimizada, prioridad, sector asignado, estado actual, canal de origen, reportante resuelto en el directorio e indicador de revisión humana.
`sector`	id (PK), nombre	Catálogo de los cinco sectores canónicos: `Seguridad Informatica`, `Soporte Tecnico Hardware`, `Soporte Tecnico Software`, `Bases de Datos` y `Sistemas`.
`estado`	id (PK), nombre, es_terminal	Catálogo de estados: nuevo, en proceso, en espera, resuelto y cerrado.
`canal_origen`	id (PK), nombre	Catálogo de canales: correo, formulario web y llamada telefónica.
`clasificacion_log`	id (PK), incidente_id (FK), sector_id_predicho (FK), sector_id_validado (FK), confianza, etapa, requiere_revision_humana	Registro de cada decisión del clasificador, con el sector predicho, la confianza asociada, la etapa que resolvió, el indicador de revisión y el sector validado por el sector responsable.
`users`	id (PK), username (UNIQUE), hashed_password, is_active	Almacena credenciales de operadores para autenticación JWT.
`directorio_empleado`	id (PK), legajo (UNIQUE), nombre, email y telefono (cifrados), email_bidx (UNIQUE), telefono_bidx, sector_id (FK), rol, activo, fecha_baja, user_id (FK)	Directorio institucional de empleados para resolución de contacto y notificación. El correo y el teléfono se cifran en reposo con Fernet y se buscan mediante un índice ciego (HMAC-SHA-256); el campo `rol` admite cuatro valores: usuario final, mesa de ayuda, administrador del directorio y gestión de incidentes. La columna `fecha_baja` registra la desactivación y sostiene la retención (relación laboral activa más un año).

Fuente: elaboración propia a partir de `App/Backend/app/models/`.

El canal de origen constituye una entrada opcional del backend: el esquema de creación de incidentes acepta `canal_origen_id` como campo anulable, por lo que un incidente puede registrarse sin canal conocido. La entidad central `incidente` referencia mediante claves foráneas a los catálogos de sector, estado y canal de origen, y mantiene una relación uno a muchos con `clasificacion_log` para preservar la trazabilidad histórica de las decisiones del clasificador. El número de incidente que se comunica al usuario corresponde al identificador

único del registro, formateado para su legibilidad; la incorporación de un prefijo configurable se prevé como evolución futura (Sección 11). El esquema completo, incluyendo restricciones de integridad referencial e índices secundarios, se documenta en el Anexo C. El directorio de empleados (`directorio_empleado`) se vincula opcionalmente con la tabla de autenticación mediante `user_id` y referencia el catálogo de sectores mediante `sector_id`; su campo `rol` distingue al usuario final, a la mesa de ayuda, al administrador del directorio y a la gestión de incidentes (cuatro valores; Tabla 5).

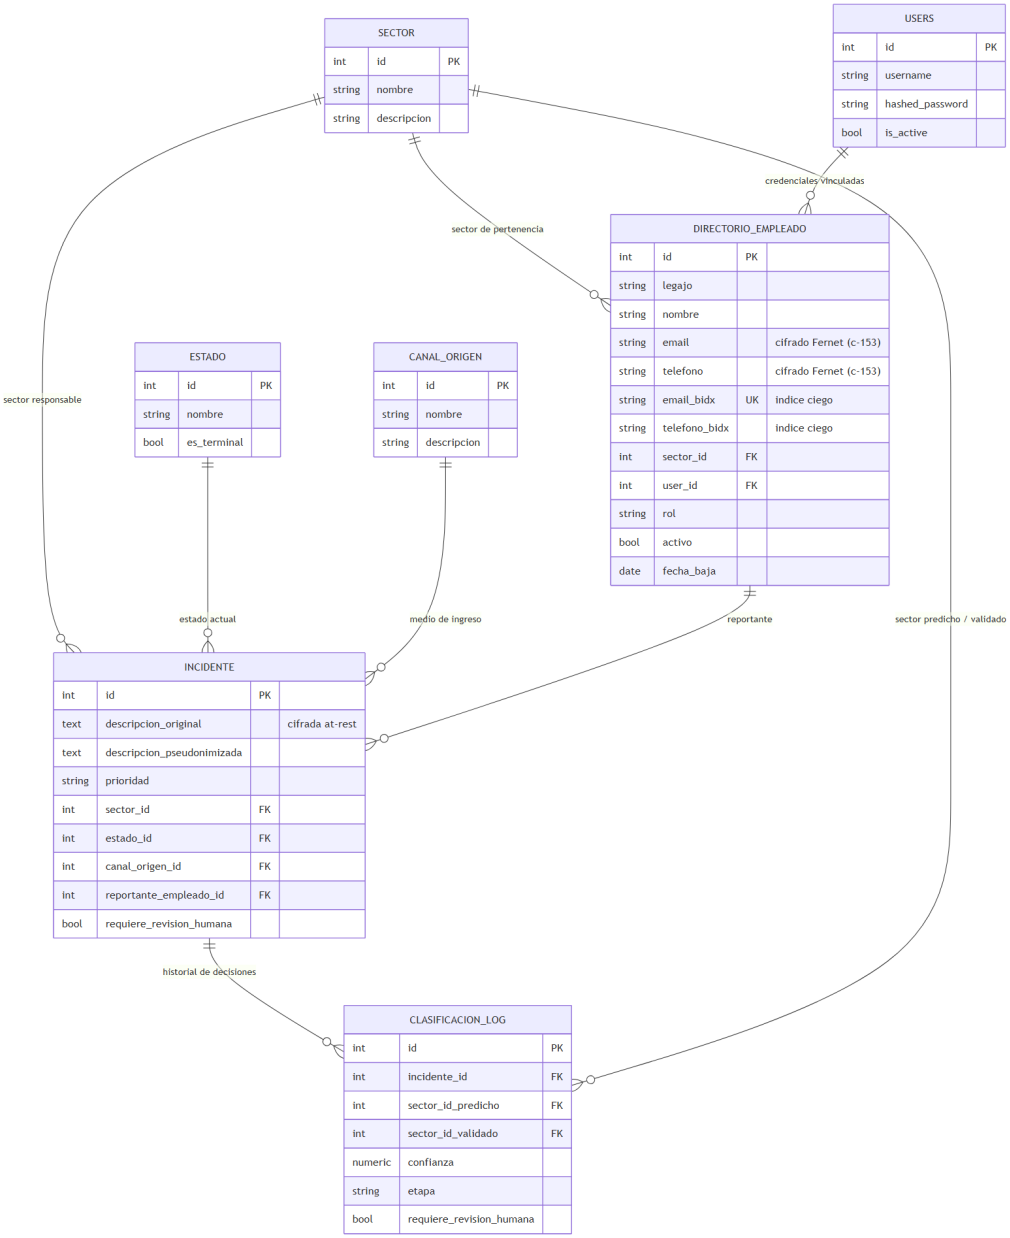


Figura 3. Diagrama entidad-relación de las siete entidades principales del modelo de datos de la configuración entregada (release `v1.3.0`; esquema completo en el Anexo C).

5.7. Contrato de la interfaz REST

La interfaz de programación de aplicaciones expuesta por el módulo Python sigue el estilo arquitectónico REST (Fielding & Taylor, 2002), con representación de recursos mediante identificadores uniformes, uso semántico de los métodos HTTP estándar y comunicación sin estado del lado del servidor. La autenticación se realiza mediante tokens JWT (JSON Web Tokens) firmados con HS256 (HMAC-SHA-256), validados en cada solicitud mediante el esquema OAuth2PasswordBearer de FastAPI. La Tabla 6 sintetiza los principales puntos de entrada.

Tabla 6. Puntos de entrada principales de la interfaz REST

Método	Ruta	Código	Función
Autenticación			
POST	`/api/v1/auth/login`, `/refresh`, `/logout`	200 OK	Inicio y renovación de sesión y cierre de sesión de operadores.
GET	`/api/v1/auth/me`	200 OK	Recupera el perfil del operador autenticado.
Incidentes			
POST	`/api/v1/incidentes`	201 Created	Crea un nuevo ticket y devuelve el identificador generado.
GET	`/api/v1/incidentes/{id}`	200 OK	Recupera la información de un ticket por su identificador.
PATCH	`/api/v1/incidentes/{id}`	200 OK	Actualiza los campos editables de un ticket.
Clasificaciones			
GET	`/api/v1/clasificaciones/incidente/{id}`	200 OK	Recupera la trazabilidad de la clasificación de un incidente.
GET	`/api/v1/clasificaciones/revision-pendiente`	200 OK	Lista los casos derivados a revisión humana.
PATCH	`/api/v1/clasificaciones/{log_id}/validar`	200 OK	Registra la categoría validada por el sector responsable.
Estadísticas			
GET	`/api/v1/estadisticas/resumen`, `/tendencias`	200 OK	Agregados y series temporales para el dashboard.
Salud			
GET	`/health` y `/health/db`	200 OK	Verificación de salud del servicio para monitoreo externo.

Fuente: elaboración propia.

Los códigos de estado HTTP se utilizan conforme a su semántica original: 201 cuando un recurso se crea exitosamente, 200 cuando una consulta se atiende con éxito, 400 cuando los datos de entrada no validan el esquema esperado, 401 cuando la autenticación falla, y 500 cuando ocurre un error interno no recuperable. La Tabla 6 no es exhaustiva: reúne los grupos principales de puntos de entrada, mientras que el contrato completo de la interfaz —

que comprende la totalidad de las rutas expuestas— se documenta en el Anexo D y se versiona en `docs/openapi.json`; la especificación OpenAPI 3.1 la genera FastAPI automáticamente.

6. Implementación

6.1. Entorno de despliegue y dependencias

La implementación del sistema se llevó a cabo combinando componentes de código abierto —Python, FastAPI y PostgreSQL— con N8N, cuya licencia Sustainable Use (*fair-code*) permite auditar su código fuente, con el objetivo de garantizar la portabilidad, la reproducibilidad y la auditoría de seguridad de la solución en organizaciones medianas. Toda la infraestructura se encapsula mediante contenedores Docker, orquestados localmente por Docker Compose (Docker, 2026) para los entornos de desarrollo y preproducción; la migración a un cluster Kubernetes 1.30 para el entorno productivo se plantea como trabajo futuro y no cuenta con manifiestos de despliegue en esta versión (Sección 11).

Las versiones específicas de los componentes de la configuración evaluada (commit `bf5e099`) son: N8N 2.11.2, Python 3.12, PostgreSQL 15.5 con volumen persistente, FastAPI 0.115, Uvicorn 0.30.6, SQLAlchemy 2.0, y el cliente google-genai >=2.20.0 (SDK unificado de Google Generative AI) para la comunicación con el modelo `gemini-3.6-flash`. Todos los servicios se despliegan sobre imágenes Docker oficiales (`python:3.12-slim` y `postgres:15.5-alpine`). La gestión de dependencias del módulo Python se realiza mediante un archivo `requirements.txt` con versiones fijadas (*pinned*) para garantizar la reproducibilidad de las compilaciones en distintos entornos. La configuración entregada (`v1.3.0`) actualiza las del *backend* y el *frontend* y sustituye la imagen oficial de N8N por una imagen derivada de `n8nio/n8n:2.11.2` con un parche de la decodificación IMAP (Tabla 29).

6.2. Construcción del módulo Python

La selección del marco de trabajo para el servicio de procesamiento implicó la evaluación de tres alternativas: Flask, Django REST Framework y FastAPI. Flask, ampliamente adoptado por su simplicidad, carece de validación nativa de esquemas y de generación automática de documentación OpenAPI. Django REST Framework ofrece un conjunto completo de herramientas, pero su modelo sincrónico y componentes no requeridos —el ORM de Django y el motor de plantillas— incrementaban la complejidad sin aportar beneficios a un microservicio acotado. FastAPI, sustentado sobre el servidor ASGI Uvicorn, resolvió esas carencias con validación automática de esquemas mediante Pydantic v2, documentación interactiva conforme a OpenAPI 3.1 y operación asincrónica nativa ante las llamadas concurrentes desde N8N (Ramírez, 2024).

El módulo Python expone su contrato REST organizado en capas, según la estructura descrita en la Sección 5, con una separación clara entre responsabilidades:

- **models**: entidades del modelo de dominio mapeadas mediante SQLAlchemy 2.0.
- **schemas**: modelos de validación y serialización con Pydantic v2.
- **services**: lógica de aplicación (IncidenteService, ClasificacionService).
- **repositories**: acceso a datos, aislando las consultas SQL del resto de la aplicación.
- **classifiers**: lógica del clasificador híbrido (filtro determinístico + LLM).
- **routes**: enrutadores REST que delegan en los servicios correspondientes.
- **core**: configuración de base de datos, manejo de errores y logging estructurado.

La construcción se realiza bajo un esquema de inyección de dependencias gestionado por las funcionalidades nativas de FastAPI (`Depends`), lo que facilita el reemplazo de implementaciones durante la ejecución de pruebas unitarias y de integración. Esta arquitectura permite, por ejemplo, sustituir el clasificador real por una implementación simulada durante las pruebas sin modificar el código de los servicios que lo consumen. La gestión de credenciales se realiza exclusivamente mediante variables de entorno, en línea con el principio de configuración de la metodología Twelve-Factor App (Wiggins, 2017).

6.3. Construcción del flujo en N8N

El flujo de orquestación implementado en N8N comprende 32 nodos (29 operativos más 3 notas adhesivas), organizados en siete etapas funcionales con ramificaciones específicas por canal. La elección de N8N frente a Apache Airflow, Zapier o Make obedeció a tres criterios. El primero: N8N admite despliegue autoalojado bajo Docker, que mantiene el procesamiento y los datos dentro del perímetro organizacional, mientras que Zapier y Make operan solo como servicios en la nube. El segundo: su editor visual de nodos arrastrables reduce la curva de aprendizaje frente a las alternativas de definición programática, lo que permitió concentrar el esfuerzo en la lógica de negocio. El tercero: la licencia de código fuente (*fair-code*) habilita la auditoría de seguridad del núcleo de orquestación (n8n GmbH, 2024). Apache Airflow, aunque autoalojable, diseña sus flujos como grafos programados por intervalos temporales, un paradigma inadecuado para un sistema reactivo a eventos no programados (Apache Software Foundation, 2024).

La composición de los 29 nodos responde a un patrón de procesamiento por canal, de cinco pasos, que se replica para cada medio de ingreso con ramificaciones específicas según

el canal:

1. **Recepción**: Tres disparadores de canal (*triggers*) reciben las entradas desde correo electrónico (IMAP), formulario web (Webhook) y telefonía (el backend entrega la transcripción al webhook `telefonia-handoff`); separarlos por canal, en lugar de un único webhook con discriminación interna, preserva la configuración de autenticación y los parámetros de reintento de cada protocolo.
2. **Normalización**: Un nodo de transformación (*Function*) homogeniza el mensaje en un formato unificado (Hohpe & Woolf, 2004) con identificador único (UUID v4), marca temporal, canal de origen, remitente y descripción normalizada; esta etapa garantiza que las capas posteriores procesen la misma estructura, sea cual sea la vía de entrada.
3. **Clasificación y persistencia**: Un nodo HTTP invoca el endpoint `POST/api/v1/incidentes` del módulo Python con la descripción textual y los metadatos del canal. La clasificación se embebe en la creación del incidente: el clasificador híbrido se invoca internamente, la creación persiste el ticket en la misma operación y la respuesta incluye el identificador del ticket, la categoría asignada y el indicador de revisión humana (`requiere_revision_humana`), que el backend activa según las condiciones de la etapa de evaluación. El canal telefónico no es una excepción: su clasificación se resuelve en el backend con la misma cascada híbrida sobre la descripción pseudonimizada, y el cuerpo de la creación no transporta una clasificación precalculada.
4. **Evaluación**: Aguas abajo del POST, un nodo condicional (*IF*) evalúa el indicador de revisión humana: si está activo, notifica al operador designado por correo electrónico y registra el evento en la auditoría; si no, continúa con las confirmaciones al usuario. Antes del POST, un nodo de validación verifica que la descripción no esté vacía y respete la longitud aceptada, por lo que una entrada inválida no genera un incidente. El backend activa el indicador cuando la etapa Gemini devuelve una confianza inferior a 0,70, cuando interviene la etapa de reserva o cuando el reportante no se identifica en el directorio de empleados (este último, posterior a la campaña 2026-10; Tabla 29); los casos del filtro determinístico no se derivan por su confianza (Subsección 5.5). La calibración de la confianza se analiza en la Sección 8.4.
5. **Notificación**: Tres nodos posteriores notifican al usuario por el canal correspondien-

te y registran la ejecución en auditoría; la persistencia ocurre en el mismo POST de creación. La notificación es paralela, por lo que la demora de un canal (por ejemplo, el correo) no bloquea el registro de auditoría ni la confirmación por otros medios.

El canal telefónico incorpora un nodo adicional de normalización y validación que prepara la transcripción pseudonimizada antes de incorporarla al flujo principal, pero no determina el sector persistido. La clasificación telefónica se resuelve con la misma cascada híbrida del backend que la del correo electrónico; la configuración con que se procesó cada corrida, incluido el agente LLM de N8N empleado en parte de la corrida telefónica, se declara en la Subsección 4.5 y en la Tabla 29. La clasificación del incidente telefónico se rige por el diseño unificado descrito en la Subsección 5.5.

La trazabilidad completa de cada ejecución se preserva almacenando los identificadores de nodo, las marcas temporales de entrada y salida de cada etapa, y los datos de entrada y salida de cada paso del flujo. Ese historial auditable facilita el cumplimiento del deber de calidad de los datos del artículo 9 de la Ley 25.326 (Sección 7), sin que la ley exija literalmente esa forma de registro. La exportación completa del flujo en formato JSON se incluye en el Anexo E.

6.4. Integración del canal telefónico

La integración con Twilio se realizó mediante el producto Programmable Voice (Twilio, 2026), que aporta la grabación de la llamada. El flujo telefónico opera de la siguiente manera. El usuario marca un número virtual asignado a la organización; un script TwiML reproduce un mensaje de bienvenida en español rioplatense y solicita al usuario describir su problema durante un máximo de 45 segundos; la grabación finaliza cuando el usuario presiona la tecla numeral (`#`) o transcurrido el tiempo máximo. Twilio notifica la grabación al backend mediante un *callback*; el backend descarga el audio, lo transcribe con la Gemini API (`gemini-3.5-transcribe`) (Google, 2026a), pseudonimiza el texto y lo entrega a N8N mediante un webhook. A partir de ese punto, el flujo continúa de manera idéntica a la de los canales escritos.

El tiempo de registro del canal telefónico —calculado, para igualar la base de comparación con el flujo manual, como la suma de la duración de la llamada grabada y la latencia de procesamiento desde el cuelgue hasta la persistencia del incidente (recálculo del 19-10-2026; Subsección 4.5)— promedió 20,1 segundos sobre los 81 casos del corpus. El corpus registra la suma de ambos tramos, no su descomposición por etapa (transcripción, clasificación y

persistencia), por lo que no se publica un desglose de latencias que el repositorio no permite reproducir con tamaño de muestra y procedimiento de medición. La grabación está acotada a un máximo de 45 s, por lo que el tiempo telefónico reportado constituye una cota inferior de la duración real de la llamada.

Unificada la clasificación, la invocación incondicional del agente de N8N dejó de reservar superficie de costo: la clasificación se computa ahora en el backend y solo escala al modelo semántico cuando la cascada híbrida lo requiere (Subsección 5.5).

6.5. Desafíos de integración

La implementación del sistema enfrentó tres desafíos de integración que merecen documentación explícita.

El primer desafío se presentó en la comunicación asincrónica entre N8N y el servicio de clasificación. El nodo HTTP de N8N invoca el endpoint de clasificación de manera sincrónica y espera la respuesta del servidor antes de continuar el flujo. Esta arquitectura, aunque simple de implementar, introduce un punto de fallo único: si el servicio Python no responde, el flujo completo se detiene y el incidente queda sin procesar. Para acotar esa exposición, la configuración entregada —no la evaluada; Tabla 29— declara en el tramo de alta una política de reintento acotada sobre sus dos nodos HTTP. Hasta tres intentos con una espera fija de cinco segundos y un tiempo de espera por intento de diez segundos en el inicio de sesión del operador y de setenta y cinco segundos en la creación del incidente. Así, el peor caso del tramo queda por debajo del tope de ejecución configurado para la plataforma. La espera es fija y no un retroceso exponencial, y el reintento es idempotente: la clave de deduplicación se calcula una sola vez por ejecución, por lo que un reenvío no duplica el incidente. Agotados los intentos, la ejecución se desvía hacia la rama de error del flujo. La invocación de alta sigue siendo sincrónica y la cola de respaldo en el servicio Python, que retendría los mensajes durante ventanas de saturación, queda como trabajo futuro (Subsección 11.9).

El segundo desafío surgió de la heterogeneidad de los formatos de entrada. Los correos electrónicos incluyen encabezados, firmas corporativas y reenvíos que contaminan el texto que el clasificador recibe; las llamadas telefónicas transcritas introducen errores de reconocimiento del habla, particularmente en términos técnicos (por ejemplo, `API` transcrito como `a p i` o `apeye`). Los formularios web, aunque proveen texto limpio, llegan con una proporción significativa de campos vacíos o con descripciones de una sola palabra. La respuesta

a esta heterogeneidad fue doble. Por un lado, se implementó un preprocesador en el nodo de normalización de N8N que elimina firmas, encabezados de reenvío y líneas de disclaimer mediante expresiones regulares específicas del dominio de correo institucional. Por el otro, se enriqueció el prompt enviado al clasificador con instrucciones explícitas para interpretar términos técnicos frecuentemente mal transcritos, lo que mejoró la robustez de la clasificación sobre transcripciones automáticas respecto de la configuración inicial sin estas instrucciones.

El tercer desafío, de naturaleza operativa, se vincula con la persistencia transaccional de la sesión de clasificación. El sistema debe garantizar que una vez que el clasificador asigna una categoría, el incidente se persiste con esa decisión o, en caso de falla de la base de datos, el estado interno del sistema refleje la inconsistencia y pueda recuperarse. La solución adoptó un enfoque pragmático: N8N invoca la creación del incidente —que clasifica y persiste en una sola operación del backend— como paso único del flujo. El nodo HTTP de creación declara un enrutamiento de error (`continueErrorOutput`) que opera una vez agotados los reintentos descritos en el primer desafío: si la persistencia falla tras los intentos, la ejecución se desvía hacia la rama de error del flujo en lugar de continuar. La recuperación del incidente exige una reejecución manual del flujo o el reproceso del mensaje de origen; esa recuperación es segura porque el alta es idempotente, por lo que un reenvío no duplica el incidente ni vuelve a clasificarlo. La tabla de trazabilidad (`clasificacion_log`) conserva un registro por clasificación ejecutada: un replay no agrega registros, y cada replay deja un evento estructurado con el identificador de origen y el del incidente, sin datos personales.

6.6. Conexión con el proceso Scrumban

La construcción del sistema fue organizada bajo el esquema Scrumban descrito en la Sección 4, ejecutando iteraciones de duración variable, ubicadas sin fechar por separado en los dos períodos de actividad del repositorio (Figura 11, Anexo A). La vinculación entre cada etapa de construcción y los artefactos de implementación producidos se detalla a continuación:

Etapa 1: La elicitación de requisitos produjo el diseño preliminar de la arquitectura de cinco capas y la especificación de la interfaz REST, documentadas en la Sección 5.

Etapa 2: La construcción del módulo Python entregó el modelo de datos, los repositorios con operaciones CRUD asincrónicas y los servicios de negocio; al cierre de la etapa exponía el endpoint de salud y aceptaba la creación de incidentes

mediante `POST/api/v1/incidentes`, con la cobertura unitaria medida por pytest-cov sobre rutas, servicios y repositorios (Subsección 6.7).

Etapa 3: La configuración inicial del flujo N8N implementó el canal de correo electrónico como vía prioritaria y fijó el patrón de procesamiento por canal que luego se replicaría; al finalizar la etapa, el sistema procesaba incidentes por correo de extremo a extremo, de la recepción a la notificación.

Etapa 4: La integración del canal telefónico y la persistencia incorporó Twilio Programmable Voice, el script TwiML y el callback de grabación y transcripción en el backend; fue la etapa que más expuso los desafíos de heterogeneidad de formatos (Subsección 6.5) y su resolución consumió cerca del 40 % del esfuerzo de la etapa.

Etapa 5: La validación funcional y el ajuste fino del clasificador se concentraron en la calibración del filtro determinístico y del prompt de Gemini, a partir de los errores observados en el corpus de validación; no se dispuso de un conjunto independiente de preproducción (Subsección 9.1).

Etapa 6: La validación experimental y la documentación final ejecutaron el protocolo de pruebas descrito en la Sección 4, recolectaron las mediciones del corpus completo y produjeron el análisis estadístico presentado en la Sección 8.

La campaña del flujo manual (junio a agosto de 2026) no es una etapa de construcción; la del flujo automatizado (septiembre a octubre de 2026) corresponde a la validación experimental, con `gemini-3.6-flash` integrado el 24 de septiembre de 2026.

La trazabilidad entre etapas y artefactos, mediada por el tablero Kanban en Jira, permitió identificar tempranamente los desvíos respecto del plan y redistribuir el esfuerzo ante imprevistos, y los límites de trabajo en curso evitaron la acumulación de tareas a medio terminar (Subsección 4.9).

6.7. Pruebas automatizadas

La estrategia de pruebas se sustentó en la pirámide clásica descrita por Crispin y Gregory (2009). En la base se ubicaron las pruebas unitarias del módulo Python construidas con el marco pytest (versiones en la Tabla 29). La cobertura de código de aplicación se mide con pytest-cov sobre los paquetes de rutas, servicios y repositorios, mediante el comando `pytest-m"notintegration"--cov=app.routes--cov=app.services--cov=a`

`pp.repositories--cov-report=term-missing`, cuyo reporte se genera en cada ejecución del pipeline de integración continua. La cobertura de sentencias de la suite unitaria sobre esos paquetes es del 90 % (2.503 sentencias, 242 sin cubrir), con 1.773 pruebas unitarias aprobadas. Se midió con el comando anterior en la corrida de integración continua sobre la rama principal del 11-11-2026 (commit `03d1612`, con código del *backend* idéntico al de la versión `v1.2.18`) y se reprodujo en forma local con el mismo total. Estas pruebas cubren los clasificadores (determinístico e híbrido), los servicios de negocio, los esquemas de validación y los repositorios de acceso a datos.

En el nivel intermedio se ejecutaron pruebas de integración en dos variantes complementarias. (a) Pruebas rápidas contra SQLite en memoria para la ejecución durante el desarrollo, utilizando el fixture `db_session` con rollback por test. (b) Pruebas de integración contra una instancia real de PostgreSQL 15.5, que validan comportamientos específicos del motor —integridad de claves foráneas, eliminación en cascada, restricciones UNIQUE, precisión de tipos `Numeric(5,4)` y zona horaria en `TIMESTAMPTZ`, índices compuestos y coexistencia de esquemas— mediante 61 pruebas marcadas como integración, que fallan de forma ruidosa si PostgreSQL no está disponible en lugar de omitirse. En el nivel superior, la configuración entregada —no la evaluada; Tabla 29— incorpora una prueba de humo de extremo a extremo que instancia N8N activo sobre una variante de costo cero del workflow versionado, sin los nodos que requieren credenciales de terceros. El recorrido envía un incidente por el webhook del canal web y verifica su persistencia, su canal de origen, que la clasificación se resuelve en la etapa determinística, la idempotencia del alta ante un reenvío y la recuperación ante una indisponibilidad transitoria del backend. La prueba excluye la etapa Gemini real, que la variante nunca invoca, y el canal telefónico, y se reejecuta sobre el commit etiquetado en cada release. La integración con la plataforma de orquestación se verifica además de forma estructural, mediante pruebas que parsean y validan el archivo `n8n/workflow.json` (composición de nodos, conexiones y límites de costo) y pruebas de API y de base de datos que ejercitan los endpoints y la persistencia del módulo Python.

El frontend se desarrolló como una aplicación React de página única (SPA; versión en la Tabla 29) con TypeScript y Vite como herramienta de construcción. La aplicación consta de dos vistas principales: un portal de reporte de incidentes con validación de formularios, y un panel de administración que incluye listado de tickets con filtros combinados, cola de revisión humana para los casos derivados por el backend, y visualización detallada de cada incidente

con trazabilidad completa de la decisión del clasificador. La comunicación con el backend se realiza mediante Axios, y la gestión del estado del servidor se apoya en React Query para caching y revalidación automática.

El frontend cuenta con una suite de pruebas automatizadas construida con Vitest y Testing Library, que alcanza una cobertura de sentencias del 99,6 % sobre los paquetes medidos, conforme al reporte reproducido con `npm run test:coverage`.

La integración continua (CI) se ejecuta automáticamente en cada solicitud de incorporación (*pull request*) al repositorio mediante GitHub Actions, ejecutando la suite completa de pruebas unitarias y de integración antes de permitir la fusión a la rama principal. El pipeline de CI incluye verificación de estilo de código (Ruff), ejecución de pruebas con reporte de cobertura, y verificación de sincronización de la especificación OpenAPI.

6.8. Dashboard de analítica

El panel de administración incluye un dashboard de analítica desarrollado con la biblioteca ReCharts de React. Este módulo proporciona visualización agregada de los datos históricos de incidentes, permitiendo identificar tendencias temporales, patrones de fallas recurrentes y desequilibrios en la distribución de carga entre sectores. Esta capacidad de análisis retrospectivo transforma los datos operativos acumulados en inteligencia organizacional accionable. La Figura 4 muestra el panel de administración sobre el que se integra esta capacidad analítica, con el listado de tickets, los filtros combinados y la pestaña de revisión humana, que lista los casos que el backend marcó con su indicador de revisión (Subsección 8.3).

El dashboard se organiza en tres visualizaciones principales. Un gráfico de tendencias muestra la evolución temporal de los incidentes, agrupables por día o por mes según la granularidad seleccionada por el operador. Un gráfico de torta presenta la distribución proporcional de incidentes entre los cinco sectores responsables. Un gráfico de barras apiladas desglosa los incidentes según su estado en el ciclo de vida, facilitando la identificación de cuellos de botella en la resolución. La Figura 5 presenta estas tres visualizaciones junto con los indicadores agregados del período seleccionado.

Los controles de filtro permiten acotar el período de análisis mediante un rango de fechas configurable, y alternar entre agrupación diaria y mensual para adaptar la granularidad al horizonte temporal de interés. Cada gráfico puede exportarse como imagen PNG para su inclusión en informes periódicos o presentaciones.

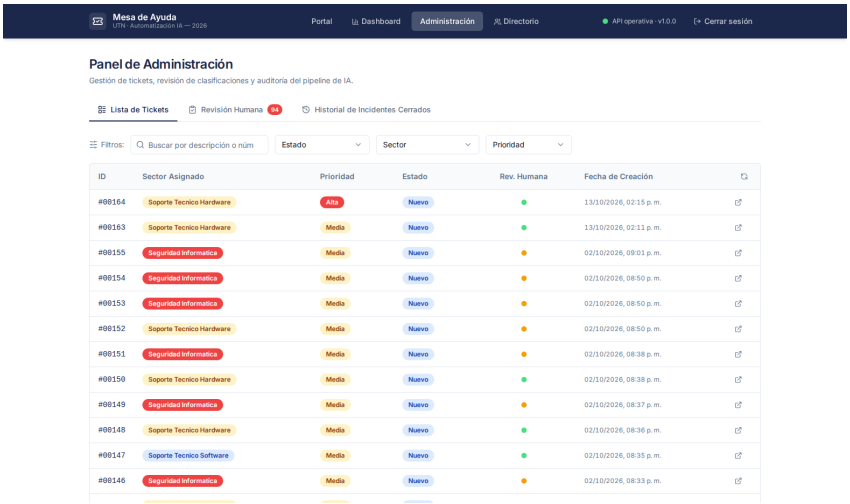


Figura 4. Panel de administración del sistema: listado de tickets con filtros combinados y cola de revisión humana. Captura del 21-10-2026 de una instancia local de desarrollo con rótulo v1.0.0: los tickets visibles son del 2 y del 13-10-2026 y la cola (94 casos) refleja el indicador `requiere_revision_humana` registrado por el backend en esa base, no la regla de confianza evaluada fuera de línea (Subsección 8.3).

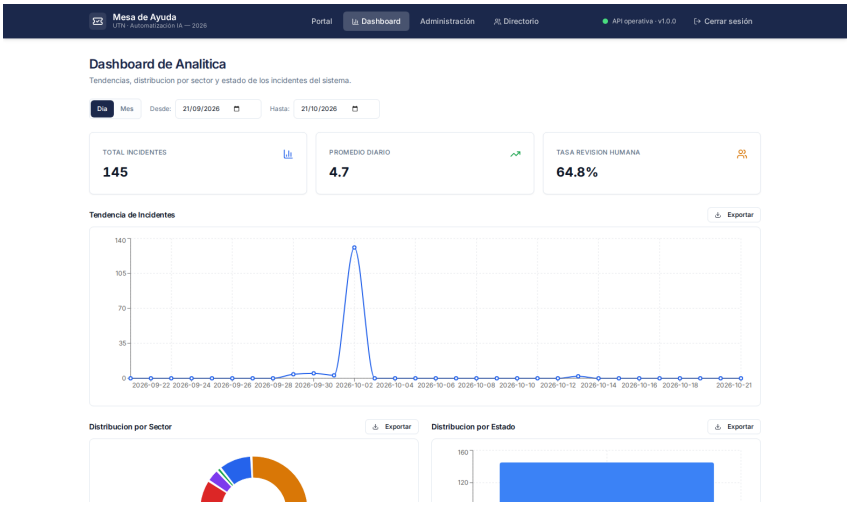


Figura 5. Dashboard de analítica del panel de administración: tendencia temporal de incidentes, distribución por sector y distribución por estado. Misma captura (21-10-2026, instancia local de desarrollo, rótulo v1.0.0), con 145 incidentes entre el 21-09 y el 21-10-2026 (el 2-10 concentra el pico); la tasa de revisión humana (64,8 %, 94 de 145) es el indicador registrado por el backend en esa base y difiere de la evaluación fuera de línea (Subsección 8.3).

La utilidad práctica del dashboard puede ilustrarse con un escenario hipotético: si el sistema detectara que veinte usuarios reportaron la rotura de auriculares en una franja temporal acotada, el patrón sugeriría un problema de calidad del proveedor antes que una serie de fallas aisladas.

7. Consideraciones éticas y aspectos legales

Este capítulo se ubica entre la implementación del sistema y la presentación de los resultados porque las condiciones legales y éticas del tratamiento de datos condicionan la lectura de la evidencia experimental: fijan el marco en el que se recolectó, transfirió y evaluó el corpus y deben conocerse antes de interpretar los resultados.

7.1. Marco normativo aplicable

El sistema desarrollado se enmarca normativamente en la Ley 25.326 de Protección de los Datos Personales de la República Argentina (Honorable Congreso de la Nación Argentina, 2000), en su decreto reglamentario, el Decreto 1558/2001 (Poder Ejecutivo Nacional, 2001), y en las disposiciones complementarias emitidas por la Agencia de Acceso a la Información Pública en su carácter de autoridad de aplicación.

El sistema realiza transferencia de fragmentos textuales hacia infraestructura de inferencia operada por proveedores con sede en los Estados Unidos. Por ello, resultan aplicables las consideraciones del artículo 12 de la mencionada ley sobre transferencia internacional de datos personales y, de manera complementaria, los lineamientos del Reglamento General de Protección de Datos de la Unión Europea (Parlamento Europeo y Consejo de la Unión Europea, 2016) respecto de las personas que se encuentren en la Unión (artículo 3.2 del RGPD). El artículo 2 de la ley define la disociación como el tratamiento que impide la identificación del titular, figura que complementa aquí a la pseudonimización. La Unión Europea reconoce a la Argentina como país con nivel adecuado de protección de datos personales mediante la Decisión 2003/490/CE, del 30 de junio de 2003 (Comisión Europea, 2003), revalidada en enero de 2024. Esta adecuación ampara el flujo desde la Unión Europea hacia la Argentina y no opera en sentido inverso. Los Estados Unidos no figuran entre los países adecuados para la normativa argentina (Dirección Nacional de Protección de Datos Personales, 2016); por lo que la transferencia desde la Argentina hacia los proveedores de inferencia y de telefonía con sede en ese país requiere un instrumento específico conforme al artículo 12 de la Ley 25.326, según se detalla en la Subsección 7.3.

7.2. Principios aplicados al tratamiento de datos

El diseño se atiene a cinco principios del tratamiento de datos personales. La licitud se funda en el artículo 5, inciso 2, apartado d) de la Ley 25.326, que admite tratar los datos

que deriven de una relación contractual, científica o profesional y resulten necesarios para su cumplimiento: la organización es la empleadora y trata datos de sus propios empleados para gestionar los incidentes que estos reportan. Esta base se distingue del consentimiento analizado para el corpus académico en la Subsección 7.5 y no dispensa el deber de información del artículo 6 de la Ley 25.326.

La finalidad determinada limita el uso de los datos a la declaración y derivación de incidentes, sin usos secundarios no compatibles. La minimización se materializa en que solo se almacena el usuario corporativo y un directorio acotado —legajo, nombre, correo electrónico corporativo, teléfono, sector y rol— para resolver el contacto y notificar al usuario, descartando otros datos capturados incidentalmente (domicilios, documentos, información financiera). La exactitud opera mediante la revisión y corrección del incidente antes de su persistencia definitiva; el acceso se satisface en los diez días corridos del artículo 14 y los derechos ARCO, en los cinco días hábiles del artículo 16 de la Ley 25.326. La trazabilidad de cada decisión del clasificador se adopta como medida técnica que facilita el cumplimiento del artículo 9 de la Ley 25.326, no como una exigencia literal de la ley. La limitación del plazo de conservación fija una retención de 12 meses rodantes para los incidentes, justificada por el ciclo estadístico anual, independiente de la retención de 30 días de los registros de ejecución con fines de auditoría y diagnóstico (Subsección 5.3). Los datos del directorio se conservan mientras la relación laboral permanezca activa y hasta un año después de su finalización, y luego se eliminan. Vencido el plazo, los datos del incidente se someten a anonimización irreversible, por lo que se eliminan los identificadores que permiten vincularlos a una persona. El bloqueo de escritura sobre los incidentes cerrados, que rechaza con un error 409 los intentos de modificación, constituye un control de integridad de auditoría y no una excepción permanente al vencimiento del plazo. La pseudonimización y el cifrado en reposo protegen la información durante el plazo de conservación declarado.

7.3. Transferencia internacional y pseudonimización

El tratamiento comporta dos transferencias internacionales hacia proveedores con sede en los Estados Unidos. La primera corresponde a la inferencia Gemini 3.6 Flash mediante la Gemini API (Google, 2026b), a la que se envían fragmentos textuales descriptivos de los incidentes. Sobre ese texto, el módulo Python local es el que pseudonimiza los nombres propios, las direcciones de correo electrónico, los números telefónicos, los identificadores corporati-

vos y los nombres de hosts internos con etiquetas genéricas como `[PERSONA]`, `[EMAIL]` o `[HOST]`, y lo hace antes de la llamada a Gemini, por lo que el texto transmitido no contiene identificadores directos.

En el corpus de este estudio no había identificadores personales directos, de modo que sus descripciones no contienen esas etiquetas. La pseudonimización se valida con expresiones regulares del dominio y pruebas unitarias dedicadas. El servicio de inferencia operó en el nivel pago de la Gemini API, con créditos prepagos; en ese nivel el proveedor no utiliza el contenido transferido para mejorar sus productos (Google, 2026c), lo que acota el tratamiento del dato transferido con independencia del instrumento de transferencia internacional. El comprobante de facturación se conserva en poder del director del trabajo y no se versiona por contener datos de la cuenta.

La segunda corresponde al canal telefónico: el llamante deja su solicitud y Twilio, con sede en los Estados Unidos, graba el audio (Twilio, 2026); el backend envía esa grabación a la Gemini API, que la transcribe (Google, 2026a), y recién después pseudonimiza el texto ya transcrito. En consecuencia, el audio crudo cruza a los Estados Unidos (a Twilio y a Google) y el número telefónico a Twilio antes de cualquier pseudonimización, que opera únicamente sobre el texto y no sobre el audio.

Ambas transferencias se dirigen a un país que no reviste la condición de adecuado para la normativa argentina, por lo que requieren un instrumento específico conforme al artículo 12 de la Ley 25.326 y su reglamentación (Dirección Nacional de Protección de Datos Personales, 2016; Poder Ejecutivo Nacional, 2001): el consentimiento del titular o la suscripción de cláusulas contractuales modelo. Las condiciones de servicio aceptadas con cada proveedor complementan ese instrumento, pero no lo sustituyen, en tanto no configuran por sí mismas una de las bases de transferencia que la ley admite.

El instrumento de transferencia internacional está documentado en el repositorio (`docs/seguridad/instrumento-transferencia-internacional.md`), pero no está suscrito. Durante el estudio no se suscribieron cláusulas contractuales modelo (Dirección Nacional de Protección de Datos Personales, 2016) ni se recabó el consentimiento de los titulares para la transferencia. A los proveedores llegaron solo descripciones pseudonimizadas de los incidentes, en forma de texto (119 casos) y de audio recitado por uno de los autores a partir de esas descripciones (81 casos; Subsección 4.5). El instrumento de transferencia queda como requisito previo para la organización adoptante, antes de operar con datos reales de sus

usuarios.

7.4. Seguridad técnica

Las medidas de seguridad técnica del sistema se sustentan en la triada confidencialidad, integridad y disponibilidad (CIA) descrita por Stallings y Brown (2018), y su evidencia de control se sintetiza en la Tabla 7 (tema Tecnológico). El cifrado en reposo con Fernet (AES-128 en modo CBC con HMAC-SHA-256), el cifrado en tránsito sobre TLS 1.2/1.3 en el borde, el control de acceso por rol. El registro de auditoría de las modificaciones, la gestión de credenciales por variables de entorno y las medidas de disponibilidad —respaldo diario cifrado con prueba de restauración, contenedores con reinicio automático y monitoreo de salud—. Todas ellas quedan mapeadas allí junto con sus brechas residuales. La capa TLS 1.2/1.3 se verifica de forma automatizada sobre el despliegue de referencia de la release v1.2.2, capacidad de la configuración entregada y no de la evaluada (Anexo B, Tabla 29); los dos despliegues de la campaña experimental y la irrelevancia de TLS para las mediciones se detallan en la Subsección 5.1.

7.5. Consentimiento, derechos del usuario y supervisión humana

Los usuarios de la organización son informados, mediante una política de privacidad accesible desde los canales de entrada, sobre las características del sistema, los datos que se recolectan, la transferencia internacional aplicable y los derechos que les asisten conforme a la normativa vigente. Se garantiza el ejercicio de los derechos de acceso, rectificación, actualización y supresión (derechos ARCO) mediante un procedimiento documentado a cargo del responsable de protección de datos designado por la organización.

En lo que respecta al consentimiento informado para los fines de investigación académica, los 120 empleados de la organización fueron notificados mediante comunicación interna formal, con descripción explícita del propósito del estudio, del tipo de datos tratados, del carácter pseudonimizado de los registros y del derecho a requerir la exclusión de sus incidentes del corpus de validación. El procedimiento fue supervisado por la dirección académica del trabajo y avalado institucionalmente mediante una carta de autorización emitida por la organización adoptante.

En relación con el protocolo de medición en vivo aplicado durante la fase experimental (Subsección 4.2), corresponde dejar constancia de lo siguiente. Una vez concluida la recolección de datos, se realizó una sesión de esclarecimiento posterior (*debriefing*) con el operador

que desconocía el propósito comparativo del estudio, externo al equipo de autores (A1); el otro operador, autor del trabajo (T1), lo conocía por esa condición y no requirió sesión. En dicha sesión se explicó el propósito del estudio, se detalló el procedimiento de medición empleado y se ofreció al operador la posibilidad de solicitar la exclusión de sus registros individuales del corpus de validación. El operador no ejerció este derecho. Este procedimiento se alinea con las recomendaciones de la Asociación Americana de Psicología para investigaciones que emplean medición con información diferida sobre el propósito del estudio (American Psychological Association, 2017), y fue supervisado por el director del trabajo.

La campaña complementaria de medición se realizó asimismo con sujetos independientes, identificados en todo el registro únicamente por alias: los etiquetadores E1 y E2 y los operadores O1 y O2. Los registros que produjeron no contienen datos personales: la tabla primaria del doble etiquetado almacena solo el alias, el identificador de caso, el sector canónico y la marca de tiempo, y el export de intervenciones identifica al actor mediante un alias derivado con clave criptográfica (HMAC-SHA-256), sin nombre, correo, teléfono ni legajo. La correspondencia entre el alias y la identidad de cada sujeto se conserva fuera del repositorio, pseudonimizada; las tablas y salidas de la campaña se versionan ya en esa forma, en consonancia con la pseudonimización descrita para el corpus académico (Subsección 7.5).

Los cuatro participantes fueron informados verbalmente, antes de realizar sus tareas, del propósito del estudio, del carácter pseudonimizado de los registros, de la voluntariedad de la participación y de su derecho a retirarse sin consecuencias. Con posterioridad a su participación firmaron una confirmación escrita de esa información y de su consentimiento; los originales firmados se conservan en el expediente físico del trabajo, en poder del director del trabajo, y no se versionan en el repositorio por contener datos personales. El repositorio conserva la plantilla de la confirmación y el registro de que se recabó para los cuatro participantes.

Los etiquetadores E3 y E4, que realizaron el doble etiquetado independiente de la validación fuera de muestra (Sección 8), y el etiquetador E5, que arbitró los casos discordantes entre ambos, fueron informados verbalmente el 12 de noviembre de 2026. Los tres firmaron la confirmación posterior de esa información y de su consentimiento el 13 de noviembre de 2026, con la plantilla que obra en el repositorio (docs/campana-medicion/confirmacion-posterior-consentimiento.md); los originales firmados se conservan en el expediente físico del trabajo, en poder del director del trabajo, y no se versionan por contener datos personales. El registro de alias, rol y fechas de los participantes se conserva sin identidad en el mismo

documento.

En concordancia con las recomendaciones contemporáneas sobre sistemas que incorporan inteligencia artificial, se preserva en todo momento la posibilidad de supervisión humana significativa. Ninguna decisión que afecte derechos sustanciales de los usuarios se toma de manera completamente automatizada sin posibilidad de revisión, y el sector responsable conserva la potestad de modificar la clasificación inicial cuando lo considere apropiado, registrándose tal modificación en la tabla de trazabilidad descrita en la Sección 5. Este mecanismo materializa el principio de la persona en el bucle (*human in the loop*) como salvaguarda frente a errores potenciales del clasificador automático. Cabe precisar su alcance.

El gate de revisión se evalúa solo sobre la salida de la etapa Gemini (Subsección 5.5), por lo que sobre el 65,5 % de los casos, resueltos por la etapa determinística, no existe derivación automática por caso basada en la clasificación. Desde el 13 de octubre de 2026, posterior a la campaña 2026-10, el backend deriva además a revisión el incidente cuyo reportante no se identifica en el directorio de empleados, condición independiente de la clasificación. Para esa fracción la salvaguarda se limita al criterio con que se fijó el punto de operación del filtro —precisión no inferior a la del modelo sobre el conjunto que resuelve, estimada sobre el corpus de validación— y a la reasignación trazable del incidente descrita. Está disponible en la interfaz REST y expuesta en la interfaz web solo para los casos derivados. El análisis de calibración por etapa muestra que la confianza de Gemini no discrimina aciertos de errores en su rango observado (0,85 a 1,00) y que la etapa de reglas no emite una confianza utilizable para derivar (Subsección 8.4); el umbral de 0,70 no garantiza, por lo tanto, la detección de errores.

7.6. Cumplimiento normativo y alineación con estándares

7.6.1. Marco de referencia adoptado

Este apartado evalúa el grado de alineación del sistema con los marcos adoptados: ISO/IEC 27001:2022 (ISO/IEC, 2022b) y su catálogo de controles ISO/IEC 27002:2022 (ISO/IEC, 2022a), NIST CSF 2.0 (National Institute of Standards and Technology [NIST], 2024), la norma de gestión de la privacidad ISO/IEC 27701:2025 (ISO/IEC, 2025) y la Ley 25.326. El relevamiento es estático y documental: describe el grado de alineación y las brechas identificadas, no un aseguramiento de un tercero (no constituye una acreditación externa ni una auditoría independiente), y su detalle se conserva en el repositorio (`docs/cumplimiento/`).

7.6.2. Estado de alineación con ISO/IEC 27002:2022

La Tabla 7 agrupa por tema los controles de ISO/IEC 27002:2022, que corresponden al Anexo A de ISO/IEC 27001:2022; el inventario de los 93 controles reside en el repositorio.

Tabla 7. Estado de alineación con los controles de ISO/IEC 27002:2022, agrupados por tema

Tema	Controles	Estado	Evidencia / brecha principal
Organizacional	5.x	Parcial	Política, clasificación, roles e IR vigentes; residual: revisión independiente (5.35)
Personas	6.x	No aplicable	Selección, formación, sanciones y cese: competen al adoptante
Físico	7.x	No aplicable	Sin infraestructura productiva; se cubren en el hosting del adoptante
Tecnológico	8.x	Alineado y parcial	Pseudonimización, Fernet, TLS, JWT y roles, vulnerabilidades en CI y respaldo cifrado, MFA de cuentas privilegiadas; residual: operación con KMS/PAM, logs centralizados y redundancia offsite

Fuente: elaboración propia a partir del gap assessment ISO/IEC 27001:2022/27002:2022 y NIST CSF 2.0.

7.6.3. Perfil de alineación con NIST CSF 2.0

La Tabla 8 cubre las seis funciones de NIST CSF 2.0 y su madurez en una escala propia del relevamiento, de 0 (inexistente) a 4 (optimizado).

Tabla 8. Perfil de alineación con las funciones de NIST CSF 2.0

Función	Subcategoría representativa	Madurez	Brecha principal
GV (Gobernar)	Políticas, roles, riesgo y proveedores	2	Política, roles y evaluación de proveedores vigentes; residual: revisión independiente del adoptante (5.35)
ID (Identificar)	Inventario de activos y clasificación	2	Inventario de activos y clasificación y etiquetado vigentes (5.9, 5.12, 5.13); residual: SBOM del adoptante
PR (Proteger)	Acceso, endurecimiento y criptografía	3	Pseudonimización, Fernet, TLS, JWT y roles, MFA de cuentas privilegiadas y SAST/auditoría de dependencias en CI; residual: KMS/PAM y SIEM del adoptante (8.5, 8.8, 8.20, 8.24)
DE (Detectar)	Monitoreo y detección de eventos	1	Logs estructurados, chequeos de salud y retención por clase (8.15 parcial); sin centralización ni alertas de seguridad (brecha 8.16)
RS (Responder)	Plan de respuesta y mitigación	2	Plan de respuesta a incidentes vigente (5.24–5.27) y manejo de evidencia (5.28 parcial); residual: operación en producción del adoptante
RC (Recuperar)	Recuperación y restauración	2	Respaldo cifrado y continuidad con RTO/RPO; copia fuera del host y redundancia como acción del adoptante (5.29, 5.30, 8.13, 8.14)

Fuente: elaboración propia a partir del gap assessment ISO/IEC 27001:2022/27002:2022 y NIST CSF 2.0 (`docs/cumplimiento/gap-assessment-iso27001-27002-nist-csf2.md`, sección 4), con el estado reconciliado al 28-10-2026 (release `v1.3.0`).

7.6.4. Brechas principales y hoja de ruta

Seis conjuntos de cambios de cumplimiento cerraron, para el alcance del repositorio, las brechas priorizadas: gobernanza documental (5.1, 5.2, 5.9, 5.12, 5.13, 5.24–5.27, 5.31,

8.26), endurecimiento de red (8.20, 8.22, 8.2, 5.14, 8.31), identidades y accesos (8.5, 5.15, 5.17, 8.2), vulnerabilidades (8.8, 8.28, 8.29, 5.19–5.23). Los otros dos, respaldo y continuidad (8.13, 8.14, 5.29, 5.30, 5.33) y privacidad (5.34, 8.12, 8.15, 5.31), completaron el conjunto. La MFA TOTP con desafío para cuentas privilegiadas y la rotación de claves (secreto JWT y clave Fernet) quedaron implementadas en el repositorio (cambios archivados el 2026-10-08). Su operación con KMS/PAM, la custodia de claves en producción, la centralización de logs, la redundancia fuera del host y el SBOM quedan como acción de la organización adoptante; las brechas organizacionales —personas (6.x), físicas (7.x), revisión independiente (5.35), segregación de funciones (5.3) y trabajo remoto (6.7, 8.1)— son responsabilidad de la organización adoptante.

7.6.5. Alineación con el marco legal

El plano legal de la alineación se desarrolla en el Subsección 7.1 y en la Subsección 7.3, a los que este apartado remite sin reproducir su contenido. Los controles de privacidad mapeados (5.31, 5.34, 8.12, 8.15) se apoyan en la base de licitud del artículo 5 de la Ley 25.326, en el instrumento de transferencia internacional del artículo 12 y en los plazos de los artículos 14 (acceso) y 16 (rectificación, actualización y supresión).

8. Resultados

Los resultados se presentan en doce apartados: comparación de tiempos de registro, métricas de clasificación, intervención humana, calibración de la confianza, sensibilidad al ajuste del clasificador, sesgo del vocabulario y dependencia de la referencia, análisis de errores, campaña complementaria de medición, validación fuera de muestra, comparación con esquemas alternativos, capacidad del tramo compartido bajo carga concurrente y sensibilidad a la referencia de verdad.

Los tiempos de registro del brazo automatizado provienen de las corridas del 2 y del 5 y 6 de octubre de 2026 (con el recálculo telefónico del 19-10-2026), mientras que las métricas de clasificación provienen de una ejecución fuera de línea del 7-10-2026 con la versión `hybrid-v3`; la procedencia de cada conjunto se detalla en la Subsección 4.5.

8.1. Comparación de tiempos de registro

La comparación de los tiempos de registro entre el flujo manual y el flujo automatizado se sintetiza en la Tabla 9. La media aritmética del tiempo manual sobre los 200 casos del corpus fue de 61,6 s (mediana de 50,0 s), con un desvío estándar de 44,9 s y un rango entre 10 y 300 s. Este valor, respaldado por la planilla de cronometraje descrita en la Subsección 4.2, corresponde a la medición experimental incidente por incidente y reemplaza a la estimación preliminar de 2 minutos con 45 segundos citada en la Subsección 1.2, obtenida sin cronometraje individual. La media del flujo automatizado fue de 17,76 s (mediana de 17,47 s), con un desvío estándar de 13,52 s y un rango entre 0,525 y 65,834 s. La reducción relativa de la media de tiempo alcanzó el 71,2 %, con un intervalo de confianza al 95 % de [67,2 %; 74,6 %]. El intervalo se obtuvo por bootstrap percentil, remuestreando los 200 pares con reemplazo (2000 remuestreos, semilla 20261021), y el de la diferencia de medias de 43,82 s es [37,93 s; 50,33 s]. Ambos describen la muestra por conveniencia de 200 casos y no se extrapolan a otras organizaciones. Como el valor puntual, se leen como cotas superiores, porque el tiempo manual se registró con redondeo hacia arriba (Subsección 4.2). La media automatizada combina 81 tiempos telefónicos con registro primario y 119 de correo y formulario sin registro primario conservado; la procedencia de ambos conjuntos se detalla en la Subsección 4.5.

El desagregado por canal de origen, con los dos brazos y el contraste intra-canal, se presenta en la Tabla 10: la reducción de la media va del 51,1 % en correo electrónico, donde se concentran los 12 pares en que el flujo automatizado no fue más rápido, al 93,4 % en formulario

Tabla 9. Estadísticos descriptivos de los tiempos de registro por flujo ($n = 200$)

Estadístico	Flujo manual	Flujo automatizado	Reducción
Media aritmética (s)	61,6	17,76	71,2 %
Mediana (s)	50,0	17,47	65,1 %
Desvío estándar (s)	44,9	13,52	—
Mínimo (s)	10	0,525	—
Máximo (s)	300	65,834	—

Nota: intervalo de confianza al 95 % de la reducción de la media: [67,2 %; 74,6 %] (bootstrap percentil por pares, 2000 remuestreos, semilla 20261021). Corresponde a una muestra por conveniencia y se lee como cota superior. *Fuente:* elaboración propia a partir del corpus de validación ($n = 200$).

web, y el contraste es significativo en los tres canales. El canal telefónico incorpora, además de la latencia de procesamiento, la duración de la llamada grabada; como la grabación está acotada a un máximo de 45 s (véase la Subsección 4.6), su valor constituye una cota inferior de la duración real de la llamada. La distribución de los tiempos de registro por canal de origen, en ambos brazos, se representa en la Figura 6.

Tabla 10. Tiempo de registro por canal de origen: flujos manual y automatizado, reducción y contraste intra-canal ($n = 200$)

		Manual (s)		Automatizado (s)					
Canal de origen	**Casos**	**Media**	**Mediana**	**Media**	**Mediana**	**Reducción de la media**	**Pares no más rápidos**	**p bilateral**	**d_z**
Llamada telefónica (cota inferior)	81	87,2	72,0	20,09	18,70	77,0 %	0 de 81	5,36e-15	1,37
Correo electrónico	66	56,5	50,0	27,65	25,82	51,1 %	12 de 66	4,78e-09	0,73
Formulario web	53	28,7	20,0	1,88	1,26	93,4 %	0 de 53	2,39e-10	1,61
Global	**200**	**61,6**	**50,0**	**17,76**	**17,47**	**71,2 %**	**12 de 200**	**3,08e-32**	**1,00**

Nota: p: valor bilateral de Wilcoxon sobre las diferencias pareadas (Subsección 4.7); d_z: media sobre desvío muestral de las diferencias (manual menos automatizado); W, T^+, T^- y r por canal figuran en `evaluation/report.md`. *Fuente:* elaboración propia a partir del corpus de validación ($n = 200$).

La prueba de Wilcoxon de rangos con signo aplicada sobre las mediciones pareadas (Virtanen et al., 2020; Wilcoxon, 1945) arrojó un estadístico de contraste $W = \text{mín}(T^+, T^-) = 363$, con una suma de rangos positivos $T^+ = 19.737$, una suma de rangos negativos $T^- = 363$ y $n = 200$ pares válidos. El valor $p = 3{,}08 \times 10^{-32}$ bilateral (Subsección 4.7) permite rechazar la hipótesis nula sobre las diferencias pareadas con un nivel de confianza superior al 99,9 %. El estadístico refleja que en 188 de los 200 pares el flujo automatizado fue más veloz que el manual; en los 12 pares restantes (6,0 %) el flujo automatizado no fue más rápido, resultado coherente con la diferencia de aproximadamente 32,5 s entre medianas. La prueba se eligió por el rechazo de la normalidad en los tres conjuntos de tiempos (Subsección 4.7).

Para cuantificar la magnitud práctica de la diferencia, se calculó el coeficiente r de correlación rank-biserial a partir de los dos estadísticos de rango ($r = 19.374/20.100 = 0{,}9639$),

un tamaño del efecto muy alto. En la escala estandarizada del contraste pareado, distinta de la anterior, el tamaño del efecto es $d_z = 1{,}00$ (media de las diferencias de 43,82 s sobre su desvío muestral de 43,81 s). La diferencia observada es, por tanto, estadísticamente significativa y, dada su magnitud absoluta, relativa y el tamaño del efecto reportado, también prácticamente relevante para la operación.

Cabe señalar que el tiempo manual se registró con redondeo hacia arriba (véase la Subsección 4.2), un sesgo de medición sistemático que infla la línea base manual. Por ese motivo la reducción del 71,2 % debe leerse como cota superior. Un análisis de sensibilidad que descuenta 5 s y 10 s a cada medición manual reduce la media manual a 56,6 s y 51,6 s, respectivamente, y sitúa la reducción en el 68,6 % y en el 65,6 % como cota inferior conservadora. Aun en el escenario más desfavorable la reducción de tiempo permanece sustancial y estadísticamente significativa ($p = 1{,}8 \times 10^{-26}$ bilateral, $r = 0{,}8683$).

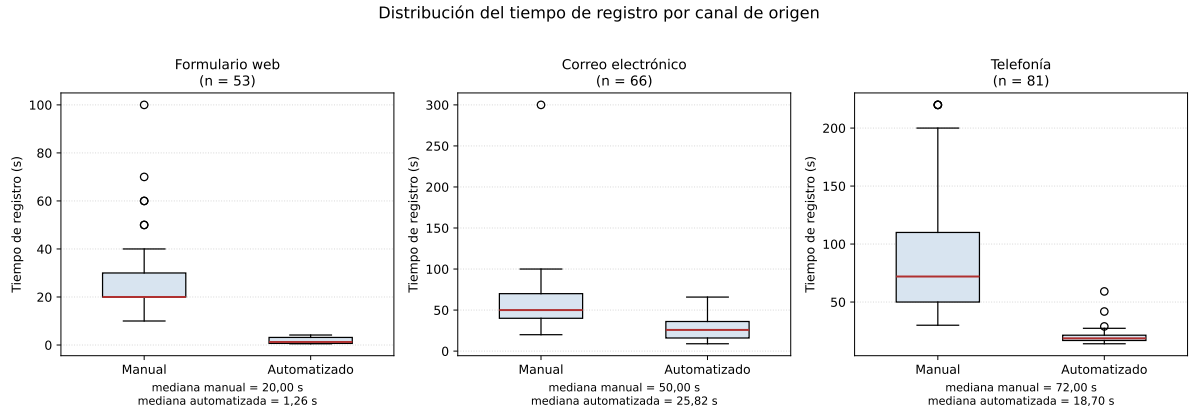


Figura 6. Distribución del tiempo de registro por canal de origen (manual frente a automatizado), para la corrida telefónica del 5 y 6 de octubre de 2026. El panel de telefonía incorpora la duración de la llamada grabada.

8.2. Matriz de confusión y métricas de clasificación

La evaluación de clasificación se realizó sobre el corpus real de 200 casos pseudonimizados, cuya distribución por sector y por canal se describe en la Subsección 4.4.

La matriz de confusión obtenida se presenta en la Tabla 11. La exactitud estricta resultante asciende al 73,5 % (147 casos correctos sobre 200).

Los valores de precisión, sensibilidad (recall) y F1 por clase, con su intervalo de confianza al 95 % (Sokolova & Lapalme, 2009), se presentan en la Tabla 13. La evaluación se enmarca en un único marco métrico cuya referencia de verdad es multietiqueta (107 de los 200 casos, 53,5 %), frente a una salida del clasificador de una etiqueta principal: la exactitud estricta del 73,5 % (147/200) es la métrica primaria monoetiqueta, con IC de Wilson al 95 %

Tabla 11. Matriz de confusión del clasificador automático ($n = 200$). Filas: sector asignado; columnas: sector predicho principal.

Asignado \ Predicho	`Seguridad Informatica`	`Soporte Tecnico Hardware`	`Soporte Tecnico Software`	`Bases de Datos`	`Sistemas`	**Total**
`Seguridad Informatica`	15	2	11	2	1	**31**
`Soporte Tecnico Hardware`	1	**77**	3	0	4	**85**
`Soporte Tecnico Software`	0	11	**48**	1	7	**67**
`Bases de Datos`	0	0	1	0	0	**1**
`Sistemas`	2	0	5	2	**7**	**16**
Total	**18**	**90**	**68**	**5**	**19**	**200**

Fuente: elaboración propia a partir del corpus de validación ($n = 200$).

Tabla 12. Exactitud estricta y laxa por etapa del pipeline y por canal de origen

Ámbito	**Casos**	**Exactitud estricta (IC 95 %)**	**Exactitud laxa (IC 95 %)**
Global	200	147/200 = 0,735 [0,670; 0,791]	179/200 = 0,895 [0,845; 0,930]
Etapa determinística	131	97/131 = 0,740 [0,659; 0,808]	119/131 = 0,908 [0,847; 0,947]
Etapa Gemini	69	50/69 = 0,725 [0,610; 0,816]	60/69 = 0,870 [0,770; 0,930]
Llamada telefónica	81	53/81 = 0,654 [0,546; 0,749]	70/81 = 0,864 [0,773; 0,922]
Correo electrónico	66	51/66 = 0,773 [0,658; 0,857]	61/66 = 0,924 [0,835; 0,967]
Formulario web	53	43/53 = 0,811 [0,686; 0,894]	48/53 = 0,906 [0,797; 0,959]
Casos con consenso `E1` = `E2`, referencia original[a]	138	109/138 = 0,790 [0,714; 0,850]	125/138 = 0,906 [0,846; 0,944]
Mismos casos, referencia de consenso `E1` = `E2`[a]	138	110/138 = 0,797 [0,722; 0,856]	117/138 = 0,848 [0,779; 0,898]

Fuente: elaboración propia ($n = 200$); IC de Wilson. La etapa de reserva no registró casos; la composición sectorial y la proporción multietiqueta difieren entre canales. [a]Las dos últimas filas excluyen los 62 casos sin consenso entre `E1` y `E2`; contra el etiquetado original esos 62 casos dan 38/62 = 0,613. La exactitud laxa contra el consenso acepta como acierto el sector predicho cuando coincide con el consenso o con la intersección de los sectores adicionales que marcaron ambos etiquetadores (Subsección 8.8).

de [67,0 %, 79,1 %]. El macro-F1 de umbral es la métrica primaria contra la que se evalúa el criterio de 0,85. Se reporta sobre las cuatro clases estimables (0,6508), con Bases de Datos excluida ($n = 1$, no estimable: su F1 depende de un único incidente y pesaría un quinto del promedio). El de cinco clases (0,5207) se conserva como valor informativo. Ambos quedan por debajo del criterio, por lo que la elección no altera el veredicto. Las métricas secundarias se calculan contra el conjunto de verdad del corpus (multietiqueta): subset accuracy 0,43 (IC [0,36; 0,50]), Hamming loss 0,3586 (IC [0,31; 0,41]) y micro-F1 0,6654 (IC [0,62; 0,71]) (Sokolova & Lapalme, 2009; Tsoumakas & Katakis, 2007). Estas métricas se calculan sobre el conjunto predicho de cada caso (una etiqueta principal y, en 8 casos de la etapa determinística, sectores adicionales; Subsección 4.7) y no son equivalentes de la exactitud estricta. El micro-F1 acumula los aciertos por etiqueta y no por caso, por lo que su valor (0,6654) no debe leerse como una exactitud (0,7350). De los 200 casos, 131 fueron resueltos por la etapa determinística del clasificador y 69 requirieron la etapa Gemini. La exactitud laxa —sector predicho principal dentro del conjunto de verdad— es secundaria y no reemplaza a la estricta: alcanza el 89,5 % (179/200; IC de Wilson de [84,5 %, 93,0 %]). La Tabla 12 desagrega ambas por etapa y por canal, como estimaciones dentro de la muestra (Subsección 8.5).

Las dos últimas filas de la Tabla 12 controlan la referencia con los 138 casos en que los etiquetadores independientes `E1` y `E2` coinciden (Subsección 8.8). Contra ese consenso, la exactitud estricta es de 110/138 = 0,797 (IC de Wilson [0,722; 0,856]). Contra el etiquetado original, sobre esos mismos casos, es de 109/138 = 0,790 [0,714; 0,850]. El veredicto de la tercera sub-hipótesis (Subsección 1.4) se mantiene sobre la referencia primaria, que es el etiquetado original y la prefijada. Con el consenso, el límite superior de la exactitud (0,856) supera el umbral de 0,85, por lo que con esa referencia el criterio de exactitud sería no concluyente. El macro-F1 contra el consenso, sobre las cuatro clases estimables, es de 0,757 y sigue por debajo del umbral; se informa el valor puntual, sin intervalo.

Las métricas por clase, calculadas según las definiciones de precisión, sensibilidad y F1 de Sokolova y Lapalme (2009), muestran un desempeño desigual entre las clases objetivo. Este desequilibrio importa en el contexto operativo, porque un clasificador que concentra sus errores en una clase minoritaria genera derivaciones erróneas en un sector específico y puede erosionar la confianza de ese equipo en la herramienta, independientemente de sus métricas agregadas.

La inspección de la matriz de confusión revela que los 53 errores totales se concen-

Tabla 13. Métricas de clasificación por clase con intervalo de confianza al 95 % (una contra el resto)

Clase	Precisión (IC 95 %)	Sensibilidad (IC 95 %)	F1 (IC 95 %)
`Soporte Tecnico Hardware`	0,8556 [0,77; 0,91]	0,9059 [0,83; 0,95]	0,8800 [0,82; 0,93]
`Soporte Tecnico Software`	0,7059 [0,59; 0,80]	0,7164 [0,60; 0,81]	0,7111 [0,61; 0,80]
`Seguridad Informatica`	0,8333 [0,61; 0,94]	0,4839 [0,32; 0,65]	0,6122 [0,44; 0,75]
`Sistemas`	0,3684 [0,19; 0,59]	0,4375 [0,23; 0,67]	0,4000 [0,16; 0,59]
`Bases de Datos`		no estimable ($n = 1$)	

Fuente: elaboración propia a partir del corpus de validación ($n = 200$). IC de precisión y sensibilidad por Wilson; IC de F1 por bootstrap percentil (2000 remuestreos).

tran en fronteras entre sectores léxicamente próximos, con Soporte Técnico Software como categoría central; su análisis cualitativo, agrupado por frontera de confusión, se desarrolla en la Subsección 8.7.

8.3. Derivación e intervención humana en la campaña complementaria

La derivación por confianza se rige por el gate de revisión implementado (Subsección 5.5). El gate no derivó ningún caso del corpus por confianza: en 124 de los 200 casos (62 %) la confianza registrada fue inferior a 0,70, pero todos pertenecen a la etapa determinística, cuya confianza mide fuerza de señal; los 69 casos de Gemini declararon siempre al menos 0,85 y la etapa de reserva no se activó. El 65,5 % de los casos (131 de 200) corresponde a la cobertura de la etapa determinística, no a una proporción de derivación. El resultado se interpreta en la Sección 9.

La segunda sub-hipótesis —proporción de casos con acción manual no superior a 0,15 (Subsección 1.4)— se contrasta con el export de intervenciones de la campaña complementaria, que registró 147 intervenciones en 200 casos. Esa tasa bruta, del 73,5 % (IC de Wilson al 95 % [67,0 %, 79,1 %]), mide la regla de derivación por reportante de la configuración de la prueba y no la necesidad de revisión que la hipótesis postula. Ningún caso se derivó por confianza. Las 147 intervenciones corresponden a la regla de derivación por reportante no identificado (requisito `VIS-005` de la especificación de visibilidad de incidentes), que el backend aplica cuando el reportante no se resuelve en el directorio de empleados. Por esa regla, la revisión humana alcanzó 66 casos de correo y 81 de telefonía y ninguno de los 53 del formulario web, cuyo reportante es la cuenta autenticada. El origen `gate` del export registra el indicador de revisión, no la regla de confianza; las demás categorías no registraron casos. La variable de la hipótesis son las intervenciones que cambiaron la derivación: 25 de los 147

casos revisados (17,0 %; IC de Wilson [11,8 %, 23,9 %]); las 122 confirmaciones restantes son el 83,0 % de los 147 revisados y el 61,0 % de los 200 casos. La regla de tres vías prefijada se aplicaba al cociente 25 de 200 (12,5 %; IC de Wilson [8,6 %, 17,8 %]), cuyo límite superior supera 0,15, y daba un resultado no concluyente. El denominador de 147 casos revisados y la lectura de la regla con ese denominador se adoptaron después de conocer los datos: no estaban fijados de antemano. Sobre los 147 revisados, la estimación puntual (17,0 %) queda por encima de la cota de 0,15, y la lectura literal de la regla daría *refutada*. Sin embargo, el intervalo [11,8 %, 23,9 %] contiene el 0,15, y la prueba binomial unilateral (hipótesis alternativa: proporción mayor que 0,15) no rechaza la cota (p = 0,28; bilateral, p = 0,49). Por eso no se sostiene una refutación. El veredicto es *no concluyente, con estimación puntual por encima de la cota*. El cociente 25 de 200 se conserva solo como dato secundario, porque cuenta como "sin acción manual" a 53 casos web que no tuvieron oportunidad de revisión. Extender esta conclusión al formulario web y a reportantes identificados en el directorio exige una corrida en la que la revisión alcance a todos los canales (Subsección 11.4). La medición completa se presenta en la Subsección 8.8.

El cotejo de las revisiones con el consenso del doble etiquetado nuevo se informa como dato y sin lectura causal: de las 85 confirmaciones con consenso disponible, 11 confirmaron un sector que el consenso considera incorrecto, y de los 25 cambios de derivación 13 tienen consenso (9 correcciones, 1 empeoramiento y 3 de un error a otro).

La proporción del tiempo dedicado a tareas manuales, segunda dimensión de la variable, se apoya en las consignas de inicio y fin. Su cobertura es de 0,9388 (147 casos con intervención y 138 con duración completa), y sobre esa base la proporción del tiempo es de 0,5307, con un intervalo bootstrap del cociente de [0,4407; 0,6111] ($B = 2000$, semilla 20261021). El denominador de esa proporción usa los tiempos automatizados de la campaña complementaria de medición (`corpus_campana.json`, 191 casos con dato completo, incluidos los 53 sin intervención) más la duración de las intervenciones. No usa el tiempo total de atención, lo que acota la lectura del valor.

8.4. Calibración de la confianza

La confianza declarada solo es útil como criterio de derivación si guarda relación con la exactitud real, y las dos etapas que la emiten lo hacen con magnitudes distintas (Subsección 5.5); por eso la Tabla 14 desagrega la exactitud por banda y por etapa. El umbral de 0,70

del gate se evalúa solo sobre la salida de Gemini (Subsección 8.3).

Tabla 14. Exactitud por banda de confianza declarada y por etapa del pipeline

	Etapa determinística			Etapa Gemini		
Banda de confianza	**Casos**	**Aciertos**	**Exactitud**	**Casos**	**Aciertos**	**Exactitud**
$[0{,}00\,;\,0{,}50)$	98	75	0,765	—	—	—
$[0{,}50\,;\,0{,}70)$	26	19	0,731	—	—	—
$[0{,}70\,;\,0{,}85)$	6	2	0,333	—	—	—
$[0{,}85\,;\,0{,}95)$	—	—	—	31	22	0,710
$[0{,}95\,;\,1{,}00]$	1	1	1,000	38	28	0,737

Fuente: elaboración propia ($n = 200$). "—": la etapa no emitió confianza en esa banda; la reserva no registró casos.

El contraste agregado entre los casos de confianza alta ($\geq 0{,}70$, exactitud 0,697) y baja ($< 0{,}70$, 0,758) es un efecto de composición, no una medida de calibración: los 124 casos por debajo de 0,70 son todos de la etapa determinística y el resto reúne 7 casos determinísticos y los 69 de Gemini. Por etapa, la exactitud estricta, estimada dentro de la muestra (Subsección 8.5), es de 0,7405 en la determinística y de 0,7246 en la de Gemini (Tabla 12). La confianza de Gemini, concentrada entre 0,85 y 1,00, no discrimina aciertos de errores: rinde 0,710 en la banda $[0{,}85\,;\,0{,}95)$ (IC de Wilson [53,4 %, 83,9 %]) y 0,737 en la banda $[0{,}95\,;\,1{,}00]$ ([58,0 %, 85,0 %]), con intervalos solapados, y los 46 casos con confianza igual o superior a 0,90 (45 de Gemini) incluyen 13 errores (28,3 %), todos de Gemini. La de la etapa determinística es una fuerza de señal en escala discreta que no ordena la correctitud (0,731 a 0,765 por debajo de 0,70; 0,333 en $[0{,}70\,;\,0{,}85)$, con 6 casos) y no es un criterio utilizable para derivar (Subsección 5.5). La conclusión se restringe, así, a Gemini en su rango observado: el umbral de 0,70 no habría aislado sus 19 errores, pues su confianza nunca fue inferior a 0,85. Este hallazgo fundamenta la discusión de la Sección 9.

Calibración, discriminación y punto de operación de la etapa Gemini. La Tabla 14 desagrega la exactitud por bandas de ancho desigual; el análisis posterior de calibración (Subsección 4.6) usa en cambio 10 bandas de igual ancho y mide, además, el orden de la confianza. Sus resultados para la etapa Gemini, dentro de la muestra (69 casos escalados de los 200, referencia original) y fuera de ella (34 escalados de los 103 con consenso de $\mathtt{E3}$ y $\mathtt{E4}$), están en la Tabla 15. No modifican las cifras de la Tabla 14: la exactitud dentro de la muestra, 0,7246, es la ya informada.

La confianza de Gemini toma pocos valores. Dentro de la muestra son 0,85 (24 casos), 0,90 (7), 0,95 (35) y 0,98 (3); fuera de ella aparece además un caso con 0,65 y los demás se

Tabla 15. Calibración y discriminación de la confianza de la etapa Gemini, dentro y fuera de la muestra

Corpus	n	Exactitud	Confianza media	ECE	Brier	AUROC (IC 95 %)
Dentro de la muestra	69	0,7246	0,9114	0,1868	0,2362	0,5168 [0,3796; 0,652
Fuera de la muestra	34	0,7647	0,9156	0,1715	0,1935	0,7163 [0,5138; 0,913
Fuera de la muestra, referencia arbitrada (descriptiva)	91	0,5934	0,9055	0,3209	0,3258	0,6912 [0,5768; 0,792

Fuente: elaboración propia a partir de `evaluation/data/campana/analisis/analisis_calibracion_gate_c214.json`. Acierto estricto; ECE con 10 bandas de igual ancho; intervalos bootstrap percentil por caso (2000 remuestreos, semilla fija). La referencia es la original dentro de la muestra y el consenso de `E3` y `E4` fuera de ella. Análisis posterior y no ciego (Subsección 4.6). La fila de la referencia arbitrada es descriptiva: el umbral no se eligió con datos fuera de la muestra.

reparten entre 0,85 (8), 0,90 (2), 0,95 (22) y 0,98 (1). Hay sobreconfianza en ambos corpus: la confianza media (0,9114 y 0,9156) supera a la exactitud (0,7246 y 0,7647), con una sobreconfianza de 0,1868 dentro de la muestra y de 0,1509 fuera de ella (IC de [0,0229; 0,2912]). Dentro de la muestra la confianza no ordena los casos: el AUROC es de 0,5168 y su intervalo, [0,3796; 0,6528], contiene 0,5. Fuera de la muestra el AUROC es de 0,7163, pero el intervalo, [0,5138; 0,9139], es ancho y su límite inferior casi toca 0,5; con 34 casos y 8 errores no se sostiene que la confianza discrimine de manera estable. Por nivel, fuera de la muestra el valor 0,85 acierta 3 de 8 casos y el 0,95, 19 de 22.

El barrido de umbrales (0,70 el vigente, 0,86, 0,91, 0,96, 0,99 y derivar todo) con la regla prerregistrada no selecciona ningún umbral dentro de la muestra. Con el piso de 0,85, y también con el de 0,8278, ninguno alcanza la exactitud selectiva requerida con al menos 10 casos aceptados: los umbrales de 0,86 y 0,91 aceptan 45 y 38 casos con exactitudes de 0,711 [0,566; 0,823] y 0,737 [0,580; 0,850], y el de 0,96 llega a 1,000 con solo 3 aceptados. Como no hay umbral seleccionado, no hay política que confirmar fuera de la muestra. El resultado es que la confianza autodeclarada no sostiene un umbral con el piso fijado. Fuera de la muestra el barrido se informa solo como descripción y no se usó para elegir: con 0,86 se aceptarían 25 casos con exactitud selectiva de 0,880 y se derivarían 9, que incluyen 5 de los 8 errores. Esa descripción no cambia el resultado de la selección, porque el umbral no se eligió con ella.

El complemento descriptivo sobre el corpus arbitrado no re-elege el umbral: la regla prerregistrada elige solo con los 200 casos de ajuste. Sobre los 91 casos de la etapa Gemini del corpus arbitrado, la exactitud es de 0,5934 y la confianza media, de 0,9055, con una sobreconfianza de 0,3121 y un ECE de 0,3209 (IC [0,2230; 0,4201]), un Brier de 0,3258 (IC [0,2465; 0,4066]) y un AUROC de 0,6912 (IC [0,5768; 0,7923]). El barrido con los mismos candidatos es descriptivo: con 0,70 se aceptarían 90 casos con exactitud selectiva de 0,5889; con 0,86, 55 con 0,7455; con 0,91, 48 con 0,7708; con 0,96, 5 con 0,6000; y con 0,99 o derivar todo,

ninguno; ningún candidato figura como seleccionado. La confianza de Gemini no es estable entre corridas: sobre los casos comunes a las dos corridas fuera de muestra, el sector y la etapa coinciden, pero la confianza difiere en 7 casos (I026, I043, I050, I055, I067, I084, I085), lo que acota la lectura de cualquier umbral apoyado en ella.

El gate vigente de 0,70 deriva 0 de los 69 casos escalados dentro de la muestra, y 1 de los 34 fuera de ella. Ese caso, el único del corpus fuera de la muestra con confianza menor que 0,70, declaró 0,65 y la etapa Gemini lo había clasificado bien: la derivación recayó sobre un acierto y el gate no atrapó ninguno de los 8 errores de ese corpus.

Las dos señales alternativas son degeneradas. En los 69 casos escalados dentro de la muestra y en los 34 de fuera, las reglas determinísticas no tienen un sector ganador único (puntaje de correctitud igual a 0,0): el acuerdo entre etapas queda en una sola categoría, sin predicción de las reglas (50 aciertos de 69, 0,7246, y 26 de 34, 0,7647), y el puntaje de las reglas toma un único valor, de modo que el AUROC de ambas es 0,5000 y ninguna política se selecciona ni se evalúa fuera de la muestra. La recalibración isotónica, ajustada en los 200 casos y aplicada fuera de la muestra, mejora el nivel (ECE de 0,1715 a 0,0435; Brier de 0,1935 a 0,1796) pero no crea capacidad de discriminación: al agrupar niveles vecinos introduce empates y el AUROC baja levemente (de 0,7163 a 0,7043), sin alterar el orden estricto de los puntajes; corrige cuánto confía el modelo, no si separa los aciertos de los errores. En el corpus evaluado, entonces, la derivación por confianza autodeclarada no se repara por recalibración. La etapa determinística no entra en este análisis como señal de derivación: su confianza es una fuerza de señal y su puntaje de correctitud ya gobierna el cortocircuito (Subsección 5.5).

8.5. Sensibilidad al ajuste del clasificador con el corpus

Las métricas de este capítulo son estimaciones dentro de la muestra (Subsección 9.1). Para acotar el sesgo atribuible al vocabulario del filtro, ampliado a partir de errores observados en el corpus, se repitió sin invocar al modelo la etapa determinística con el vocabulario previo a esa ampliación (89 de los 151 patrones). Se conservaron la lógica de decisión y el punto de operación evaluados. Con la lógica de decisión de entonces, la repetición reprodujo la medición registrada antes del ajuste. La reconstrucción del vocabulario por pliegues no es factible, porque el repositorio no registra qué casos motivaron cada patrón. La Tabla 16 resume los resultados.

El efecto de la ampliación del vocabulario admite dos lecturas que conviene separar.

Tabla 16. Sensibilidad de la exactitud al vocabulario ajustado con el corpus

Filtro determinístico	Casos	Exactitud (IC 95 %)	Global[a]
Evaluado (vocabulario ampliado)	131	0,7405 [0,6593; 0,8079]	146/200
Vocabulario previo, lógica vigente	74	0,5270 [0,4148; 0,6366]	128/200
Vocabulario y lógica previos	72	0,5139 [0,4007; 0,6257]	—

Fuente: elaboración propia a partir del corpus de validación ($n = 200$) y de `evaluation/report_sensibilidad_ajustes.md`. Casos y exactitud de la etapa determinística. [a]Aciertos con las predicciones de la etapa Gemini fijas (caché de calibración); la exactitud global oficial es 147/200.

Por un lado, un efecto de *cobertura*, que es el dominante: el filtro determinístico pasó de resolver 74 casos a resolver 131. Por otro, un efecto de *exactitud* sobre los casos que ambas configuraciones resuelven: en los 67 casos comunes, el vocabulario ampliado acertó 38 frente a los 37 del vocabulario previo, por lo que la ampliación no deterioró la exactitud sobre los casos que ya resolvía. La diferencia de 21,3 puntos entre las exactitudes de la etapa determinística (0,7405 sobre 131 casos frente a 0,5270 sobre 74) puede leerse como señal del sesgo, y entonces es una *cota pesimista*. Es una interpretación de los autores, no una medición, porque las dos cifras se calculan sobre conjuntos de casos distintos. Además, el vocabulario previo carece del conocimiento del dominio que una ampliación hecha con datos independientes habría aportado. Con las predicciones de la etapa Gemini fijas, la exactitud global pasa de 146 a 128 aciertos sobre 200 casos (McNemar exacto (McNemar, 1947), $p < 0{,}001$). El efecto de las reglas de frontera del prompt, limitado a los 69 casos de la etapa Gemini, se acotó con una ablación controlada de dos brazos sobre los mismos casos y en una misma sesión. Con el prompt vigente esa etapa acertó 50 de 69, y sin las reglas de frontera, 46 de 69 (reservas contadas como error: 0 en ambos brazos). Esa diferencia no alcanza significación (McNemar exacto entre brazos, $p = 0{,}3438$). Sin los casos que motivaron las reglas, la etapa con el prompt vigente acertó 48 de 66 (nivel a; `evaluation/report_sensibilidad_ajustes.md`, línea 95). El análisis estima la sensibilidad de las métricas y no sustituye la medición del sistema evaluado.

8.6. Sesgo del vocabulario y dependencia de la referencia

Hay dos preguntas (método en la Subsección 4.7). La primera es cuánto del desempeño de la etapa determinística depende de haber ajustado su vocabulario con el mismo corpus. La segunda es cuánto de la exactitud depende de la robustez de la referencia. Antes de medir se reprodujo que el vocabulario vigente cubre 131 de los 206 casos, cortocircuita 115 y acierta 88, y que el clasificador congelado acierta 142 de 206 (Tabla 17).

El vocabulario externo cubre 48 casos menos y cortocircuita 40 menos que el vigente, con una precisión 4,5 puntos menor y con intervalos que se solapan. En los 54 casos que

Tabla 17. Etapa determinística con tres vocabularios

Vocabulario	Patrones	Cobertura	Cortocircuito	Aciertos	Precisión (IC 95 %)
Vigente	151	131	115	88	0,7652 [0,6800; 0,8333]
Externo al corpus	90	83	75	54	0,7200 [0,6096; 0,8090]
Previo a la ampliación	89	97	88	65	0,7386 [0,6382; 0,8191]

Nota: 206 casos arbitrados; sensibilidad, no exactitud corregida; los conjuntos cortocircuitados difieren. *Fuente:* `evaluation/data/campana/analisis/analisis_sesgo_corpus_referencia_c219.json`.

ambos cortocircuitan coinciden en el sector en 47 (aciertos: 40 y 43). Se lee como sensibilidad: la diferencia es sobre todo de cobertura, y el vocabulario previo va en la misma dirección. Los límites son la independencia procedimental, los conjuntos de casos distintos y una fuente pública de ciberseguridad y no de mesa de ayuda, con un vocabulario más pobre en las clases de soporte. Se mide la etapa determinística, no el híbrido de extremo a extremo.

Tabla 18. Exactitud estricta del clasificador congelado según el origen de la referencia

Subconjunto	Casos	Aciertos	Exactitud (IC 95 %)
Consenso de `E3` y `E4`	142	109	0,7676 [0,6916; 0,8295]
Arbitrado por `E5`	64	33	0,5156 [0,3958; 0,6337]
Total	206	142	0,6893 [0,6231; 0,7486]

Nota: el subconjunto en que `E3`, `E4` y `E5` coinciden es vacío por construcción (0 casos). *Fuente:* `evaluation/data/campana/analisis/analisis_sesgo_corpus_referencia_c219.json`.

La exactitud es 0,7676 sobre el consenso y 0,5156 sobre lo arbitrado, con intervalos que no se solapan, y los 6 casos de tres vías, incluidos entre los arbitrados, no fueron acertados. La diferencia es descriptiva: con estos datos no se separa una referencia menos robusta de un caso más ambiguo. No se afirma causalidad y la cifra de 0,6893 no cambia.

8.7. Análisis de errores y casos límite

El análisis cualitativo de los 53 casos mal clasificados permitió identificar patrones de error recurrentes, agrupados por frontera de confusión y sintetizados en la Tabla 19.

El patrón dominante, presente en 14 casos (26,4 % de los errores), corresponde a la frontera entre Soporte Técnico Hardware y Soporte Técnico Software. Son incidentes en que una falla física de un equipo afecta a una aplicación, o en que una tarea sobre una aplicación se describe con términos de equipamiento. La decisión correcta depende, entonces, del juicio humano sobre qué aspecto prevalece. El segundo patrón, presente en 12 casos (22,6 %), corresponde a la frontera entre Sistemas y Soporte Técnico Software, asociada a acciones sobre servidores y servicios de plataforma descritas como problemas de una aplicación. El tercer patrón, presente en 11 casos (20,8 %), corresponde a la frontera entre Seguridad Informática y Soporte Técnico Software, vinculada a incidentes de acceso y credenciales. El 30,2 % restan-

Tabla 19. Confusiones observadas en la clasificación automática, por frontera, con los aciertos laxos entre los errores estrictos

Frontera de confusión	Casos	Proporción	Aciertos laxos
`Soporte Tecnico Hardware` ↔ `Soporte Tecnico Software`	14	26,4 %	5
`Sistemas` ↔ `Soporte Tecnico Software`	12	22,6 %	10
`Seguridad Informatica` ↔ `Soporte Tecnico Software`	11	20,8 %	8
Otras fronteras	16	30,2 %	9
Total	**53**	**100 %**	**32**

Fuente: elaboración propia a partir del corpus de validación ($n = 200$) y de la evidencia de la ejecución `hybrid-v3` del 7-10-2026. Un acierto laxo es un error estricto cuyo sector predicho pertenece al sector asignado o a los sectores adicionales de la referencia (Subsección 4.7). Recuento: `docs/Tesis/Correcciones/recontar_errores_frontera.py`.

te se reparte entre las demás fronteras, incluidas las confusiones que involucran a Bases de Datos, con un único caso de soporte.

Como lectura interpretativa de la última columna de la Tabla 19, 32 de los 53 errores estrictos (60,4 %) derivaron a un sector que la referencia considera corresponsable (acierto laxo), y solo 21 (39,6 %) a un sector ajeno al conjunto de verdad; ambas cifras son consistentes con la exactitud laxa de 179 aciertos sobre 200 (147 estrictos más 32 laxos). La corresponsabilidad se concentra en las fronteras de Sistemas con Soporte Técnico Software (10 de 12) y de Seguridad Informática con Soporte Técnico Software (8 de 11), mientras que en la de Soporte Técnico Hardware con Soporte Técnico Software predominan los errores plenos (9 de 14), que son los que exigen una reasignación. Esta lectura no modifica el balance neto (Subsección 9.5).

Los patrones anteriores se ilustran con tres casos con error estricto del corpus. Las descripciones se reproducen literalmente, tal como figuran en el corpus ya pseudonimizado, y se acompañan con el identificador del caso, el sector asignado, el sector predicho, la confianza y la etapa que resolvió. El primero (R001) corresponde al patrón de descripción corta: “No puede ingresar al sistema principal” fue asignada a Seguridad Informática y predicha como Soporte Técnico Software por Gemini con una confianza de 0,95; su brevedad no aporta contexto sobre el recurso ni sobre la naturaleza del acceso fallido, por lo que la frontera resulta indistinguible sin información adicional. El segundo (R032) ilustra la mezcla de categorías: “Su PC se reinicia a cada rato, sospecha que son los cables de la computadora.” fue asignada a Soporte Técnico Software y predicha como Soporte Técnico Hardware por la etapa determinística con 0,50 de confianza. Combina un síntoma de nivel de aplicación con una hipótesis de

causa física cuyo peso relativo no queda determinado por el texto. El tercero (R015) ejemplifica la jerga local: “No le salen correos por flujo del sistema principal y no le llegan las instancias” fue asignada a Sistemas y predicha como Soporte Técnico Software por Gemini con 0,85 de confianza, y apela a términos organizacionales (“flujo”, “instancias”) cuyo significado no está disponible para el clasificador. La confianza se lee por etapa: en R001 y R015 la declarada por Gemini es alta (0,95 y 0,85) pese al error estricto; en R032 la de 0,50 corresponde a la etapa determinística, mide la fuerza de la señal y no es criterio de derivación a revisión (Subsección 8.4). Los tres casos son aciertos laxos: el sector predicho figura entre los sectores adicionales de la referencia (Subsección 4.7).

8.8. Resultados de la campaña complementaria de medición

Esta subsección reúne los resultados de la campaña complementaria de medición, que instrumentó con sujetos independientes las mediciones que la campaña 2026-10 había dejado pendientes (Subsección 4.2). Sus valores **no reemplazan** los valores canónicos de la campaña 2026-10 reportados en las subsecciones anteriores. Los tiempos registrados en esta campaña alimentan el análisis del efecto de posición y la proporción de tiempo (Subsección 8.3) y no intervienen en el contraste principal de tiempos (Subsección 8.1).

Fiabilidad del doble etiquetado. El doble etiquetado independiente de la campaña, realizado por los etiquetadores `E1` y `E2` sobre los 200 casos, produjo un kappa de Cohen de 0,5569 ($p_o = 0,69$; $p_e = 0,30$) y un PABAK de 0,6125. El intervalo de confianza al 95 % es [0,4725; 0,6413] por la aproximación asintótica (Fleiss et al., 1969) y [0,4751; 0,6387] por bootstrap percentil (2000 remuestreos); el rótulo de Landis y Koch del valor puntual es *moderado*, y ambos intervalos abarcan las categorías moderada y sustancial. El doble etiquetado original, que fijó la referencia primaria de la campaña 2026-10, no conserva registro y no permite un contraste con este kappa (Subsección 4.4).

Tiempos del brazo manual por operador. En la campaña complementaria, el operador recibió una hoja con el identificador y la descripción de cada caso. Registró el instante en que tomó el caso y el instante en que asignó el sector. El tiempo así medido corresponde a la decisión de sector. No incluye la lectura, la búsqueda ni la carga del ticket, que sí formaron parte del cronometraje de la campaña 2026-10 (Subsección 4.2). Por eso estos tiempos no reemplazan el contraste principal de la Subsección 8.1. La Tabla 20 los desagrega por operador.

Tabla 20. Tiempo del brazo manual de la campaña complementaria por operador y reducción frente al brazo automatizado de la misma campaña

Operador	Casos	Manual: media (desvío) (s)	Manual: mediana (s)	Automatizado, mismos casos: media (s)	Reducción de la media	p (Wilcoxon pareado)	r
O1	110	20,1 (9,2)	18,0	13,3	33,8 %	$9{,}8 \times 10^{-7}$	0,54
O2	110	76,6 (21,4)	73,0	15,5	79,7 %	$9{,}0 \times 10^{-20}$	1,00
Agregado por caso	200	47,6 (28,7)	49,0	14,6	69,3 %	$3{,}0 \times 10^{-28}$	0,90

Nota: duración manual: instante de asignación del sector menos instante en que el operador tomó el caso. El brazo automatizado es el de la corrida propia de la campaña complementaria (media de 14,6 s), no el del corpus canónico (17,76 s). p: valor bilateral de Wilcoxon sobre las diferencias pareadas; r: correlación rank-biserial. El agregado promedia los tiempos de los 20 casos con doble cobertura. *Fuente:* elaboración propia sobre `brazo_manual.csv` y `corpus_campana.json`.

La reducción de la media va del 33,8 % con O1 al 79,7 % con O2, y ambas son significativas. La magnitud depende de quién opere, porque el tiempo manual no es una propiedad estable del incidente. La reducción se mantiene significativa con el operador más rápido. El agregado por caso es de 47,6 s frente a 14,6 s, con una reducción del 69,3 %, del mismo orden que el 71,2 % obtenido con operadores distintos. El automatizado de esta comparación es el de la corrida de la campaña complementaria, y no el del corpus canónico. Veinte casos tienen doble cobertura de O1 y O2: el agregado promedia sus dos tiempos, por lo que son 200 casos y no 220 registros. En esos 20 casos las medias son de 20,1 s para O1 y de 92,8 s para O2. Un registro de O1 (R025) dura 0 s, porque el instante de inicio coincide con el de asignación. Sin ese registro, O1 da 20,3 s y una reducción del 34,3 %. El tiempo manual por caso casi no correlaciona entre campañas (Spearman de 0,15 para O1 y de $-0{,}05$ para O2). Los tiempos automatizados de las dos campañas sí correlacionan ($\rho = 0{,}70$). Con los tiempos automatizados del corpus canónico de la campaña 2026-10 sobre esos mismos casos, las reducciones serían del 19,6 % para O1, del 75,9 % para O2 y del 62,7 % en el agregado por caso. La diferencia con la tabla proviene solo del brazo automatizado. Estos tiempos miden la decisión de sector y no reemplazan el contraste principal.

Exactitud del brazo manual. Sobre la referencia construida como consenso de E1 y E2, con los casos discordantes excluidos, la exactitud estricta del brazo manual fue de 0,8875 para O1 (71 de 80 casos; IC de Wilson [0,7998; 0,9397]) y de 0,7606 para O2 (54 de 71; [0,6496; 0,8448]). En forma agregada, la exactitud estricta fue de 0,8278 (125 de 151 derivaciones de operador, 80 de O1 y 71 de O2, sobre 138 casos únicos, 13 de ellos con doble cobertura; IC bootstrap por caso [0,7647; 0,8882]) y la laxa, de 0,8609 (130 de 151). El

contraste de McNemar entre el brazo manual y el automatizado sobre los casos con predicción de ambas vías no resultó significativo (para `O1`, p exacto $= 0,2668$; para `O2`, p exacto $= 1,0000$), por lo que no se detecta una diferencia de exactitud entre ambos brazos. Como referencia de comparabilidad, la exactitud estricta del brazo automatizado sobre la misma referencia nueva es de 0,7971 (110 de 138 casos; IC de Wilson [0,7224; 0,8557]; Tabla 12). Las unidades difieren (por caso en el automatizado, por derivación en el manual), por lo que el contraste formal es el McNemar por operador, que empareja casos. El 0,7971 proviene de `predicciones_in_sample.json` (7-10), que contiene las mismas 200 predicciones que `evaluation/evidence/predicciones_hybrid-v3_2026-10-07.json`, y no de la salida en vivo de la campaña, que difiere en 13 casos (7 de 119 escritos y 6 de 81 telefónicos). La salida en vivo telefónica proviene de la columna `sector_predicho` del export de intervenciones (los sidecars telefónicos tienen el sector nulo) y el contraste de McNemar usa la predicción de la caché `predicciones_hybrid-v3_2026-10-07.json`. El conjunto de verdad laxo del brazo manual se define como el consenso de `E1` y `E2` más la intersección de los sectores adicionales que marcaron ambos etiquetadores. Este valor es propio de la campaña y no reemplaza la exactitud del corpus de 0,7350 (147/200) reportada en la Subsección 8.2, que sigue siendo la métrica primaria del clasificador.

Efecto de posición y de orden. En la ejecución, el brazo manual precedió al automatizado en los 200 casos (Subsección 4.2): los dos grupos de `brazo_primero` recibieron la misma condición en el mismo orden, por lo que su contraste no estima el efecto de orden y sus valores se consignan solo en el memo de números canónicos. El efecto de *posición* del caso en la secuencia, estimado por correlación de rangos de Spearman, no fue significativo para `O1` ($\rho = -0,0628$, $p = 0,5147$) y sí lo fue para `O2` ($\rho = -0,3604$, $p = 0,00011$). El efecto mínimo detectable es de $\rho = 0,276$. Se calculó como la tangente hiperbólica del efecto mínimo de Fisher con $n = 110$ ($n - 3 = 107$) y la eficiencia de la correlación de Spearman frente a la de Pearson bajo normalidad ($9/\pi^2 \approx 0{,}912$): $\tanh\left((z_{0,975} + z_{0,80})/\sqrt{107 \cdot 0{,}912}\right) = 0{,}276$. Un resultado no significativo no equivale a ausencia de efecto: solo descarta magnitudes mayores que el efecto mínimo detectable de cada contraste.

8.9. Validación fuera de muestra

La validación fuera de muestra se realizó con el clasificador congelado `hybrid-v3` sobre un corpus independiente de 150 casos nuevos, sin solape con los 200 de ajuste y pseudonimizados con el mismo protocolo, con la referencia de consenso de dos etiquetadores independientes. La referencia excluye los 47 casos discordantes y deja un n efectivo de 103. La Tabla 21 reúne las cifras de la validación. Sobre ese n, la exactitud estricta es de 0,8447 y la laxa, de 0,8738. Por etapa de la cascada, la determinística resolvió 69 casos (0,8841) y Gemini 34 (0,7647); no hubo casos de reserva. Ponderada por la composición por sector del corpus de 200, la exactitud estricta baja a 0,8146. Sobre el mismo n efectivo de 103, la macro-F1 de las cinco clases y la *balanced accuracy* (media de las sensibilidades por clase) quedan por debajo de la exactitud estricta por el desbalance de clases. Por clase, la F1 (precisión; sensibilidad; soporte) es de 0,8333 (1,0000; 0,7143; 21) en Seguridad Informatica, 0,9048 (0,8636; 0,9500; 40) en Soporte Tecnico Hardware, 0,8000 (0,7692; 0,8333; 24) en Soporte Tecnico Software, 0,9630 (0,9286; 1,0000; 13) en Bases de Datos y 0,2222 (0,2500; 0,2000; 5) en Sistemas, la clase de menor soporte, cuya confusión dominante es con Soporte Tecnico Software (3 de 5 casos). El kappa de Cohen del clasificador contra la referencia es de 0,7862 (p_o = 0,8447; p_e = 0,2734), una concordancia entre el clasificador y la referencia y no una fiabilidad entre etiquetadores. Todas estas métricas son estimaciones sobre el n efectivo de 103; la macro-F1 no es equivalente de la exactitud estricta de etiqueta única, y con 5 casos en Sistemas la estimación de esa clase es muy imprecisa. El semi-ancho del IC de Wilson de la exactitud estricta (6,98 puntos) queda por debajo del objetivo de diseño de 8,4 puntos. La exclusión de los 47 casos discordantes sesga la referencia hacia los casos más fáciles, de modo que la cifra es una estimación sobre el n efectivo y no una confirmación fuerte del desempeño fuera de la muestra; se lee junto al 0,7350 estricto dentro de la muestra (Subsección 8.5).

La fiabilidad entre los dos etiquetadores independientes se calculó sobre el sector principal de los 150 casos. Coincidieron en 103 (acuerdo observado de 0,6867) y su kappa de Cohen fue de 0,6055, con un intervalo asintótico al 95 % de [0,5186; 0,6924] y un intervalo bootstrap de [0,5175; 0,6839]. El rótulo de Landis y Koch del valor puntual es *sustancial*, y ambos intervalos abarcan las categorías moderada y sustancial. Este valor es menor que el kappa del clasificador contra la referencia (0,7862), que se calcula solo sobre los casos en que los etiquetadores coinciden.

El arbitraje de los casos discordantes se ejecutó: un tercer etiquetador (`E5`, código `P11`) arbitró los 64 casos discordantes (47 originales y 17 del refuerzo) y se sumaron 56 casos de refuerzo, de modo que la referencia cubre 206 casos sin exclusión. Sobre ese n, la exactitud estricta cruda es de 0,6893 (142 de 206; IC de Wilson [0,6231; 0,7486]) y es la cifra primaria; la laxa es de 0,7864 (162 de 206; [0,7255; 0,8369]). Como lecturas complementarias, la exactitud ponderada por la composición por sector del corpus de 200 es de 0,7489 (bootstrap [0,6822; 0,8099]) y la de los 150 casos del diseño original, sin exclusión, de 0,7467 (112 de 150; IC de Wilson [0,6715; 0,8095]); el límite superior de las tres lecturas queda por debajo del umbral de 0,85, de modo que la referencia arbitrada no acredita el umbral. El clasificador acertó 25 de los 47 discordantes originales (0,5319) y 30 de los 56 casos de refuerzo (0,5357); por etapa de la cascada, las reglas determinísticas acertaron 88 de 115 (0,7652) y Gemini 54 de 91 (0,5934). Por origen de la referencia, la exactitud es de 0,7676 sobre el consenso de `E3` y `E4` (109 de 142) y de 0,5156 sobre lo arbitrado por `E5` (33 de 64) (Subsección 8.6). Con la referencia arbitrada, la clase `Sistemas` pasa a 61 casos y deja de ser no estimable; su sensibilidad es de 31/61 (0,5082). La estimación con exclusión sobre el n efectivo de 103 (exactitud estricta 0,8447) se conserva como etapa previa y como cota de sensibilidad.

8.10. Comparación con esquemas alternativos

Comparación con una línea de base clásica. La comparación con un clasificador supervisado clásico se realizó sobre los 206 casos fuera de muestra de la referencia arbitrada, de modo que las cifras son comparables con las del corpus arbitrado de la Tabla 21. La línea de base se entrenó con los 200 casos de ajuste y se evaluó con las mismas funciones puras de métricas que el híbrido. La Tabla 23 reúne las métricas globales. La línea de base (con re-ponderación de clases) queda por debajo del híbrido en las cuatro métricas: 0,4903 frente a 0,6893 en exactitud estricta (101 y 142 aciertos de 206), 0,5874 frente a 0,7864 en exactitud laxa, 0,3884 frente a 0,7024 en macro-F1 y 0,4475 frente a 0,7177 en *balanced accuracy*. Por clase, la línea de base también queda por debajo en las cinco clases: `Seguridad Informatica` 0,4368 frente a 0,6349; `Soporte Tecnico Hardware` 0,6957 frente a 0,8224; `Soporte Tecnico Software` 0,5565 frente a 0,6408; `Bases de Datos` 0,0000 frente a 0,8235; y `Sistemas` 0,2532 frente a 0,5905. La caída de `Bases de Datos` a F1 0,0000 en la línea de base se explica por su único caso de ajuste: el clasificador clásico no puede aprender una clase con un solo ejemplo. La línea de base es un clasificador clásico

Tabla 21. Validación fuera de muestra del clasificador congelado `hybrid-v3` sobre el corpus independiente

Indicador	Valor	Intervalo o nota
Casos del corpus independiente (n primario)	150	—
Casos discordantes entre `E3` y `E4` (excluidos del n de 103)	47	arbitrados por `E5`
n efectivo (consenso de `E3` y `E4`)	103	—
Acuerdo observado entre `E3` y `E4`	0,6867 (103 de 150)	—
Kappa de Cohen entre `E3` y `E4`	0,6055	asintótico [0,5186; 0,6924]; bootstrap [0,5175; 0,6839]
Exactitud estricta del clasificador	0,8447 (87 de 103)	Wilson [0,7625; 0,9021]
Exactitud laxa del clasificador	0,8738 (90 de 103)	Wilson [0,7960; 0,9247]
Exactitud estricta ponderada por sector (etapa previa, corpus de 200)	0,8146	—
Macro-F1 (cinco clases)	0,7447	—
Balanced accuracy	0,7395	—
Kappa del clasificador contra la referencia	0,7862	asintótico [0,6919; 0,8805]
Peor caso, etapa previa (los 47 excluidos fallan)	0,5800 (87 de 150)	cota inferior de sensibilidad
Mejor caso, etapa previa (los 47 excluidos aciertan)	0,8933 (134 de 150)	cota superior de sensibilidad
Cota, etapa previa (excluidos a la tasa del límite inferior de Wilson)	0,8189	análisis de sensibilidad
n efectivo (corpus arbitrado sin exclusión)	206	—
Exactitud estricta (corpus arbitrado, primaria)	0,6893 (142 de 206)	Wilson [0,6231; 0,7486]
Exactitud estricta ponderada (corpus arbitrado, complementaria)	0,7489	bootstrap [0,6822; 0,8099]
Exactitud estricta (150 originales sin exclusión, complementaria)	0,7467 (112 de 150)	Wilson [0,6715; 0,8095]
Exactitud laxa (corpus arbitrado)	0,7864	Wilson [0,7255; 0,8369]

Nota: los escenarios de peor caso, mejor caso y cota son análisis de sensibilidad al sesgo de exclusión, no mediciones del clasificador sobre los casos excluidos. La exclusión de los discordantes sesga la referencia hacia los casos más fáciles. Las filas del corpus arbitrado (206 casos) provienen del arbitraje de `E5` y son mediciones sin exclusión. *Fuente:* elaboración propia a partir del corpus independiente y de las predicciones del clasificador congelado.

Tabla 22. Matriz de confusión y métricas por clase del corpus arbitrado completo ($n = 206$)

Asignado \ Predicho	`Seguridad Informatica`	`Soporte Tecnico Hardware`	`Soporte Tecnico Software`	`Bases de Datos`	`Sistemas`	**Total**
`Seguridad Informatica`	**20**	3	5	0	4	**32**
`Soporte Tecnico Hardware`	0	**44**	2	0	5	**51**
`Soporte Tecnico Software`	3	6	**33**	1	3	**46**
`Bases de Datos`	0	0	1	**14**	1	**16**
`Sistemas`	8	3	16	3	**31**	**61**
Total	**31**	**56**	**57**	**18**	**44**	**206**

Nota: corpus arbitrado completo, sin exclusión por discordancia. Precisión, sensibilidad, F1 y soporte por clase: `Seguridad Informatica` 0,6452 / 0,6250 / 0,6349 / 32; `Soporte Tecnico Hardware` 0,7857 / 0,8627 / 0,8224 / 51; `Soporte Tecnico Software` 0,5789 / 0,7174 / 0,6408 / 46; `Bases de Datos` 0,7778 / 0,8750 / 0,8235 / 16; `Sistemas` 0,7045 / 0,5082 / 0,5905 / 61. Macro-F1 0,7024. *Fuente:* `evaluation/data/campana/analisis/analisis_propagacion_arbitraje_c221.json`.

de TF-IDF y regresión logística, no un modelo ajustado, por lo que la comparación no se presenta como un benchmark definitivo. La lectura ponderada a la prevalencia natural de los 200 casos da, para la línea de base, macro-F1 0,5700 y *balanced accuracy* 0,6715; es una post-estratificación y no una medición nueva. *Fuente:* línea de base y salida arbitrada del híbrido, `evaluation/data/campana/analisis/contraste_linea_de_base_c213_arbitrado.json`.

Tabla 23. Comparación de la línea de base clásica con el híbrido `hybrid-v3` sobre los 206 casos fuera de muestra arbitrados

Métrica	**Línea de base (balanceada)**	**Híbrido `hybrid-v3`**	**Diferencia**
Exactitud estricta	0,4903 (101 de 206)	0,6893 (142 de 206)	$-0,1990$
Exactitud laxa	0,5874 (121 de 206)	0,7864 (162 de 206)	$-0,1990$
Macro-F1 (cinco clases)	0,3884	0,7024	$-0,3140$
Balanced accuracy	0,4475	0,7177	$-0,2702$

Nota: diferencia = línea de base menos híbrido. La línea de base es una unión de TF-IDF de palabras y caracteres con regresión logística regularizada (semilla 42), entrenada con los 200 casos de ajuste y evaluada sobre los 206 casos fuera de muestra arbitrados. No es un modelo ajustado. *Fuente:* línea de base y salida arbitrada del híbrido, `contraste_linea_de_base_c213_arbitrado.json`.

Contraste pareado frente a la línea de base. Como ambos sistemas se evaluaron sobre los mismos 206 casos, la diferencia de exactitud estricta se contrastó con una prueba pareada. En la variante primaria (balanceada), ambos aciertan en 81 casos, solo el híbrido en 61, solo la línea de base en 20 y ninguno en 44. La prueba de McNemar exacta bilateral da $p = 5{,}7 \times 10^{-6}$ (con corrección por continuidad, $p = 8{,}8 \times 10^{-6}$). La diferencia de exactitudes pareadas es

0,1990, con un intervalo de confianza del 95 % bootstrap percentil pareado de [0,1165; 0,2767] (10.000 remuestreos, semilla 20261021). La variante sin re-ponderación es más desfavorable para la línea de base: la diferencia es 0,2621, con intervalo [0,1845; 0,3398]. La diferencia es estadísticamente significativa en este contraste sobre este corpus (Tabla 23). *Fuente:* `evaluation/data/campana/analisis/contraste_linea_de_base_c213_arbitrado.json`.

Contraste frente a un esquema de modelo de lenguaje solo. Para contrastar la hipótesis subsidiaria de eficiencia, el brazo que clasifica cada caso solo con Gemini 3.6 Flash (una sola corrida, temperatura 0,3) se comparó con el híbrido sobre los mismos casos (Tabla 24). Este contraste se informa sobre el bloque de 103 casos fuera de muestra con consenso de `E3` y `E4`, que es la etapa previa y prerregistrada del diseño; la referencia arbitrada de 206 casos de la Tabla 21 es el complemento de exactitud fuera de muestra y se reporta por separado, de modo que las dos estimaciones no se agrupan en una sola. En el bloque primario, el híbrido acierta 87 casos (0,8447) y el brazo de modelo solo 90 (0,8738). Discrepan en 9 casos: en 3 acierta solo el híbrido y en 6 solo el brazo de modelo solo. La prueba de McNemar exacta bilateral da $p = 0{,}5078$ y la diferencia de exactitudes (híbrido menos modelo solo) es $-0{,}0291$, con un intervalo bootstrap percentil pareado de [$-0{,}0874$; 0,0291]. No se detectó diferencia de exactitud, lo que no equivale a que ambos esquemas sean equivalentes. El límite inferior del intervalo queda por debajo del margen de no inferioridad prerregistrado ($-0{,}05$), de modo que no puede afirmarse que el híbrido no sea inferior, y la estimación puntual fuera de muestra favorece al brazo de modelo solo. El componente de exactitud de la regla es, entonces, indeterminado y, con el ahorro cumplido, el veredicto prerregistrado es no concluyente. El brazo de modelo solo no registró fallos ni errores en este bloque.

En eficiencia el resultado es concluyente y favorable al híbrido. El híbrido invocó al modelo en 34 de los 103 casos del bloque primario y el brazo de modelo solo en los 103: la razón de llamadas es 0,3301 (intervalo [0,2427; 0,4175]). La razón de costo de inferencia estimado es 0,3295 ([0,2421; 0,4176]), con USD 0,0222 frente a USD 0,0672 al precio introductorio y USD 0,0443 frente a USD 0,1345 al precio estándar. Ambos límites superiores quedan por debajo del umbral prerregistrado de 0,90, de modo que el ahorro es material y concluyente: el híbrido usó aproximadamente un tercio de las llamadas y del costo de inferencia. Ese ahorro proviene de que las reglas determinísticas resuelven casos sin invocar al modelo; en este bloque aportan ahorro y no exactitud, porque el híbrido no acierta más que el brazo de modelo

Tabla 24. Contraste pareado del híbrido frente al brazo de modelo de lenguaje solo, por bloque

Bloque	n	Exactitud híbrido	Exactitud modelo solo	Diferencia [IC 95 %]	p	Llamadas híbrido	Llamadas modelo solo	Razón de llamadas [IC 95 %]
Primario (fuera de muestra)	103	0,8447 (87)	0,8738 (90)	$-0{,}0291$ [$-0{,}0874$; 0,0291]	0,5078	34	103	0,3301 [0,2427; 0,4175]
Secundario (dentro de muestra)	200	0,7350 (147)	0,6800 (136)	0,0550 [0,0000; 0,1150]	0,0895	69	200	0,3450 [0,2800; 0,4100]

Nota: exactitud estricta, con los casos acertados entre paréntesis; diferencia = híbrido menos modelo solo, con intervalo bootstrap percentil pareado de 10.000 remuestreos (semilla 20261021); p = McNemar exacta bilateral; razón de llamadas = llamadas del híbrido sobre las del modelo solo. El bloque primario es la etapa previa y prerregistrada de 103 casos con consenso de `E3` y `E4` y no se agrupa con la referencia arbitrada de 206 de la Tabla 21, que es el complemento de exactitud. El bloque secundario no es una prueba limpia, porque las reglas del híbrido se ajustaron con esos casos, y es solo informativo; decide el bloque primario. Una sola corrida a temperatura 0,3. *Fuente:* `analisis_brazo_gemini_solo_c215.json`.

solo. La latencia media de clasificación medida del lado del cliente fue menor en el híbrido (357,3 ms frente a 1076,3 ms por caso, con la latencia del modelo imputada donde el híbrido escaló y 0 ms donde resolvieron las reglas, una cota inferior), y no entra en la regla de decisión.

El bloque dentro de la muestra (200 casos) es informativo, rotulado como no limpio y optimista para el híbrido, y no se usa para sostener la hipótesis. Allí el híbrido acierta 147 casos (0,7350) y el brazo de modelo solo 136 (0,6800), con una diferencia de 0,0550 (intervalo [0,0000; 0,1150]), $p = 0{,}0895$ y una razón de llamadas de 0,3450. El control de deriva no mostró señal de inestabilidad: en los casos que el híbrido ya había escalado al modelo, la nueva corrida coincide con la predicción cacheada en 64 de 69 casos dentro de la muestra, en 34 de 34 fuera de ella y en 98 de 103 en conjunto (0,9515), por encima del umbral de 0,90, aunque este control no separa la deriva del modelo del azar de muestreo a temperatura 0,3. Como desviación del prerregistro, 112 casos del bloque dentro de la muestra fallaron en la primera tanda sin llegar al modelo (fallo técnico del proveedor, sin respuesta) y se reintentaron, con 303 llamadas con respuesta del modelo en total; ninguno estaba en el bloque primario y ninguno sigue fallido. La decisión de reintentar se tomó después de ver los resultados, lo que se declara como amenaza a la validez; el veredicto del bloque primario no depende de ella. *Fuente:* `evaluation/data/campana/analisis/analisis_brazo_gemini_solo_c215.json`.

8.11. Capacidad del tramo compartido bajo carga concurrente

Para contrastar la dimensión de capacidad de la hipótesis subsidiaria de integración multicanal se midió el tramo en que convergen los canales con el protocolo de la Subsección 4.5. La Tabla 25 resume la latencia, el throughput y la tasa de error por nivel de concu-

rrencia y por capa. Cada nivel agrupa 120 solicitudes (40 por repetición, 3 repeticiones). La tasa de error fue 0 en los 960 envíos, sin respuestas con error ni vencimientos de plazo, y el registro de clasificación de los 960 incidentes creados muestra la etapa determinística en todos: ninguno escaló al modelo.

Tabla 25. Latencia, throughput y tasa de error por nivel de concurrencia y por capa

Capa	Concurrencia	p50 (ms)	p95 (ms)	p99 (ms)	Throughput (sol./s)	Tasa de error
Backend	1	44,5	62,2	84,6	20,79	0
Backend	5	186,9	290,6	324,5	25,19	0
Backend	10	349,5	457,4	588,3	26,84	0
Backend	20	594,8	1215,8	1293,8	24,21	0
Webhook de N8N	1	307,4	338,4	368,2	3,21	0
Webhook de N8N	5	1339,6	1804,2	2157,3	3,75	0
Webhook de N8N	10	2565,4	3526,5	4065,0	3,82	0
Webhook de N8N	20	4732,6	6788,4	7469,2	3,78	0

Nota: latencia medida por el cliente (envío a respuesta) sobre 120 solicitudes por nivel; la capa «Backend» es el alta autenticada de un incidente y la capa «*Webhook* de N8N» es la entrada del canal web. Una sola máquina, entorno desechable y camino determinístico sin inferencia paga. Fuente: `evaluation/evidence/load_test_multicanal_2026-11-13.json`.

En la capa del backend la regla de decisión se cumple en los cuatro niveles. El p95 máximo es 1215,8 ms, muy por debajo del techo de 5000 ms, y el throughput sube de 20,79 a un máximo de 26,84 solicitudes por segundo con 10 concurrentes y baja a 24,21 con 20: una caída del 9,8 %, dentro de la tolerancia del 10 % por un margen estrecho. El control secundario (cociente de p95 de 19,5, frente a la cota de 20) también se cumple con poca holgura.

La capa del *webhook* de N8N no cumple la regla. Con 20 solicitudes concurrentes el p95 es 6788,4 ms, 1,36 veces el techo, mientras que con 1, 5 y 10 queda por debajo (338,4, 1804,2 y 3526,5 ms). Su throughput se estabiliza en torno a 3,8 solicitudes por segundo desde 5 concurrentes (3,75, 3,82 y 3,78) y la latencia crece con la concurrencia sin que el throughput aumente, que es el patrón de una cola frente a un recurso saturado; el control secundario tampoco se cumple (cociente de 20,06 frente a la cota de 20). No se diagnosticó el origen de la saturación. La latencia de extremo a extremo que registra el servidor para los incidentes creados por esta vía acompaña a la del cliente (mediana de 246,0 ms con 1 solicitud concurrente y de 4118,0 ms con 20); en el alta directa al backend el cliente no sella el instante de ingreso, por lo que solo se informa la latencia del cliente. El veredicto global es «no sostenida», por la violación del techo de latencia en la capa de orquestación con 20 concurrentes. Ninguna solicitud falló: el límite observado es de latencia y no de disponibilidad.

Estas cifras valen para una sola máquina, un perfil desechable, una instancia de N8N con la configuración del *stack* y el camino determinístico, sin inferencia paga; la latencia con

inferencia no se midió. La copia del flujo que se activó en el N8N desechable conserva el camino del canal web pero omite los nodos que exigen credenciales externas (disparadores de correo y telefonía y envíos de correo), por lo que el tiempo de esos envíos no está incluido. Los niveles de 1 a 20 concurrentes se fijaron a priori como niveles de carga y no estiman la demanda real de una mesa de ayuda, que no se midió. Los canales de correo y telefonía quedaron fuera de la inyección concurrente, y el resultado no se extrapola a producción ni a otro hardware. La complejidad operativa percibida no se midió.

8.12. Sensibilidad a la referencia de verdad

La pregunta es cuánto del error observado sobre la referencia arbitrada de 206 casos es atribuible a la fragilidad de esa referencia y cuánto persiste con una etiqueta independiente del acuerdo medido. El método se define en la Subsección 4.7: simulación calibrada al kappa 0,6055 de `E3` y `E4`, $B = 2000$, semilla 20261021, cotas con δ de Wilson y rango de los 6 casos de tres vías. No corrige la exactitud ni mide la verdad latente: genera referencias alternativas plausibles y describe cuánto cambia la métrica.

Tabla 26. Sensibilidad de la exactitud estricta y la macro-F1 a referencias alternativas plausibles

Indicador	Observado	Mediana	q2,5	q97,5
Exactitud estricta	0,6893	0,5097	0,4515	0,5631
Macro-F1 (cinco clases)	0,7024	0,5109	0,4513	0,5692
δ (cota superior de Wilson al 95 %) / cotas	0,3698 / [0,3204; 1,0000]			
Rango de los 6 casos de tres vías	142/206 a 147/206			

Nota: 2000 réplicas con semilla 20261021. Las cotas son de sensibilidad bajo el supuesto de que a lo sumo 76 etiquetas de referencia son erróneas, no mediciones. La simulación no mide la verdad latente. *Fuente:* `evaluation/data/campana/analisis/analisis_ruido_referencia_c216.json`.

Bajo 2000 referencias alternativas, la exactitud estricta tendría mediana 0,5097 e intervalo [0,4515; 0,5631] al 95 %, y la macro-F1, mediana 0,5109 e intervalo [0,4513; 0,5692]; ninguna de las 2000 réplicas alcanza el valor observado de 0,6893. La diferencia con el valor observado no se lee como una exactitud corregida: mide cuán específica es la métrica de esta referencia.

El error observado (64) queda por debajo del intervalo simulado [90; 113]; el error robusto es 90 y el componente atribuible a la referencia, -26. La simulación compara el clasificador contra referencias ruidosas de forma controlada, de modo que su dirección esperada es a la baja; la diferencia con el valor observado cuantifica cuán específica es la métrica respecto de esta referencia y no modifica la cifra reportada. Las cotas distribution-free, con $\delta = 0{,}3698$ y

$m = 76$, dan [0,3204; 1,0000] bajo el supuesto de que a lo sumo 76 etiquetas son erróneas; son cotas de sensibilidad. Los 6 casos de tres vías mueven la exactitud entre 142/206 y 147/206 y no se resuelven eligiendo una etiqueta verdadera: el rango es el resultado.

9. Discusión

9.1. Interpretación de los resultados

Los resultados confirman la hipótesis de trabajo (Subsección 1.4) en el tiempo de registro y la refutan en la clasificación. La hipótesis principal queda así parcialmente confirmada y parcialmente refutada. La reducción del 71,2 % en el tiempo medio de registro es estadísticamente significativa y operativamente relevante. La exactitud estricta del 73,5 % del clasificador automático quedó por debajo del umbral del 85 % del segundo objetivo específico, resultado que se analiza entre las limitaciones. La segunda sub-hipótesis, sobre la proporción de casos con acción manual, queda *no concluyente, con estimación puntual por encima de la cota*. La tasa bruta (147 de 200) mide la derivación por reportante no identificado. La revisión humana alcanzó 66 casos de correo, 81 de telefonía y ninguno de los 53 del formulario web. De los 147 revisados, 25 cambiaron la derivación (17,0 %; IC de Wilson [11,8 %, 23,9 %]), por encima de la cota de 0,15. El intervalo contiene el 0,15 y la prueba binomial unilateral no rechaza la cota ($p = 0{,}28$). El denominador de 147 casos se adoptó después de conocer los datos. Con el denominador prefijado (25 de 200) la regla daba un resultado no concluyente, y con el de 147 su lectura literal daría refutada, pero el intervalo contiene el 0,15 y no se sostiene una refutación. Con ello hay una sub-hipótesis corroborada (tiempo), una no concluyente (intervención humana) y una refutada (exactitud y macro-F1). La validación fuera de muestra, realizada después con el clasificador congelado sobre el corpus independiente, da una exactitud estricta cruda de 0,6893 (142 de 206) sobre el corpus arbitrado completo, sin exclusión, y lecturas complementarias de 0,7489 (ponderada por la composición del corpus de 200) y 0,7467 (150 casos del diseño original, sin exclusión); los límites superiores de las tres lecturas quedan por debajo del umbral de 0,85, de modo que la referencia arbitrada no acredita el umbral (Subsección 8.9). El resultado acota el sesgo de la estimación dentro de la muestra y no reemplaza el veredicto sobre la referencia primaria.

La reducción de tiempo se midió con la inferencia externa incluida y con configuraciones que invocaban al modelo con mayor frecuencia que la evaluada en la clasificación, cuya etapa determinística resuelve el 65,5 % de los casos sin invocar al modelo (Subsección 4.5); esa proporción no interviene en la reducción medida. La hipótesis subsidiaria de eficiencia del esquema híbrido se contrastó con un brazo de modelo de lenguaje solo, con resultado no concluyente (Tabla 24): el ahorro de llamadas y de costo fue concluyente y favorable al híbrido

(aproximadamente un tercio de ambos), pero no se estableció la no inferioridad de la exactitud con el margen prerregistrado y no se detectó diferencia de exactitud. Resolver casos sin el modelo no demuestra por sí solo mayor eficiencia sin comparar la exactitud de cada alternativa. En los 131 casos de esa etapa las reglas aciertan 97/131 (0,7405). Sobre los 130 casos con predicción de ambas etapas, aciertan 96/130 (0,7385) frente a los 88/130 (0,6769) de Gemini, ejecutado con el cortocircuito deshabilitado. Ambas son estimaciones dentro de la muestra y sin diferencia significativa (McNemar exacta bilateral (McNemar, 1947), $p = 0{,}1516$). Además, con el vocabulario previo a su ajuste con el corpus la etapa de reglas no supera a Gemini (Subsección 8.5), por lo que esa ventaja no se toma como evidencia de eficiencia. El costo de inferencia recae así únicamente en los casos que el filtro no resuelve, y la latencia no se midió por etapa. La hipótesis subsidiaria de integración multicanal se contrastó en su dimensión de capacidad con un test de carga de costo cero (Tabla 25), con veredicto «no sostenida»: el punto de convergencia del backend cumplió la regla prerregistrada hasta 20 solicitudes concurrentes (p95 máximo de 1215,8 ms y sin errores), pero la capa de orquestación del canal web superó el techo de 5000 ms con 20 concurrentes (p95 de 6788,4 ms) y estabilizó su throughput en torno a 3,8 solicitudes por segundo desde 5 concurrentes, también sin errores. La medición corresponde a una sola máquina, a un perfil desechable y al camino determinístico, sin inferencia paga; excluye los canales de correo y telefonía y no se extrapola a producción. La complejidad operativa percibida no se midió, de modo que la hipótesis no queda contrastada en esa dimensión.

La dispersión de los tiempos automatizados muestra una compresión sustancial de la variabilidad. El desvío estándar pasa de 44,9 s en el manual a 13,52 s en el automatizado, cerca de la tercera parte, consecuencia de la automatización y no un objetivo del diseño.

Si se proyecta el ahorro medio de tiempo por incidente ($61{,}6 - 17{,}76 = 43{,}8$ s) sobre el volumen trimestral de 2.646 incidentes, la automatización liberaría aproximadamente 32,2 horas-persona brutas por trimestre —unas cuatro jornadas laborales de un operador—,[1] tiempo que el personal podría redirigir a tareas de resolución técnica o a actividades de mejora continua. Ese ahorro es bruto: no descuenta el costo de las derivaciones erróneas que el clasificador agrega respecto del flujo manual, cuyo balance se analiza en la Subsección 9.5.

Sin embargo, la lectura conjunta de la derivación por gate y del análisis de calibración (Sección 8.4) matiza ese resultado, que debe leerse por etapa. El gate del 70 % presupone que

[1] Cálculo: $43{,}8$ s/incidente $\times$ 2.646 incidentes$/3.600$ s/h $\approx 32{,}2$ h-persona por trimestre.

la confianza declarada discrimina los casos correctos de los incorrectos. Solo se evalúa sobre la salida de Gemini y, en el rango observado (0,85 a 1,00), esa confianza no los discrimina. La etapa determinística no emite una confianza utilizable para derivar. La supervisión humana efectiva no puede depender del umbral de confianza: debe complementarse con señales independientes del puntaje —la ambigüedad léxica entre las categorías candidatas o la revisión por muestreo de los casos de alta confianza—. El esquema *human in the loop* conserva su valor de diseño y, en el corpus, actuó por la regla del reportante no identificado: 147 intervenciones (66 de correo y 81 de telefonía) y 25 cambios de derivación (17,0 %; IC [11,8 %, 23,9 %]) (Subsección 8.3). La señal de confianza no discriminó: AUROC 0,5168 y ningún umbral alcanzó el piso, por lo que el gate de 0,70 no derivó casos por confianza (Subsección 11.1).

La exactitud laxa, que acepta como acierto el sector principal predicho cuando integra el conjunto de verdad, alcanza el 89,5 % (179/200) y se lee como la proporción de derivaciones operativamente aceptables, dado que el 53,5 % de los casos admite más de un sector. No es la métrica del segundo objetivo específico y no modifica por sí misma su estado. Por canal, la exactitud estricta fue de 0,654 en la llamada telefónica, 0,773 en el correo electrónico y 0,811 en el formulario web (laxa: 0,864, 0,924 y 0,906), evidencia sobre la dimensión de calidad del tercer objetivo específico y el efecto potencial de la transcripción. La comparación no aísla ese efecto, porque la composición sectorial y la proporción multietiqueta difieren entre canales (49 de 81 telefónicos frente a 15 de 53 del formulario web): la diferencia no se atribuye a la transcripción.

La procedencia de los datos de ajuste merece una observación aparte. Las reglas de frontera del prompt, la ampliación del vocabulario del filtro y el punto de operación del cortocircuito se derivaron de errores observados en el corpus de evaluación. El punto de operación se fijó con validación cruzada fuera de muestra, pero ese protocolo no cubre la ampliación del vocabulario ni las reglas del prompt, definidas sobre la totalidad del corpus. Tampoco la campaña complementaria obtuvo un corpus independiente en su momento. La validación fuera de muestra se realizó después con el clasificador congelado sobre un corpus independiente de 150 casos (Sección 8), que luego se arbitró: sobre el corpus arbitrado de 206 casos, sin exclusión, el clasificador acertó 25 de los 47 discordantes originales (0,5319) y 30 de los 56 casos de refuerzo, y la lectura de los 150 casos del diseño original, sin exclusión, es de 0,7467 (Subsección 8.9). El arbitraje reemplazó al análisis de escenarios: en lugar de suponer qué ocurriría si los discordantes fallaran o acertaran, la referencia arbitrada los mide. La limitación de fon-

do subsiste: el vocabulario del filtro y las reglas del prompt se ajustaron con el mismo corpus de evaluación, de modo que las métricas primarias siguen siendo estimaciones dentro de la muestra, probablemente optimistas; la Subsección 8.5 acota la parte atribuible al vocabulario.

La reducción del tiempo de registro, aunque estadísticamente robusta, admite seis explicaciones rivales. Primero, la asimetría del instrumento: el flujo manual se cronometró en vivo e incluye lectura, comprensión, búsqueda y carga del ticket, mientras que el automatizado se midió con marcas de tiempo del sistema. Eso favorece al segundo. Lo debilita el análisis de sensibilidad, que mantiene la reducción por encima del 65 % aun descontando 10 s por caso. Se descartaría midiendo ambos flujos con el mismo instrumento. Segundo, la mezcla de canales: parte de la diferencia podría reflejar la composición. Lo debilita el desagregado de la Tabla 10, con reducciones del 51,1 al 93,4 % y contraste intra-canal significativo, aunque la magnitud global depende de la composición. Tercero, la novedad o efecto Hawthorne y el aprendizaje del operador: los operadores sabían que se cronometraba, y el procedimiento lo atenúa sin eliminarlo (Subsección 4.2). Además, el enmascaramiento del propósito comparativo no existió para el operador que es autor del trabajo. La atenuación se aplica, a lo sumo, a la mitad del brazo manual, sin dirección declarada por falta de evidencia. El orden temporal de la campaña (manual antes que automatizado) sesga, de hacerlo, en contra de la hipótesis. La campaña complementaria de medición no lo resolvió, porque el brazo manual precedió al automatizado en los 200 casos y el contraste entre grupos `brazo_primero` no estima el efecto de orden. El efecto de *posición* del caso en la secuencia fue significativo para uno de los dos operadores, acotado por su efecto mínimo detectable (Subsección 8.8). Por eso el orden no se descarta como explicación rival. Cuarto, la selección de los 200 casos: es una muestra no probabilística, por conveniencia, de una sola organización, formada por los incidentes que se cronometraron. La magnitud observada no es extrapolable sin nuevas validaciones (Subsección 4.8).

Quinto, la dependencia del operador. En la campaña complementaria, la reducción de la media va del 33,8 % con el operador más rápido al 79,7 % con el más lento (Tabla 20). El tiempo manual no es una propiedad estable del incidente: cambia con quién lo registra. La reducción se mantiene significativa con el operador más rápido, y el agregado (69,3 %) es del mismo orden que el 71,2 % del contraste principal. Esta explicación acota la magnitud de la diferencia, no su sentido. Sexto, la procedencia de las llamadas. Las 81 llamadas las recitó uno de los autores, que conocía el caso y el sistema, a partir de la descripción pseudonimizada

(Subsección 4.8). Un locutor así habla más claro y más breve que un usuario real, lo que pudo favorecer el tiempo medido y la transcripción. Aun así, el canal telefónico obtuvo la exactitud más baja (0,654). Las cifras telefónicas no se extrapolan a usuarios reales. Ninguna de estas explicaciones rivales se descarta por completo con el diseño actual.

El patrón de error más informativo es la confusión sistemática de Sistemas: de los 16 casos asignados, solo 7 se clasificaron correctamente y los errores se repartieron entre Soporte Técnico Software (5), Bases de Datos (2) y Seguridad Informática (2). Esa frontera combina dos causas. La primera es una ambigüedad léxica y taxonómica: las descripciones sobre servidores, plataformas o aplicaciones admiten más de un sector, y la referencia resuelve esa ambigüedad mediante una convención que el clasificador no conoce. La segunda es falta de contexto: muchas entradas son demasiado breves para desambiguar el sector responsable y el modelo carece de señales que un operador obtendría por conocimiento organizacional. Solo la segunda admite mitigación por enriquecimiento del protocolo de captura; la primera exige revisar la taxonomía o el criterio de etiquetado. Cabe advertir, además, que Bases de Datos ($n = 1$) no es estimable: su F1 no debe leerse como evidencia de que el clasificador falla en esa clase, sino como ausencia de soporte estadístico.

La validación fuera de muestra lleva ese patrón a un extremo y confirma que `Sistemas` es la clase de peor desempeño medido. Con la referencia arbitrada, que amplía su soporte, la clase reúne 61 casos (21 del diseño original y 40 del refuerzo): su F1 es de 0,5905, su precisión de 0,7045 y su sensibilidad de 31/61 (0,5082). Los 30 errores no se dirigen a una única clase: 16 van a `Soporte Tecnico Software`, 8 a `Seguridad Informatica`, 3 a `Soporte Tecnico Hardware` y 3 a `Bases de Datos` (Subsección 8.9). Esto refuerza la lectura de este apartado: la frontera entre `Sistemas` y `Soporte Tecnico Software` es, antes que una limitación de capacidad del clasificador, un problema de taxonomía o de criterio de etiquetado, y merece medirse con un diseño que lo aborde. No se afirma que el clasificador vaya a mejorar esa clase: se afirma que hoy su desempeño es bajo y que el límite es, en primer lugar, de definición de la clase.

Esa lectura no equivale a una confirmación concluyente: la evidencia es compatible con explicaciones rivales que el diseño no descarta por completo. Mientras que la reducción observada admite una lectura causal fuerte en el plano práctico —el sistema registra cada incidente en menos tiempo que el proceso manual—, su atribución a cada componente del esquema y su extrapolación a otras organizaciones permanecen abiertas. Las amenazas a la

validez que acotan estas conclusiones están enumeradas en la Subsección 4.8.

9.2. Comparación con la literatura

Los valores de exactitud y F1 macro obtenidos se contrastan a continuación con los reportados en la literatura comparable. Paramesh y Shreedhara (2019) comparan Naive Bayes multinomial, regresión logística, k vecinos más cercanos y SVM sobre tickets reales y reportan buen desempeño de SVM en todas las muestras, sin que el resumen consigne cifras comparables. Revina et al. (2020), en cambio, muestran que los clasificadores simples y explicables construidos con rasgos lingüísticos del dominio son competitivos frente a alternativas más complejas.

Los resultados del presente trabajo —73,5 % de exactitud estricta y un F1 macro de 0,6508 sobre las cuatro clases estimables (0,5207 al incluir la clase de soporte unitario, no estimable)— no admiten una comparación directa con la literatura revisada. Los trabajos citados reportan clasificación de etiqueta única. La evaluación propia se mide contra una referencia multietiqueta sobre cinco sectores canónicos en español rioplatense, tarea considerablemente más exigente. La exactitud laxa (89,5 %) tampoco es comparable con las cifras de etiqueta única y se informa solo como referencia secundaria. Frente al enfoque SVM de Paramesh y Shreedhara (2019) y a la competitividad de los métodos simples de Revina et al. (2020), el esquema propuesto no requiere GPU para inferencia local ni un corpus etiquetado de gran escala. Eso lo hace más accesible para organizaciones medianas, aunque la evidencia no permite ubicar su exactitud frente a la de esos enfoques.

La evidencia de Revina et al. (2020) resulta, en apariencia, contraria al enfoque del presente trabajo, que apuesta por un LLM de propósito general; la tensión, sin embargo, refuerza el análisis: aquellos autores excluyen por diseño las representaciones preentrenadas, al considerar que el vocabulario del dominio podría degradarlas, lo que desaconseja suponer una transferencia no supervisada trivial. Por eso la elección del LLM aquí no se justifica por transferencia pasiva de conocimiento lingüístico, sino por la tarea concreta —clasificación de categoría con contexto instruccional y esquema híbrido de reglas más modelo—, donde el modelo opera como motor de inferencia guiado y no como representación preentrenada sin ajuste.

La literatura de calibración y cascadas (Subsección 3.4) permite leer dos resultados. La confianza de la etapa Gemini se concentró en el extremo superior de la escala y no dis-

criminó aciertos de errores en su rango observado (Subsección 8.4). Esto está en línea con la sobreconfianza y la concentración en el extremo alto de la escala que Xiong et al. (2024) documentan para la confianza verbalizada. Para esos autores, predecir las fallas sigue siendo un desafío; Tian et al. (2023) muestran, sin embargo, que depende de la elicitación. En las cascadas la derivación exige una señal de fiabilidad correlacionada con el acierto y un umbral (Chen et al., 2024; Varshney & Baral, 2022). El cortocircuito de la etapa determinística la adopta con el puntaje de correctitud, que ordena la correctitud esperada sin ser una probabilidad calibrada. La revisión humana, en cambio, depende de la confianza verbalizada de Gemini, la señal que esa literatura describe como sobreconfiada. La eficiencia del esquema híbrido frente a una alternativa solo-modelo se contrastó con resultado no concluyente: ahorro medido y no inferioridad de la exactitud no establecida (Tabla 24). La medición posterior de la calibración (Tabla 15) precisa por qué la derivación por confianza no discriminó: no fue solo que el umbral de 0,70 estuviera mal ubicado, sino que la señal no discrimina. Dentro de la muestra el AUROC de la confianza de Gemini es 0,5168 y ningún umbral candidato alcanza el piso prerregistrado; fuera de la muestra el AUROC es 0,7163, con un intervalo que casi toca 0,5. La recalibración isotónica corrige el nivel, no la capacidad de discriminación (preserva el orden estricto de los puntajes; el AUROC solo baja por los empates que introduce la agrupación de niveles). Es una limitación del diseño que queda medida y no resuelta: reubicar el umbral o recalibrar la confianza no repara la derivación en este corpus, y una señal de incertidumbre distinta exigiría cambiar el contrato o la configuración del clasificador (Subsección 11.1).

La novedad del aporte radica en la validación específica sobre español rioplatense aplicado a un dominio de mesa de ayuda de organización mediana, segmento escasamente cubierto por la literatura previa. Diversos trabajos han señalado que el ajuste y la evaluación de los LLM se concentran en el inglés y que su rendimiento cae en los idiomas con menos recursos (Lai et al., 2023; Xuan et al., 2025). Los resultados del presente trabajo (F1 macro = 0,6508 sobre las cuatro clases estimables) sugieren, de forma indirecta y no comparable con las cifras de etiqueta única de la literatura revisada, que el desempeño en español rioplatense resulta inferior al reportado para el inglés. Esa brecha se atribuye, al menos en parte, al esquema multietiqueta de cinco sectores adoptado en esta evaluación.

9.3. Limitaciones del estudio

El estudio presenta nueve limitaciones que deben considerarse al interpretar los hallazgos y al planificar replicaciones futuras.

Primero, el tamaño de la muestra ($n = 200$) basta para una validación piloto pero no para generalizaciones poblacionales sobre el universo de mesas de ayuda en organizaciones medianas. El intervalo de confianza al 95 % de la exactitud estricta, [67,0 %, 79,1 %], queda íntegramente por debajo del umbral del 85 %, por lo que el segundo objetivo específico no se alcanza; muestras mayores, un corpus más equilibrado y una revisión del clasificador serían necesarios para cerrar la brecha.

Segundo, la circunscripción del corpus a una única organización del sector servicios de la provincia de Mendoza restringe la validez externa de los hallazgos. La distribución de tipos de incidentes, el léxico organizacional y los patrones de redacción pueden variar significativamente entre organizaciones, sectores y regiones.

Tercero, la dependencia operativa de un servicio externo de inferencia condiciona el rendimiento del sistema. Un eventual deterioro del servicio de Gemini 3.6 Flash, un cambio significativo en las condiciones comerciales del proveedor, o una modificación en el comportamiento del modelo debido a actualizaciones afectaría directamente la operación. Esta dependencia es intrínseca al enfoque basado en LLM externo y debe ser gestionada como un riesgo operativo.

Cuarto, los resultados reflejan el comportamiento del modelo en su versión vigente durante la campaña automatizada (`gemini-3.6-flash`, integrada al clasificador el 24 de septiembre de 2026; Figura 11). Las actualizaciones futuras del proveedor pueden modificar tanto el desempeño bruto como la estructura del prompt requerido para alcanzar resultados equivalentes, lo que aconseja la implementación de un régimen de monitoreo continuo de las métricas de clasificación.

Quinto, la comparación con clasificadores alternativos se amplió con una línea de base clásica de TF-IDF y regresión logística, entrenada sobre los 200 casos de ajuste y evaluada sobre los mismos 206 casos fuera de muestra arbitrados que el híbrido (Tabla 23). El híbrido supera a la línea de base en las cuatro métricas globales y en las cinco clases; la línea de base colapsa en `Bases de Datos` (F1 0,0000, con un solo caso de ajuste) y queda muy por debajo en `Sistemas` (F1 0,2532 frente a 0,5905 del híbrido). La diferencia de exactitud estricta

es estadísticamente significativa en el contraste pareado (McNemar exacta, $p = 5{,}7 \times 10^{-6}$). Esa comparación no agota el espacio de alternativas: el esquema de modelo de lenguaje solo se midió aparte, con resultado no concluyente (Tabla 24), pero no se midió un clasificador entrenado sobre el corpus propio acumulado por la organización, que es el escenario de mayor interés práctico. Una comparación sistemática con ese esquema, con partición y código preservados, queda como trabajo futuro.

Sexto, los analistas que etiquetaron la referencia de la campaña 2026-10 operaron también el brazo manual y uno de ellos es autor del trabajo (Subsección 4.4). Eso acota la independencia del *ground truth* de esa campaña. Junto con la falta de registro por caso de la derivación manual, impidió medir sin sesgo la exactitud de ese brazo. La campaña complementaria resolvió esa coincidencia y midió la exactitud del brazo manual con etiquetadores y operadores independientes (Subsección 8.8, Subsección 9.5).

Séptimo, el vocabulario del filtro determinístico y las reglas de frontera del prompt se ajustaron con errores observados en el mismo corpus de evaluación, por lo que las métricas de clasificación son estimaciones dentro de la muestra. Sin ese vocabulario, la exactitud de la etapa determinística baja de 0,7405 a 0,5270. Los autores interpretan esa diferencia como cota pesimista del sesgo atribuible a él (interpretación, no medición: los dos valores se calculan sobre conjuntos de casos distintos). El efecto de las reglas del prompt, acotado por una ablación controlada de dos brazos, es de 50 frente a 46 aciertos sobre los 69 casos de la etapa Gemini (diferencia no significativa; McNemar exacto (McNemar, 1947), $p = 0{,}3438$; `evaluation/report_sensibilidad_ajustes.md`, línea 98) (Subsección 8.5). Solo un corpus independiente permitiría estimar el desempeño fuera de la muestra. Esa validación se realizó después con un corpus independiente de 150 casos y el clasificador congelado; su resultado, con el arbitraje de los casos discordantes, se detalla en la Subsección 8.9. La limitación de fondo —que el ajuste se derivó del mismo corpus— no desaparece del todo (Subsección 8.5).

Octavo, la propia campaña complementaria cuestiona la fiabilidad de la referencia: su doble etiquetado nuevo arrojó un kappa de 0,5569 (moderado; IC [0,4725; 0,6413]; tabla conservada). El doble etiquetado original no conserva registro y no permite un contraste con ese valor (Subsección 4.4). El consenso nuevo coincide con el sector original en 116 de 138 casos (84,1 %). Las métricas primarias se calculan contra la referencia original y heredan esa incertidumbre (Subsección 8.8). Contra el consenso independiente, el límite superior de la exactitud

estricta (0,856) supera el umbral de 0,85: con esa referencia, el criterio de exactitud sería no concluyente, y el macro-F1 (0,757) seguiría por debajo del umbral (Subsección 8.2).

Novena, la única obra del estado del arte cuyo texto completo no pudo consultarse es Paket et al. (2024), de acceso cerrado en IEEE Xplore, cuya ficha se apoya en el resumen publicado. Ante el requerimiento de aportar la copia, los autores intentaron adquirir el PDF en IEEE Xplore y acceder mediante la suscripción institucional de la facultad entre el 7 y el 14 de noviembre de 2026, sin resultado: no fue posible crear una cuenta ni iniciar sesión con ese acceso. La atribución a esa obra queda por tanto acotada a lo que su resumen consigna.

La referencia de verdad se sometió a un análisis de sensibilidad (Subsección 8.12). Bajo 2000 referencias alternativas calibradas al acuerdo `E3`/`E4`, la exactitud estricta tendría mediana 0,5097 e intervalo [0,4515; 0,5631], y el error observado (64) queda por debajo del intervalo simulado [90; 113]; el componente atribuible a la referencia es -26. Se lee como sensibilidad, no como exactitud corregida: la simulación tiene dirección esperada a la baja y cuantifica cuán específica es la métrica de esta referencia sin modificar la cifra reportada, y no respalda que el ruido de la referencia infle el error. No elimina las demás amenazas del criterio 4 (ajuste y evaluación sobre el mismo corpus, instrumentos asimétricos y orden fijo de los brazos).

Dos análisis adicionales acotan, sin eliminarlas, las amenazas de ajuste y evaluación sobre el mismo corpus y de referencia frágil (Subsección 8.6). Con un vocabulario externo al corpus, la etapa determinística acierta 54 de 75 casos cortocircuitados (0,7200) frente a 88 de 115 (0,7652) del vigente: se pierde sobre todo cobertura. La exactitud del clasificador es 0,7676 sobre el consenso y 0,5156 sobre lo arbitrado. Ambos resultados son sensibilidad: la independencia del vocabulario es procedimental, la comparación de precisión no es pareada y la diferencia entre subconjuntos no prueba que la referencia la cause. La ablación mide la etapa determinística y no el híbrido completo: propagar el vocabulario externo exigiría una corrida paga con el modelo que no se realizó, y por eso no se presentan resultados de ella. Ninguno de los dos análisis elimina el ajuste con el mismo corpus, los instrumentos asimétricos ni el orden fijo de los brazos.

El clasificador de la configuración entregada (release `v1.3.0`) es el mismo `hybrid-v3` que el evaluado: entre `bf5e099` y `v1.3.0` el código de `app/classifiers` solo cambia en documentación e importación perezosa, y no cambian el vocabulario, el *prompt* ni los umbrales. Por eso la evaluación de clasificación se refiere también a la configuración entregada y no

requiere una corrida nueva; lo que la entregada agrega respecto de la evaluada —la regla del reportante, el cierre TLS y la política de reintentos— es andamiaje de operación que no interviene en la exactitud de clasificación. Sí difieren las versiones de las dependencias del servicio de inferencia; la posible deriva del modelo alojado es una amenaza ajena al código del clasificador, ya declarada.

9.4. Implicancias prácticas

Desde el punto de vista práctico, los resultados sugieren que organizaciones medianas con volúmenes comparables pueden reducir sustancialmente el tiempo de registro con soluciones híbridas similares, con un saldo neto dependiente de la exactitud efectiva (Subsección 9.5). Automatizar el registro libera al personal técnico para la resolución efectiva de los casos, donde el juicio experto sigue siendo insustituible.

La trazabilidad del registro de cada decisión del clasificador habilita dos procesos de mejora continua. El primero identifica patrones de error sistemáticos y ajusta el filtro determinístico o el prompt. El segundo, con la acumulación sostenida de decisiones validadas por los sectores responsables, constituye un activo informacional que —del orden de 5.000 casos, referencia indicativa, no derivada del corpus ni de un cálculo de potencia— permitiría entrenar modelos específicos del dominio organizacional, con ventajas en costo, latencia y soberanía sobre los datos.

En el plano económico, el costo operativo del sistema se compone de dos rubros principales. El primero es la infraestructura autoalojada: una instancia pública con 2 vCPU y 4 GB de memoria se ofrece a 24 USD/mes. Ese rubro incluye 4.000 GiB de transferencia saliente y 80 GiB de disco SSD. Se le suman, si se contratan, el respaldo automático (entre el 20 % semanal y el 30 % diario del costo de la instancia) y otros servicios de almacenamiento y direccionamiento. El costo mensual se ubica así en el orden de 24 a 32 USD/mes (DigitalOcean, 2026).[2] El segundo rubro es el costo de inferencia del LLM. El precio introductorio vigente del modelo `gemini-3.6-flash` es de 0,75 USD por millón de tokens de entrada y 3,75 USD por millón de tokens de salida (Google, 2026c).[3] Los supuestos explícitos son de aproximadamen-

[2] Precio de lista consultado el 19 de octubre de 2026 en https://www.digitalocean.com/pricing/droplets: Droplet Basic de 2 vCPU y 4 GB, 24 USD/mes, con 4.000 GiB de transferencia y 80 GiB de SSD incluidos; el respaldo automático agrega entre el 20 % (semanal) y el 30 % (diario) del costo de la instancia. No se computan volúmenes adicionales, instantáneas ni direcciones IP reservadas.

[3] Precios de lista consultados el 19 de octubre de 2026 en https://ai.google.dev/gemini-api/docs/pricing: Gemini 3.6 Flash, precio introductorio de 0,75/3,75 USD por millón de tokens de entrada/salida vigente hasta el 31 de diciembre de 2026; desde el 1 de enero de 2027 rige el precio estándar de 1,50/7,50 USD por millón de tokens, que duplica la cifra. Equivalen a $0{,}75 \times 10^{-6}$ y $3{,}75 \times 10^{-6}$ USD por token.

te 800 tokens de entrada (prompt con la descripción de las cinco categorías, un único ejemplo representativo por sector y el incidente) y 30 tokens de salida (JSON estricto con categoría y confianza). Con ellos, cada invocación cuesta del orden de 7×10^{-4} USD, entre 0,0006 y 0,0009 USD según el tamaño del prompt.[4] Para un volumen de 2.646 incidentes trimestrales, con un 34,5 % requiriendo inferencia externa, el costo trimestral de API se sitúa en el orden de 1 USD y en ningún caso por encima de 2 USD, un valor marginal frente a las 32,2 horas-persona brutas liberadas. El costo de la transcripción del canal telefónico queda excluido de este cálculo, porque el modelo (`gemini-3.5-transcribe`) se factura por audio procesado, magnitud que la campaña no registró por caso: el costo reportado corresponde solo a la clasificación.

Un aspecto que excede el alcance técnico pero condiciona la efectividad en operación real es la dimensión organizacional de la adopción. La experiencia de campo indica que los empleados con mayor antigüedad tienden a resistir los cambios de procedimiento, aun con beneficios demostrables, por familiaridad con los procedimientos vigentes y por la percepción —fundada o no— de que el nuevo sistema puede resultar complejo o invasivo. Por eso la puesta en producción se beneficia de un despliegue gradual: un grupo piloto reducido, extensión progresiva a otros sectores y capacitación breve y contextualizada en cada etapa. El enfoque incremental reduce la fricción inicial, ajusta la configuración a cada sector y afianza la confianza de los usuarios finales, condición para que los beneficios cuantificados —reducción del 71,2 % en el tiempo de registro— se traduzcan en mejoras sostenibles.

9.5. Balance neto de la automatización

La proyección de 32,2 horas-persona por trimestre es un ahorro bruto: no descuenta las derivaciones erróneas que el clasificador agrega respecto del flujo manual. Sean $N = 2.646$ incidentes por trimestre (Subsección 9.1), $\Delta t = 43{,}82$ s el ahorro medio por incidente (Sección 8), $e_{\text{aut}} = 0{,}265$ (53/200) la tasa de error estricta del clasificador medida contra el etiquetado original del corpus, e_{man} la tasa de derivación errónea manual (un supuesto de sensibilidad, sin referencia medida; 15 % preliminar; Subsección 1.2) y c el costo de cada una (10 a 15 minutos, estimación propia; Subsección 1.6). El balance neto trimestral, en horas-persona, es $B = (N/3.600)\,[\Delta t - (e_{\text{aut}} - e_{\text{man}})\,c]$ y la exactitud mínima de equilibrio, $a^* =$

[4] Cálculo: $800 \times 10^{-6} \times 0{,}75 + 30 \times 10^{-6} \times 3{,}75 \approx 7 \times 10^{-4}$ USD por invocación; el límite de salida configurado es de 100 tokens y el JSON de respuesta ronda los 15–30 tokens. No se computan reintentos ni la transcripción de voz, que se factura por separado.

$1 - e_{\text{man}} - \Delta t/c$, independiente de N.

Tabla 27. Exactitud mínima de equilibrio y balance neto trimestral según la tasa de derivación errónea manual y el costo por derivación

	Exactitud mínima a^* (%)			**Balance neto B (h-persona)**		
Tasa manual	5 min	10 min	15 min	5 min	10 min	15 min
10 %	75,4	82,7	85,1	−4,2	−40,6	−76,9
15 % (preliminar)	70,4	77,7	80,1	+6,9	−18,5	−43,9
20 %	65,4	72,7	75,1	+17,9	+3,5	−10,8
26,5 % (paridad)	58,9	66,2	68,6	+32,2	+32,2	+32,2

Fuente: elaboración propia a partir de $N = 2.646$, $\Delta t = 43{,}82$ s y $e_{\text{aut}} = 53/200$. Tasas y costos son supuestos de sensibilidad, no mediciones, y e_{aut} se mide contra el etiquetado original. Referencias: exactitud estricta 73,5 % (IC 95 %: [67,0 %; 79,1 %]) y laxa 89,5 % (IC 95 %: [84,5 %; 93,0 %]). Una decimal; con $\Delta t = 43{,}8$ s dos celdas difieren en 0,1.

En la rejilla, con 15 % y entre 10 y 15 minutos por reasignación, el clasificador agrega unas 304 derivaciones erróneas por trimestre, que cuestan entre 50,7 y 76,1 horas-persona frente a las 32,2 de ahorro: un balance de $-18{,}5$ a $-43{,}9$ horas-persona. El equilibrio tolera entre 7,3 y 4,9 puntos porcentuales de error adicional; el observado es de 11,5. El intervalo de Wilson de la exactitud estricta, [67,0 %; 79,1 %], contiene a $a^* = 77{,}7$ % (15 %, 10 minutos), por lo que ni con esos supuestos la muestra fija el signo; con 15 minutos, $a^* = 80{,}1$ % lo supera. El umbral del 85 % equivale a la paridad con el 15 % manual, y a^*, que solo acredita el ahorro de registro, es menos exigente. Con la exactitud laxa, que supera los doce valores de a^*, el balance resultaría positivo en todos los escenarios (de +28,9 a +138,1 horas-persona; +42,1, +52,1 y +62,0 en el central); es, sin embargo, la lectura favorable, porque supone que ninguna derivación a un sector válido genera reasignación.

La rejilla combina, sin embargo, dos referencias distintas. La campaña 2026-10 no midió la exactitud del brazo manual (sin registro por caso de la derivación del operador y con operadores que fijaron la referencia), y la campaña complementaria sí la midió, con etiquetadores y operadores independientes. De su exactitud estricta agregada por derivación (0,8278; 125 de 151) se deriva $e_{\text{man}} = 26/151 = 0{,}1722$, medida contra el consenso de $\texttt{E1}$ y $\texttt{E2}$, que excluye los casos discordantes, y contada por derivación de operador y no por caso. La tasa $e_{\text{aut}} = 53/200$, en cambio, se mide contra el etiquetado original. Esa mezcla penaliza al clasificador: la diferencia $e_{\text{aut}} - e_{\text{man}}$ es de $0{,}0928$ con referencias mezcladas. Contra el mismo consenso el clasificador falla en 28 de 138 casos ($e_{\text{aut}} = 0{,}2029$) y la diferencia baja a $+0{,}0307$, con un intervalo bootstrap por caso al 95 % de $[-0{,}0460;\ +0{,}1070]$.

Con ambas tasas medidas contra el consenso, el balance neto estimado es positivo: $+25{,}4$, $+18{,}7$ y $+11{,}9$ horas-persona por trimestre con 5, 10 y 15 minutos por derivación erró-

nea, y $a^* = 68{,}2$ %, 75,5 % y 77,9 %. La exactitud estricta del clasificador contra ese consenso (0,7971) supera los tres valores, aunque su intervalo de Wilson [0,7224; 0,8557] contiene a los de 10 y 15 minutos. El intervalo bootstrap por caso al 95 % de B es [$+8{,}6$; $+42{,}4$] con 5 minutos, que fija el signo positivo, y [$-15{,}0$; $+52{,}5$] y [$-38{,}6$; $+62{,}7$] con 10 y 15 minutos, que incluyen el cero. La muestra solo fija el signo con 5 minutos por derivación. Con 10 y 15 depende del costo c, una estimación propia que la campaña no cronometró, por lo que el balance se declara *condicional*. Si ambas tasas se miden contra el etiquetado original, el brazo manual acierta de forma estricta en 143 de 220 derivaciones ($e_{\text{man}} = 0{,}35$) y el balance es positivo con los tres costos (de $+51{,}0$ a $+88{,}4$ horas-persona, con intervalos por encima del cero). Esa segunda referencia compara contra un único sector asignado cuando el 53,5 % de los casos admite más de uno, por lo que se informa como complemento y no como lectura principal.

La referencia común no iguala todas las diferencias. e_{aut} se cuenta por caso y e_{man} por derivación, y 13 de los 138 casos tienen doble cobertura de los operadores. Δt proviene de la campaña 2026-10, que cronometró la carga completa del ticket, mientras que el brazo manual de la campaña complementaria mide solo la decisión de sector; los intervalos lo tratan como constante. El consenso excluye los casos discordantes entre etiquetadores, que sesgan la referencia hacia los casos más fáciles, para ambas tasas. El 26,5 % sigue siendo una cota superior de la tasa operativa, porque el 53,5 % de los casos admite más de un sector.

Como sensibilidad adicional se recalcula el balance con la tasa de error fuera de muestra, rotulada como sensibilidad que mezcla corpus y referencias y que no reemplaza el balance con referencia común. Con la exactitud ponderada ($e_{\text{aut}} = 1 - 0{,}7489 = 0{,}2511$), el balance es de $+14{,}8$, $-2{,}6$ y $-20{,}0$ horas-persona por trimestre con 5, 10 y 15 minutos por derivación, y de $+28{,}2$ con el costo medido de 69,51 s (Sección 3.31); con la exactitud cruda ($e_{\text{aut}} = 64/206 = 0{,}3107$), es de $+1{,}7$, $-28{,}9$ y $-59{,}4$ horas-persona, y de $+25{,}1$ con 69,51 s. El signo depende, así, de la exactitud de referencia y del costo por derivación.

En síntesis, con una referencia común el balance neto no resulta negativo: es positivo en la estimación puntual con los tres costos, pero el signo depende de la exactitud de referencia y del costo por derivación, y la muestra solo lo fija con 5 minutos. Queda sostenida la viabilidad técnica (reducción del 71,2 % del tiempo de registro) y el costo monetario de la inferencia es marginal; la viabilidad económica y operativa permanece condicional al costo por derivación errónea. Cronometrar las reasignaciones es una línea futura (Subsección 11.7).

9.6. Reflexiones sobre la generalización

La generalización a otras organizaciones requiere tres condiciones. La primera es un corpus etiquetado de tamaño y calidad similares, que implica inversión inicial en doble etiquetado y validación del acuerdo inter-evaluador. La segunda es la viabilidad técnica de desplegar localmente la infraestructura de orquestación y persistencia, que descarta a organizaciones sin capacidades mínimas para administrar contenedores Docker. La tercera es un marco normativo compatible con enviar fragmentos descriptivos a un servicio externo de inferencia, que en la Argentina contempla la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000) bajo las condiciones de minimización y disociación de la Sección 7.

10. Conclusiones

El trabajo desarrollado ha cumplido parcialmente el objetivo general de evaluar la viabilidad y el desempeño de la automatización del registro inicial de incidentes, con el desarrollo y la implementación del sistema como medio. La combinación de N8N como orquestación, FastAPI como núcleo de procesamiento, PostgreSQL como persistencia, Twilio como canal telefónico y Gemini 3.6 Flash como motor de inferencia resultó técnicamente viable y eficiente en el registro. El costo monetario de la inferencia es marginal. Con una referencia común, el balance neto estimado es positivo, pero la muestra solo fija su signo con 5 minutos por derivación errónea (Subsección 9.5), por lo que la viabilidad económica y operativa queda condicionada. Ese cumplimiento no se extiende al segundo objetivo específico. La exactitud estricta y el macro-F1 de umbral quedaron por debajo de las cotas mínimas de 85 % y 0,85 fijadas a priori como criterio de éxito (Subsección 8.2), por lo que ese objetivo no se alcanza. La reducción del tiempo de registro sí se sostiene como resultado central, con significación estadística (Sección 8). Por sub-hipótesis, la hipótesis principal se confirma en tiempo de registro, queda no concluyente en intervención humana, con estimación puntual por encima de la cota, y se refuta en el umbral de clasificación. Hay, en suma, una sub-hipótesis corroborada, una no concluyente y una refutada. La hipótesis subsidiaria de eficiencia se contrastó con resultado no concluyente: el ahorro de llamadas y de costo fue concluyente y favorable al híbrido, pero la no inferioridad de la exactitud con el margen prerregistrado quedó indeterminada (Tabla 24); la de integración multicanal se contrastó solo en su dimensión de capacidad, con veredicto «no sostenida» en la capa de orquestación con 20 solicitudes concurrentes y sin cuello de botella en el punto de convergencia del backend (Tabla 25); la complejidad percibida no se midió (Subsección 9.1).

10.1. Cumplimiento de los objetivos del trabajo

La Tabla 28 sintetiza el grado de cumplimiento de cada objetivo y la evidencia que lo respalda.

La arquitectura de cinco capas distribuyó las responsabilidades entre componentes comunicados mediante interfaces REST, y la elección de tecnologías maduras y autoalojadas (Docker, PostgreSQL, N8N) respondió a las restricciones presupuestarias, cambiarias y normativas de las organizaciones medianas argentinas. El primer objetivo específico se alcanza solo parcialmente. La invocación de N8N al servicio de clasificación es sincrónica y la termi-

Tabla 28. Cumplimiento de los objetivos del trabajo y evidencia de respaldo

Objetivo	Cumplimiento	Evidencia
Objetivo general: viabilidad y desempeño	Alcanzado parcialmente	Tiempo de registro alcanzado (71,2 %); clasificación por debajo del umbral (objetivo 2); intervención humana no concluyente, con estimación puntual por encima de la cota (25 de 147, 17,0 %, frente a la cota de 0,15); viabilidad operativa condicionada (Subsección 9.5)
Objetivo específico 1: arquitectura	Alcanzado parcialmente	Sección 5; alta sincrónica con reintentos idempotentes de la configuración entregada (Subsección 6.5) y TLS 1.2/1.3 verificado después de la campaña, en el despliegue de referencia (Subsección 5.1)
Objetivo específico 2: clasificador	No alcanzado	Exactitud 73,5 %, IC [67,0 %, 79,1 %]; macro-F1 de umbral 0,6508 (0,5207 con cinco clases, una no estimable); fuera de muestra, 0,6893 sobre el corpus arbitrado de 206 (primaria, sin exclusión), con lecturas complementarias de 0,7489 (ponderada) y 0,7467 (150 originales); la estimación con exclusión de 0,8447 sobre el n efectivo de 103 queda rotulada como etapa previa (Tabla 21)
Objetivo específico 3: tres canales	Alcanzado parcialmente	Subsección 5.2; latencia y exactitud por canal (Tabla 12); complejidad percibida no medida
Objetivo específico 4: comparación	Alcanzado parcialmente	Subsección 8.1; exactitud del brazo manual medida y contrastada frente al automatizado (Subsección 8.8); alcanzado en tiempo y en esa exactitud; intervención humana no concluyente (25 de 147; el intervalo contiene 0,15 y la regla del reportante acotó la revisión)
Objetivo específico 5: documentación	Alcanzado	Anexo B; Sección 11
Objetivo específico 6: errores/calibración	Alcanzado parcialmente	Subsección 8.7; Subsección 8.4; Subsección 8.5; Subsección 11.1; confianza sin recalibrar; en la muestra; calibración y punto de operación medidos (Tabla 15): ningún umbral alcanza el piso dentro de la muestra y la recalibración no repara el orden

Fuente: elaboración propia.

nación TLS 1.2/1.3 se verificó después de la campaña, en el despliegue de referencia y no en la configuración evaluada ni en la instancia operativa (Tabla 29).

Sobre esa arquitectura se construyó el clasificador híbrido, cuyo desempeño sobre el corpus real quedó por debajo de las cotas mínimas fijadas en el segundo objetivo específico, por lo que ese objetivo no se alcanza. La brecha se analiza en la Sección 9. Las exactitudes estricta y laxa, por etapa y por canal, se presentan en la Tabla 12 y son estimaciones dentro de la muestra. La estrategia compositiva combina un filtro determinístico de primera etapa y un modelo de lenguaje grande reservado para los casos que el filtro no resuelve (Subsección 5.5). Que esa estrategia sea más eficiente que un esquema solo de modelo se contrastó con resultado no concluyente: usó aproximadamente un tercio de las llamadas y del costo de inferencia, sin diferencia de exactitud detectada, pero sin establecer la no inferioridad con el margen fijado (Tabla 24). La validación fuera de muestra con el clasificador congelado se detalla en la Subsección 8.9: el arbitraje de los casos discordantes se ejecutó, la referencia arbitrada cubre 206 casos sin exclusión y la exactitud estricta es de 0,6893, por lo que la cifra no acredita el umbral. El segundo objetivo sigue sin alcanzarse. Entre las cinco clases, la de peor desempeño medido es `Sistemas`: con el soporte ampliado a 61 casos su F1 es de 0,5905 y su sensibilidad de 31/61, y los errores se reparten entre `Soporte Tecnico Software` (16), `Seguridad Informatica` (8), `Soporte Tecnico Hardware` (3) y `Bases de Datos` (3) (Tabla 22); su frontera es un problema de taxonomía o de criterio de etiquetado que este estudio no resuelve (Subsección 11.3).

Los tres canales quedaron integrados en un único flujo de orquestación. El canal telefónico incorpora la transcripción automática del habla, y su tiempo de registro incluye la duración de la llamada grabada, acotada a 45 s (Subsección 4.6). Ese tiempo se midió con llamadas recitadas por uno de los autores a partir de descripciones pseudonimizadas. Es, por lo tanto, una cota inferior de la duración real y no se extrapola a usuarios reales (Subsección 4.8). La normalización de la entrada se realiza en el propio N8N, antes de invocar al servicio de clasificación. La capacidad del tramo compartido se contrastó con un test de carga de costo cero (Tabla 25): el punto de convergencia del backend sostuvo hasta 20 solicitudes concurrentes sin errores, pero el *webhook* de N8N superó el techo prerregistrado de latencia con 20 concurrentes, de modo que el veredicto es «no sostenida». La medición es de una sola máquina, sobre el camino determinístico y sin los canales de correo y telefonía, y no se extrapola a producción. La complejidad percibida no se midió, por lo que la hipótesis no queda contrastada

en esa dimensión. El tercer objetivo específico se alcanza parcialmente (latencia y exactitud medidas por canal).

La evaluación comparativa entre el flujo manual y el automatizado se presenta en la Subsección 8.1 y se interpreta, con sus alcances y límites, en la Subsección 9.1. El sistema automatizado resultó más rápido que el operador humano en la gran mayoría de los pares medidos, con la reducción del tiempo de registro como resultado central. La campaña complementaria de medición midió la exactitud del brazo manual y la contrastó con la del brazo automatizado. Su resultado sobre la segunda sub-hipótesis, de intervención humana, es no concluyente, con estimación puntual por encima de la cota (Subsección 8.3). La revisión humana actuó por la regla del reportante (147; 25 cambios, 17,0 %) y la confianza no discriminó (AUROC 0,5168). El brazo manual precedió al automatizado en los 200 casos, por lo que el efecto de orden no se resolvió. Solo el efecto de posición fue significativo, para uno de los dos operadores. Con ello el cuarto objetivo específico se alcanza parcialmente, en tiempo y en exactitud del brazo manual. El saldo neto del ahorro de registro frente a las derivaciones erróneas permanece condicional al costo (Subsección 8.8, Subsección 9.5).

La documentación generada —arquitectura, procedimientos de despliegue, especificación OpenAPI, flujo N8N exportable, análisis tipificado de errores y bandas de confianza— constituye el aporte documental del quinto objetivo específico y sustenta parcialmente el sexto. La tipología de tres patrones de error (descripciones cortas, mezcla de categorías y jerga local) ofrece un punto de partida para replicar o adaptar el sistema y anticipar fallos probables.

10.2. Aportes y generalización

Más allá del cumplimiento de los objetivos específicos, los resultados permiten formular una conclusión acotada a este corpus y al contraste efectivamente realizados. En este corpus de 200 incidentes de mesa de ayuda, en español rioplatense y con cinco categorías canónicas, un modelo de lenguaje grande invocado mediante instrucciones contextualizadas —sin ajuste fino— resultó una alternativa técnicamente viable para la clasificación de tickets, aunque su exactitud no alcanza el umbral de 0,85 ni dentro ni fuera de la muestra. Esa viabilidad se sostiene cuando se combina con un filtro determinístico. Fuera de la muestra, sobre el corpus arbitrado, la etapa Gemini acertó 54 de 91 casos (0,5934) frente a 88 de 115 (0,7652) de las reglas determinísticas; la comparación no es directa, porque la etapa Gemini recibe los casos que las reglas no resuelven, y el brazo que clasifica solo con el modelo no mostró diferencia de

exactitud sobre los 103 casos con consenso (Tabla 24). Ese filtro resolvió 131 de los 200 casos sin invocar al modelo; que eso reduzca el costo o mejore la eficiencia frente a un esquema solo de modelo se contrastó con resultado no concluyente: ahorro concluyente y favorable, y no inferioridad de la exactitud no establecida (Tabla 24). Esta lectura se limita a este dominio. La comparación con un clasificador clásico entrenado sobre el mismo corpus se realizó y el híbrido la supera, con una diferencia estadísticamente significativa en el contraste pareado (Tabla 23), pero el esquema de modelo de lenguaje solo se midió con resultado no concluyente y no se midió un clasificador entrenado sobre el corpus propio de la organización, por lo que no se sostiene aquí una superioridad general de los modelos de lenguaje (véase la Subsección 9.3).

Esta combinación arquitectónica —orquestación visual, filtrado determinístico y LLM como árbitro semántico— constituye un patrón de diseño reproducible en una organización mediana argentina, el único contexto en que se evaluó. Su transferencia a otras organizaciones de la región, donde la restricción presupuestaria y la soberanía de datos también pueden ser determinantes, es una hipótesis por validar. La arquitectura propuesta no requiere GPU propia, pero depende de servicios externos (Gemini API y Twilio) y de N8N; su costo monetario, dominado por la infraestructura y no por la inferencia, se cuantifica en la Subsección 9.4.

El trabajo aporta tres contribuciones que se sostienen más allá del caso particular. La primera es una arquitectura reproducible documentada en todos sus niveles —modelo de datos, contrato REST y flujo de orquestación—, replicable por cualquier equipo con conocimientos básicos de Docker, Python y N8N. La segunda es evidencia empírica, bajo un diseño cuasiexperimental con muestras pareadas, doble etiquetado (de acuerdo moderado, kappa de 0,5569, en la campaña complementaria) y prueba no paramétrica, sobre el desempeño de LLM en un dominio y una variante lingüística escasamente documentados. Sus límites de independencia y de fiabilidad de la referencia se declaran en la Subsección 9.3. La tercera es un marco de implementación que identifica desde el diseño las condiciones normativas argentinas. La operación con datos reales queda condicionada a la suscripción del instrumento de transferencia internacional, que aún no está suscrito, y el audio cruza al exterior antes de pseudonimizarse (Subsección 7.3).

11. Recomendaciones y líneas de trabajo futuro

A partir de los resultados, del análisis de errores (Subsección 8.7), de la calibración y la intervención humana medidas (Subsección 8.4, Subsección 8.3) y de las limitaciones (Subsección 9.3), se formulan recomendaciones y líneas de trabajo futuro en tres niveles de prioridad, y el orden de las subsecciones siguientes los respeta. El primer nivel ataca los defectos medidos: la calibración del gate de confianza (Subsección 11.1) y el clasificador supervisado con corpus propio (Subsección 11.2). El segundo fortalece la evidencia o el clasificador y agrupa las líneas ancladas a una limitación medida: el análisis de la taxonomía en la frontera entre `Sistemas` y `Soporte Tecnico Software` (Subsección 11.3), la medición de la intervención humana con reportantes identificados (Subsección 11.4), cuya sub-hipótesis la campaña complementaria dejó no concluyente con estimación puntual por encima de la cota (Subsección 8.3), la extensión de la validación independiente a otros corpus (Subsección 11.5), el aprendizaje activo (Subsección 11.6), la replicación (Subsección 11.7) y la evaluación de modelos abiertos (Subsección 11.8). El tercer nivel reúne las extensiones funcionales que amplían el alcance sin alterar la validez de lo medido: la cola de respaldo del alta (Subsección 11.9) y un conjunto de ampliaciones de producto que no derivan de ninguna limitación medida (Subsección 11.10).

11.1. Calibración del gate de confianza

Por etapa (Subsección 8.4), el gate de 0,70 solo se evalúa sobre la salida de Gemini, la etapa de reserva deriva siempre a revisión y la etapa determinística no deriva por su confianza y se rige por su puntaje de correctitud (Subsección 5.5). La confianza autodeclarada de Gemini, concentrada entre 0,85 y 1,00, no discrimina aciertos de errores, por lo que el gate no derivó ningún caso. Lo que antes era una propuesta se midió, y no alcanza (Tabla 15). Con una regla fijada de antemano y elegida solo con los 200 casos, ningún umbral alcanza el piso de exactitud selectiva dentro de la muestra, de modo que no hay política que confirmar fuera de ella. Las dos señales independientes del puntaje que se pueden recomputar sin costo (el acuerdo entre etapas y el puntaje de correctitud de las reglas) son degeneradas, porque en los casos que escalan a Gemini las reglas no tienen un sector ganador. La recalibración isotónica (Niculescu-Mizil & Caruana, 2005) corrige el nivel de la confianza, sobreconfiada y dependiente de la elicitación (Tian et al., 2023; Xiong et al., 2024), pero no la capacidad de discriminación: su carácter monótono preserva el orden estricto y el AUROC solo baja por los empates de la agrupación. En este corpus, entonces, la derivación por confianza autodeclarada no se repara

por recalibración ni por reubicación del umbral, y el gate de 0,70 no derivó casos; la revisión humana actuó por la regla del reportante (147; 25; 17,0 %; Subsección 8.3). Lo que queda como trabajo futuro es lo que exige cambiar el contrato o la configuración del clasificador, sin que esta tesis afirme que funcionaría: (i) otra señal de incertidumbre, como la autoconsistencia por muestreo repetido, las probabilidades de los *tokens* de salida o el acuerdo con un segundo clasificador, o el margen entre las dos primeras categorías, que exige ampliar el contrato de salida (Anexo H); (ii) la revisión por muestreo de casos de alta confianza (Subsección 2.4), que no depende de la calidad de la señal; y (iii) el escalado de temperatura (Guo et al., 2017) si se obtienen puntajes por categoría. Cualquiera de ellas debería evaluarse con la misma disciplina: umbral elegido en un conjunto, con un piso declarado antes de observarlo, y confirmado en un corpus independiente (Subsección 11.5). Esa evaluación permitiría contrastar también los parámetros de inferencia, sin optimización documentada (Subsección 5.4).

11.2. Incorporación de un clasificador supervisado con corpus propio

Se sugiere incorporar progresivamente un clasificador supervisado entrenado con el corpus etiquetado generado por el propio sistema durante su operación. La acumulación sostenida de decisiones validadas por los sectores responsables constituye un activo informacional valioso que, una vez alcanzado un volumen del orden de magnitud indicado en la Subsección 9.4, permitiría entrenar modelos de clasificación específicos del dominio organizacional. Las ventajas potenciales de esta migración incluyen: reducción del costo marginal por incidente clasificado al eliminar la dependencia del servicio externo de inferencia, disminución de la latencia al ejecutar la inferencia localmente, y ganancia de soberanía sobre los datos al evitar la transferencia internacional de fragmentos textuales. La disponibilidad de modelos de pesos abiertos, como Llama 2 (Touvron et al., 2023), abre una vía hacia un sistema completamente autoalojado; sin embargo, en clasificación de tickets con muchas clases los modelos tipo BERT superaron a LLM abiertos como Llama y Mistral (Paket et al., 2024), por lo que esa vía debería evaluarse con modelos ajustados al dominio y no solo mediante *prompts*. Esta línea responde a la limitación que subsiste: la comparación con un clasificador clásico ya se midió y el híbrido la supera (Tabla 23), pero no se midió un clasificador entrenado sobre el corpus propio acumulado por la organización, y el esquema de modelo de lenguaje solo se midió con resultado no concluyente (Tabla 24; Subsección 9.3), y el volumen indicado es el tamaño de muestra objetivo para esa comparación. Para obtener un veredicto concluyente sobre la efi-

ciencia frente al esquema de modelo de lenguaje solo, el contraste debería repetirse con más casos fuera de muestra y con corridas repetidas, que eleven la potencia del margen de no inferioridad de cinco puntos.

11.3. Medición de la frontera `Sistemas–Soporte Tecnico Software`

La clase de peor desempeño medido es `Sistemas`: con la referencia arbitrada reúne 61 casos (21 del diseño original y 40 del refuerzo), con una F1 de 0,5905, una precisión de 0,7045 y una sensibilidad de 31/61, y sus 30 errores se reparten entre `Soporte Tecnico Software` (16), `Seguridad Informatica` (8), `Soporte Tecnico Hardware` (3) y `Bases de Datos` (3) (Tabla 22). El error es sistemático pero no se dirige a una única clase. Esa frontera es, antes que una limitación de capacidad del clasificador, un problema de taxonomía o de criterio de etiquetado (Subsección 9.1). La línea de trabajo futuro es el análisis de la taxonomía con los casos disponibles: revisar las definiciones de `Sistemas` y de `Soporte Tecnico Software`, examinar los casos de error y ajustar el codebook de etiquetado. El criterio de éxito es que la revisión reduzca la ambigüedad de la frontera, medida como la proporción de casos que los etiquetadores asignan a una sola clase tras la revisión. No se afirma que el clasificador vaya a mejorar esa clase: se propone analizar la taxonomía.

11.4. Medición continua de la intervención humana en operación

La campaña complementaria dejó la segunda sub-hipótesis no concluyente, con estimación puntual por encima de la cota: sus 147 intervenciones corresponden a la derivación por reportante no identificado y no a la confianza, y de los 147 casos que tuvieron revisión humana (66 de correo y 81 de telefonía) 25 cambiaron la derivación (17,0 %; IC [11,8 %, 23,9 %]; Subsección 8.3). La tasa bruta del 73,5 % mide la configuración de la prueba y no un defecto del clasificador. El denominador de 147 casos se fijó después de conocer los datos, por lo que una réplica debería prefijarlo junto con la regla de decisión. Se recomienda repetir la medición con reportantes identificados en el directorio y evaluar entonces el refinamiento del clasificador y del gate —mediante las señales independientes del puntaje y la recalibración de la Subsección 11.1— contra la proporción de intervenciones que cambian la derivación. Tres requisitos acotan esa medición futura. Que la revisión alcance a todos los canales, o a una muestra aleatoria de cada uno, para que el denominador sea el de los casos revisables; que cada validación se coteje con una referencia independiente, para medir cuántas veces la revisión acierta y no solo cuántas cambia; y que la muestra se dimensione para que el límite

superior del intervalo de Wilson pueda quedar por debajo de 0,15: con una proporción cercana a la cota, una muestra del orden de 150 casos no permite declarar compatibilidad. Para vigilarla se propone registrar, en operación y para cada caso, la ocurrencia y el origen de la intervención (derivación por el gate, revisión por muestreo, corrección o rederivación por el sector receptor, completado manual de datos), una consigna de tiempo de inicio y de fin, el resultado (categoría confirmada o corregida) y el operador, pseudonimizado. El registro ampliaría `clasificacion_log`, que hoy guarda el indicador de revisión y la categoría validada, o se llevaría en una tabla dedicada vinculada al incidente, preferible cuando un incidente acumula varias intervenciones. La definición operacional seguiría las dos formas rotuladas de la Tabla 3 —proporción de casos y proporción del tiempo del proceso— y se aplicaría de igual modo en ambos brazos. El mismo registro mediría las derivaciones erróneas y su costo en tiempo, insumos del balance neto (Subsección 9.5).

11.5. Validación sobre un corpus independiente

El clasificador evaluado se ajustó, en parte, con el mismo corpus sobre el que se reportan las métricas de clasificación (vocabulario del filtro determinístico y reglas de frontera del prompt), por lo que esas métricas son estimaciones dentro de la muestra (Subsección 8.5). La validación fuera de muestra con el clasificador congelado se realizó sobre un corpus independiente, etiquetado con el mismo protocolo, sin solapamiento con el corpus de evaluación y con los casos discordantes ya arbitrados (Subsección 8.9). Resta como trabajo futuro repetirla sobre corpus de composición natural, con cuotas prefijadas por canal y por sector y con arbitraje por mayoría de tres etiquetadores, en lugar de la regla actual en que decide un único tercer etiquetador. El criterio de éxito es que el intervalo de confianza se estime sobre el universo completo, sin excluir casos.

11.6. Mecanismos de aprendizaje activo

Se propone incorporar mecanismos de aprendizaje activo (*active learning*; Subsección 2.4) que seleccionen los casos para revisión y reentrenamiento mediante las señales independientes del puntaje de la Subsección 11.1: ambigüedad léxica, margen entre categorías, desacuerdo entre etapas y muestreo de casos de alta confianza. La confianza declarada solo se usaría como criterio de prioridad una vez recalibrada y validada según esa subsección, porque en el rango observado de Gemini no discrimina aciertos de errores y la etapa determinística no emite una confianza utilizable. Las revisiones que alimenten el ajuste incremental

serían las registradas según la Subsección 11.4, para que cada intervención mejore al clasificador con un costo operativo controlado. El criterio de éxito es que la selección por aprendizaje activo eleve la proporción de errores detectados por revisión respecto de una selección por muestreo uniforme, sin aumentar la carga de revisión por caso.

11.7. Estudios de replicación

Se sugiere realizar estudios de replicación en organizaciones de distinto tamaño, sector y región geográfica, para fortalecer la validez externa de los hallazgos y reunir evidencia empírica sobre soluciones similares en contextos heterogéneos. Serían relevantes las réplicas en organizaciones del sector público (con más incidentes de sistemas administrativos), del sector industrial (con más incidentes de infraestructura física) y de mayor tamaño, donde el volumen diario supere las 100 unidades. La exactitud del flujo manual sobre el mismo corpus ya se midió en la campaña complementaria de medición, con etiquetadores distintos de los operadores del brazo manual (Subsección 8.8); toda replicación debería conservar ese criterio de independencia y, además, cronometrar las reasignaciones, que el análisis de esa campaña no registró (Subsección 9.5). Convendría, asimismo, una asignación muestral no proporcional que sobremuestree las clases minoritarias —como Bases de Datos, con un solo caso— y pondere las estimaciones globales por la distribución del universo (Subsección 4.4).

11.8. Evaluación de modelos de lenguaje de código abierto

Se propone evaluar la integración de modelos de lenguaje de código abierto desplegados localmente —tales como Llama 3, Mistral o Qwen— como alternativa al modelo externo Gemini 3.6 Flash. Esta evaluación permitiría cuantificar el costo en exactitud frente a la ganancia en soberanía de datos, la eliminación de la dependencia de un proveedor único y la reducción de costos operativos a largo plazo. La realización de un benchmark comparativo sobre un corpus independiente del de 200 casos usado para ajustar el clasificador, con partición y código preservados, constituiría una contribución adicional significativa al estado del arte. Esta línea responde a la dependencia medida de un servicio externo de inferencia (Subsección 9.3); su criterio de éxito es cuantificar la pérdida o ganancia de exactitud frente a Gemini 3.6 Flash sobre ese corpus independiente.

11.9. Cola de respaldo y alta asincrónica

La invocación de alta es sincrónica. Una evolución de mayor alcance la desacopla mediante un patrón *outbox* o un intermediario de mensajes con reproceso, para que el alta se persista de forma diferida. Esa línea tensiona la respuesta sincrónica que el formulario web consume para informar el número de incidente y la medición de los tiempos de ingreso y persistencia (Subsección 6.5) sobre la que se apoyan los resultados del Capítulo 8, y exigiría reintroducir la infraestructura de mensajería que el stack retiró (Sección 5); se propone como trabajo futuro y no altera lo medido. El criterio de éxito es que el alta diferida mantenga la idempotencia y la medición de tiempos de ingreso y persistencia, y que el reproceso no duplique incidentes.

11.10. Ampliaciones de producto no derivadas de una limitación medida

Las líneas siguientes amplían el alcance del sistema sin derivar de una limitación medida en este trabajo ni alterar la validez de lo medido; se consignan como oportunidades de producto, no como respuestas a defectos observados. En canales, la mensajería corporativa (Slack o Microsoft Teams) y las aplicaciones móviles propias, que la arquitectura modular admite con un disparador adicional en N8N sin modificar las capas de procesamiento ni de persistencia. En observabilidad, una capa de monitoreo en tiempo real sobre Prometheus y Grafana, y flujos ETL sobre los incidentes acumulados para indicadores de gestión. En integración, el enlace con un sistema de inventario de activos o una base de datos de gestión de configuración (CMDB) para contrastar la derivación con la titularidad registrada. En autoservicio, una base de conocimientos de soluciones verificadas que absorba casos simples y repetitivos, y la consiguiente automatización de la etapa de resolución técnica bajo supervisión humana. En el canal telefónico, un agente conversacional en tiempo real sobre Twilio Media Streams que reemplace la captura de toma única —una grabación de hasta 45 segundos— por un diálogo con preguntas de aclaración, condicionado a la madurez de las interfaces de audio bidireccional y a infraestructura no contemplada (punto de entrada WebSocket con *upgrade*, transcodificación del audio (mu-law, 8 kHz) al formato del modelo (PCM, 16 kHz) y gestión de turnos de habla). Ninguna de estas líneas cuenta con criterio de éxito ni tamaño de muestra en este trabajo, porque no se derivan de una limitación medida.

Referencias bibliográficas

Ahuja, K., Diddee, H., Hada, R., Ochieng, M., Ramesh, K., Jain, P., Nambi, A., Ganu, T., Segal, S., Ahmed, M., Bali, K., & Sitaram, S. (2023). MEGA: Multilingual evaluation of generative AI. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*, 4232–4267. https://doi.org/10.18653/v1/2023.emnlp-main.258

American Psychological Association. (2017). Ethical principles of psychologists and code of conduct [2002, con enmiendas efectivas del 1 de junio de 2010 y del 1 de enero de 2017]. Recuperado el 19 de octubre de 2026, de https://www.apa.org/ethics/code

Amershi, S., Weld, D., Vorvoreanu, M., Fourney, A., Nushi, B., Collisson, P., Suh, J., Iqbal, S., Bennett, P. N., Inkpen, K., Teevan, J., Kikin-Gil, R., & Horvitz, E. (2019). Guidelines for human-AI interaction. *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems (CHI 2019)*, 1–13. https://doi.org/10.1145/3290605.3300233

Apache Software Foundation. (2024). *Apache Airflow documentation (Version 2.10)* [Documentación técnica]. Recuperado el 25 de octubre de 2026, de https://airflow.apache.org/docs/

Atlassian. (2026). *Jira Service Management* [Documentación de la plataforma]. Recuperado el 9 de noviembre de 2026, de https://www.atlassian.com/software/jira/service-management

Bernal-Beltrán, T., Paredes-Valverde, M. A., Salas-Zárate, M. d. P., García-Díaz, J. A., & Valencia-García, R. (2025). Sentiment analysis in Mexican Spanish: A comparison between fine-tuning and in-context learning with large language models. *Future Internet*, *17*(10), 445. https://doi.org/10.3390/fi17100445

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, *78*(1), 1–3. https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 1877–1901. https://arxiv.org/abs/2005.14165

Cabinet Office. (2011). *ITIL service operation*. The Stationery Office.

Chen, L., Zaharia, M., & Zou, J. (2024). FrugalGPT: How to use large language models while reducing cost and improving performance [TMLR; versión previa: arXiv:2305.05176]. *Transactions on Machine Learning Research*. https://openreview.net/forum?id=cSimKw5p6R

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Colavito, G., Lanubile, F., & Novielli, N. (2025). Benchmarking large language models for automated labeling: The case of issue report classification. *Information and Software Technology*, *184*, 107758. https://doi.org/10.1016/j.infsof.2025.107758

Comisión Europea. (2003, 30 de junio). Decisión 2003/490/CE de la Comisión, de 30 de junio de 2003, con arreglo a la Directiva 95/46/CE, sobre la protección adecuada de los datos personales en Argentina [Diario Oficial de la Unión Europea, L 168, 8 de julio de 2003]. Recuperado el 29 de octubre de 2026, de https://eur-lex.europa.eu/eli/dec/2003/490/oj

Crispin, L., & Gregory, J. (2009). *Agile testing: A practical guide for testers and agile teams*. Addison-Wesley.

Date, C. J. (2004). *An introduction to database systems* (8.ª ed.). Addison-Wesley.

DigitalOcean. (2026). *Pricing — Droplets* [Precio de lista]. Recuperado el 19 de octubre de 2026, de https://www.digitalocean.com/pricing/droplets

Dirección Nacional de Protección de Datos Personales. (2016, 16 de noviembre). Disposición 60-E/2016: Cláusulas contractuales tipo de transferencia internacional (aprobación) [Boletín Oficial de la República Argentina n.º 33507, 18 de noviembre de 2016]. Recuperado el 9 de noviembre de 2026, de https://www.argentina.gob.ar/normativa/nacional/267922/texto

Docker. (2026). *Docker Compose* [Documentación oficial]. Recuperado el 9 de noviembre de 2026, de https://docs.docker.com/compose/

Efron, B., & Tibshirani, R. J. (1994). *An introduction to the bootstrap*. Chapman & Hall/CRC. https://doi.org/10.1201/9780429246593

Fielding, R. T., & Taylor, R. N. (2002). Principled design of the modern web architecture. *ACM Transactions on Internet Technology*, *2*(2), 115–150. https://doi.org/10.1145/514183.514185

Fleiss, J. L., Cohen, J., & Everitt, B. S. (1969). Large sample standard errors of kappa and weighted kappa. *Psychological Bulletin*, *72*(5), 323–327. https://doi.org/10.1037/h0028106

Freshworks. (2026). *Freshdesk — Software de soporte al cliente* [Documentación de la plataforma (capacidades y precios)]. Recuperado el 19 de octubre de 2026, de https://www.freshworks.com/freshdesk/

Galup, S. D., Dattero, R., Quan, J. J., & Conger, S. (2009). An overview of IT service management. *Communications of the ACM*, *52*(5), 124–127. https://doi.org/10.1145/1506409.1506439

Gomez, L., Bustos, C., & Sevilla, G. (2026). Automatización de mesa de ayuda N8N (Versión 1.4.0) [Software de computadora. GitHub]. Recuperado el 14 de noviembre de 2026, de https://github.com/lucaGomezB/Automatizacion-de-Mesa-de-Ayuda-N8N

Google. (2026a). *Audio understanding* [Documentación de la Gemini API]. Recuperado el 9 de noviembre de 2026, de https://aistudio.google.com/docs/audio

Google. (2026b). *Gemini API additional terms of service* [Vigentes desde el 23 de marzo de 2026]. Recuperado el 9 de noviembre de 2026, de https://aistudio.google.com/docs/terms

Google. (2026c). *Gemini API pricing* [Precios de lista de la Gemini API]. Recuperado el 9 de noviembre de 2026, de https://ai.google.dev/gemini-api/docs/pricing

Grandury, M., Aula-Blasco, J., Falcão, J., Fourrier, C., González Saiz, M., Martínez, G., Santamaria Gomez, G., Agerri, R., Aldama García, N., Chiruzzo, L., Conde, J., Gomez Adorno, H., Guerrero Nieto, M., Ivetta, G., López Fuertes, N., Plaza-del-Arco, F. M., Martín-Valdivia, M.-T., Montoro Zamorano, H., Muñoz Sanz, C., … Zubiaga, I. (2025). La leaderboard: A large language model leaderboard for Spanish varieties and languages of Spain and Latin America. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 32482–32524. https://doi.org/10.18653/v1/2025.acl-long.1561

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning*, *70*, 1321–1330. https://proceedings.mlr.press/v70/guo17a.html

Hernández Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill.

Hodges, J. L., & Lehmann, E. L. (1956). The efficiency of some nonparametric competitors of the t-test. *The Annals of Mathematical Statistics*, *27*(2), 324–335. https://doi.org/10.1214/aoms/1177728261

Hohpe, G., & Woolf, B. (2004). *Enterprise integration patterns: Designing, building, and deploying messaging solutions*. Addison-Wesley.

Honorable Congreso de la Nación Argentina. (2000, 4 de octubre). Ley 25.326 de Protección de los Datos Personales [Boletín Oficial de la República Argentina]. Recuperado el 25 de octubre de 2026, de http://servicios.infoleg.gob.ar/infolegInternet/anexos/60000-64999/64790/norma.htm

INCIBE. (2017). *Glosario de términos de ciberseguridad: una guía de aproximación para el empresario* [Instituto Nacional de Ciberseguridad de España, colección Protege tu empresa, versión 1]. Recuperado el 13 de noviembre de 2026, de https://www.incibe.es/sites/default/files/contenidos/guias/doc/guia_glosario_ciberseguridad_metad.pdf

ISO/IEC. (2022a). *Information security, cybersecurity and privacy protection — Information security controls* (Norma ISO/IEC N.º 27002:2022). Recuperado el 25 de octubre de 2026, de https://webstore.iec.ch/en/publication/74287

ISO/IEC. (2022b). *Information security, cybersecurity and privacy protection — Information security management systems — Requirements* (Norma ISO/IEC N.º 27001:2022). Recuperado el 25 de octubre de 2026, de https://webstore.iec.ch/en/publication/79694

ISO/IEC. (2025). *Information security, cybersecurity and privacy protection — Privacy information management systems — Requirements and guidance* (Norma ISO/IEC N.º 27701:2025). Recuperado el 25 de octubre de 2026, de https://webstore.iec.ch/en/publication/110123

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, *55*(12), 1–38. https://doi.org/10.1145/3571730

Jurafsky, D., & Martin, J. H. (2026). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models* [Borrador de la 3.ª edición, versión del 19 de agosto de 2026]. Recuperado el 25 de octubre de 2026, de https://web.stanford.edu/~jurafsky/slp3/

Kerby, D. S. (2014). The simple difference formula: An approach to teaching nonparametric correlation. *Comprehensive Psychology*, *3*, 11.IT.3.1. https://doi.org/10.2466/11.IT.3.1

Ladas, C. (2009). *Scrumban: Essays on Kanban systems for lean software development*. Modus Cooperandi Press.

Lai, V. D., Nguyen, C., Ngo, N., Nguyen, T., Dernoncourt, F., Rossi, R. A., & Nguyen, T. H. (2023). Okapi: Instruction-tuned large language models in multiple languages with reinforcement learning from human feedback. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 318–327. https://doi.org/10.18653/v1/2023.emnlp-demo.28

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159–174. https://doi.org/10.2307/2529310

Liu, F., He, X., Zhang, T., Chen, J., Li, Y., Yi, L., Zhang, H., Wu, G., & Shi, R. (2025). TickIt: Leveraging large language models for automated ticket escalation. *Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering (FSE Companion '25)*, 343–354. https://doi.org/10.1145/3696630.3728558

Mayor-Rocher, M., Melero, N., Merino-Gómez, E., Grandury, M., Conde, J., & Reviriego, P. (2026). Evaluating large language models with tests of Spanish as a foreign language: pass or fail? [Versión de revista. Publicación anticipada en línea (10 de septiembre de 2026). Versión preliminar: arXiv:2409.15334]. *Applied Linguistics*. https://doi.org/10.1093/applin/amag048

McCambridge, J., Witton, J., & Elbourne, D. R. (2014). Systematic review of the Hawthorne effect: New concepts are needed to study research participation effects. *Journal of Clinical Epidemiology*, *67*(3), 267–277. https://doi.org/10.1016/j.jclinepi.2013.08.015

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, *12*(2), 153–157. https://doi.org/10.1007/BF02295996

Mosqueira-Rey, E., Hernández-Pereira, E., Alonso-Ríos, D., Bobes-Bascarán, J., & Fernández-Leal, Á. (2023). Human-in-the-loop machine learning: A state of the art. *Artificial Intelligence Review*, *56*(4), 3005–3054. https://doi.org/10.1007/s10462-022-10246-w

n8n GmbH. (2024). *n8n documentation* [Documentación técnica oficial]. Recuperado el 25 de octubre de 2026, de https://docs.n8n.io/

National Institute of Standards and Technology. (2024). *The NIST cybersecurity framework (CSF) 2.0* (NIST Cybersecurity White Paper N.º 29). https://doi.org/10.6028/NIST.CSWP.29

Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, 625–632. https://doi.org/10.1145/1102351.1102430

Opitz, J., & Burst, S. (2019). Macro F1 and macro F1. https://doi.org/10.48550/arXiv.1911.03347

osTicket. (2026). *osTicket — Support ticketing system* [Sitio oficial del proyecto]. Recuperado el 9 de noviembre de 2026, de https://osticket.com/

Paket, E., Şenerkek, G., Akyol, F. B., & Salman, F. (2024). IT service desk ticket classification via large language models [Texto completo de acceso cerrado (IEEE); DOI verificado en Crossref y en OpenAlex (W4405272672) el 2026-11-11. Los datos que la tesis toma de esta obra provienen de su resumen publicado]. *2024 9th International Conference on Computer Science and Engineering (UBMK)*, 135–140. https://doi.org/10.1109/ubmk63289.2024.10773473

Paramesh, S. P., Ramya, C., & Shreedhara, K. S. (2018). Classifying the unstructured IT service desk tickets using ensemble of classifiers. *2018 3rd International Conference on Computational Systems and Information Technology for Sustainable Solutions (CSITSS)*, 221–227. https://doi.org/10.1109/CSITSS.2018.8768734

Paramesh, S. P., & Shreedhara, K. S. (2019). Automated IT service desk systems using machine learning techniques. En P. Nagabhushan, D. S. Guru, B. H. Shekar & Y. H. Sharath Kumar (Eds.), *Data Analytics and Learning: Proceedings of DAL 2018* (Vol. 43, pp. 331–346). Springer. https://doi.org/10.1007/978-981-13-2514-4_28

Parlamento Europeo y Consejo de la Unión Europea. (2016, 27 de abril). Reglamento (UE) 2016/679 — Reglamento General de Protección de Datos [Diario Oficial de la Unión Europea, L 119/1]. Recuperado el 25 de octubre de 2026, de https://eur-lex.europa.eu/eli/reg/2016/679/oj

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Poder Ejecutivo Nacional. (2001, 29 de noviembre). Decreto 1558/2001: Reglamentación de la Ley 25.326 de Protección de los Datos Personales [Boletín Oficial de la República Argentina, 3 de diciembre de 2001]. Recuperado el 9 de noviembre de 2026, de https://www.argentina.gob.ar/normativa/nacional/decreto-1558-2001-70368/texto

Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, *2*(1), 37–63. https://arxiv.org/abs/2010.16061

Pressman, R. S., & Maxim, B. R. (2020). *Software engineering: A practitioner's approach* (9.ª ed.). McGraw-Hill.

Rabiner, L., & Juang, B.-H. (1993). *Fundamentals of speech recognition*. Prentice Hall.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. *Proceedings of the 40th International Conference on Machine Learning*, *202*, 28492–28518. https://proceedings.mlr.press/v202/radford23a.html

Ramírez, S. (2024). *FastAPI documentation* [Documentación técnica oficial]. Recuperado el 25 de octubre de 2026, de https://fastapi.tiangolo.com/

Ramón-Ferrer, V., Badenes-Olmedo, C., & Corcho, Ó. (2026). Spanish triple-to-text benchmark on low-resource large language models. *Semantic Web*, *17*(3). https://doi.org/10.1177/22104968261440701

Revina, A., Buza, K., & Meister, V. G. (2020). IT ticket classification: The simpler, the better. *IEEE Access*, *8*, 193380–193395. https://doi.org/10.1109/ACCESS.2020.3032840

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4.ª ed.). Pearson.

Secretaría de la Pequeña y Mediana Empresa. (2026). ¿Qué es una MiPyME? [Ministerio de Economía de la Nación Argentina]. Recuperado el 19 de octubre de 2026, de https://www.argentina.gob.ar/produccion/registrar-una-pyme/que-es-una-pyme

ServiceNow. (2026). *ServiceNow ITSM* [Documentación oficial de la plataforma]. Recuperado el 14 de noviembre de 2026, de https://www.servicenow.com/docs/

Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, *52*(3–4), 591–611. https://doi.org/10.1093/biomet/52.3-4.591

Shneiderman, B. (2020). Human-centered artificial intelligence: Reliable, safe & trustworthy. *International Journal of Human–Computer Interaction*, *36*(6), 495–504. https://doi.org/10.1080/10447318.2020.1741118

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, *45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Stallings, W., & Brown, L. (2018). *Computer security: Principles and practice* (4.ª ed.). Pearson.

The PostgreSQL Global Development Group. (2024). *PostgreSQL 15 documentation* [Documentación técnica oficial]. Recuperado el 25 de octubre de 2026, de https://www.postgresql.org/docs/15/

Tian, K., Mitchell, E., Zhou, A., Sharma, A., Rafailov, R., Yao, H., Finn, C., & Manning, C. D. (2023). Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*, 5433–5442. https://doi.org/10.18653/v1/2023.emnlp-main.330

Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., Bikel, D., Blecher, L., Canton Ferrer, C., Chen, M., Cucurull, G., Esiobu, D., Fernandes, J., Fu, J., Fu, W., … Scialom, T. (2023). Llama 2: Open foundation and fine-tuned chat models [arXiv:2307.09288]. https://doi.org/10.48550/arXiv.2307.09288

Tsoumakas, G., & Katakis, I. (2007). Multi-label classification: An overview. *International Journal of Data Warehousing and Mining*, *3*(3), 1–13. https://doi.org/10.4018/jdwm.2007070101

Twilio. (2026). *Recordings resource* [Documentación de Twilio Programmable Voice]. Recuperado el 9 de noviembre de 2026, de https://www.twilio.com/docs/voice/api/recording

Varshney, N., & Baral, C. (2022). Model cascading: Towards jointly improving efficiency and accuracy of NLP systems. *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP 2022)*, 11007–11021. https://doi.org/10.18653/v1/2022.emnlp-main.756

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 5998–6008. https://arxiv.org/abs/1706.03762

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, *17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Wiggins, A. (2017). The twelve-factor app [Manifiesto de arquitectura de software]. Recuperado el 25 de octubre de 2026, de https://12factor.net/

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, *1*(6), 80–83. https://doi.org/10.2307/3001968

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, *22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953

Wu, T., Terry, M., & Cai, C. J. (2022). AI chains: Transparent and controllable human-AI interaction by chaining large language model prompts. *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems (CHI 2022)*, 1–22. https://doi.org/10.1145/3491102.3517582

Xiong, M., Hu, Z., Lu, X., Li, Y., Fu, J., He, J., & Hooi, B. (2024). Can LLMs express their uncertainty? An empirical evaluation of confidence elicitation in LLMs. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. https://openreview.net/forum?id=gjeQKFxFpZ

Xuan, W., Yang, R., Qi, H., Zeng, Q., Xiao, Y., Feng, A., Liu, D., Xing, Y., Wang, J., Gao, F., Lu, J., Jiang, Y., Li, H., Li, X., Yu, K., Dong, R., Gu, S., Li, Y., Xie, X., … Li, I. (2025). MMLU-ProX: A multilingual benchmark for advanced large language model evaluation. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP 2025)*, 1513–1532. https://doi.org/10.18653/v1/2025.emnlp-main.79

Zangari, A., Marcuzzo, M., Schiavinato, M., Gasparetto, A., & Albarelli, A. (2023). Ticket automation: An insight into current research with applications to multi-level classification scenarios. *Expert Systems with Applications*, *225*, 119984. https://doi.org/10.1016/j.eswa.2023.119984

Zanzotto, F. M. (2019). Viewpoint: Human-in-the-loop artificial intelligence. *Journal of Artificial Intelligence Research*, *64*, 243–252. https://doi.org/10.1613/jair.1.11345

Zendesk. (2026). *AI-powered customer service software* [Página del producto de software de servicio al cliente de Zendesk]. Recuperado el 19 de octubre de 2026, de https://www.zendesk.com/service/

Zhang, R., Cahyawijaya, S., Cruz, J. C. B., Winata, G. I., & Aji, A. F. (2023). Multilingual large language models are not (yet) code-switchers. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*, 12567–12582. https://doi.org/10.18653/v1/2023.emnlp-main.774

Zhao, Z., Wallace, E., Feng, S., Klein, D., & Singh, S. (2021). Calibrate before use: Improving few-shot performance of language models. *Proceedings of the 38th International Conference on Machine Learning*, *139*, 12697–12706. https://proceedings.mlr.press/v139/zhao21c.html

A. Diagrama de arquitectura del sistema

El Anexo A inventaría los diagramas de la arquitectura del sistema entregado (release `v1.3.0`). Los diagramas de arquitectura y despliegue se incluyen como figuras de la Sección 5 y no se reproducen aquí; los diagramas de secuencia, componentes y cronograma se reproducen a continuación. Los cinco artefactos son:

- **Diagrama de arquitectura del sistema** (Figura 1, Sección 5): las cinco capas de la Tabla 4 y los tres canales de entrada (correo, formulario web y telefonía), sin versiones de bibliotecas, que constan en la Tabla 4 y en la Tabla 29. Fuente versionada: `docs/diagrams/arquitectura_sistema.md`.
- **Diagrama de despliegue** (Figura 2, Sección 5): reúne los cinco componentes principales (N8N, FastAPI, PostgreSQL, Gemini 3.6 Flash, Twilio) y el proxy inverso Nginx. El proxy provee terminación TLS 1.2/1.3 verificada en el despliegue de referencia y forma parte del stack base sobre el que corrió la ingesta del 2 de octubre. La medición telefónica del 5 y 6 de octubre usó el perfil aislado `corpus`, sin proxy. Se representan también las relaciones de comunicación entre los componentes. Fuente versionada: `docs/diagrams/despliegue.md`.
- **Diagrama de secuencia** (Figuras 7 y 8): flujo extremo a extremo de un incidente desde su recepción en cualquiera de los tres canales (correo electrónico, formulario web o telefonía) hasta la confirmación al usuario o la derivación a revisión humana, incluyendo las interacciones con el clasificador híbrido y la base de datos. Fuente versionada: `docs/diagrams/secuencia.md`.
- **Diagrama de componentes** (Figuras 9 y 10): organización interna del módulo Python por capas (routes, services, repositories, models, classifiers), con sus dependencias y relaciones. Fuente versionada: `docs/diagrams/componentes.md`.
- **Cronograma** (Figura 11, Subsección 6.6): construcción, campañas de medición de la campaña 2026-10, campaña complementaria de medición y versión del modelo evaluada, con la procedencia de cada fecha. Fuente versionada: `docs/diagrams/cronograma.md`.

Los diagramas se generan a partir de fuentes Mermaid versionadas en formato `.md` en el directorio `docs/diagrams/` del repositorio y se renderizan a imágenes PNG para su inclusión en el documento (Gomez et al., 2026).

B. Repositorio de código fuente

El código fuente del módulo Python, los scripts de migración de la base de datos PostgreSQL gestionados mediante Alembic, los archivos de configuración del despliegue en contenedores Docker y los flujos de integración continua sobre GitHub Actions se encuentran disponibles en el repositorio público del proyecto (Gomez et al., 2026), accesible en https://github.com/lucaGomezB/Automa

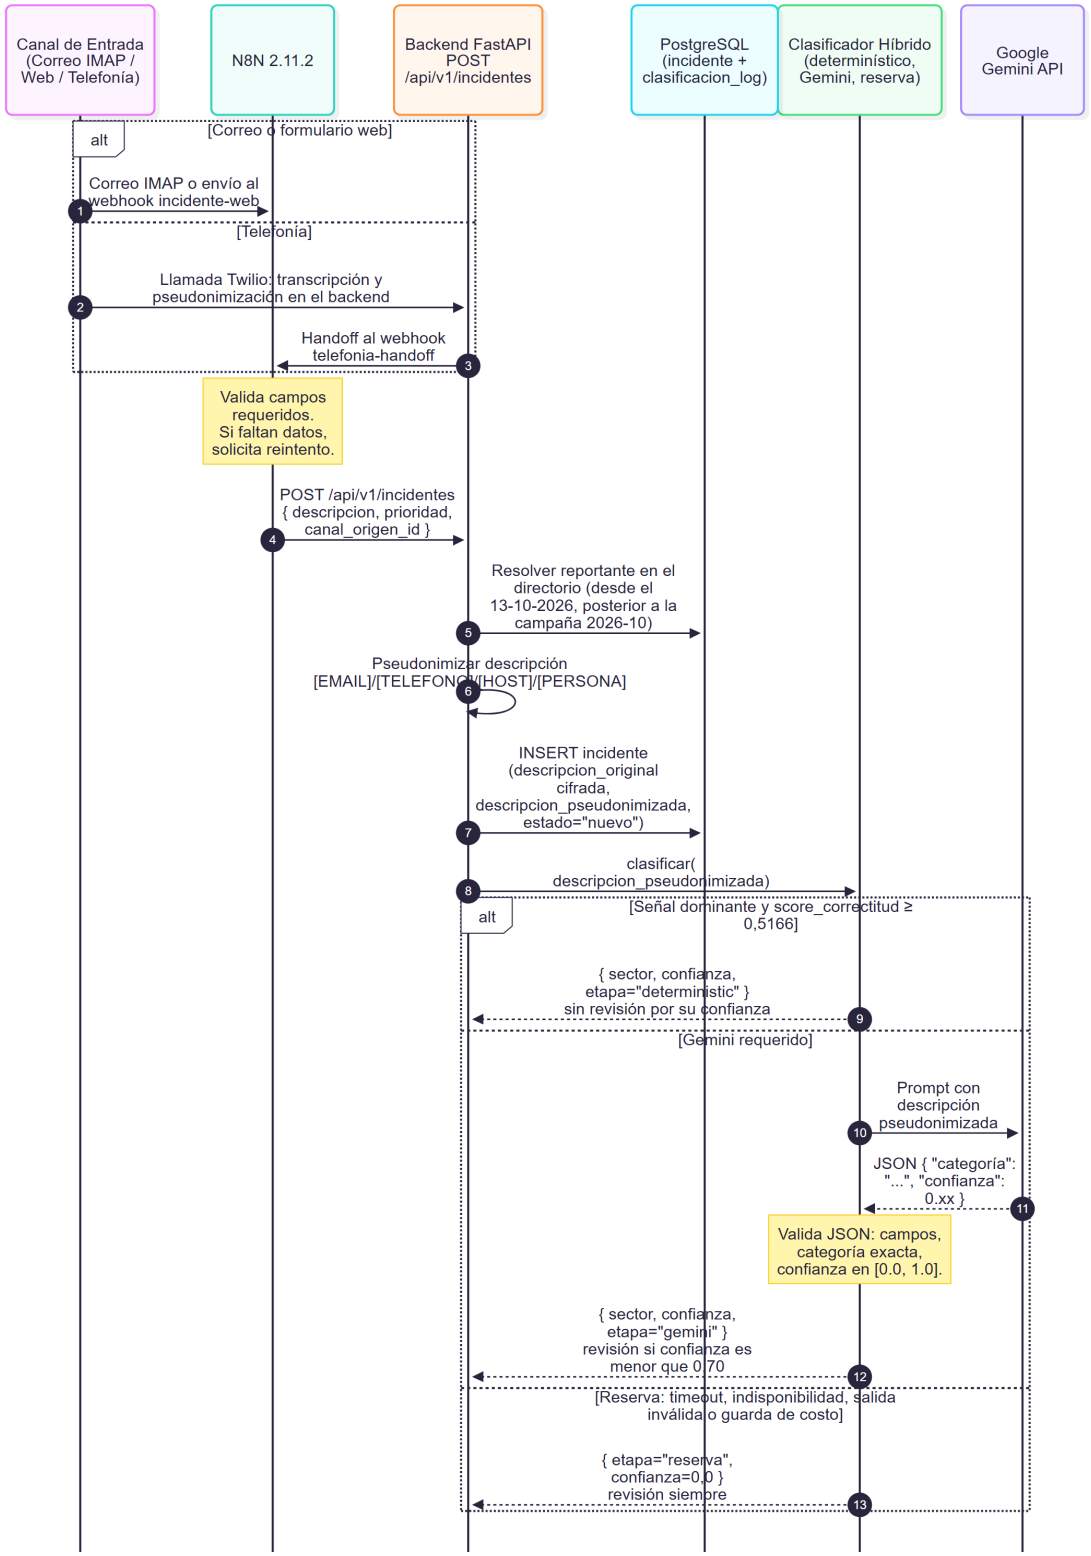


Figura 7. Diagrama de secuencia del flujo extremo a extremo de un incidente, desde el canal de entrada hasta la confirmación o la derivación a revisión humana, en la configuración entregada (release `v1.3.0`). El disparador por reportante no identificado en el directorio es posterior a la campaña 2026-10 (13-10-2026): véase la Tabla 29. Parte A: ingreso, alta y clasificación (mensajes 1 a 13), que continúa en la Figura 8.

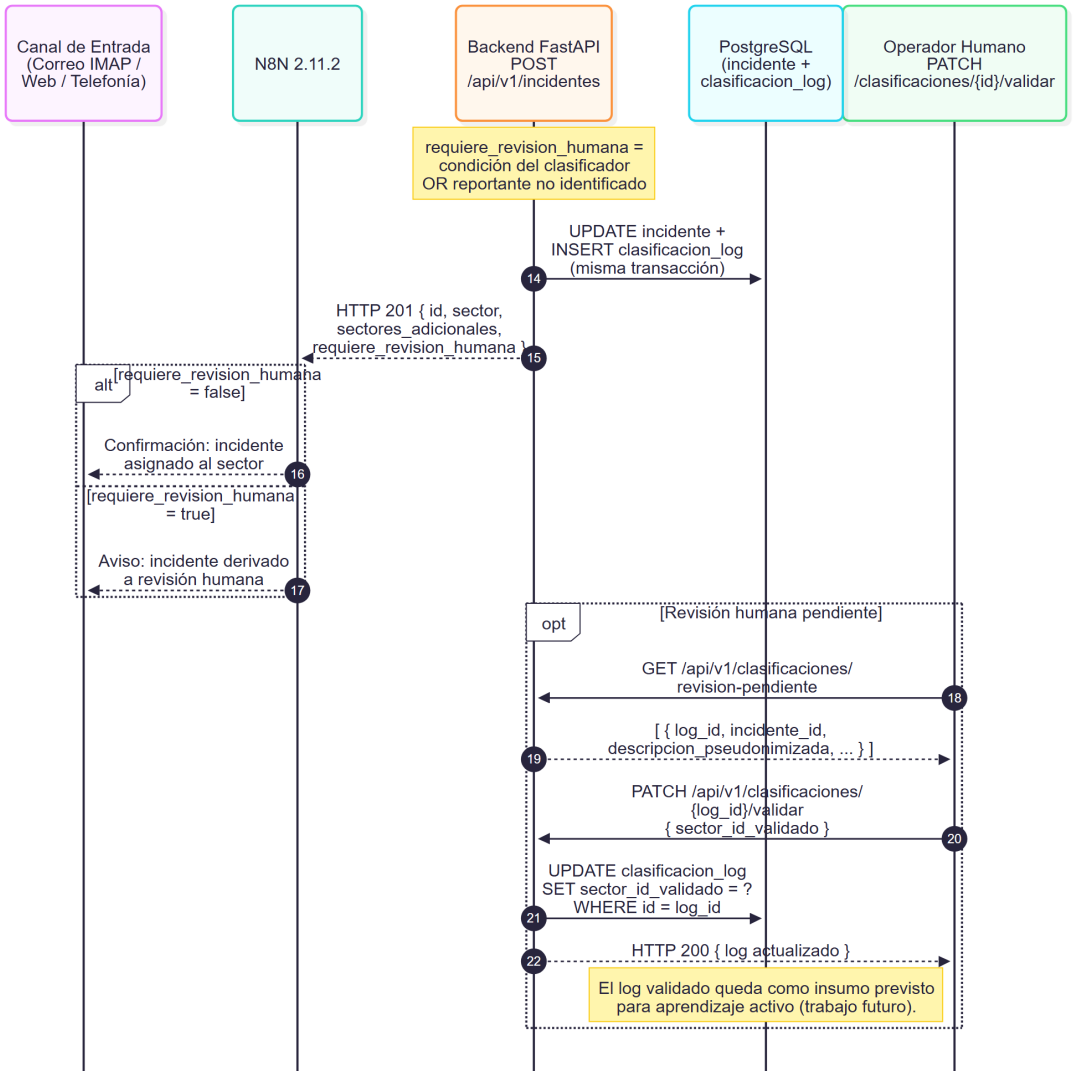


Figura 8. Diagrama de secuencia del flujo extremo a extremo de un incidente (continuación de la Figura 7). Parte B: persistencia del resultado, respuesta al canal y ciclo de revisión humana (mensajes 14 a 22).

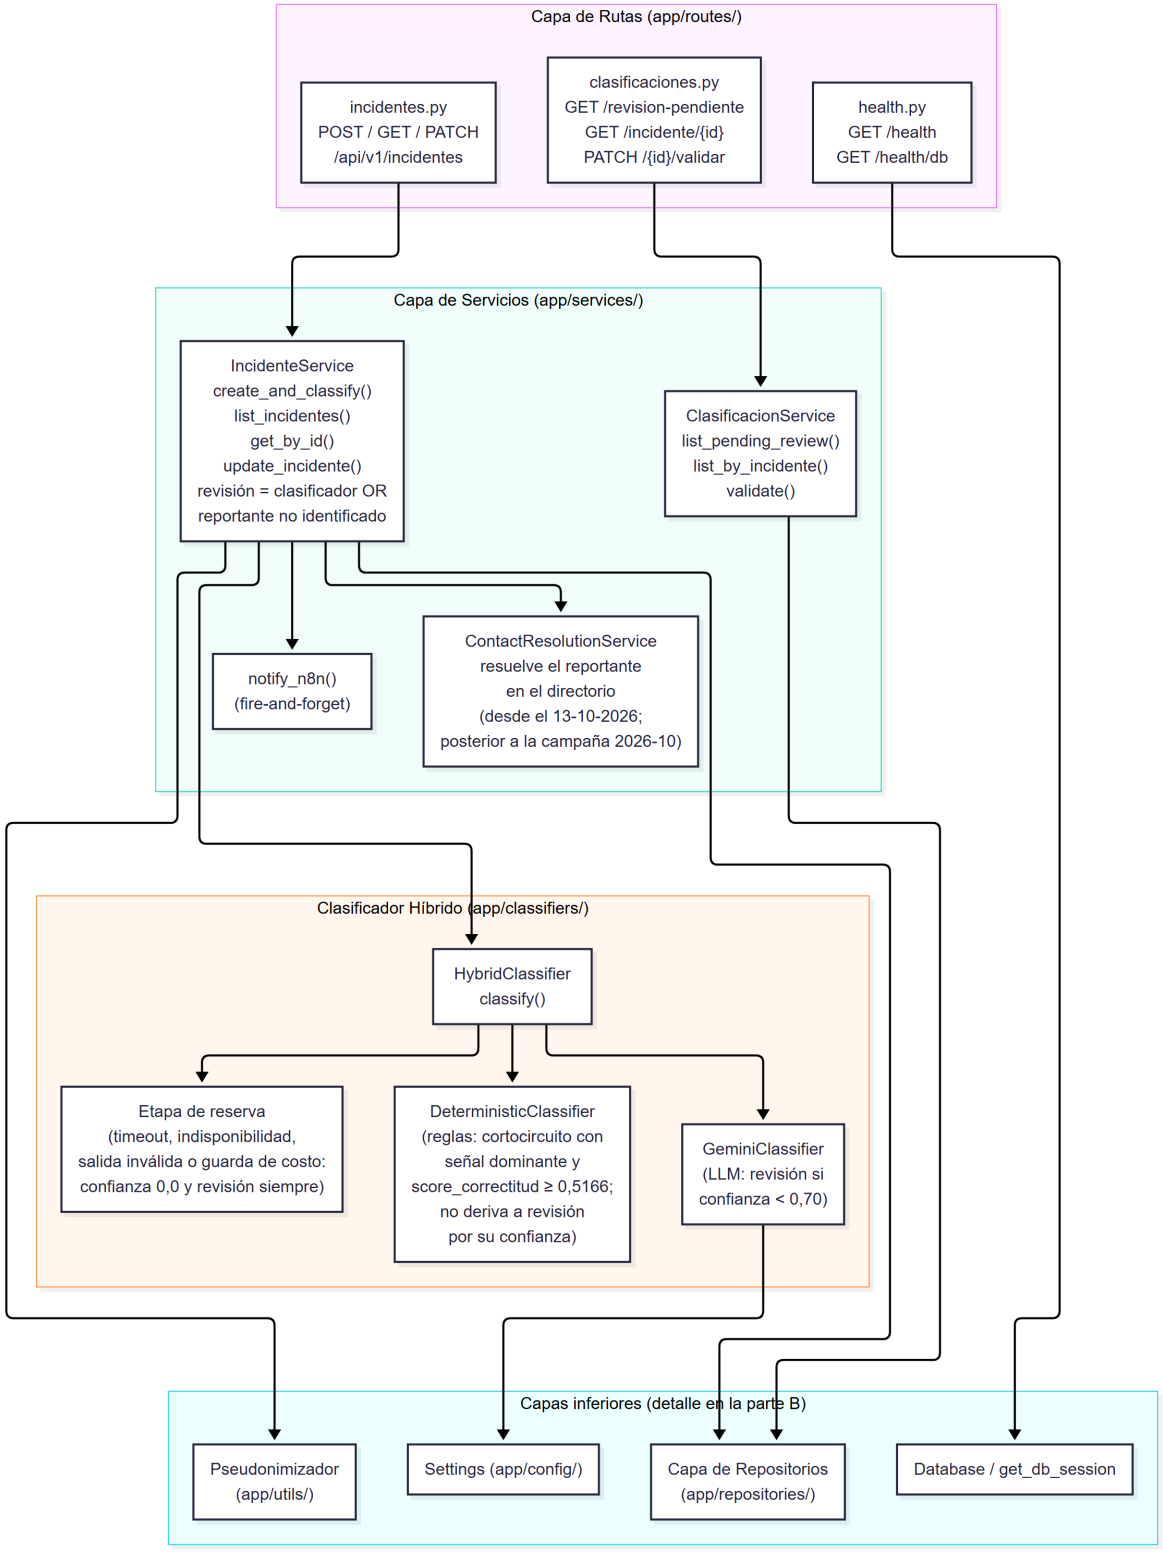


Figura 9. Diagrama de componentes del módulo Python organizado en capas (routes, services, repositories, classifiers). Describe la configuración entregada (release `v1.3.0`): el filtro determinístico cortocircuita con señal dominante y puntaje de correctitud $\geq 0{,}5166$ sin derivar por su confianza, la revisión por confianza menor que 0,70 rige solo sobre Gemini, la etapa de reserva deriva siempre, y el disparador por reportante no identificado en el directorio es posterior a la campaña 2026-10 (13-10-2026; Tabla 29). Fuente: `docs/diagrams/componentes.md`. Parte A: capas de rutas, servicios y clasificadores, que continúa en la Figura 10.

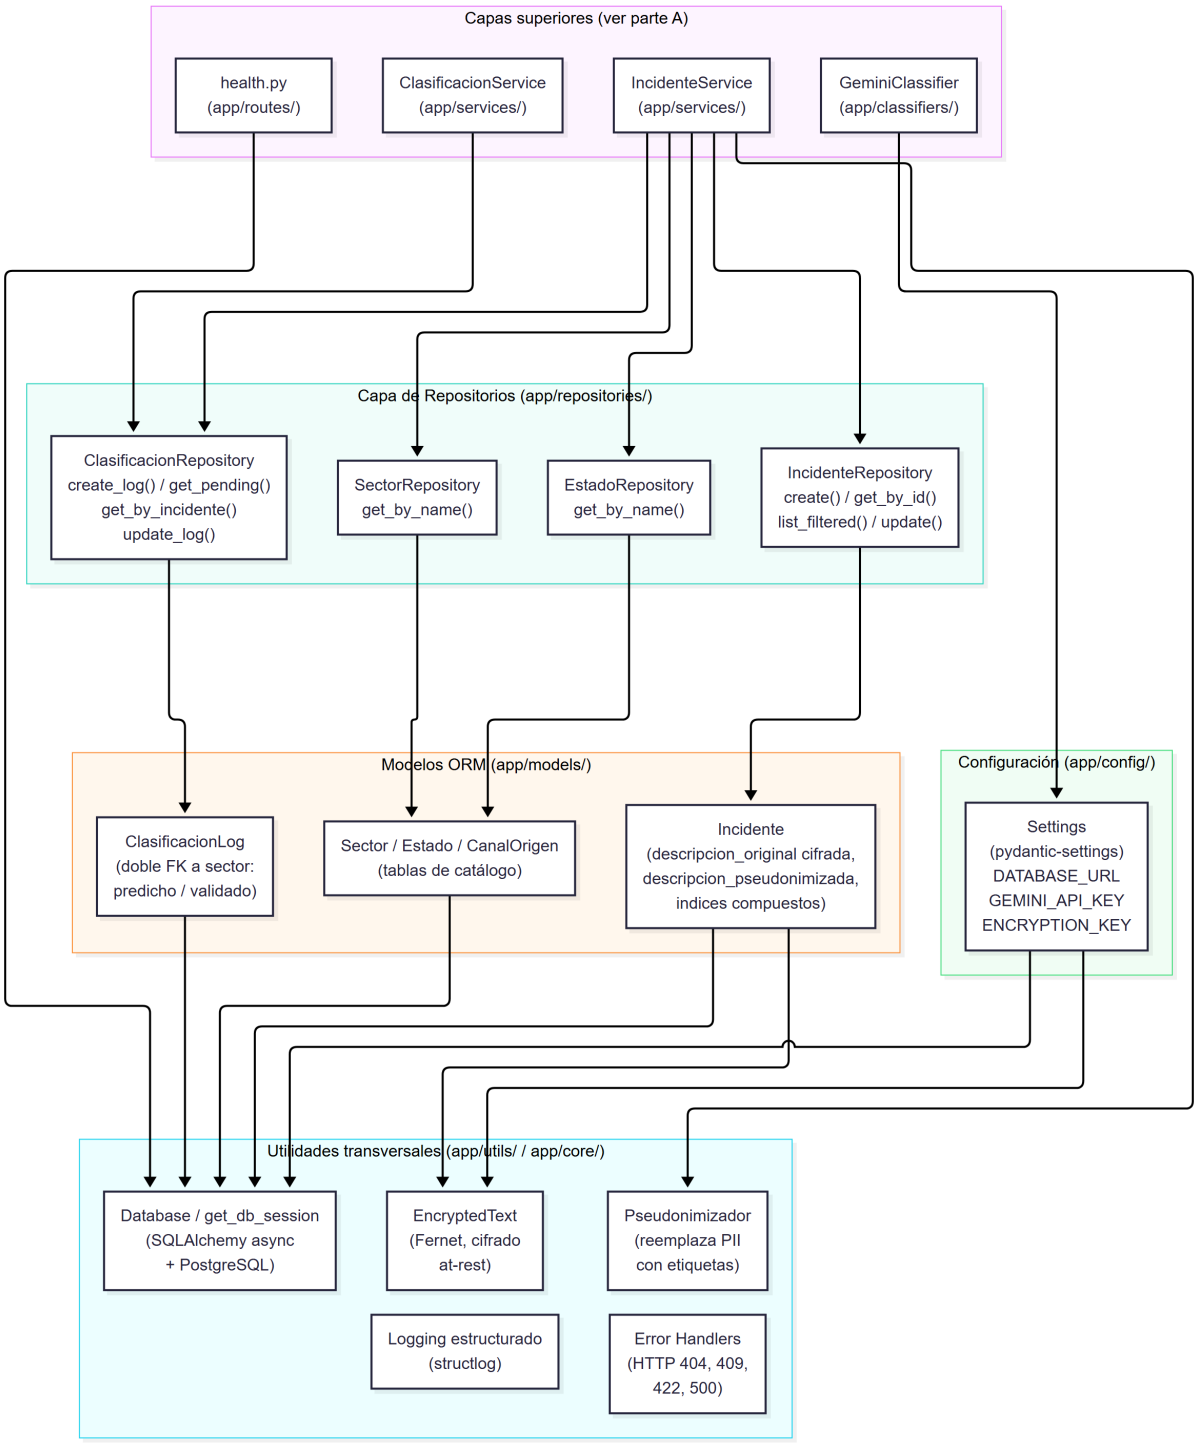


Figura 10. Diagrama de componentes del módulo Python organizado en capas (continuación de la Figura 9). Parte B: repositorios, modelos ORM, utilidades transversales y configuración.

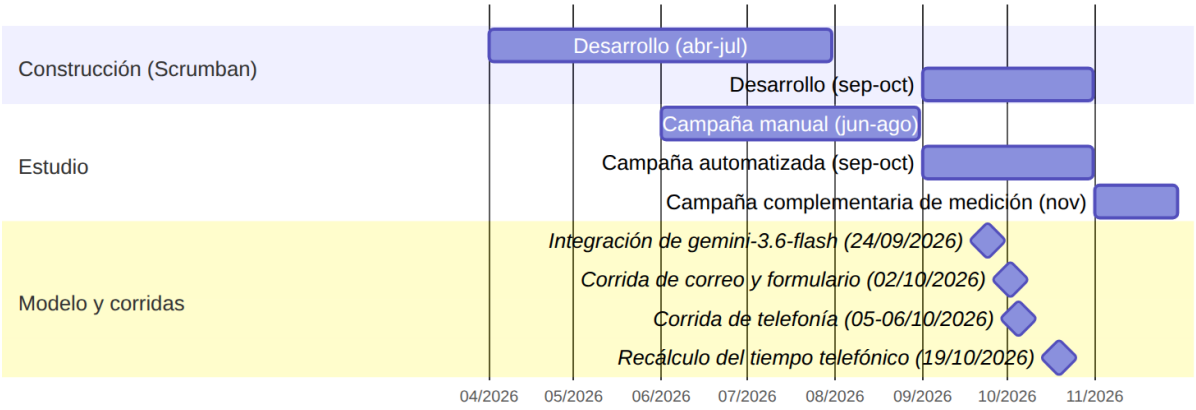


Figura 11. Cronograma de la construcción, las campañas y la versión del modelo (barras con precisión de mes; hitos, de día). Fuente: historial del repositorio para los hitos, incluido el recálculo del tiempo telefónico del 19-10-2026; las fechas de la corrida telefónica (el 5 y 6 de octubre de 2026) provienen de la respuesta de los autores del 2026-10-28, y la confirmación del 9-10-2026 cubre las ventanas de las campañas. La campaña complementaria de medición corrió en noviembre de 2026; su plan pre-registrado se versionó el 2026-11-01 y sus tablas primarias y análisis, entre el 2026-11-04 y el 2026-11-08. El doble etiquetado de los 150 casos originales por `E3` y `E4` se registró el 2026-11-12 y, el 2026-11-13, el del refuerzo de 56 casos junto con el arbitraje de `E5`, la línea de base, la calibración, el análisis de ruido y el brazo solo-LLM, con la fecha de sus marcas y de sus commits.

tizacion-de-Mesa-de-Ayuda-N8N. El commit de referencia para la versión entregada al jurado se identifica con el tag anotado `v1.4.0`, que fija el contenido de la versión entregada. Como un commit no puede contener su propio hash, un commit inmediatamente posterior consigna en este anexo ese hash: `406ce2bf328bc22fca786d8a158bf8e48136534d`, que constituye la referencia verificable de la versión entregada.

La verificación de la compilación se conserva en `paper/compilacion.md`, que registra las páginas, los errores y el SHA-256 del PDF, y la de la matriz de trazabilidad de las correcciones, en `docs/Tesis/Correcciones/verificar_matriz_trazabilidad.py`; ambos artefactos corresponden a este anexo de repositorio.

La versión entregada no es la que se evaluó. La *configuración evaluada* es la del commit `bf5e099` (7-10-2026), primera revisión que versiona la cascada `hybrid-v3`; las corridas de tiempos usaron revisiones anteriores con las mismas dependencias (Subsección 4.5). La *configuración entregada* es la del tag `v1.3.0`. La *configuración de la campaña complementaria* no es un único commit. El brazo automatizado de correo y formulario web corrió desde `cda7712` (5-11-2026), y el de telefonía desde el 6-11-2026, tras ajustar el bloqueo de la llamada siguiente en el softphone y el aviso de voz. Las intervenciones se validaron entre el 7 y el 8-11-2026 (ajustes de la interfaz y de la codificación del correo), todas con `hybrid-v3`, la instrumentación de intervención y la derivación por reportante activas (Subsección 8.8). La Tabla 29 consigna, con valores verificados sobre las tres revisiones, lo que cambió; los pasajes de la tesis que citan versiones o capacidades remiten a ella.

La estructura del repositorio separa el módulo de procesamiento (`App/Backend/`, con la aplicación FastAPI, las migraciones Alembic y las pruebas), la interfaz de usuario (`App/Frontend/`, React con TypeScript), la definición del flujo de orquestación (`n8n/workflow.json`), los artefactos de eva-

Tabla 29. Configuración evaluada, configuración entregada y configuración de la campaña complementaria

Elemento	Configuración evaluada (`bf5e099`)	Configuración entregada (`v1.3.0`)	Campaña complementaria
FastAPI y Uvicorn	0.115.0 y 0.30.6	0.162.0 y 0.54.0	Como la entregada
SQLAlchemy	2.0.36	2.1.6	Como la entregada
`google-genai`	`>=2.20.0`	`>=2.33.0,<3`	Como la entregada
pytest y pytest-cov	8.3.3 y 5.0.0	9.1.1 y 7.1.0	Como la entregada
React	18.3.1	19.3.1	Como la entregada
Flujo N8N	28 nodos (25 operativos y 3 notas); 38 (35 y 3) hasta el retiro del agente LLM telefónico	32 nodos (29 operativos y 3 notas)	Como la entregada
Reintentos del alta	No	Sí: hasta 3 intentos, espera fija de 5000 ms y tiempo de espera por intento de 10 s (inicio de sesión) y 75 s (alta)	Como la entregada
Revisión por reportante no identificado	No	Sí	Sí
Propagación del contacto del reportante en el POST	No	Sí (posterior a la campaña 2026-10): el flujo N8N envía `reportante_email` (correo) y `reportante_telefono` (telefonía), que habilitan la resolución del reportante	Sí
Prueba de humo E2E y verificación de TLS	No	Sí	No registrado
Instrumentación de intervención	No	Sí	Sí (parte de las de `O1` con un *frontend* previo)
Imagen de N8N	`n8nio/n8n:2.11.2`	Derivada de `n8nio/n8n:2.11.2` (`docker/n8n/Dockerfile`) con parche de la decodificación IMAP	`n8nio/n8n:2.11.2`; la derivada es posterior (7-11-2026)
`classifier_version`	`hybrid-v3`	`hybrid-v3`	`hybrid-v3`
Modelo de transcripción	`gemini-3.5-transcribe`	`gemini-3.5-transcribe`	Como la entregada
Sin cambios	Python 3.12-slim, PostgreSQL 15.5-alpine, `gemini-3.6-flash` con sus parámetros, umbrales (0,5166 y 0,70), vocabulario y *prompt*; la lógica del clasificador solo cambió en comentarios e importaciones diferidas		Sin cambios

Fuente: elaboración propia a partir de `git show bf5e099:`*archivo*, `git show v1.3.0:`*archivo* y `git show bf5e099:App/Backend/app/constants.py` sobre `requirements.txt`, `package-lock.json`, `n8n/workflow.json`, `docker-compose.yml` y `settings.py`, y de las especificaciones archivadas de los cambios, y de `git diff --stat cda7712 v1.3.0 -- App/ n8n/ docker/ docker-compose.yml` (24 archivos; no cambian `requirements.txt`, `package-lock.json`, `n8n/workflow.json` ni `settings.py`; cambian `docker-compose.yml` y `docker/n8n/`, por la imagen derivada de N8N, y archivos del backend y del frontend que no intervienen en la clasificación). La campaña complementaria usó `hybrid-v3` sobre un *backend* posterior, con la derivación por reportante y la propagación de su contacto activas; *no registrado* señala lo que los artefactos no permiten recuperar.

luación (`evaluation/`), el corpus pseudonimizado (`data/`), los scripts auxiliares (`scripts/`) y la documentación (`docs/`). A esa organización se suman las especificaciones de los cambios (`openspec/`) y los archivos de orquestación local `docker-compose.yml` y `Makefile`. El archivo `README.md` describe esta organización y reúne las instrucciones detalladas para el despliegue local en menos de 15 minutos; por eso constituye el punto de entrada al código fuente disponible en el repositorio público (Gomez et al., 2026).

C. Esquema de base de datos

El esquema completo de la base de datos PostgreSQL se documenta mediante scripts SQL versionados. Esos scripts definen las siete entidades descritas en la Tabla 5 de la Sección 5, las restricciones de integridad referencial (claves foráneas con eliminación en cascada condicional), los índices secundarios sobre los atributos de búsqueda frecuente (fecha de creación, sector responsable y estado actual del ticket) y la generación de los identificadores de incidente. La capa de acceso a datos del módulo utiliza SQLAlchemy 2.0 como mapeador objeto-relacional y `asyncpg` como driver asincrónico para PostgreSQL, en coherencia con la Sección 5.4 y con el código del repositorio. Las migraciones incrementales se gestionan mediante Alembic, lo que permite reproducir el estado de la base en cualquier punto histórico del desarrollo y revertir cambios cuando resulte necesario.

La migración inicial incluye la creación de las tablas de catálogo (`sector`, `estado`, `canal_origen`) con sus valores semilla, garantizando que un despliegue nuevo del sistema comience con los datos de referencia correctos. Las migraciones subsiguientes documentan la evolución del esquema durante las etapas de desarrollo descritas en la Sección 4.

El diagrama entidad-relación de las siete entidades se incluye como Figura 3 de la Sección 5; su fuente Mermaid versionada reside en `docs/diagrams/er_modelo_datos.md`.

D. Especificación OpenAPI de la interfaz REST

La especificación completa de la interfaz REST se genera automáticamente mediante FastAPI conforme a la versión 3.1 de la especificación OpenAPI (Ramírez, 2024). El documento resultante describe los puntos de entrada listados en la Tabla 6 de la Sección 5, los esquemas de los cuerpos de solicitud y respuesta validados mediante Pydantic v2, los códigos de estado posibles para cada método HTTP, y ejemplos representativos para cada caso de uso.

La interfaz se encuentra disponible adicionalmente en formato interactivo a través del componente Swagger UI integrado en el servidor, accesible bajo la ruta `/docs` durante la ejecución, y en formato estático como archivo `openapi.json` en el directorio `docs/` del repositorio. La sincronización entre el código y la especificación estática se verifica automáticamente en el pipeline de integración continua.

La especificación OpenAPI vigente describe 33 puntos de entrada que exponen 41 métodos

HTTP y 44 esquemas de datos, agrupados por recurso: autenticación, catálogos, clasificaciones, incidentes, directorio, estadísticas, telefonía, control de costo y salud.

A título ilustrativo, los 44 esquemas de datos comprenden las estructuras de los catálogos, las entidades de dominio y los objetos de respuesta de cada recurso. El esquema `IncidenteRead`, por ejemplo, expone el identificador del ticket, la descripción pseudonimizada, la prioridad, el sector y los sectores adicionales, el estado, el canal de origen, el reportante, las marcas temporales de ingreso y persistencia, y los indicadores de latencia end-to-end y de latencia anómala, con sus tipos y campos de solo lectura. El detalle exhaustivo de atributos, tipos y ejemplos reside en `docs/openapi.json`.

E. Configuración del flujo N8N

La exportación del flujo de orquestación en formato JSON incluye la totalidad de los 32 nodos configurados, sus parámetros operativos, las credenciales referenciadas mediante identificadores opacos sin exposición de valores, y los conectores entre nodos. El archivo `n8n/workflow.json` contiene esta exportación. La importación de este artefacto en una instancia limpia de N8N 2.11.2 reproduce íntegramente el comportamiento operativo del sistema, sujeta únicamente a la provisión de las credenciales correspondientes a los servicios externos integrados (servidor IMAP de correo, cuenta Twilio y clave de API de Gemini) mediante el sistema de credenciales nativo de la plataforma.

Las Figuras 12 a 14 presentan una reconstrucción esquemática del flujo, derivada de la exportación JSON y agrupada por etapa funcional. Los 29 nodos operativos (más 3 notas adhesivas, 32 nodos en total) se organizan en siete etapas. La entrada (triggers) comprende la recepción de correo por IMAP y los disparadores de telefonía, formulario web y notificación de clasificación. La validación y normalización de la información de entrada incluye la marca de canal y el sellado de ingreso. El envío al backend comprende la autenticación del operador y la solicitud POST del incidente. Luego siguen el ruteo por canal de origen, la revisión humana —con la notificación al operador designado y las respuestas de handoff—, la respuesta y auditoría del ticket, y el aviso post-revisión. La parametrización completa de cada nodo reside en `n8n/workflow.json`.

F. Corpus de validación

El corpus de 200 incidentes utilizado para la validación experimental reside en el repositorio en formato JSON, en su forma pseudonimizada y versionada, bajo la ruta `data/corpus_evaluacion_pseudonimizado.json`. Cada caso incluye el identificador anónimo, la descripción cruda pseudonimizada, el canal de origen, el sector asignado por consenso humano, los sectores adicionales de verdad y el tiempo de registro medido en cada flujo. La categoría predicha por el clasificador y la confianza asociada no forman parte del corpus: se conservan en la copia versionada de la caché, `evaluation/evidence/predicciones_hybrid-v3_2026-10-07.json`. Los tiempos automatizados constan por caso en el corpus; sus registros primarios (base operativa del 2-10-2026

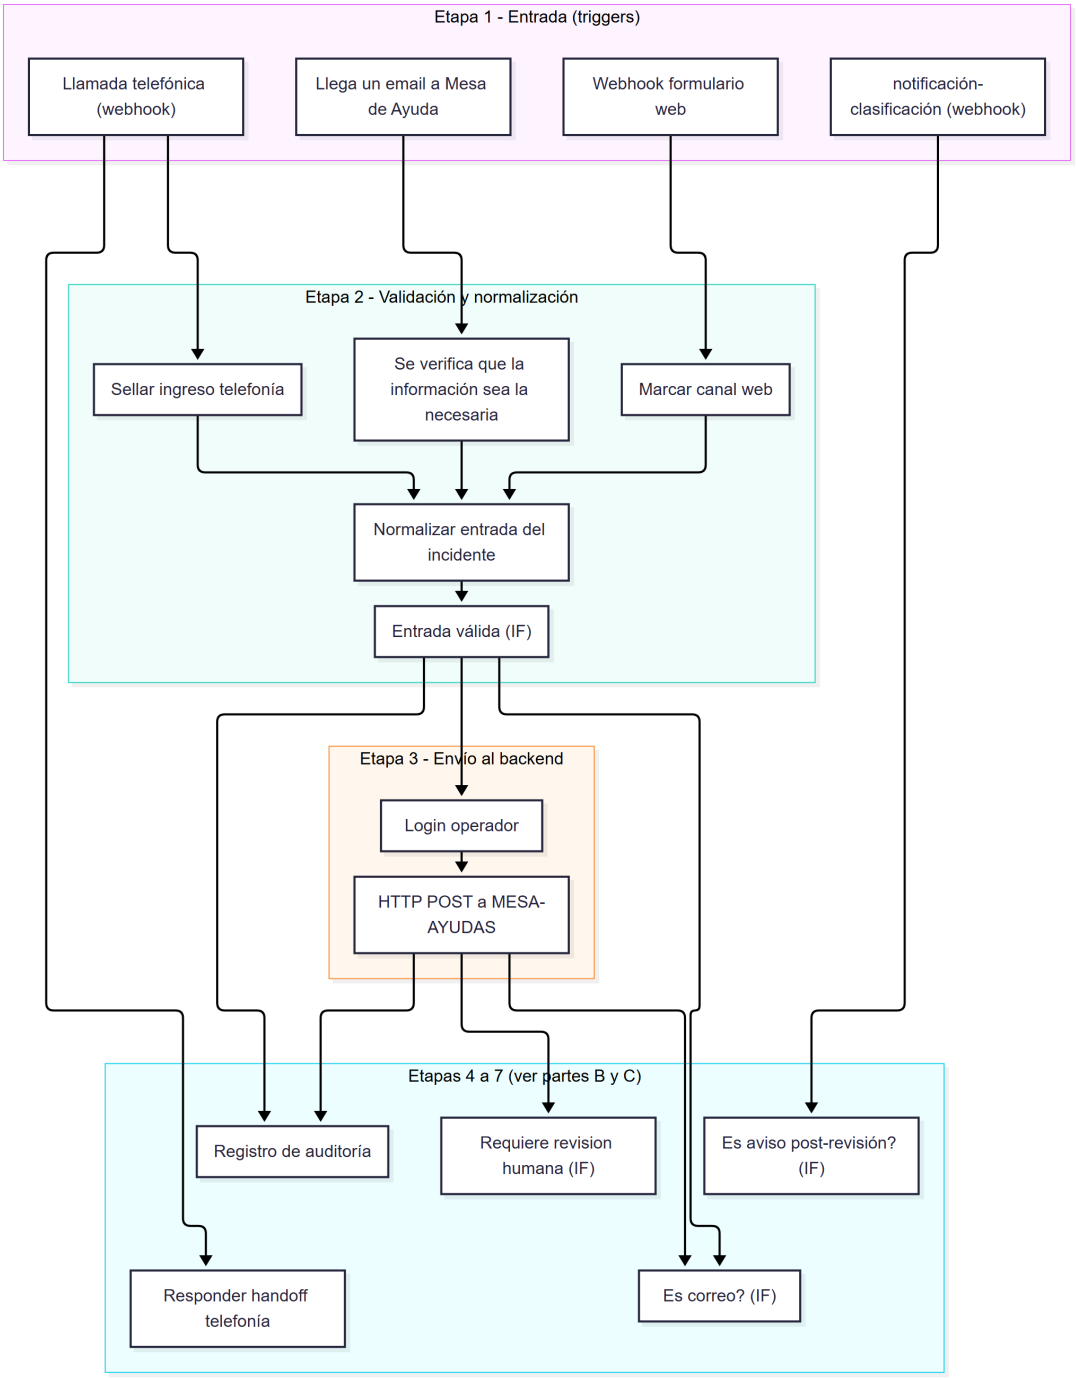


Figura 12. Reconstrucción esquemática del flujo de orquestación N8N: no es una captura de la interfaz; los 29 nodos operativos se agrupan por etapa funcional. Parte A: etapas 1 a 3 (entrada, validación y envío al backend), que continúa en la Figura 13. Los nodos punteados son referencias a las otras partes.

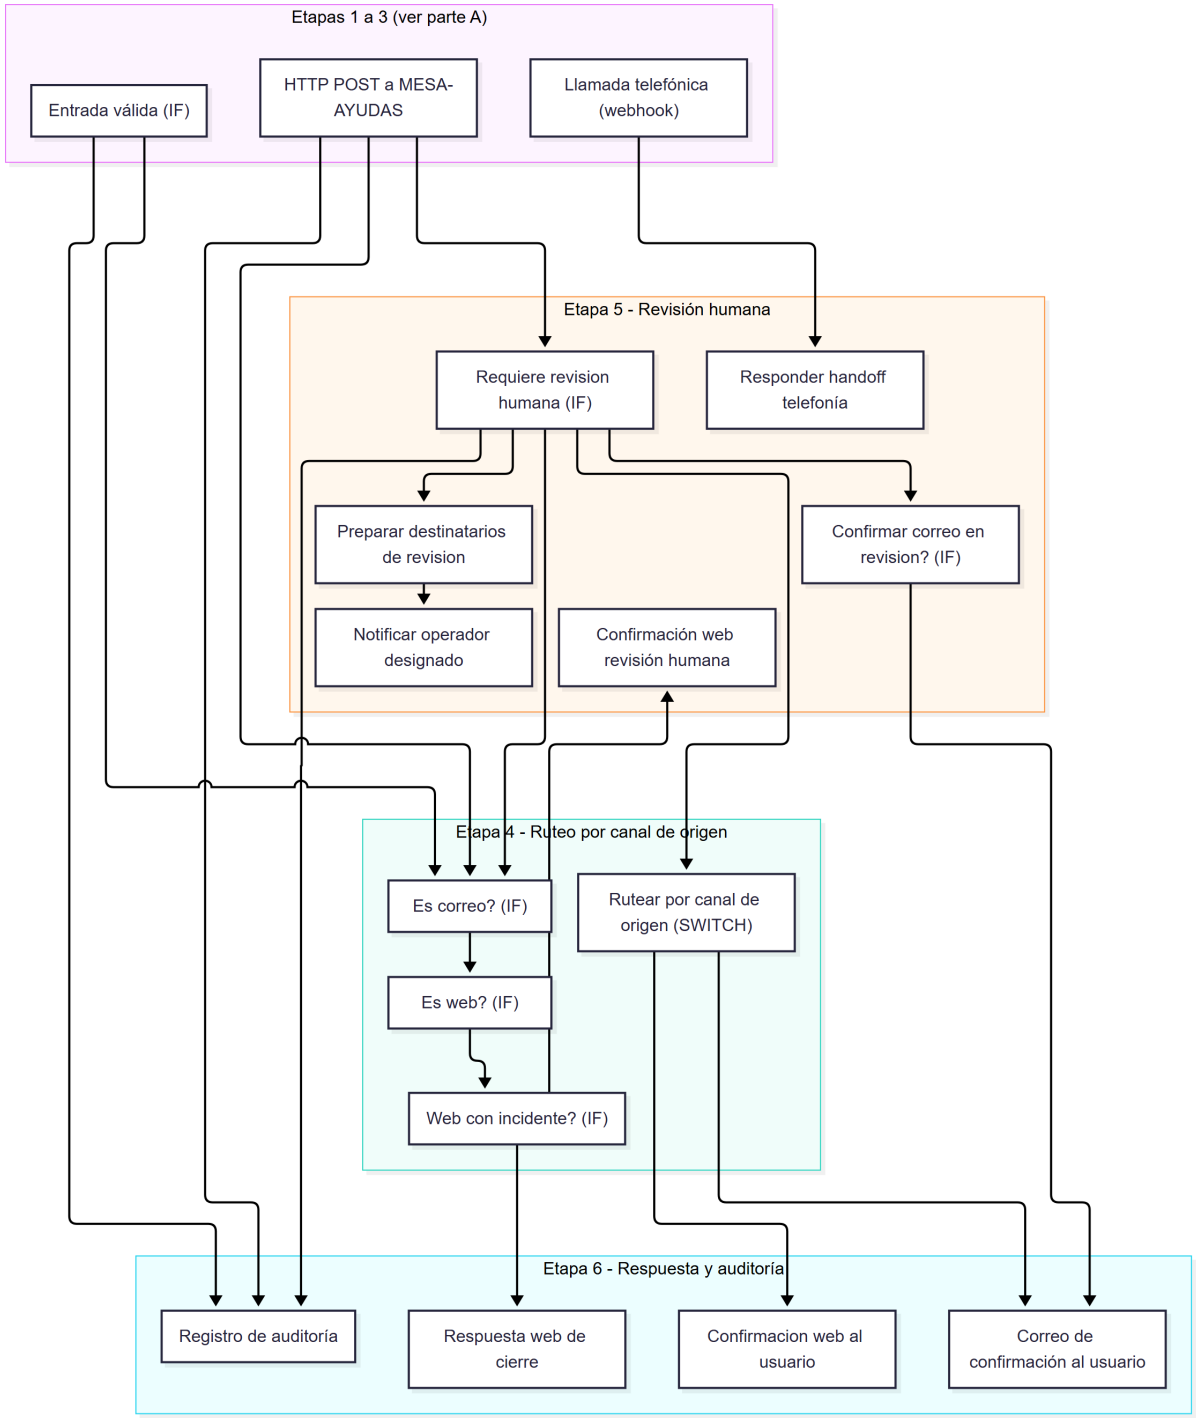


Figura 13. Reconstrucción esquemática del flujo de orquestación N8N (continuación de la Figura 12). Parte B: etapas 4 a 6 (ruteo por canal de origen, revisión humana, respuesta y auditoría).

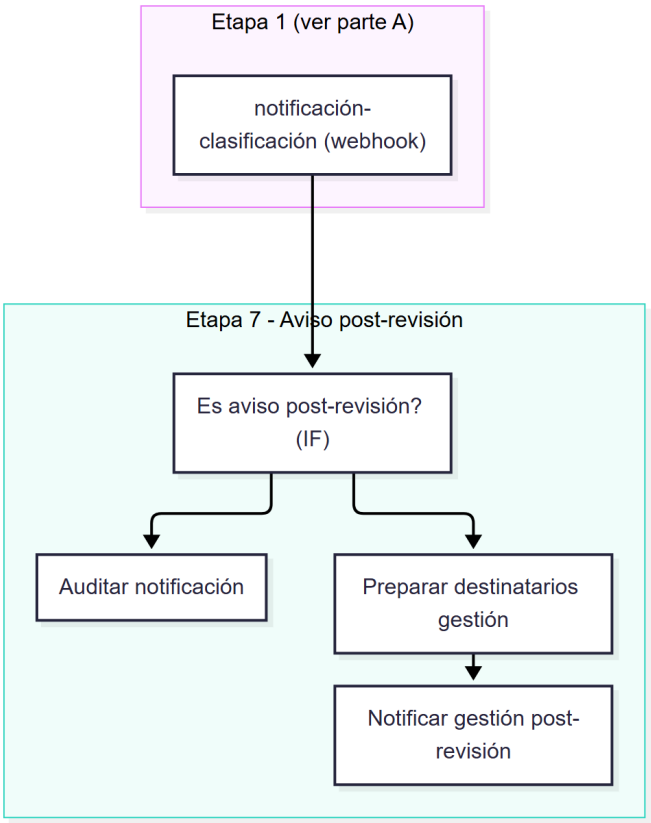


Figura 14. Reconstrucción esquemática del flujo de orquestación N8N (continuación de la Figura 13). Parte C: etapa 7 (aviso posterior a la revisión).

con los incidentes ingresados, respaldo del 9-10-2026 de los 81 ingresos telefónicos y ejecuciones de N8N) no se conservan en el repositorio. Los 81 tiempos telefónicos coinciden con el archivo versionado `data/corpus_resultados_telefonia.json`. Los 119 de correo y formulario web constan en el corpus y su registro primario pseudonimizado se versiona en `data/corpus_resultados_web_correo.json`, que reúne 118 de esos casos con las marcas de tiempo de la base (ingreso y persistencia); `R001` es el único caso sin registro. Ese registro acredita la existencia y la procedencia de los incidentes, no la medición de extremo a extremo, porque no incluye el envío; `data/corpus_resultados.json` corresponde a otra corrida y no los respalda (Subsección 4.5). Se incluyen además las planillas de cronometraje del flujo manual.

Cada uno de los 200 casos del corpus se compone de siete campos. El primero es `id` (identificador anónimo, por ejemplo `R001`). El segundo es `descripcion` (el texto pseudonimizado que produce el módulo de pseudonimización del sistema; ese módulo reemplaza los identificadores personales directos —nombres propios, direcciones de correo electrónico, números telefónicos, hosts internos e identificadores corporativos— por etiquetas genéricas. En el corpus de este estudio los incidentes no incluían identificadores personales directos, por lo que las descripciones no contienen ninguna de esas etiquetas). Los demás son `canal_origen` (correo electrónico, formulario web o llamada telefónica), `sector_asignado` (sector principal de verdad, exactamente uno de los cinco sectores canónicos), `sectores_adicionales` (sectores de verdad complementarios, sin repetir el asigna-

do), `tiempo_manual_s` (tiempo de clasificación manual, en segundos) y `tiempo_automatizado_s` (tiempo del sistema automatizado, en segundos). El corpus completo reside en `data/corpus_evaluacion_pseudonimizado.json` y las predicciones del clasificador en `evaluation/evidence/predicciones_hybrid-v3_2026-10-07.json`.

Por razones de privacidad y en cumplimiento de la Ley 25.326 (Honorable Congreso de la Nación Argentina, 2000), el módulo de pseudonimización del sistema se aplica a cada incidente en producción antes de su clasificación y de su persistencia, y es la herramienta que produce el texto `descripcion` del corpus. En el corpus de este estudio no había identificadores personales directos, por lo que las descripciones publicadas no contienen etiquetas de pseudonimización.

Una precisión de procedencia sobre ese módulo: su heurística de nombres propios sobreenmascaraba términos que no eran personas (por ejemplo, `Su PC`, `Adobe PDF Reader` o `Recursos Humanos`). La corrección del sobreenmascarado ajustó esa heurística. El corpus evaluado no se ve afectado por ese ajuste: sus descripciones no contienen etiquetas y coinciden con el texto de origen, de modo que repetir la corrida de clasificación no altera ningún resultado. Esta precisión no modifica ninguna cifra ni conclusión del estudio.

G. Documentación operativa

La documentación operativa del sistema, que reúne los procedimientos de despliegue, configuración, respaldo y restauración, monitoreo y respuesta ante incidentes operativos, se versiona en el repositorio junto con el código fuente; el runbook operativo reside en `docs/operational-guide.md`, y el procedimiento de la prueba de humo y de la verificación del borde TLS del despliegue de referencia, en `docs/runbook-smoke-stack-referencia.md`.

H. Especificación del prompt de Gemini 3.6 Flash

Este anexo documenta la especificación del prompt enviado al modelo `gemini-3.6-flash` (Gemini 3.6 Flash en el texto) y los parámetros de configuración de la inferencia. El prompt se mantiene en el repositorio bajo `docs/prompt_gemini.txt` y es único para los tres canales de entrada. El canal telefónico emplea además el modelo de transcripción `gemini-3.5-transcribe`, declarado en la configuración del backend (`settings.py`) y excluido del cálculo económico (Subsección 9.4).

H.1. Estructura y contenido del prompt

El prompt sigue una estructura fija en español organizada en cinco componentes funcionales y un conjunto de reglas de desambiguación:

1. **Instrucción de rol**: define que el modelo actúa como agente especializado en clasificación de incidentes técnicos en español rioplatense, lo que ancla el comportamiento en el dominio y el dialecto del estudio.
2. **Definición de categorías**: presenta los cinco sectores canónicos con sus *strings* exactos

(sensibles a mayúsculas y sin tildes), un ámbito descriptivo por sector y un único ejemplo representativo extraído del dominio real por clase (cinco en total).

3. **Formato de respuesta**: solicita un JSON válido con exactamente dos campos, `categoría` (uno de los cinco valores canónicos) y `confianza` (número entre 0,0 y 1,0), sin texto adicional, comentarios ni explicaciones.
4. **Lógica de decisión**: indica analizar la descripción y asignar una categoría única entre las cinco opciones; ante elementos de múltiples categorías, elegir la dominante.
5. **Validación sintáctica**: exige validar la corrección sintáctica del JSON antes de devolverlo y reducir la confianza cuando no sea posible clasificar con seguridad.
6. **Reglas de desambiguación de frontera**: las acciones sobre aplicaciones o sistemas operativos (acceder, iniciar sesión, abrir una aplicación) se orientan a `Soporte Tecnico Software`; los dispositivos físicos y su digitalización (escáner, impresora, periférico, error de digitalización) a `Soporte Tecnico Hardware`; y la infraestructura y los servicios de plataforma (servidor, red, SMTP, VM) a `Sistemas`. Estas reglas corrigen casos de frontera medidos sobre el corpus.

H.2. Parámetros de configuración

La invocación del modelo se realiza mediante el SDK `google-genai` (`>=2.20.0`, configuración evaluada; Tabla 29), con los hiperparámetros que resume la Tabla 30, que corresponden a la configuración adoptada para el despliegue y no al resultado de una calibración documentada frente a valores alternativos (Subsección 5.4).

H.3. Validación de la respuesta

Antes de aceptar la respuesta del modelo, el módulo de clasificación valida que el texto sea JSON parseable, que contenga exactamente las claves `categoría` y `confianza`, que la categoría sea uno de los cinco valores canónicos y que la confianza sea un número en el intervalo $[0{,}0, 1{,}0]$. Si cualquiera de estas condiciones falla, se registra la excepción, se asigna confianza 0,0, se marca el incidente para revisión humana y no se propagan estados inconsistentes a la base de datos. Este procedimiento garantiza la confiabilidad operativa frente a errores de formato o alucinaciones del modelo. El Listado 1 resume la rutina de validación.

```
1 def validar_respuesta_gemini(response_text: str) -> tuple[bool, dict]:
2     try:
3         data = json.loads(response_text)
4     except json.JSONDecodeError as e:
5         return False, {"error": f"JSON invalido: {e}"}
6     if "categoría" not in data:
```

Tabla 30. Parámetros de configuración de la inferencia con `gemini-3.6-flash`.

Parámetro	Valor	Justificación
`temperature`	0,3	Valor bajo que reduce la variabilidad de la generación y mejora la consistencia en tareas de clasificación determinística.
`top_p`	0,9	*Nucleus sampling* que admite variantes léxicas válidas en español rioplatense sin sacrificar coherencia.
`max_tokens`	100	Límite suficiente para la respuesta JSON, con margen ante variaciones y sin truncamiento.
`candidate_count`	1	Respuesta única sin remuestreo, que acota la latencia del procesamiento en tiempo real.
`safety_settings`	Cuatro categorías con umbral `BLOCK_NONE`	Desactiva los cuatro filtros de contenido (`HARM_CATEGORY_HARASSMENT`, `HARM_CATEGORY_HATE_SPEECH`, `HARM_CATEGORY_SEXUALLY_EXPLICIT` y `HARM_CATEGORY_DANGEROUS_CONTENT`, todos con umbral `BLOCK_NONE`) para no rechazar descripciones legítimas de incidentes; no se configura ningún filtro de umbral intermedio.
`timeout`	30 segundos por intento; 60 segundos en total	Límite de latencia por intento del backend al modelo (hasta dos reintentos ante fallas transitorias, dentro de un presupuesto total de 60 segundos por clasificación; no son reintentos de N8N al backend); al agotarse, el clasificador devuelve confianza 0,0 y marca el caso para revisión humana.
Umbral de revisión humana	0,70	Confianza mínima de una respuesta del modelo para no marcarla para revisión; se evalúa solo sobre la salida de Gemini (la reserva deriva siempre y la etapa determinística no deriva por su confianza; Subsección 5.5). Desde el 13 de octubre de 2026 el backend deriva además a revisión al reportante no identificado en el directorio de empleados.
SDK	`google-genai >=2.20.0`	Versión de la configuración evaluada; la entregada exige `>=2.33.0,<3` (Tabla 29).

Fuente: elaboración propia a partir de la documentación del SDK `google-genai`.

```
        return False, {"error": "Falta campo 'categoría'"}
    if data["categoría"] not in SECTORES_CANONICOS:
        return False, {"error": f"Categoría invalida: {data['categoría']}"}
    if "confianza" not in data:
        return False, {"error": "Falta campo 'confianza'"}
    if not isinstance(data["confianza"], (int, float)) \
            or not (0.0 <= data["confianza"] <= 1.0):
        return False, {"error": f"Confianza invalida: {data['confianza']}"}
    return True, data
```

Listing 1. Validación de la respuesta de Gemini (resumen).

H.4. Iteración y mejora del prompt

El prompt de la versión evaluada se ajustó de forma iterativa a partir de errores observados en el corpus de validación; no se dispuso de un corpus independiente de preproducción. Las versiones históricas del prompt se conservan en el historial de versiones del repositorio (archivo `docs/prompt_gemini.txt`) para auditoría y eventual reversión.

H.5. Recomendaciones para futuras iteraciones

Ante una degradación de las métricas por cambios en el modelo, se recomienda ampliar los ejemplos por clase (partiendo del único ejemplo actual, hasta cuatro o cinco), agregar contraejemplos de incidentes limítrofes, especificar umbrales de confianza explícitos e incluir un diccionario de términos clave por categoría. Una vez acumulado un corpus etiquetado del orden de magnitud indicado en la Subsección 9.4, se recomienda migrar a un modelo ajustado específicamente al dominio.

I. Trazabilidad de las correcciones de los dictámenes

I.1. Nota de versiones

La versión del 3 de julio de 2026 informó una reducción del tiempo medio de registro de 165,3 s a 18,2 s (89,0 %), una exactitud de 92 %, $W = 0$ y un kappa de 0,87. Los tiempos, la exactitud y el estadístico provenían de un corpus sintético de 200 casos generado durante el desarrollo, no de incidentes reales. Ese corpus se descartó y se eliminó del repositorio. La versión actual los reemplaza por los del corpus real pseudonimizado: tiempo medio de 61,6 s a 17,76 s (reducción de 71,2 %), exactitud de 73,5 % y $W = 363$. El kappa de 0,87 figuraba en aquella versión, pero sus planillas no se conservan. Por eso ya no se presenta como evidencia de fiabilidad (Subsección 4.4).

I.2. Revisiones que originaron las correcciones

Las correcciones de la tesis responden a la auditoría integral del tribunal del 4 de agosto de 2026, a una serie de autoevaluaciones internas frente a criterios de la CONEAU y a la devolución de segunda instancia del tribunal del 11 de noviembre de 2026. El detalle de cada observación, el cambio responsable y la sección donde se atendió se conserva como trazabilidad operativa del proyecto y no se reproduce en este anexo.

La redacción de esta tesis contó con asistencia de un modelo de lenguaje para la corrección de estilo y la edición del texto, y para la generación de diagramas de flujo a partir de la estructura planteada previamente. El diseño metodológico, la recolección y verificación de datos, las decisiones de contenido y la responsabilidad final del texto son de los autores.